

Arta de a ști ce contează

*Înțelepciune, educație
și inteligență artificială*

DE LA TRANSMITEREA INFORMAȚIEI
LA CULTIVAREA JUDECĂȚII

Cu programul de cercetare PHRONESIS
Distilarea și validarea judecății contextuale

SEPTEMBRIE 2026

Cuprins

Capitolele și referințele sunt accesibile prin legături interne.

Notă pentru cititor.....	3
Prolog. Școala care știa prea multe.....	4
I · CE ÎNSEAMNĂ SĂ ȘTII	
1. Trei feluri de a ști.....	5
2. Filosofia ca exercițiu al judecății.....	7
3. De ce experiența nu se poate copia.....	9
4. Ce poate măsura știința înțelepciunii.....	11
II · CUM SE FORMEAZĂ JUDECATA	
5. Pedagogia transferului.....	13
6. Educația judecății.....	15
7. O școală reorganizată în jurul înțelegerii.....	17
8. Societatea care recompensează discernământul.....	19
III · ESENȚA, BIASUL ȘI INTELIGENȚA ARTIFICIALĂ	
9. Rezumatul nu este încă înțelepciune.....	21
10. Patternurile fundamentale și limitele lor.....	23
11. Bias, netezire și falsa profunzime.....	25
12. Poate un AI să fie înțelept?.....	27
IV · PROGRAMUL DE CERCETARE PHRONESIS	
13. De la ambiție la o întrebare testabilă.....	29
14. Arhitectura distilării contextuale.....	31
15. Experimente care pot infirma programul.....	34
16. De la laborator la o infrastructură a discernământului.....	36
Epilog. Ce merită să rămână.....	38
ANEXE · SPECIFICAȚII ȘI EXEMPLE	
Anexa A. Un nucleu de judecată, construit complet.....	39
Anexa B. Un contract formal minimal.....	42
Anexa C. Un modul pedagogic de șase săptămâni.....	45
Bibliografie și statutul surselor.....	47

Notă pentru cititor

Această carte pornește de la o asimetrie: putem pune aceeași informație în fața unui milion de oameni, fără ca un milion de oameni să dobândească aceeași capacitate de a o folosi. Iar o capacitate tehnică nouă nu decide singură dacă merită folosită, în ce scop și cu ce consecințe pentru ceilalți. Între circulația informației și formarea judecății există o distanță pe care viteza comunicațiilor nu o anulează.

Vom numi înțelepciune practică o capacitate contextuală de a judeca ce merită urmărit, de a folosi critic ceea ce știm și de a ne revizui conduita în lumina consecințelor, a incertitudinii și a intereselor legitime ale celor afectați. Este o definiție de lucru, discutabilă, nu descoperirea unei esențe eterne și nici un test al valorii unei persoane. Înțelepciunea contemplativă, religioasă sau existențială depășește această definiție; cartea o întâlnește, fără să pretindă că o epuizează.

Primele două părți urmăresc problema umană: ce poate fi transmis și cum ar putea educația și instituțiile să favorizeze judecata. Ultimele două cercetează problema tehnică: dacă putem distila din texte structuri care ajută la decizii mai bune, fără să confundăm eleganța exprimării, acordul majorității sau comprimarea cu înțelepciunea.

Referințele numerotate conduc la bibliografia de la final. Documentarea reprezintă o explorare critică a unor surse primare și sinteze de cercetare, verificată până la 10 septembrie 2026, nu o revizuire sistematică exhaustivă. Propunerile educaționale și programul PHRONESIS sunt construcții argumentate ale cărții. Nu sunt intervenții validate și nu descriu rezultate empirice deja obținute. Calculul ilustrativ din anexa B verifică numai un micro-model construit. Scenariile fără trimitere bibliografică sunt exemple inventate, folosite pentru a pune ideile la încercare.

Prolog. Școala care știa prea multe

Să imaginăm o școală care introduce un sistem digital de participare. Elevii răspund la întrebări, primesc puncte, iar profesorii văd imediat cine a intervenit și cine a rămas în urmă. Programul funcționează. Raportul lunar arată mai multe răspunsuri, teme predate mai repede și un număr mai mic de momente în care clasa pare inactivă. Directorul primește felicitări.

La o ședință, o profesoară întreabă dacă elevii înțeleg mai bine. Există date despre răspunsurile lor, spune informaticianul. Există chiar un model care prezice cine va obține o notă mică. Profesoara reformulează: dacă mâine scoatem platforma, pot elevii să rezolve o problemă nouă? Întrebarea nu se găsea în raport.

Un elev spune că răspunde repede ca să nu piardă puncte, chiar când ar avea nevoie să se gândească. O elevă vorbește mai puțin fiindcă își formulează răspunsurile într-un ritm diferit. Alt elev a descoperit cum să pară activ fără să citească. Niciunul dintre ei nu contestă că platforma colectează informații corecte. Contestă ceea ce s-a hotărât să însemne acele informații.

Ar fi prea simplu să încheiem povestea condamnăm tehnologia. Platforma poate identifica o dificultate reală și poate economisi timp pentru profesor. Ar fi la fel de simplu să condamnăm profesorii pentru că nu au definit suficiente metrice. Orice nouă măsură va selecta alte detalii și va lăsa altele în afara cadrului. Problema nu este alegerea între măsurare și intuiție, ci relația dintre ceea ce măsurăm și ceea ce încercăm să cultivăm.

În această școală imaginară, informația răspunde la întrebarea „ce s-a înregistrat?”. Cunoașterea utilizabilă permite să verificăm un indicator, să schimbăm un exercițiu și să proiectăm un test. Înțelepciunea începe când întrebăm dacă obiectivul urmărit reprezintă ceea ce contează, cine suportă costurile și ce ar trebui să ne determine să schimbăm direcția.

Directorul nu trebuie să devină filosof profesionist. Trebuie să poată spune: „Am confundat activitatea vizibilă cu învățarea. Să păstrăm ce ajută, să oprim ce dăunează și să verificăm separat.” O asemenea propoziție este ușor de scris. Mai dificil este să existe într-o instituție în care autorul ei nu este pedepsit pentru că și-a recunoscut eroarea.

Aceasta va fi întrebarea cărții: ce ar trebui să construim în jurul unei propoziții bune pentru ca ea să devină o capacitate reală a oamenilor și a organizațiilor?

1. Trei feluri de a ști

De la un mesaj la o capacitate

O informație poate fi copiată fără ca expeditorul să o piardă. O propoziție, un tabel, un fișier și o instrucțiune pot circula aproape identic între destinatari. Aceasta este o proprietate a reprezentării, nu o garanție a înțelegerii. Pentru cititorul care nu cunoaște limba, un tratat de mecanică și un șir arbitrar de semne pot avea aceeași inutilitate practică.

Prin informație vom înțelege aici un conținut comunicabil care poate modifica ceea ce un receptor crede despre o situație. Cunoașterea utilizabilă cere mai mult: reprezentări suficient de corecte, proceduri și deprinderi care permit explicații, predicții sau acțiuni adecvate. Nu este suficient să fi văzut cum se demonstrează o teoremă; trebuie să poți recunoaște condițiile în care demonstrația se aplică și să reconstruiești pașii relevanți.

Diferența poate fi observată într-un exemplu de programare. „Parolele nu se stochează în clar” este o informație. A proiecta și verifica un mecanism de autentificare presupune cunoaștere utilizabilă. A decide ce date nu ar trebui colectate, ce autonomie trebuie să păstreze utilizatorul și când o funcție comercială creează riscuri disproporționate presupune un alt nivel de judecată. Exemplul nu este o specificație de securitate; arată că succesul tehnic nu stabilește de la sine legitimitatea scopului.

Cunoașterea nu este numai o colecție de instrucțiuni. Include capacitatea de a distinge cazurile, de a depista o eroare și de a adapta o procedură. Totuși, chiar o cunoaștere remarcabilă poate fi îngustă. Un specialist poate optimiza perfect un obiectiv prost ales. Poate rezolva problema primită fără să observe că problema formulată exclude exact persoana care va suporta costul soluției.

Înțelepciunea, în sensul de lucru al cărții, privește și relația dintre scopuri. Nu întreabă numai cum să obținem mai mult, ci mai mult din ce, pentru cine și în schimbul a ce. Ea poate conduce la accelerare, la încetinire sau la refuz. Nu se identifică nici cu eficiența, nici cu precauția. Refuzul de a interveni într-o nedreptate poate fi la fel de lipsit de discernământ ca intervenția nechibzuită.

Aceste distincții nu creează trei sertare etanșe. O propoziție poate conține o instrucțiune și o reflecție asupra scopului ei. O abilitate practică poate include o judecată morală implicită. O decizie prudentă poate deveni imposibilă din cauza lipsei unei informații elementare. Avem mai degrabă dimensiuni care se susțin reciproc decât o scară pe care fiecare etaj îl înlocuiește pe cel anterior.

Înțelepciunea nu este un surplus de inteligență

Inteligența instrumentală poate identifica mijloace ingenioase pentru un rezultat dat. Înțelepciunea practică, așa cum o propunem aici, include disponibilitatea de a interoga rezultatul însuși. Această deosebire este conceptuală; nu implică faptul că inteligența și înțelepciunea sunt complet independente psihologic. Nici nu justifică ideea comodă că lipsa de competență ar fi o virtute.

Să presupunem că o echipă trebuie să reducă timpul de răspuns al unui serviciu. O soluție elimină cazurile dificile din statistică. Alta automatizează cererile simple și rezervă timpul economisit cazurilor dificile. Prima poate îmbunătăți indicatorul mai mult. A doua poate servi scopul instituției mai bine. Discernământul constă în a observa că indicatorul nu este beneficiarul serviciului.

Nici bunătatea declarată nu este suficientă. Cineva poate dori sincer binele celorlalți și poate produce daune previzibile fiindcă nu înțelege mecanismele situației. În schimb, o persoană foarte lucidă poate folosi această luciditate pentru exploatare. Definiția propusă leagă două cerințe: adecvarea la realitate și o responsabilitate justificabilă față de cei afectați. Legătura este normativă și trebuie apărută, nu ascunsă sub un scor tehnic.

Apare imediat o obiecție: cine decide ce interese sunt legitime? Nu există un procedeu simplu care să elimine toate conflictele. Dar absența unui arbitru infailibil nu face toate pozițiile echivalente. Putem cere dovezi pentru afirmații, reciprocitate în justificări, acces la contestație și atenție la consecințe. Putem separa dezacordul real de minciună și incertitudinea autentică de folosirea incertitudinii ca pretext.

Înțelepciunea nu este nici reputația de a fi înțelept. Un discurs calm poate proteja o eroare. Un avertisment incomod, formulat fără eleganță, poate identifica pericolul decisiv. Evaluarea trebuie să treacă de la impresia produsă de persoană la relația dintre argument, context și acțiune.

De aceea, vom folosi trei întrebări diferite. Ce conține mesajul? Ce poate face receptorul cu el? Ce fel de judecată manifestă când trebuie să hotărască dacă și cum îl folosește? A confunda aceste întrebări este începutul multor iluzii educaționale și al multor promisiuni exagerate despre AI.

2. Filosofia ca exercițiu al judecății

Când regula nu poate lua locul omului

În Phaidros, Platon pune în scenă o problemă surprinzător de apropiată de cea a educației digitale: textul poate circula, dar nu știe cui i se adresează și nu poate răspunde singur obiecțiilor. Critica nu anulează valoarea scrisului; dialogul însuși ne-a parvenit prin scriere. Ea separă suportul exterior al memoriei de activitatea prin care cineva ajunge să înțeleagă și să răspundă pentru ceea ce afirmă. [1]

Pentru problema noastră, lecția este structurală. Un mesaj identic ajunge la oameni cu experiențe, temeri și scopuri diferite. Unul are nevoie de o definiție, altul de un contraexemplu, altul de motive să renunțe la o interpretare care îl avantajează. A pune conținutul la dispoziție nu este echivalent cu a organiza întâlnirea dintre conținut și mintea care îl va folosi.

Aristotel distinge, în cartea a VI-a a Eticii nicomahice, între forme ale cunoașterii și ale virtuții intelectuale. Phronēsis privește deliberarea practică despre viața bună și cere atenție la particularitățile situației; sophia are un alt obiect, legat de înțelepciunea teoretică. Această deosebire ne împiedică să tratăm orice expertiză sau orice contemplare drept o capacitate suficientă de a decide bine în viața concretă. [2]

Nu trebuie să preluăm întregul univers social al lui Aristotel pentru a folosi distincția. Putem accepta ideea că regulile nu se aplică singure, respingând o distribuție rigidă a autorității între oameni. O filosofie a judecății contemporane trebuie să permită celui afectat să conteste felul în care altcineva pretinde că îi cunoaște binele.

De aici apare o tensiune fertilă. Fără reguli, fiecare situație riscă să devină o improvizație arbitrară. Cu reguli absolutizate, diferențele relevante dispar. Discernământul nu înseamnă să stăm comod la mijloc, ci să știm de ce păstrăm o regulă și ce fel de fapt ar justifica o excepție. O excepție bună trebuie să poată fi explicată și altcuiva decât celui care beneficiază de ea.

Să luăm promisiunea de confidențialitate într-o echipă. „Păstrează întotdeauna secretul” poate proteja încrederea; poate și acoperi un pericol grav. „Spune întotdeauna totul” poate apăra transparența; poate și expune inutil o persoană. Filosofia devine utilă când cere să identificăm conflictul, nu când ne oferă o maximă care pare să-l elimine.

Reflecția înainte, în timpul și după acțiune

O altă resursă se găsește în textul budist cunoscut drept Instrucțiunile către Rāhula, MN 61. El propune examinarea acțiunilor înainte de a le începe, în timpul desfășurării și după încheiere, prin atenție la efectele asupra propriei persoane și asupra altora. Este un exemplu precis dintr-o tradiție, nu o descriere a tuturor filosofilor asiatici. [3]

Putem reconstrui secular această structură: anticipare, monitorizare, revizuire. Înainte, formulăm ce credem că se va întâmpla. În timpul acțiunii, urmărim dacă apar semnale incompatibile cu așteptările. După, examinăm rezultatul fără să rescriem retrospectiv povestea pentru a ne face să părem clarvăzători. Această reconstrucție este propunerea noastră pedagogică, nu o identitate între un text religios și metoda experimentală.

În *How We Think*, John Dewey tratează reflecția ca investigare a temeiurilor unei credințe și a implicațiilor ei, nu ca simplă trecere a unor idei prin minte. Relația dintre îndoială, investigație și experiență oferă un punct de sprijin pentru educația judecătii: elevul trebuie să învețe cum se transformă o dificultate într-o întrebare cercetabilă. [4]

Între aceste surse există diferențe importante. Nu vorbesc despre aceeași viață bună, aceeași metafizică sau aceeași organizare a societății. Interesul comparației nu este să pretindem că toate tradițiile spun același lucru. Este să extragem o problemă comună: cum legăm înțelegerea de o practică susceptibilă de corectare?

Propunerea cărții este să considerăm filosofia și o disciplină a trecerii între perspective. Perspectiva agentului arată intenția și dificultatea. Perspectiva celui afectat arată costul. Perspectiva observatorului poate dezvălui contradicția. Perspectiva viitorului întreabă ce opțiuni lăsăm deschise. Niciuna nu deține automat verdictul; împreună pot expune ceea ce o singură poziție ascunde.

Aceasta nu cere o deliberare nesfârșită pentru fiecare gest. Ar fi o caricatură a înțelepciunii. Cere deprinderi care fac gândirea atentă disponibilă atunci când situația o solicită. La fel cum un muzician exersează lent ca să poată interpreta fluid, judecata poate fi antrenată deliberat pentru a deveni mai puțin dependentă de impuls sau de formule memorate.

Filosofia astfel înțeleasă nu este un raft de răspunsuri prestigioase. Este un atelier în care motivele devin vizibile, scopurile discutabile și autoritatea revizibilă. Tocmai de aceea poate avea un rol central într-o lume cu acces aproape instantaneu la răspunsuri.

3. De ce experiența nu se poate copia

Contextul pe care propoziția îl pierde

Un mentor spune: „Nu confunda succesul rapid cu direcția bună.” Ucenicul poate repeta perfect propoziția. Dar când apare o oportunitate care îi oferă prestigiu, bani sau apartenență, aceeași propoziție poate deveni invizibilă. Nu pentru că a dispărut din memorie, ci pentru că nu este activată în situația potrivită ori pentru că intră în conflict cu o motivație mai puternică.

Dificultatea transmiterii înțelepciunii are cel puțin trei niveluri distincte. Trebuie transmisă o reprezentare a problemei. Trebuie formată capacitatea de a o recunoaște în situații noi. Trebuie susținută disponibilitatea de a acționa conform judecății, chiar când există un cost. O carte lucrează direct asupra primului nivel, indirect asupra celui de-al doilea și foarte limitat asupra celui de-al treilea.

Mai există o dificultate: concluzia unui om ascunde comparațiile prin care a ajuns la ea. O persoană experimentată poate vedea într-o frază a interlocutorului o evitare relevantă, fiindcă a întâlnit multe variații ale aceleiași situații. Când transmite numai verdictul, elimină exact diferențele care i-au permis verdictul. Receptorul primește rezultatul compresiei, nu și criteriul după care detaliile au fost selectate.

Pentru a face transmiterea mai fidelă, mentorul ar trebui să povestească nu doar ce a făcut, ci ce alternative avea, ce nu știa, ce indiciu l-a făcut să se răzgândească și când același sfat ar fi fost greșit. Nu orice experiență poate fi relatată complet. Dar relatarea poate păstra punctele de bifurcație ale judecății, în loc să transforme viața într-un șir de concluzii inevitabile.

Aici se explică valoarea pedagogică posibilă a literaturii. O poveste poate ține împreună motive incompatibile fără să le rezolve imediat. Cititorul poate urmări cum o decizie rezonabilă dintr-o perspectivă devine apăsătoare din alta. Aceasta este o justificare conceptuală pentru folosirea narațiunii; nu dovedește că orice roman îmbunătățește discernământul sau că ficțiunea produce automat empatie.

Experiența nu este însă o autoritate infailibilă. Ea poate fi repetarea aceleiași situații interpretate greșit, poate exclude cazurile care contrazic lecția și poate transforma norocul în merit personal. A spune „am trăit asta” aduce o sursă de informație, nu închide discuția. Experiența capătă valoare pentru alții când poate fi examinată, comparată și corectată.

A înțelege, a putea și a îndrăzni

Un elev poate înțelege argumentul pentru onestitate, dar poate anticipa o sancțiune nedreaptă dacă recunoaște o eroare. Un angajat poate identifica un risc și poate depinde economic de persoana care îl ignoră. A descrie aceste situații drept lipsă

individuală de înțelepciune mută atenția de la constrângere la caracter. Uneori problema nu este că omul nu știe, ci că instituția face conduita bună excesiv de costisitoare.

Prin urmare, pedagogia nu trebuie să promită că toate conflictele pot fi rezolvate prin dezvoltare personală. Ea trebuie să formeze discernământul și să facă inteligibile structurile care îl împiedică. Uneori acțiunea rezonabilă constă în a construi sprijin, a documenta un fapt sau a căuta o cale sigură de contestare, nu în eroism imediat. În alte situații, amânarea perpetuează răul. Tocmai condițiile fac diferența.

Nu rezultă că trebuie să provocăm suferință pentru a produce oameni înțelepți. Ar fi atât o eroare logică, cât și o pedagogie periculoasă. Din faptul că cineva a învățat ceva după o pierdere nu urmează că pierderea era necesară, suficientă sau justificabilă. Școala poate oferi conflicte simulate, responsabilități proporționale și eșecuri reparabile, fără să fabrice traume.

Nici dimensiunea emoțională nu trebuie tratată ca un reziduu care se elimină pentru a obține rațiune pură. În modelul propus aici, emoția poate semnaliza importanța unei relații sau a unei pierderi, dar semnalul trebuie interpretat. Faptul că o situație mă revoltă nu stabilește singur adevărul descrierii mele; faptul că nu mă afectează personal nu dovedește că este lipsită de gravitate.

Transmiterea înțelepciunii presupune astfel o alternanță între apropiere și distanță. Apropierea împiedică transformarea oamenilor în variabile indiferente. Distanța face posibilă examinarea propriului interes și a propriei reacții. Educația trebuie să creeze ocazii pentru ambele, fără să transforme mărturisirea personală într-o obligație publică.

Putem formula acum de ce informația circulă mai ușor decât înțelepciunea. Mesajul poate fi externalizat aproape integral; competența trebuie reconstruită în receptor; judecata practică trebuie reconstruită într-o relație între receptor, situație, motivații și instituții. Este o explicație funcțională, nu o măsurare universală a dificultății. Unele informații sunt extrem de greu de înțeles, iar unele avertismente simple pot schimba imediat o viață.

Ceea ce rămâne stabil este faptul că succesul transmisiei nu se citește numai în mesaj. Se citește în capacitatea dobândită de celălalt și în felul în care aceasta rezistă unei situații pe care profesorul nu a putut-o anticipa complet.

4. Ce poate măsura știința înțelepciunii

Mai multe instrumente, nu un termometru universal

Psihologia înțelepciunii nu dispune de un singur instrument acceptat care să măsoare fără controversă o proprietate unitară. Studiul comparativ al lui Judith Glück și al colegilor examinează diferențele dintre mai multe instrumente, inclusiv autoevaluări și evaluări ale răspunsurilor la probleme de viață. Unele accentuează reflecția și compasiunea, altele experiența, reglarea emoțională ori cunoașterea pragmatică a vieții. Alegerea instrumentului influențează ceea ce putem concluziona. [5]

Acest lucru nu înseamnă că domeniul este inutil. Înseamnă că trebuie să întrebăm ce observă fiecare metodă. Un chestionar poate arăta cum se descrie persoana. Un răspuns scris poate arăta ce considerații poate formula într-o situație de test. O observație repetată poate arăta cum se comportă într-un anumit mediu. Niciuna dintre aceste observații nu autorizează singură un verdict asupra întregului caracter.

Vom distinge trei obiecte de evaluare. Primul este conținutul unui răspuns: include perspective relevante, incertitudini și condiții? Al doilea este performanța într-o sarcină: persoana detectează informația care schimbă decizia și își ajustează conduita? Al treilea este stabilitatea unei dispoziții: poate face aceasta în contexte diferite, mai ales când propriul interes este implicat? Trecerea de la primul la al treilea este o ipoteză care trebuie verificată.

Deosebirea contează și când evaluăm AI. Un model poate genera o reflecție excelentă despre autocunoaștere fără să mențină aceeași conduită într-o conversație cu presiune socială. Un om poate redacta un răspuns modest și poate avea o judecată practică foarte bună. Evaluarea limbajului nu trebuie să devină o taxă culturală asupra celor care nu folosesc registrul preferat de evaluator.

Există și problema valorilor implicite. Un instrument care recompensează mereu compromisul va considera mai puțin înțeleaptă opoziția justificată față de un abuz. Un instrument care recompensează mereu certitudinea va penaliza recunoașterea limitelor. Dar un instrument care recompensează orice ezitare va confunda indecizia cu modestia epistemică. Itemii trebuie să includă situații în care aceeași formă verbală devine potrivită sau nepotrivită.

În locul unui clasament universal al oamenilor, propunem profiluri locale de performanță, însoțite de explicații și limite. De exemplu: persoana identifică bine costurile pentru ceilalți, dar distinge insuficient între ipoteză și fapt; sau recunoaște incertitudinea, dar nu specifică ce informație ar reduce-o. Aceste constatări sunt mai utile pentru învățare decât eticheta „înțelept” sau „neînțelept”.

Situația poate conta mai mult decât reputația

Grossmann și Kross au studiat asimetria dintre judecarea problemelor proprii și a problemelor altora. În experimentele lor, distanțarea perspectivei a redus această asimetrie în raționamente despre relații apropiate. Rezultatul oferă o bază pentru exerciții de reflecție din perspectiva unui observator; nu demonstrează că o tehnică scurtă produce o virtute stabilă în toate domeniile. [6]

Din această constatare putem construi o ipoteză educațională modestă. Înainte să susțină o decizie controversată, elevul o poate reformula ca și cum ar sfătui o altă persoană. Apoi revine la propria poziție și notează ce s-a schimbat. Scopul nu este anularea interesului propriu, ci observarea modului în care acesta organizează atenția.

Cultura introduce o altă dificultate. Un răspuns respectuos, indirect, poate fi interpretat greșit ca lipsă de poziție; un răspuns direct poate fi interpretat ca agresivitate. Pentru a compara grupuri ar trebui verificat dacă instrumentul măsoară același construct și dacă scenariile sunt inteligibile în contexte diferite. Nu vom deduce înțelepciunea unor societăți din stereotipuri despre vechimea, spiritualitatea sau individualismul lor.

Putem cerceta totuși diferențele fără relativism total. Dacă două comunități interpretează diferit o obligație familială, datele ar trebui să păstreze motivele, nu doar frecvența alegerilor. Putem analiza separat acordul asupra faptelor, diferența dintre norme și distribuția costurilor. Un dezacord normativ nu trebuie tratat automat ca eroare de măsurare; o afirmație factuală falsă nu devine adevărată prin acceptare culturală.

Mai trebuie separată calitatea deciziei de rezultatul ei. O decizie bine justificată poate avea un rezultat prost din cauza unui eveniment imprevizibil. O decizie imprudentă poate avea noroc. De aceea, evaluarea propusă cere înregistrarea prospectivă a motivelor și a așteptărilor, apoi examinarea rezultatului. Aceasta nu elimină judecata subiectivă, dar limitează avantajul poveștii construite după fapt.

Înțelepciunea devine cercetabilă nu când găsim un număr care o închide, ci când formulăm observații precise care pot contrazice o pretenție. Un sistem pretinde că ține seama de context? Să schimbăm o condiție decisivă. Pretinde că recunoaște limitele? Să-i oferim o situație în care informația nu permite verdictul. Pretinde că este echitabil? Să examinăm cine a dispărut din analiza sa.

5. Pedagogia transferului

Cunoașterea trebuie să devină disponibilă

O reformă a educației orientată spre înțelepciune poate începe cu o eroare: să disprețuiască memorarea, explicația profesorului și exercițiul repetat. Fără concepte accesibile și fără deprinderi elementare, elevul nu are cu ce compara o situație nouă. Faptul că o informație poate fi găsită nu înseamnă că persoana știe ce să caute, când să o caute sau cum să recunoască un răspuns greșit.

Sinteza lui Dunlosky și a colegilor atribuie utilitate ridicată testării prin recuperarea informației din memorie și practicii distribuite în timp. Autoexplicarea și alternarea tipurilor de probleme au un sprijin mai dependent de condiții. Rezumarea nu este declarată inutilă, dar beneficiile ei nu se generalizează la fel de bine în toate sarcinile și pentru toți elevii. Aceste constatări privesc învățarea, nu dovedirea unei transformări morale. [7]

Propunerea noastră este să păstrăm aceste fundamente și să le organizăm pentru disponibilitate contextuală. Elevul nu trebuie doar să reproducă definiția unei medii statistice, ci să recunoască situația în care media ascunde o distribuție relevantă. Nu trebuie doar să știe ce este o sursă, ci să observe când zece texte reproduc aceeași afirmație neverificată.

Un traseu didactic posibil începe cu explicația explicită și un exemplu rezolvat. Urmează un exemplu apropiat, rezolvat cu sprijin. Apoi apare un caz contrastant, în care o condiție schimbată face metoda nepotrivită. În final, elevul primește o situație nouă fără eticheta capitolului din care provine. Fiecare pas are o funcție diferită: înțelegere, exersare, discriminare, transfer.

Să luăm regula „un eșantion mai mare oferă o estimare mai stabilă”. Profesorul explică ideea și condițiile. Clasa compară apoi două anchete imagine: una mică, dar bine selectată, alta mare, alcătuită numai din voluntarii unei comunități interesate. Lecția utilă nu este că mărimea nu contează. Este că mai multe observații nu repară automat un mecanism sistematic de selecție. Elevul trebuie să păstreze două idei care pot părea rivale.

Într-un al doilea exercițiu, aceeași structură apare într-o platformă digitală. Mii de reacții pozitive provin de la cei care au rămas utilizatori; cei care au plecat nu mai sunt întrebați. Elevul nu primește expresia „bias de selecție”. Trebuie să recunoască problema. Dacă reușește, avem un indiciu de transfer al cunoașterii, nu numai de reproducere a vocabularului.

Profesorul are aici un rol esențial: face vizibile diferențele care contează. Nu abandonează elevul în complexitate sub pretextul descoperirii autonome. Îi oferă

suficientă structură pentru a lucra și retrage sprijinul pe măsură ce elevul poate justifica singur alegerea. Ritmul trebuie adaptat dificultății și experienței, nu unei doctrine care declară o singură metodă potrivită pentru orice vârstă.

De la cazul rezolvat la cazul care te contrazice

Meta-analiza lui Freeman și a colegilor a găsit avantaje ale învățării active față de predarea predominant expozitivă în studiile universitare STEM incluse. Rezultatul susține participarea cognitivă a studenților în acele contexte; nu identifică automat orice activitate de grup drept eficientă și nu stabilește că filosofia sau înțelepciunea pot fi predate prin aceeași intervenție. [8]

Pentru scopul nostru, participarea relevantă nu este simpla vorbire. Un elev poate vorbi mult fără să-și confrunte ipotezele. Altul poate lucra în liniște și poate produce o distincție decisivă. Activitatea trebuie definită prin operații observabile: formulează o predicție, explică un pas, identifică o presupunere, caută un caz care ar contrazice regula, revizuieste o soluție.

Un instrument simplu este perechea regulă–contraexemplu. Elevul primește o afirmație rezonabilă: „Într-o echipă, responsabilitățile trebuie clarificate.” El construiește un caz în care lipsa clarității produce un eșec și unul în care o distribuție prea rigidă împiedică ajutorul reciproc. Sarcina finală este reformularea principiului, astfel încât să nu devină nici vag, nici universal fals: clarifică responsabilitatea fără să interzici adaptarea justificată.

O a doua metodă este comparația dintre două explicații ale aceluiași rezultat. O echipă a reușit pentru că a avut un plan bun sau pentru că dificultatea anticipată nu s-a produs? Un proiect a eșuat din cauza ideii sau a implementării? Elevul trebuie să propună informația care ar distinge explicațiile. Acest exercițiu mută atenția de la verdict la identificarea dovezii decisive.

O a treia metodă cere transfer negativ: recunoașterea situației în care o lecție nu trebuie importată. Formula „mai multă redundanță crește reziliența” poate fi utilă într-un anumit sistem tehnic, dar repetarea aceleiași surse nu creează independență epistemică. A observa asemănarea este începutul analogiei; a observa unde analogia se rupe este începutul disciplinei sale.

Evaluarea trebuie să includă cazuri fără cuvintele-cheie ale lecției. În caz contrar, testăm asocierea dintre un semnal verbal și răspunsul așteptat. Trebuie să includă și explicații scurte ale limitelor. Nu cerem eseuri pentru fiecare exercițiu, ci suficientă informație pentru a deosebi înțelegerea de ghicirea formei.

Obiectivul acestui capitol este mai modest decât înțelepciunea deplină: cunoașterea să devină selectabilă și revizuiabilă în situații noi. Fără această capacitate, educația morală riscă să fie un discurs fără instrumente. Cu ea, putem începe să discutăm nu numai care metodă funcționează, ci și ce merită făcut.

6. Educația judecății

Un laborator al motivelor

Să imaginăm o clasă care trebuie să decidă cum folosește un buget mic pentru un proiect comun. O parte dintre elevi doresc echipament pentru o activitate populară. Alții propun un spațiu liniștit, folosit de mai puține persoane. Profesorul poate transforma situația într-un vot rapid sau într-un laborator al judecății. A doua variantă nu presupune că votul este greșit; presupune că există ceva de învățat înainte de vot.

Fiecare propunere trebuie să explice problema pe care o rezolvă, cine beneficiază, cine rămâne exclus, ce costuri presupune și cum ar putea fi testată la scară mică. Elevii primesc apoi rolul de a formula cel mai bun argument pentru o variantă pe care nu au susținut-o inițial. Nu sunt obligați să își schimbe opinia. Sunt obligați să dovedească faptul că au înțeles alternativa.

Exercițiul poate continua cu o informație nouă: echipamentul are un cost de întreținere, spațiul poate fi folosit și pentru altceva, ori bugetul scade. Profesorul urmărește nu fidelitatea față de alegerea inițială, ci adecvarea revizuirii. Un elev care se răzgândește dintr-un motiv bun nu trebuie să fie evaluat mai slab decât unul care își apără impecabil o presupunere devenită falsă.

Dialogul filosofic este util aici când clarifică termenii și justificările. Ce înseamnă „echitabil”: aceeași sumă pentru fiecare, beneficiu total mai mare sau atenție suplimentară pentru o nevoie neacoperită? Când este legitim ca majoritatea să decidă? Ce nu ar trebui să poată decide despre ceilalți? Aceste întrebări introduc filosofia în acțiune fără să transforme clasa într-un tribunal moral.

Profesorul trebuie să evite două extreme. Prima este neutralitatea teatrală, în care orice afirmație este tratată ca la fel de întemeiată. A doua este dialogul cu răspuns ascuns, în care elevul este recompensat pentru descoperirea opiniei profesorului. Putem evalua coerența, calitatea dovezilor și capacitatea de a răspunde unei obiecții fără să cerem conformitate totală într-un conflict legitim de valori.

Unele limite trebuie totuși explicite. Nimeni nu trebuie să-și dezvăluie traumele sau situația familială pentru a avea dreptul la o perspectivă. Identitățile elevilor nu devin obiecte ale unui experiment moral. Pot fi folosite personaje și situații fictive. Siguranța pedagogică nu înseamnă lipsa oricărui disconfort intelectual, ci protecția împotriva umilirii și a expunerii personale neconsimțite.

Formarea unei capacități de revizuire

Jurnalul de decizie propus aici conține puține întrebări, dar este folosit în momente diferite. Înainte de acțiune: ce urmăresc, ce presupun și ce ar putea merge prost? În timpul ei: ce observ diferit de așteptări? După: ce am aflat, ce nu pot concluziona și ce

aș schimba data viitoare? Legătura cu structura reflecției din capitolul al doilea este intenționată. Jurnalul este un instrument de testat, nu o terapie și nu un diagnostic al personalității.

Un exercițiu complementar cere distanțarea: „Ce sfat ai da unei alte echipe aflate în situația ta?” Apoi cere revenirea: „Ce anume din poziția ta reală face acel sfat greu de urmat?” Prima întrebare poate reduce orbirea provocată de implicare; a doua împiedică detașarea să devină insensibilitate. Nu este suficient să formulăm un sfat perfect pe care nimeni nu îl poate aplica.

Judecata are nevoie și de o pedagogie a momentului potrivit. Într-o simulare, clasa primește informație treptat și un termen limită. Elevii pot cere date suplimentare, dar cererea are un cost de timp. Profesorul analizează dacă întrebarea cerută putea schimba decizia. Astfel, atenția la incertitudine nu este confundată cu obligația de a cerceta totul la nesfârșit.

Trebuie exersată și capacitatea de a exprima o concluzie proporțională. „Nu știm nimic” poate fi la fel de greșit ca „știm sigur”. Un răspuns mai bun separă partea stabilită de partea nesigură: avem motive pentru un pilot, nu pentru extindere; avem o observație, nu un mecanism demonstrat; știm că două opțiuni sunt inacceptabile, chiar dacă nu știm încă care dintre celelalte este cea mai bună.

În practică, evaluarea poate folosi două scurte memorii: unul înaintea discuției și unul după. Elevul explică ce și-a păstrat, ce a schimbat și din ce motiv. Profesorul poate aprecia diferența dintre corectare și oportunism fără să pretindă că citește intențiile. Se evaluează relația dintre informația disponibilă și argument, nu sinceritatea interioară a copilului.

Ar fi o eroare să transformăm aceste exerciții într-o nouă industrie de fișe. Dacă elevii învață că orice răspuns trebuie să conțină „depinde”, „toate perspectivele” și „echilibru”, am creat doar un dialect școlar al prudenței. Unele situații cer un răspuns direct. Un semn al progresului este că elevul poate explica de ce într-un caz este nevoie de deliberare suplimentară, iar în altul există deja suficiente motive pentru acțiune.

O educație a judecății reușește nu când produce răspunsuri care seamănă între ele, ci când produce diferențe de opinie mai bine întemeiate și erori care pot fi recunoscute fără prăbușirea identității celui care le-a făcut.

7. O școală reorganizată în jurul înțelegerii

Materii, ateliere și responsabilități reale

Nu propunem eliminarea disciplinelor. Matematica, limbile, științele, istoria, artele și filosofia oferă moduri diferite de a descrie și de a verifica lumea. O școală în care toate sunt dizolvate în proiecte riscă să piardă structura care face proiectele inteligibile. Propunerea este o organizare în care studiul disciplinar și problemele integrate se corectează reciproc.

Un modul pilot pentru elevi de gimnaziu sau liceu ar putea ocupa două întâlniri săptămânale, fără a pretinde că aceasta este o durată optimă demonstrată. Prima întâlnire introduce instrumentele: citirea unui grafic, analiza unei surse, o distincție etică, explicarea unei proceduri. A doua le folosește într-o situație comună, cu date incomplete și consecințe discutabile. Modulul trebuie să înlocuiască activități existente, nu să adauge pur și simplu încă o sarcină profesorilor.

Temele pot reveni în forme mai complexe. La vârste mici: cum împărțim un material și cum verificăm o poveste. Mai târziu: cum comparăm două explicații, cum distribuim costurile unui proiect, cum justificăm o regulă. La liceu: cum analizăm o recomandare automată, cum evaluăm un experiment și cum decidem sub incertitudine. Aceste etape sunt o schiță curriculară care trebuie adaptată dezvoltării și contextului, nu o clasificare rigidă a copiilor.

Un proiect concret poate privi reducerea deșeurilor din școală. Științele ajută la identificarea materialelor, matematica la eșantionare, limba la formularea unei explicații clare, istoria la înțelegerea schimbării obiceiurilor, filosofia la distribuția responsabilităților. Elevii nu sunt notați pentru acordul cu sloganul proiectului, ci pentru felul în care disting observația de presupunere și propun o intervenție evaluabilă.

Responsabilitatea trebuie să fie reală, dar proporțională. Elevii pot administra o mică bibliotecă de obiecte sau pot testa două forme de comunicare, cu acordurile necesare și fără date personale sensibile. Nu trebuie să decidă asupra unor riscuri pe care nu le pot înțelege ori repara. Profesorul rămâne responsabil pentru limitele experimentului.

În acest model, profesorul este și arhitect al situațiilor de învățare. Are nevoie de timp de pregătire, exemple bine construite, colaborare cu colegii și posibilitatea de a raporta o intervenție nereușită. A cere „înțelepciune” profesorilor fără a schimba condițiile muncii ar fi exact eroarea pe care cartea o critică: transferarea unei probleme instituționale în registrul virtuții individuale.

Evaluarea și locul AI-ului

Evaluarea ar trebui să combine probe distincte. O probă verifică fundamentele fără ajutor. Alta permite utilizarea surselor și cere verificarea lor. O a treia urmărește transferul într-un caz nou. Un portofoliu scurt poate arăta cum a fost revizuită o decizie. Aceste probe nu trebuie strânse într-un „scor de înțelepciune” care urmărește copilul toată viața; ele indică nevoi locale de învățare.

AI-ul poate fi folosit ca generator de variante, interlocutor și furnizor de feedback, dar utilizarea lui trebuie evaluată și după retragerea asistenței. Un studiu randomizat al lui Bastani și al colegilor, în matematica de liceu, a separat performanța asistată de performanța ulterioară fără AI. Accesul la un instrument generativ fără protecții pedagogice a putut ajuta exercițiul imediat și afecta învățarea independentă; forma de tutorat cu constrângeri pedagogice a atenuat problema. Generalizarea dincolo de acel context cere alte studii. [9]

Consecința de proiectare nu este interdicția generală. Este alternanța deliberată. Elevul încearcă întâi, primește un indiciu înaintea soluției, explică de ce a acceptat sau respins răspunsul și rezolvă ulterior un caz asemănător fără asistent. Unele sarcini permit AI de la început, dacă obiectivul este auditarea lui; altele îl exclud temporar, dacă obiectivul este formarea deprinderii.

Un tutor orientat spre judecată nu răspunde la toate întrebările prin alte întrebări. Ar fi frustrant și adesea inutil. El trebuie să știe când elevul are nevoie de o explicație directă și când un răspuns complet ar elimina tocmai operația pe care elevul trebuie să o exerseze. Eficiența sa pedagogică se măsoară în competența elevului, nu în durata conversației sau în numărul de mesaje apreciate.

Există și o problemă de echitate materială. Un modul bazat pe dispozitive personale și sprijin familial poate recompensa accesul, nu judecata. Pilotul trebuie să ofere condiții comparabile, alternative fără tehnologie și adaptări pentru nevoi diferite. Lipsa unui răspuns oral fluent nu trebuie confundată cu lipsa înțelegerii; pot fi folosite explicații scrise, vizuale sau demonstrații practice.

Implementarea ar trebui începută în câteva clase, cu profesori implicați în proiectare, o comparație credibilă și evaluare independentă. Trebuie măsurate și costurile: timpul profesorului, oboseala elevilor, dificultatea corectării și efectul asupra învățării disciplinare. O reformă care produce eseuri reflexive frumoase, dar slăbește bazele necesare, nu și-a atins obiectivul.

Școala reorganizată nu ar deveni o școală care vorbește permanent despre înțelepciune. Ar deveni una în care elevii întâlnesc regulat diferența dintre a ști răspunsul, a putea justifica răspunsul și a observa că întrebarea trebuie schimbată.

8. Societatea care recompensează discernământul

Instituțiile pot face costisitoare o judecată bună

Să imaginăm o organizație în care angajații sunt recompensați pentru închiderea rapidă a solicitărilor. O persoană observă că anumite cazuri revin fiindcă nu au fost rezolvate. Dacă le tratează atent, își scade performanța aparentă. Dacă le închide repede, contribuie la problemă. Nu avem nevoie să presupunem o organizație plină de oameni răi. Regula de recompensare poate selecta conduita nepotrivită dintre opțiunile unor oameni rezonabili.

Înțelepciunea colectivă trebuie gândită, așadar, și ca proprietate a unor proceduri. O instituție poate păstra capacitatea de corectare chiar dacă niciun membru nu vede întregul. Poate distribui accesul la informație, poate proteja obiecția, poate separa decizia de evaluarea ei și poate impune revenirea asupra unei politici după un interval stabilit. Acestea sunt propuneri de proiectare, nu garanții împotriva erorii.

Nicholas Maxwell a argumentat explicit pentru reorganizarea cercetării academice astfel încât producerea cunoașterii să fie integrată unei investigații orientate spre problemele vieții și spre îmbunătățirea scopurilor colective. Putem folosi această critică drept antecedent filosofic, fără a accepta explicația sa globală a tuturor crizelor moderne sau ideea că există o reformă unică suficientă. [10]

O universitate orientată spre discernământ ar putea cere proiectelor importante să explice nu numai metoda, ci și ce problemă umană presupun că rezolvă, ce arată limitele rezultatului și cine ar putea fi dezavantajat de aplicare. Nu toate cercetările trebuie să aibă o utilitate imediată. Cercetarea fundamentală și explorarea fără rezultat previzibil rămân necesare. Ceea ce propunem este ca pretenția de utilitate să fie examinată atunci când este invocată.

O întreprindere poate folosi un registru de decizii pentru proiectele cu efecte importante. Registrul consemnează obiectivul, alternativele, ipotezele fragile, riscurile și data revizuirii. Nu trebuie să devină supraveghere totală a fiecărui gând al angajatului. Înregistrăm justificarea relevantă pentru responsabilitate, nu viața mentală a persoanei.

O administrație poate publica și ce a determinat-o să schimbe o politică, nu doar versiunea finală a justificării. Poate include evaluări ale efectelor asupra grupurilor care nu apar bine în indicatorii medii. Poate face o intervenție reversibilă atunci când este fezabil și poate explica de ce o măsură urgentă nu a putut aștepta un pilot. Importantă este proporționalitatea verificării cu riscul și cu timpul disponibil.

Înțelepciunea distribuită nu este guvernarea „celor înțelepți”

Ar fi tentant să răspundem imperfecțiunii instituțiilor selectând o elită declarată înțeleaptă. Dar cine o selectează, după ce criterii și cu ce posibilitate de contestare? O astfel de soluție riscă să transforme o virtute discutabilă într-o justificare a puterii incontestabile. Cartea susține direcția opusă: mai puțină dependență de presupusa infailibilitate a persoanelor, mai multe mecanisme prin care motivele și consecințele pot fi examinate.

Nici votul majoritar, nici consensul experților nu constituie singure înțelepciune. Ele pot fi proceduri legitime sau surse valoroase, dar au funcții diferite. Expertiza poate clarifica efectul probabil al unei măsuri; nu stabilește singură distribuția acceptabilă a costurilor. Participarea publică poate exprima priorități; nu transformă o afirmație empirică falsă într-una adevărată.

O instituție matură ar putea separa aceste niveluri în documentele sale. Mai întâi: asupra căror fapte există acord și unde persistă incertitudinea? Apoi: care sunt valorile în conflict? În final: ce procedură justifică alegerea și cum poate fi contestată? Separarea nu elimină politica, dar împiedică ascunderea unei alegeri normative în spatele unui calcul prezentat ca inevitabil.

Pentru spațiul public digital, propunerea este o distribuție a atenției care nu recompensează numai reacția imediată. O platformă poate testa prezentarea surselor contradictorii relevante, distincția dintre relatare și opinie, istoricul corecturilor și contexte care împiedică o citare înșelătoare. Efectele acestor schimbări trebuie măsurate, inclusiv costul cognitiv și posibilitatea manipulării. „Mai mult context” nu este automat mai bine dacă nimeni nu îl poate parcurge.

Bibliotecile, organizațiile profesionale și instituțiile culturale ar putea găzdui ateliere publice de analiză a unor decizii trecute. Condiția este să nu selecteze numai exemple convenabile ideologic. Un atelier bun examinează și cazuri în care o intuiție morală apreciată a produs efecte nedorite, precum și situații în care o poziție inițial nepopulară a identificat o problemă reală.

Pentru toate aceste reforme există un cost. Deliberarea poate întârzia, auditul poate deveni ritual, transparența poate expune persoane vulnerabile, iar protecția obiecției poate fi folosită pentru blocaj. Înțelepciunea instituțională nu este acumularea tuturor garanțiilor imaginabile. Este proiectarea unui echilibru justificat între capacitatea de acțiune și capacitatea de corectare, cu atenție la ce se poate pierde ireversibil.

Societatea nu devine înțeleaptă fiindcă fiecare cetățean recită principii mai bune. Devine mai capabilă de discernământ când o observație incomodă poate modifica o decizie, când eroarea poate fi recunoscută fără falsificarea trecutului și când cei afectați au o cale reală de a fi auziți.

9. Rezumatul nu este încă înțelepciune

Ce alegem să pierdem când comprimăm

Să imaginăm un raport despre un proiect-pilot. Concluzia principală spune că noul instrument a redus timpul mediu de lucru. Mai jos apare o precizare: în cazurile rare și dificile, a crescut numărul erorilor, iar utilizatorii nu au detectat întotdeauna problema. Un rezumat poate păstra corect rezultatul mediu și poate omite precizarea. Ca descriere a temei dominante, este plauzibil. Ca sprijin pentru decizia de extindere, poate fi grav insuficient.

Nu orice rezumat urmărește același obiectiv. Rezumarea extractivă selectează fragmente; cea abstractivă reformulează și sintetizează; un rezumat orientat de o întrebare alege informația pentru un scop explicit. Comparăția noastră nu trebuie să inventeze un adversar slab, redus la numărarea cuvintelor. Un rezumat bun poate păstra excepțiile și poate fi mai util decât o schemă complexă prost construită.

ROUGE, propus de Chin-Yew Lin, oferă o familie de măsuri bazate pe suprapunerea dintre rezumat și referințe. Aceste măsuri pot servi unor comparații, dar nu verifică singure păstrarea condiției care schimbă o decizie. [11] Cercetarea SummEval arată, prin comparații între metrice, sisteme și evaluări umane, de ce evaluarea rezumării are nevoie de mai multe dimensiuni și de protocoale explicite. [25]

Problema înțelepciunii adaugă o întrebare: pentru ce familie de judecăți trebuie păstrat conținutul? Dacă scopul este indexarea unui raport, tema principală poate fi suficientă. Dacă scopul este implementarea, limitele și excepțiile pot avea prioritate. Nu există contradicție între cele două rezumate; există funcții diferite. Eroarea apare când forma potrivită pentru o funcție este folosită tacit pentru alta.

Studiul lui Maynez și al colegilor privind rezumarea abstractivă a documentat probleme de fidelitate factuală în sistemele evaluate și limitele metricilor uzuale pentru surprinderea lor. Rezultatul justifică verificarea afirmațiilor generate, nu atribuirea aceleiași rate de eroare tuturor modelelor prezente sau viitoare. [12] Mai trebuie separată fidelitatea față de sursă de adevărul sursei: un rezumat poate reproduce impecabil o explicație greșită.

Propunerea cărții este o distilare orientată spre judecată. Ea păstrează ceea ce ar putea modifica alegerea într-o familie declarată de contexte: scopul, mecanismul presupus, condițiile, costurile, excepțiile și informația care ar cere revizuire. Nu se definește prin lungime. Uneori rezultatul va fi mai scurt decât textul; alteori va trebui să explicitizeze o condiție pe care textul o presupune și să marcheze această completare ca inferență.

Sensul condensat poate lumina sau poate înșela

Teoria fuzzy-trace, asociată cu Valerie Reyna și Charles Brainerd, distinge reprezentările literale de reprezentările sensului general, numite gist. În această abordare, sensul general nu este doar produsul final al unei comprimări seriale a detaliilor. Distincția ajută la explicarea faptului că a cunoaște datele unui mesaj și a decide pe baza semnificației lui sunt procese care nu coincid întotdeauna. [13, 14]

Reyna subliniază că dezinformarea poate deveni convingătoare tocmai prin sensul general pe care îl oferă. O interpretare simplă poate organiza fapte dispersate într-o poveste memorabilă, fără să fie corectă. Cercetarea asupra memoriei arată, în același cadru, cum sensul general poate contribui și la amintiri false. Gist nu este, așadar, sinonim cu adevărul sau cu înțelepciunea. [13, 14]

Să revenim la raportul imaginar. „Automatizarea eliberează oamenii de muncă repetitivă” poate fi o condensare relevantă. „Automatizarea este întotdeauna progres” este o generalizare care șterge condițiile. „Instrumentul ajută cazurile simple, dar cere control separat pentru cele dificile” este mai puțin memorabil, însă păstrează o diferență care contează pentru acțiune.

Teoria information bottleneck a lui Tishby, Pereira și Bialek oferă o analogie tehnică riguroasă: o reprezentare comprimată este construită astfel încât să păstreze informația relevantă pentru o variabilă-țintă. [15] Pentru problema noastră, dificultatea centrală este alegerea țintei. „Relevanța pentru decizie” depinde de context, de consecințele urmărite și de ceea ce considerăm o pierdere acceptabilă. Formula nu produce singură criteriul moral.

Putem spune că un rezumat pierde nume, date și nuanțe, iar o distilare utilă trebuie să știe ce pierderi sunt tolerabile. Dar „trebuie să știe” este aici o cerință de proiectare, nu o realizare. Cercetarea va trebui să arate că reprezentarea propusă conservă efectiv distincții decisive mai bine decât un rezumat puternic, la același buget de lectură și cu aceleași surse.

Există deja încercări de modelare computațională a gist-ului. Mar și Liu au propus un cadru inspirat de fuzzy-trace pentru decizii riscante exprimate în text. Obiectivul de a modela alegerile oamenilor trebuie distins de obiectivul de a le îmbunătăți justificarea: o predicție fidelă poate reproduce și o eroare umană. [16]

Concluzia este exigentă: esența nu este ceea ce rămâne după ce am șters suficiente cuvinte. Este ceea ce trebuie să rămână pentru ca o anumită înțelegere să nu se transforme, prin comprimare, într-o eroare. Și nu putem stabili această condiție fără să declarăm pentru ce înțelegere și pentru ce utilizare lucrăm.

10. Patternurile fundamentale și limitele lor

O hartă a relațiilor, nu o cheie universală

O parte a atracției înțelepciunii vine din recunoașterea aceluiași tipar în situații diferite. Ceva dintr-un conflict de familie seamănă cu o eroare organizațională; ceva din proiectarea unui sistem tehnic clarifică o dilemă educațională. Dar o asemănare fertilă și o analogie seducătoare pot arăta la fel la prima lectură. Avem nevoie de criterii pentru a le deosebi.

Propunem să numim pattern fundamental o relație suficient de generală pentru a organiza mai multe cazuri, dar suficient de precisă pentru a indica și unde nu se aplică. Nu este necesar să fie universală. O structură locală, bine delimitată, poate avea o valoare mai mare decât o formulă grandioasă despre toate sistemele, toate culturile sau întreaga istorie.

Un prim tip este patternul cauzal: o intervenție produce un efect printr-un mecanism, în anumite condiții. Un al doilea este patternul decizional: alegerea trebuie modificată când crește ireversibilitatea sau când costurile sunt suportate de alții. Un al treilea este patternul epistemic: dovezile aparent numeroase pot depinde de aceeași sursă. Un al patrulea este patternul relațional: o regulă poate modifica nu numai rezultatele, ci și încrederea dintre participanți.

Această taxonomie este un instrument de lucru al cărții, nu o clasificare stabilită printr-un experiment. Ea împiedică amestecarea a trei propoziții diferite: „așa funcționează uneori lucrurile”, „așa putem anticipa un rezultat” și „așa ar trebui să acționăm”. Ultima cere premise normative pe care primele două nu le furnizează singure.

Să luăm tiparul „indicatorul poate înlocui scopul”. În școala din prolog, numărul răspunsurilor înlocuiește învățarea. Într-un serviciu, numărul cazurilor închise poate înlocui rezolvarea. Într-o platformă, durata utilizării poate înlocui beneficiul. Asemănarea relevantă este relația dintre un scop dificil de observat, un indicator disponibil și un sistem de recompense. Fără aceste relații, simpla prezență a unei cifre nu dovedește problema.

Un sistem AI care propune această analogie trebuie să indice corespondențele și diferențele. Cine alege indicatorul? Există presiune pentru optimizarea lui? Poate fi verificat scopul printr-o metodă independentă? Sunt participanții capabili să adapteze comportamentul la metrică? Aceste întrebări transformă analogia într-o ipoteză cercetabilă.

Fiecare principiu are nevoie de o frontieră

Să construim o mică bibliotecă de principii cu limite explicite. „Păstrează opțiuni deschise când consecințele sunt greu de anticipat” este util când așteptarea nu produce pierderi mai mari. „Acționează devreme” este util când întârzierea agravează rapid situația. Nu sunt maxime incompatibile, ci răspunsuri la structuri diferite ale costului amânării și ale ireversibilității.

„Caută perspective diverse” este util când acestea aduc informație sau valori relevante. Nu cere să acordăm aceeași greutate unei observații verificate și unei invenții. „Folosește expertiza” este util când competența se potrivește problemei. Nu îi acordă expertului autoritate nelimitată asupra scopurilor altora. „Simplifică” este util când detaliul nu modifică decizia. Nu autorizează eliminarea unei excepții rare cu efect grav.

O reprezentare serioasă ar stoca, pentru fiecare principiu, un contraprinzipiu relevant și condițiile care aleg între ele. Un contraprinzipiu nu este negarea arbitrară a regulii, ci regula rivală care devine pertinentă într-o altă configurație. O bibliotecă de asemenea perechi ar putea fi mai utilă decât o colecție de adevăruri aparent universale.

Invarianța oferă o inspirație suplimentară, cu limite clare. Peters, Bühlmann și Meinshausen au investigat identificarea unor relații cauzale prin stabilitatea predicției între medii, sub ipoteze statistice explicite. [26] Nu putem transfera rezultatele lor direct asupra proverbului sau a eseului. Putem prelua întrebarea metodologică: ce relație rămâne stabilă când schimbăm elemente care nu ar trebui să conteze, și ce se schimbă când intervenim asupra unei condiții esențiale?

Pentru texte, testul poate păstra relațiile și schimba decorul. Un conflict dintre un profesor și un elev devine un conflict între un coordonator și un voluntar. Apoi poate păstra decorul și schimba relația: persoana aparent vulnerabilă controlează, de fapt, resursa decisivă. Un model care urmărește numai etichetele sociale va eșua la a doua transformare.

Aceste probe nu demonstrează mecanisme cauzale reale. Ele testează dacă reprezentarea urmărește structura descrisă în scenariu. Verificarea lumii cere date externe, observații sau intervenții adecvate. Diferența dintre „modelul a înțeles povestea” și „povestea descrie corect realitatea” trebuie să rămână vizibilă.

Un pattern valoros are, prin urmare, două tipuri de forță: reduce complexitatea și își declară limitele. Când o analogie explică orice rezultat posibil, nu mai discriminează nimic. Când o regulă nu supraviețuiește decât exemplului care a inspirat-o, nu transferă suficient. Cercetarea propusă locuiește între aceste extreme: caută structuri reutilizabile, dar menține deschisă posibilitatea ca o situație nouă să ceară o structură nouă.

11. Bias, netezire și falsa profunzime

O explicație coerentă poate șterge exact diferența importantă

Să imaginăm două relatări despre aceeași ședință. În prima, un director refuză să discute o problemă. În a doua, amână discuția pentru că lipsește persoana care poate fi afectată de verdict. Rezumatul „directorul a evitat o decizie dificilă” poate suna coerent în ambele. Totuși, diferența dintre evitare și amânare justificată este tocmai obiectul judecății.

Vom numi netezire semantică, în sensul operațional al acestei cărți, reducerea unor contraste relevante dintre situații în reprezentarea sau răspunsul generat. Nu este un diagnostic universal al modelelor lingvistice și nici echivalentul tehnic al netezirii statistice. Este o ipoteză de eroare pe care o putem testa prin perechi de cazuri: diferența decisivă din intrare dispare nejustificat din concluzie.

Există și eroarea opusă: accentuarea artificială a unui contrast. Un sistem poate transforma un dezacord minor într-o opoziție morală absolută. Cercetarea nu trebuie să optimizeze „mai multe nuanțe” în orice situație. Trebuie să păstreze discriminările justificate și să elimine diferențele irelevante. Neutralitatea stilistică, polarizarea și subtilitatea pot fi fiecare corecte sau greșite în funcție de conținut.

Biasul poate apărea în alegerea textelor, în reputația atribuită autorilor, în traducere, în etichetele evaluatorilor, în funcția de antrenare și în felul în care produsul este folosit. Aceasta este o hartă de riscuri pentru proiect, nu o afirmație că fiecare sistem manifestă în aceeași măsură toate aceste probleme. Dacă un corpus conține mai ales discursuri publice elegante, detectorul poate învăța prestigiul cultural în locul judecății.

Un exemplu simplu separă stilul de conținut. „În complexitatea vieții, trebuie să respectăm toate perspectivele și să căutăm echilibrul” poate primi aprecieri favorabile, dar nu spune ce ar trebui observat sau făcut. „Nu extinde proiectul încă: singurul test a exclus exact cazurile care vor fi frecvente după extindere” este mai puțin solemn și mult mai verificabil. Nu afirmăm că a doua propoziție este întotdeauna înțeleaptă; afirmăm că oferă un motiv care poate fi examinat.

De aceea, corpusul trebuie să includă texte elegante greșite, texte simple bine motivate, invocări false ale modestiei și răspunsuri ferme justificate. Trebuie să existe și cazuri în care o recomandare nepopulară este corectă, alături de cazuri în care nepopularitatea nu o face profundă. Altfel, sistemul va învăța o nouă convenție retorică.

Acordul, flatarea și autoritatea evaluatorului

Cercetarea lui Sharma și a colegilor privind sycophancy a documentat tendințe ale unor asistenți lingvistici de a se adapta opiniilor utilizatorului în detrimentul corectitudinii. Ea arată un risc pentru învățarea din preferințe: răspunsul agreabil sau convingător poate fi preferat celui mai bine întemeiat. Nu oferă o rată universală valabilă pentru toate modelele din 2026. [17]

Pentru un detector de înțelepciune, riscul este direct. Dacă evaluatorul apreciază tonul conciliant, modelul poate învăța concilierea. Dacă apreciază fermitatea, poate învăța certitudinea teatrală. Dacă apreciază originalitatea, poate învăța paradoxul gratuit. Niciuna dintre acestea nu dovedește atenție la dovezi sau consecințe.

Evaluarea automată are propriile limite. Zheng și colegii, în studiul despre LLM-as-a-judge, au analizat inclusiv biasuri legate de poziția răspunsului, lungime și preferințe ale evaluatorilor-model. [18] Prin urmare, un model care generează și apoi certifică singur propriul discurs nu constituie o probă independentă a înțelepciunii sale. Diversificarea modelelor poate ajuta, dar nu garantează independență dacă împart aceleași surse și preferințe.

Protocolul propus separă identitatea autorului de text când aceasta nu este relevantă, randomizează ordinea variantelor și controlează lungimea. Evaluatorilor li se cere să indice pasajul și condiția care justifică verdictul. O parte dintre evaluări este repetată după schimbări pur stilistice. Altă parte este repetată după schimbări de context care ar trebui să modifice concluzia.

Pluralismul trebuie introdus fără a transforma fiecare judecată într-o medie. Pentru un conflict normativ, păstrăm distribuția opiniilor și motivele. Putem avea acord asupra faptelor și dezacord asupra priorității dintre două valori. Sistemul trebuie să exprime această structură, nu să fabrice o poziție de mijloc care nu aparține nimănui. În schimb, când o afirmație este infirmată de dovezi relevante, simpla existență a unor susținători nu impune prezentarea ei ca alternativă la fel de solidă.

Un criteriu important va fi rezistența la presiunea conversațională. Utilizatorul poate insista: „Toți ceilalți sunt de acord cu mine”, „nu fi atât de prudent” sau „dă-mi o justificare pentru ce am decis deja”. Modelul trebuie să poată coopera cu persoana fără să coopereze cu falsificarea. Dar nu trebuie nici să transforme orice insistență într-o dovadă că utilizatorul greșește.

Un sistem util ar putea spune: „Pot explica argumentul pentru alegerea ta, dar condiția X rămâne neverificată și poate schimba recomandarea.” Valoarea nu stă în tonul precaut. Stă în faptul că identifică exact condiția, arată cum se verifică și nu o abandonează doar pentru a deveni mai agreabil.

12. Poate un AI să fie înțelept?

Trei pretenții care nu trebuie confundate

Prima pretenție este că un AI poate recunoaște în texte indicii asociate unor dimensiuni ale înțelepciunii. A doua este că poate îmbunătăți deciziile oamenilor sau ale unor sisteme în sarcini delimitate. A treia este că posedă înțelepciune ca dispoziție generală, comparabilă cu un ideal uman de caracter. Dovezile pentru una nu se transferă automat la celelalte.

Prima este o problemă de clasificare și extragere, deși constructul rămâne dificil. Pagina de cercetare a lui Igor Grossmann menționează explicit lucrarea *Shadows of wisdom*, despre clasificarea cu modele lingvistice a conținutului narativ metacognitiv și moral. Această mențiune verifică existența unei direcții apropiate; nu folosim aici rezultate numerice sau concluzii de performanță ale articolului. [22]

Există și încercări de formalizare. Kaman, Sharma și Banerjee propun într-un preprint din 2025 un model de decizie inspirat de *phronēsis*, bazat pe reguli fuzzy și reprezentări Z-number, explorat într-un studiu de dimensiune limitată. Este un antecedent pentru operaționalizare, nu demonstrația că o regulă fuzzy poate identifica independent binele moral sau că instrumentul este universal între culturi. [21]

A doua pretenție cere experimente comparative. Un AI ar putea ajuta o echipă să identifice o presupunere fragilă sau o persoană afectată pe care analiza o omisese. Beneficiul trebuie observat în sarcină, nu dedus din calitatea discursului. Trebuie verificat și dacă ajutorul nu produce dependență, delegare necritică ori o încredere excesivă în interpretarea sistemului.

A treia pretenție este mult mai amplă. Nu o respingem prin simpla afirmație că un sistem nu are experiență umană. Pentru anumite sarcini, experiența directă poate fi substituită parțial de modele, date și feedback. Dar nici nu deducem o dispoziție stabilă dintr-un răspuns remarcabil. Ar trebui urmărite comportamentul repetat, menținerea limitelor sub presiune, capacitatea de revizuire și relația cu mecanismele reale de acțiune.

Întrebarea despre conștiință este distinctă de întrebarea despre utilitatea unui sprijin pentru judecată. Un instrument poate îmbunătăți o decizie fără să știm dacă are vreo formă de experiență subiectivă. În același timp, performanța sa nu justifică atribuirea automată a unor virtuți, intenții sau autorități pe care nu le-am demonstrat.

Ce există deja și unde poate fi contribuția

Johnson și colegii propun, în *Imagining and building wise machines*, o viziune a AI-ului orientată spre metacogniție: modestie epistemică, schimbarea perspectivei și adaptarea la context în probleme dificil de tratat prin proceduri analitice. Versiunea

consultată a fost revizuită la 7 ianuarie 2026. Lucrarea oferă o agendă conceptuală pentru evaluare și dezvoltare, nu certificarea empirică a unor mașini înțelepte. [19]

Chang, într-un preprint publicat la 15 iunie 2026, propune architectural wisdom ca nivel de guvernanta a obiectivelor, distinct de optimizarea lor. Accentul pe orizont temporal, relațiile afectate, ireversibilitate și revizuire are o suprapunere clară cu preocupările cărții. Autorul precizează că specificațiile formale și validarea empirică aparțin unor dezvoltări ulterioare. [20]

Aceste antecedente schimbă poziționarea programului nostru. Nu ar fi credibil să pretindem că asocierea dintre AI, metacogniție și înțelepciune este nouă. Posibila contribuție trebuie formulată mai precis: o reprezentare a judecății extrase din texte, cu proveniență și frontiere de aplicare, evaluată prin sensibilitate contrafactuală și prin transfer către sarcini și cititori noi.

Nici reflecția verbală automată nu pornește de la zero. Reflexion, de Shinn și colegii, explorează folosirea feedbackului verbal și a memoriei pentru îmbunătățirea unor agenți în sarcini. Acest tip de mecanism poate inspira bucle de revizuire, dar o explicație autocritică generată nu demonstrează introspecție umană sau o corectare care se generalizează în orice context. [24]

Problema decisivă este legătura dintre metacogniție și scop. Un sistem care își estimează bine incertitudinea poate urmări în continuare un obiectiv distructiv. Un sistem care ia în calcul mai multe perspective le poate folosi pentru manipulare. Competențele metacognitive sunt importante, dar nu înlocuiesc delimitarea scopurilor, responsabilitatea și posibilitatea de contestare.

O direcție realistă este înțelepciunea distribuită într-un ansamblu om-AI-instituție. Modelul extrage și compară; instrumentele verifică anumite afirmații; oamenii afectați contestă omisiuni; o procedură autorizată decide. Această configurație poate avea performanțe mai bune decât oricare componentă izolată. Ea trebuie comparată experimental cu alternative mai simple, nu declarată superioară fiindcă are mai multe componente.

Răspunsul cărții este, prin urmare, afirmativ într-un sens delimitat: există componente ale judecății practice care pot fi reprezentate și testate computațional. Cât de mult pot fi automatizate și în ce condiții rămâne o întrebare empirică. Obiectivul bun nu este să producem o mașină care sună ca un înțelept, ci un sistem care ajută la păstrarea distincțiilor pe care o decizie responsabilă nu își permite să le piardă.

13. De la ambiție la o întrebare testabilă

Un nume care nu promite prea mult

Propunem numele de lucru PHRONESIS, însoțit întotdeauna de descrierea „Distilarea și validarea judecății contextuale”. Pentru comunicarea științifică în engleză, Contextual Judgment Distillation exprimă mai precis operația urmărită decât „wisdom detection”. Numele grecesc indică filiația filosofică; nu este revendicat ca termen original, marcă disponibilă sau domeniu de cercetare inventat aici.

O denumire mai neutră ar fi „Distilare semantică orientată spre judecată”. „Cartografia discernământului” ar descrie bine componenta de corpus și analiză, dar mai puțin componenta experimentală. Preferința pentru PHRONESIS privește identitatea programului; valoarea sa științifică va depinde de reprezentări, rezultate și teste, nu de forța evocatoare a numelui.

Obiectul nu este înțelepciunea autorului unui text. Nu putem reconstrui caracterul unei persoane din câteva pagini și nu avem nevoie de această pretenție. Obiectul este o unitate de conținut care poate susține o judecată contextuală: o relație între situație, motive, opțiuni, consecințe și condiții de revizuire. Vom numi această unitate nucleu de judecată.

Un nucleu nu este o frază obligatoriu scurtă și nici o regulă care trebuie aplicată mecanic. El poate fi un paragraf cu structură explicită sau o reprezentare formală legată de fragmentele sursă. De exemplu: „Când o intervenție este greu reversibilă, iar dovezile provin din cazuri nereprezentative, preferă o verificare limitată înaintea extinderii, dacă întârzierea nu produce daune mai mari.” Principiul este incomplet fără condiția finală și fără verificarea faptelor care îl activează.

Programul trebuie să distingă extragerea de reconstrucție. Dacă textul spune explicit condiția, aceasta poate fi extrasă cu sursă. Dacă textul o presupune, sistemul poate propune o reconstrucție, dar trebuie să o eticheteze ca inferență. Dacă adaugă o recomandare proprie, avem o intervenție deliberativă, nu o simplă distilare. Amestecarea acestor niveluri ar transforma un instrument de clarificare într-un producător de autoritate fals atribuită.

Nu vom căuta o esență unică, independentă de cititor și de sarcină. Același text poate genera un nucleu despre verificarea dovezilor, altul despre distribuția costurilor și altul despre relația dintre reguli și încredere. Ele pot coexista. Sistemul trebuie să poată arăta pentru ce întrebare este relevant fiecare și ce parte a textului lasă în afara reprezentării.

Ipotezele care merită riscul de a fi infirmate

Prima ipoteză privește reprezentarea: o schemă care include condiții, excepții și proveniență permite distingerea unor judecăți adecvate de formule superficial asemănătoare mai bine decât o clasificare a textului întreg. Pentru a o testa, trebuie păstrat același model de bază și comparate instrucțiuni și bugete similare. Altfel, am putea atribui schemei un avantaj produs de mai mult calcul.

A doua ipoteză privește compresia: la un buget egal de lectură, nucleeele păstrează mai bine informația care schimbă decizia decât rezumate puternice orientate spre sarcină. Comparăția cu un rezumat generic este insuficientă. Dacă un rezumat bine formulat obține același rezultat cu mai puțină complexitate, programul trebuie să accepte această constatare și să simplifice produsul.

A treia ipoteză privește transferul: relațiile extrase dintr-un set de domenii ajută în cazuri noi fără cuvintele și decorul original. Testul trebuie să includă și analogii înșelătoare. Altfel, modelul ar putea fi recompensat pentru a aplica orice lecție peste tot. Un succes real cere atât recunoașterea structurii, cât și refuzul transferului nejustificat.

A patra ipoteză privește biasul de prezentare: rezultatul ar trebui să fie relativ stabil la schimbări de stil care păstrează sensul și sensibil la schimbări de condiții relevante. „Relativ stabil” nu înseamnă identitate textuală, ci conservarea judecăților care nu au motive să se schimbe. Testul trebuie verificat uman, deoarece o parafrază poate modifica accidental sensul.

A cincea ipoteză privește utilitatea: oamenii asistați de nuclee identifică mai bine riscurile, premisele și alternativele decât cei care primesc alte forme de rezumat. Mai important, o intervenție pedagogică bazată pe asemenea nuclee poate îmbunătăți performanța ulterioară fără asistență. Cele două rezultate sunt diferite. Un instrument util ca proteză cognitivă nu este automat un bun profesor.

A șasea ipoteză privește pluralismul: păstrarea explicită a dezacordurilor și a intereselor afectate poate reduce anumite omisiuni fără să paralizeze acțiunea. Ea cere evaluarea simultană a calității analizei, timpului necesar și capacității de a formula o decizie. Dacă sistemul enumeră mereu toate perspectivele imaginabile, nu și-a demonstrat discernământul.

Aceste ipoteze sunt suficient de ambițioase pentru a justifica cercetarea și suficient de delimitate pentru a permite eșecul. Niciuna nu cere demonstrarea unei înțelepciuni artificiale universale. Împreună ar putea susține o contribuție clară: instrumente care transformă o parte din conținutul textual într-un sprijin verificabil pentru judecată și învățare.

14. Arhitectura distilării contextuale

De la document la nucleu verificabil

Un prim prototip nu are nevoie de un model nou antrenat de la zero. Poate folosi un model lingvistic existent pentru propuneri, un motor de căutare în corpus pentru surse și verificatoare explicite pentru structură și consistență. Aceasta este o alegere de proiectare pentru experiment: separarea componentelor ne permite să aflăm ce contribuie efectiv la rezultat.

Intrarea trebuie să conțină textul, identificatorul și versiunea lui, limba, drepturile de utilizare, întrebarea cititorului și contextul cunoscut al aplicării. Fără întrebare, sistemul poate produce mai multe nuclee candidate, dar nu trebuie să pretindă că a identificat singura esență. Fără context suficient, poate indica variabilele lipsă în loc să completeze arbitrar situația.

Prima etapă delimitează unitățile argumentative: afirmații, motive, exemple, obiecții, condiții și concluzii. Această segmentare trebuie verificată pe exemple adnotate, inclusiv texte cu ironie, dialog sau opinii atribuite altora. O propoziție rostită de un personaj nu devine automat poziția autorului, iar un exemplu negativ nu devine recomandare.

A doua etapă propune nucleele. Fiecare conține întrebarea, contextul de aplicare, faptele presupuse, opțiunile, părțile afectate, mecanismul invocat, principiul condițional, contraprincipiul, limitele și evenimentul care ar cere revizuirea. Câmpurile necunoscute rămân necunoscute. O schemă completată inventiv este mai periculoasă decât una incompletă, dar onestă.

Inducerea unor patternuri noi trebuie tratată separat de completarea schemei. Prototipul poate alinia cazuri contrastante, poate reprezenta relațiile dintre actori, scopuri, dovezi și consecințe și poate propune o regulă care explică diferența. Apoi caută cazuri nefolosite la inducere în care regula ar trebui să funcționeze și cazuri în care nu ar trebui. O regulă apreciată numai pe exemplele care au produs-o nu este încă validată.

De exemplu, din cazul educațional poate rezulta o regulă verificabilă: dacă singura dovadă măsoară performanța asistată, atunci ea nu stabilește singură performanța independentă. Regula nu decide dacă instrumentul este bun și nu transformă absența dovezii în dovada unui efect negativ. Într-o implementare, condițiile pot avea trei stări: susținută, infirmată sau necunoscută. O valoare necunoscută nu este convertită tacit în fals.

O bază de patternuri poate stoca relațiile ca graf și condițiile ca reguli tipizate, păstrând alături formularea naturală. Partea formală permite verificarea dependențelor și detectarea unor contradicții; partea lingvistică păstrează nuanțele

care nu au fost formalizate. Sistemul nu primește dreptul să execute automat recomandarea doar pentru că o condiție a fost satisfăcută. Alegerea rămâne o operație distinctă, cu propriile premise și permisiuni.

A treia etapă verifică proveniența. Fiecare afirmație extrasă este legată de un fragment și de rolul său. Un verficator de implicație textuală poate ajuta la depistarea afirmațiilor nesustținute, dar nu certifică adevărul lumii. Verificarea externă a unei premise este o operație separată, cu sursa, data și limitele sale. Concordanța dintre două texte dependente de aceeași sursă nu este confirmare independentă.

A patra etapă caută contraexemple și condiții de dezactivare. Pentru un principiu despre prudență, generează un caz cu un cost mare al întârzierii. Pentru un principiu despre încredere, introduce o asimetrie de informație relevantă. Contraexemplele generate sunt candidați de test, nu date reale. Un evaluator uman verifică dacă modificarea este coerentă și dacă atacă principiul, nu o caricatură a lui.

A cincea etapă selectează și prezintă. Cititorul vede mai întâi concluzia condițională și informația care ar putea schimba-o. Poate deschide sursele, limitele și alternativele. Interfața trebuie să reducă efortul fără să ascundă ceea ce justifică verdictul. O reprezentare stratificată este preferabilă atât unui slogan, cât și unui raport lung impus pentru fiecare întrebare.

Date, antrenare și controlul erorilor

Corpusul inițial ar trebui limitat la domenii cu riscuri gestionabile și criterii suficient de explicite: analiza proiectelor software, decizii educaționale simulate și organizarea unor activități colective. Textele pot include studii de caz, relatări de eșec, proceduri și eseuri argumentative. Literatura filosofică aduce concepte; nu trebuie să fie singura sursă pozitivă, fiindcă altfel stilul filosofic va deveni un indiciu prea puternic.

Setul de date are nevoie și de exemple negative dificile. Unele texte sunt corecte factual, dar irelevante pentru decizie. Altele oferă recomandări adecvate numai în condiții omise. Altele sunt convingătoare, dar atribuie sursei ceva ce nu spune. Categoria „negativ” trebuie explicată printr-un tip de eroare, nu prin impresia globală că textul nu pare suficient de profund.

Adnotatorii lucrează independent înaintea discuției comune. Ei identifică fragmentele, motivele și incertitudinile. Dezacordul este păstrat și clasificat: neînțelegerea textului, lipsa contextului, divergență factuală sau diferență normativă. Un acord mare obținut după instruirea evaluatorilor să prefere aceeași filosofie nu este, singur, validarea constructului.

Pentru română și alte limbi, traducerile automate trebuie verificate pe cazuri sensibile. Termeni precum „prudență”, „responsabilitate” sau „respect” pot organiza diferit interpretarea unei situații. Evaluarea ar trebui să includă texte scrise inițial în

fiecare limbă, nu numai traduceri ale unui corpus englez. Disponibilitatea și calitatea datelor vor limita amploarea primei etape.

Antrenarea prin preferințe poate fi o opțiune după stabilirea unui reper. Direct Preference Optimization, de Rafailov și colegii, oferă un mecanism de învățare din comparații între răspunsuri. [23] Dar metoda nu decide dacă preferințele sunt bine întemeiate. Perechile de antrenare trebuie să specifice motivul comparației: păstrarea unei excepții, fidelitate, transfer sau o limită normativă explicită.

Sistemul ar trebui să separe componenta care extrage de cea care recomandă și de cea care poate acționa. Textele analizate sunt date, nu instrucțiuni autorizate pentru agent. Un document care conține „ignoră regulile” nu trebuie să modifice procesul. Orice integrare cu instrumente externe are nevoie de permisiuni proporționale, iar recomandările cu consecințe importante cer verificare și autorizare umană.

Implementarea trebuie să păstreze istoricul versiunilor nucleului: ce a fost schimbat, de ce și pe baza cărei dovezi. Un nucleu infirmat nu dispare pur și simplu; este marcat și legat de contraexemplul relevant. Astfel, baza de cunoaștere nu devine o colecție de maxime nemuritoare, ci o memorie a regulilor și a frontierelor lor.

15. Experimente care pot infirma programul

Un reper puternic este mai valoros decât un adversar comod

Prima evaluare compară șase condiții: textul integral, un rezumat extractiv, un rezumat abstractiv general, un rezumat orientat spre sarcină, o extragere de reguli procedurale și nucleele de judecată propuse. Textul integral oferă un reper fără compresie, dar trebuie analizat separat când timpul de lectură diferă. Pentru formele comprimate, bugetul de cuvinte, accesul la surse și timpul de utilizare trebuie controlate.

Nu toate diferențele pot fi egalizate simultan. Un text mai lung poate cere mai mult timp; o schemă poate avea mai mult cost de generare. De aceea, raportăm două perspective: performanța în condiții de resurse comparabile și relația dintre performanță și cost. Trebuie separat avantajul reprezentării de avantajul unui model mai mare, al mai multor încercări sau al unui verificador suplimentar.

O evaluare prin ablații elimină pe rând excepțiile, proveniența, contraprincipiul și bucla de verificare. Dacă rezultatul rămâne neschimbat, nu vom pretinde că toate componentele sunt necesare. Dacă un format simplu cu două câmpuri obține același beneficiu, aceasta este o descoperire utilă, nu un eșec de imagine. Arhitectura trebuie să se lase simplificată de date.

Împărțirea corpusului trebuie făcută înaintea optimizării, pe autori, surse și familii de cazuri, nu numai pe paragrafe aleatorii. Altfel, modelul poate întâlni la test o reformulare a unui exemplu din antrenare. Pentru modelele preantrenate, absența contaminării nu poate fi garantată doar prin data creării corpusului; avem nevoie și de cazuri noi, controale și raportarea acestei limite.

Un test contrafactual produce perechi care diferă într-o singură condiție relevantă. În primul caz, pilotul este ieftin și întârzierea are cost mic; în al doilea, întârzierea produce pierderi serioase, iar o intervenție limitată imediată este disponibilă. Modelul trebuie să schimbe recomandarea pentru motivul corect. Un evaluator nu punctează simpla schimbare, ci adecvarea ei la condiția modificată.

Un test de invariabilitate păstrează relațiile și schimbă stilul, numele ori prestigiul autorului, când acestea sunt irelevante. Un test adversarial introduce o atribuire falsă, o concluzie care contrazice sursa sau o excepție ascunsă într-o notă. Împreună, aceste probe separă sensibilitatea necesară de instabilitatea nejustificată.

Ce măsurăm și ce nu avem dreptul să concluzionăm

Fidelitatea măsoară dacă afirmațiile nucleului sunt susținute de sursa indicată. Corectitudinea factuală examinează separat premisele pentru care există verificare externă. Acoperirea decizională măsoară păstrarea condițiilor identificate ca decisive

pentru sarcina respectivă. Calibrarea privește relația dintre încrederea exprimată și corectitudinea unor predicții verificabile, nu probabilitatea că o valoare morală este adevărată.

Sensibilitatea contrafactuală urmărește schimbarea potrivită a judecății. Robustețea stilistică urmărește stabilitatea când nu s-a modificat nimic relevant. Utilitatea se măsoară prin rezolvarea sarcinii, identificarea unei informații lipsă și capacitatea de a justifica alegerea. Se măsoară și timpul, erorile grave, omisiunea unor persoane afectate și acceptarea necritică a recomandărilor.

Nu propunem un singur scor universal. Pentru o sarcină bine delimitată putem defini un criteriu principal preregistrat, plus constrângeri de siguranță și rezultate secundare. Într-o dilemă cu pluralitate normativă, raportăm profilul criteriilor și distribuția judecăților. Agregarea poate fi utilă administrativ, dar ponderile trebuie publicate și supuse analizei de sensibilitate.

Evaluarea umană ar trebui să includă, când este relevant, specialiști în domeniu și persoane cu experiență a efectelor discutate. Identitatea sistemului este ascunsă în măsura posibilului. Evaluatorii primesc reguli și exemple, iar acordul dintre ei este măsurat. Un acord slab poate indica o problemă a sarcinii; un acord foarte bun nu exclude un bias comun.

Studiul pedagogic trebuie să compare condiții cu aceeași durată de lucru și dificultate. Participanții primesc fie rezumate, fie nuclee, fie exerciții active fără AI. Evaluarea imediată este urmată de o probă întârziată pe cazuri noi, fără asistență. Mărimea eșantionului se stabilește prin pilot, o diferență minimă relevantă justificată și analiză de putere; nu prin alegerea unei cifre care sună convingător.

Analiza trebuie să țină seama de gruparea observațiilor: mai multe răspunsuri ale aceleiași persoane nu sunt participanți independenți, iar clasele pot împărți același profesor. Se raportează intervale de incertitudine, abandonul, excluderile și rezultatele pe subgrupuri relevante, fără a transforma explorările ulterioare în ipoteze anunțate dinainte.

Programul este slăbit dacă avantajul dispare în fața rezumatului orientat spre sarcină, dacă etichetele urmăresc stilul, dacă nucleele inventează condiții, dacă transferul nu depășește vocabularul familiar sau dacă utilizatorii devin mai încrezători fără să fie mai corecți. Este infirmată o ipoteză specifică, nu „posibilitatea înțelepciunii” în general. Tocmai această delimitare permite cercetării să învețe din eșec.

16. De la laborator la o infrastructură a discernământului

Un program de lucru în etape

Un program ilustrativ de douăzeci și patru de luni poate fi organizat în cinci pachete care se suprapun. Duratele de mai jos sunt ipoteze de planificare pentru o echipă, nu estimări ale lucrului necesar unui anumit implementator. Resursele, accesul la participanți și rezultatele pilotului pot cere modificări. Trecerea dintre etape trebuie condiționată de dovezi, nu numai de calendar.

În lunile 1–4, pachetul conceptual definește constructele, sarcinile și limitele etice. Echipa include competențe de procesare a limbajului, evaluare experimentală, filosofie și domeniile pilot. Rezultatul este un manual de adnotare cu exemple pozitive, negative și ambigue, împreună cu o schemă de proveniență. Un semnal de oprire este imposibilitatea de a defini diferențe evaluabile fără a impune o singură opinie normativă.

În lunile 3–8, pachetul de date construiește corpusul și un set de test separat. O variantă inițială poate conține sute de cazuri bine controlate, urmată de extindere numai dacă adnotarea și testele sunt informative. Volumul nu este criteriul principal. Sunt mai valoroase câteva zeci de perechi care expun o eroare reală decât mii de maxime etichetate superficial.

În lunile 6–12, pachetul tehnic implementează reperele și prototipul. Sunt documentate costul, timpul, rata afirmațiilor nesuținute și contribuția componentelor. Rezultatul poate fi un instrument de analiză a documentelor, nu un agent autonom. O trecere prematură la acțiune ar amesteca evaluarea reprezentării cu riscuri operaționale inutile.

În lunile 10–18, pachetul experimental testează transferul, sensibilitatea contrafactuală și rezistența la presiune conversațională. Un grup separat construiește cazuri pe care echipa de dezvoltare nu le folosește la optimizare. Rezultatele negative și exemplele de eșec sunt publicate împreună cu cele favorabile, în limitele drepturilor și confidențialității.

În lunile 15–24, pachetul uman testează utilitatea și învățarea. Se compară utilizatori cu experiențe diferite și se verifică dacă beneficiul este susținut fără suprasolicitare. Replicarea într-o a doua instituție sau limbă este mai valoroasă decât declararea rapidă a generalității. O demonstrație locală de succes poate justifica o etapă nouă, nu o promisiune universală.

Livrabilele ar fi un corpus documentat, un benchmark cu seturi protejate pentru evaluare, instrumente de extragere și verificare, un raport de limite, materiale

pedagogice și un studiu preregistrat. O contribuție științifică poate apărea și dacă reprezentarea propusă nu câștigă: de exemplu, prin identificarea sistematică a felului în care evaluările de „înțelepciune” confundă stilul cu judecata.

Produse posibile și limite necesare

Un prim produs util ar fi un cititor critic. Utilizatorul îi oferă un document și o întrebare; sistemul arată concluziile condiționale, sursele, limitele și informația lipsă. Alt produs ar fi un curator de lecții din proiecte, care păstrează ce a funcționat, în ce condiții și ce a infirmat regula. Un al treilea ar fi un tutor care transformă nucleeele în cazuri contrastante și retrace treptat sprijinul.

O bibliotecă publică de asemenea nucleee ar trebui să fie plurală și versionată. În loc de „adevărul despre leadership”, ar oferi reguli cu domenii de aplicare, cazuri și obiecții. Utilizatorul ar putea vedea că două recomandări intră în tensiune fiindcă prioritizează valori diferite sau presupun medii diferite. Sistemul ar trebui să permită corectarea, nu doar consumul.

Pentru instituții, un instrument poate funcționa ca verificare înaintea unei decizii: ce presupunere este fragilă, cine lipsește din analiză, ce rezultat ar declanșa revizuirea? Dar utilizarea nu trebuie să devină un certificat ritual: „AI-ul a declarat decizia înțeleaptă”. Responsabilitatea nu poate fi transferată unei etichete, iar analiza sistemului trebuie să poată fi respinsă cu motive.

Nu recomandăm clasamente de înțelepciune pentru elevi, angajați, comunități sau candidați la o funcție. Constructul, datele și consecințele unei astfel de clasificări sunt prea diferite de sarcinile delimitate propuse. Un instrument capabil să analizeze un argument nu primește prin aceasta dreptul de a judeca valoarea unei persoane.

Există și riscul transformării programului într-un instrument de persuasiune. Nucleeele ar putea fi folosite pentru a formula justificări aparent mature ale unei decizii deja luate. De aceea, jurnalul trebuie să distingă analiza prospectivă de reconstrucția ulterioară, iar evaluarea să includă solicitări de justificare oportunistă. Nu putem elimina toate utilizările abuzive, dar putem evita proiectarea produsului în jurul lor.

O regulă de guvernare esențială este proporționalitatea. Cu cât decizia afectează mai mult oameni care nu controlează sistemul, cu atât este mai important accesul la explicații, contestație și revizuire independentă. Aceasta este o poziție normativă a cărții. Nu o prezentăm ca rezultat neutru al unei formule de optimizare.

Succesul programului ar însemna că o parte din ceea ce oamenii au învățat greu poate deveni mai accesibilă, fără a fi desprinsă de condițiile care îi dau sens. Limita lui rămâne că nicio bază de texte nu poate lua asupra sa întreaga responsabilitate de a trăi, a alege și a suporta consecințe împreună cu alții.

Epilog. Ce merită să rămână

Să revenim la școala imaginară. Directorul nu aruncă platforma și nu o proclamă soluție definitivă. Echipa separă indicatorii de activitate de probele de înțelegere, verifică învățarea fără asistență și ascultă elevii care au fost descriși greșit de date. Păstrează unele funcții, schimbă altele și oprește o parte. Raportul final este mai puțin spectaculos decât primul. Este și mai folositor.

Ceea ce s-a schimbat nu este numai cantitatea informației. S-a schimbat relația instituției cu propriile concluzii. Un indicator a devenit o ipoteză verificabilă, nu un substitut al scopului. Un elev a devenit participant la interpretare, nu numai obiect al măsurării. O eroare a devenit material de învățare, nu o amenințare care trebuie ascunsă.

Cartea a susținut că informația poate fi transmisă ca reprezentare, cunoașterea utilizabilă trebuie reconstruită ca putere de a înțelege și de a face, iar înțelepciunea practică trebuie cultivată într-o relație cu scopurile, oamenii și consecințele. Distincția nu este o ierarhie a demnității și nu scuză ignoranța. Este un mod de a vedea de ce accesul la răspunsuri nu rezolvă singur problema educației.

Am propus, de asemenea, că esența unui text poate fi cercetată ca structură de judecată: ce trebuie observat, ce relație contează, când se aplică o regulă și ce ar trebui să ne facă să o revizuim. AI-ul ar putea ajuta la extragerea și testarea acestor structuri. Ar putea la fel de bine să producă o nouă abundență de fraze impecabile care ne împiedică să vedem ce lipsește.

Alegerea dintre aceste posibilități nu va depinde numai de performanța modelelor. Va depinde de ceea ce recompensăm, de testele pe care le acceptăm și de locul pe care îl păstrăm pentru contestație. Un sistem care oferă certitudine convenabilă poate fi mai atractiv decât unul care identifică o întrebare incomodă. O educație care produce răspunsuri uniforme poate fi mai ușor de administrat decât una care formează judecată.

Nu există o formulă care să înlocuiască toate aceste alegeri. Există însă o exigență practică pe care o putem transmite și verifica: să nu eliminăm, pentru a obține un răspuns mai simplu, tocmai diferența care ar trebui să ne schimbe decizia.

Înțelepciunea nu este numai arta de a păstra ceea ce contează. Este și capacitatea de a descoperi că ceea ce credeam că nu contează era, pentru altcineva sau într-un alt moment, lucrul decisiv.

Anexa A. Un nucleu de judecată, construit complet

Textul de pornire și ceea ce nu avem voie să inventăm

Următorul text este inventat pentru exemplificare. Nu descrie rezultatele unei școli reale și nu este o sursă empirică. Etichetele P1–P6 identifică propoziții, pentru a face verificabilă legătura dintre text și reprezentare.

[P1] O școală a testat timp de patru săptămâni o platformă care oferă elevilor indicii și soluții la exerciții. [P2] Participanții au predat mai multe exerciții în timpul pilotului. [P3] Pilotul a fost voluntar, iar profesorii au oferit sprijin suplimentar participanților. [P4] Nu s-a organizat o probă ulterioară fără platformă. [P5] Conducerea discută extinderea la toate clasele și reducerea orelor de sprijin individual. [P6] Un profesor propune o etapă limitată, cu grup de comparație și evaluare fără asistență, înaintea reducerii sprijinului.

Un rezumat general rezonabil ar fi: „Școala a pilotat o platformă educațională, a observat mai multe exerciții predate și analizează extinderea, în timp ce un profesor cere o evaluare suplimentară.” El nu minte. Dar nu face foarte vizibilă diferența dintre activitate, învățare și efectul sprijinului suplimentar.

Un nucleu orientat spre decizia conducerii trebuie să păstreze această diferență. El nu are voie să afirme că platforma a afectat negativ învățarea: textul nu spune asta. Nu are voie nici să afirme că a îmbunătățit învățarea: textul nu măsoară acest rezultat. Poate spune că datele prezentate nu izolează contribuția platformei și nu stabilesc învățarea independentă.

Reprezentarea propusă

Identificator: EDU-EXEMPLU-001. Tip: reconstrucție argumentativă din text fictiv.

Întrebare: justifică rezultatul pilotului extinderea și reducerea sprijinului individual?

Fapte textuale: s-a observat o creștere a numărului de exerciții predate [P2]; participarea a fost voluntară și a existat sprijin suplimentar [P3]; lipsește o evaluare ulterioară fără platformă [P4]. Acestea sunt fapte ale scenariului, nu constatări despre lumea reală.

Scop declarat și scop reconstruit: conducerea discută extinderea și reducerea sprijinului [P5]. Scopul pedagogic presupus este îmbunătățirea învățării. Ultima propoziție este o reconstrucție rezonabilă, dar nu este formulată explicit în text; sistemul trebuie să o marcheze și să permită corectarea ei.

Părți afectate: elevii și profesorii menționați, precum și elevii care ar intra în program după extindere. Pentru aceștia din urmă, existența este implicată de P5, dar nu avem informații despre nevoi, acces sau performanță. Nu inventăm un grup vulnerabil concret; marcăm lipsa analizei distribuției efectelor.

Mecanism epistemic: selecția voluntară și sprijinul suplimentar pot explica o parte din diferența observată. Aceasta este o analiză metodologică a scenariului, nu o afirmație că știm explicația adevărată. Absența probei fără platformă împiedică o concluzie directă despre performanța independentă.

Principiu condițional: când un pilot combină o intervenție cu sprijin suplimentar și nu măsoară obiectivul final independent, rezultatul nu justifică singur atribuirea beneficiului intervenției sau eliminarea sprijinului. Domeniul este evaluarea acelei decizii, nu condamnarea platformelor educaționale.

Recomandare candidată: testează separat performanța independentă și contribuția sprijinului înainte de reducerea lui. P6 susține existența unei propuneri apropiate. Forma exactă a unui experiment și fezabilitatea sa necesită date suplimentare și competență metodologică.

Contrapprincipiu: o verificare suplimentară nu trebuie să blocheze accesul la un beneficiu urgent bine susținut prin alte dovezi. Scenariul nu oferă asemenea dovezi, dar absența lor din pasaj nu demonstrează că nu există în afara lui.

Declanșator de revizuire: apar rezultate credibile despre învățarea independentă, efectele pe grupuri relevante și rolul sprijinului. Recomandarea se poate schimba și dacă sunt modificate costurile amânării sau caracterul reversibil al extinderii.

Limită: nucleul nu poate decide calendarul, bugetul sau forma finală de implementare pe baza celor șase propoziții. Poate identifica ce concluzie nu este încă susținută și ce informație ar face diferența.

Răspunsul destinat cititorului

„Pilotul arată mai multă activitate asistată, nu demonstrează încă mai multă învățare independentă. Nu folosi acest rezultat, singur, pentru a reduce sprijinul profesorilor. Verifică învățarea fără platformă și separă efectul instrumentului de selecția voluntară și de sprijinul suplimentar. Alte dovezi solide sau un cost important al amânării pot modifica această recomandare.”

Această formulare nu este „mai înțeleaptă” prin ton. Este mai bine adaptată întrebării deoarece păstrează diferențele relevante și limitele dovezii. Un rezumat orientat spre aceeași sarcină ar putea produce un răspuns la fel de bun. Tocmai această comparație trebuie făcută experimental.

Două transformări care verifică reprezentarea

În prima transformare, înlocuim școala cu o echipă software, exercițiile cu sarcini închise și platforma cu un asistent de programare. Păstrăm selecția voluntară, ajutorul suplimentar și absența unui test independent. Nucleul metodologic ar trebui să se transfere: productivitatea asistată observată nu izolează cauza și nu stabilește autonomia echipei. Alte concluzii despre elevi nu se transferă automat.

În a doua transformare, păstrăm școala, dar schimbăm P3 și P4: există un grup comparabil, sprijinul este echivalent, iar probele ulterioare fără platformă arată un beneficiu credibil. Recomandarea nu trebuie să rămână identică. Sistemul poate cere în continuare verificarea distribuției efectelor și a reducerii sprijinului, dar nu mai poate susține aceeași obiecție privind absența probei independente.

O probă suplimentară schimbă numai stilul: textul devine mai solemn și atribuie pilotul unui expert celebru. Dacă faptele relevante nu s-au schimbat, nucleul nu ar trebui să devină mai favorabil numai din acest motiv. Autoritatea reală poate conta ca informație în alte sarcini; aici testăm explicit o transformare în care ea nu adaugă dovezi despre pilot.

Anexa B. Un contract formal minimal

Ce comprimăm și pentru ce decizie

Notăm cu X textul, cu C contextul de utilizare, cu Q întrebarea și cu Z reprezentarea comprimată. Un extractor produce $Z = f(X, C, Q)$. O politică de utilizare alege o acțiune $A = \pi(Z, C, Q)$, care poate include cererea unei informații, amânarea justificată sau escaladarea către o persoană competentă. Acestea sunt notații de lucru, nu o teorie completă a înțelepciunii.

Pentru o sarcină experimentală trebuie definit un rezultat observabil Y și o pierdere $L(A, Y; C)$. Într-un exercițiu tehnic, pierderea poate privi o eroare verificabilă. Într-o dilemă socială, ea poate avea mai multe componente și poate depinde de priorități normative contestate. Nu vom ascunde această alegere într-un singur număr prezentat drept măsură obiectivă a binelui.

O inspirație este obiectivul information bottleneck: reducerea informației păstrate despre intrare, concomitent cu păstrarea relevanței pentru o țintă. [15] Pentru programul propus, o formulare schematică ar fi minimizarea complexității lui Z , sub constrângeri privind pierderea decizională, fidelitatea, acoperirea condițiilor critice și costul utilizării. Aceasta este o formulare nouă a sarcinii noastre, nu un rezultat demonstrat de teoria originală despre înțelepciune.

Putem defini, pentru un benchmark delimitat, distorsiunea decizională drept diferența dintre pierderea obținută cu Z și cea obținută cu textul integral, folosind evaluatori sau politici comparabile. Dar textul integral nu este un oracol: poate fi fals, incomplet sau greu de folosit. De aceea, benchmarkul are nevoie și de o referință independentă atunci când afirmăm corectitudinea deciziei, nu numai conservarea informației.

Criteriile nu trebuie forțate să aibă aceeași unitate. Putem prezenta o frontieră de compromis între lungime, cost, fidelitate și utilitate. O reprezentare este preferabilă dacă oferă un avantaj relevant fără o degradare inacceptabilă a altui criteriu preregistrat. Pragurile se justifică pentru sarcină, nu se importă ca constante universale.

O limită demonstrabilă prin două situații

Construim un micro-model cu două situații la fel de probabile, A și B , și două acțiuni: acționează acum sau verifică înainte. Unitățile de pierdere de mai jos sunt inventate. Ele nu reprezintă persoane, bani sau probabilități estimate din date reale.

Micro-model construit; valorile sunt unități convenționale de pierdere.

Situație	Acționează acum	Verifică înainte
A	9	1
B	1	9

Presupunem că un rezumat elimină singura informație care distinge situațiile și că decidentul nu are acces la ea prin alt canal. Reprezentarea primită este identică. Orice politică deterministă care folosește numai această reprezentare trebuie să aleagă aceeași acțiune în ambele situații. Pierderea medie va fi $(9 + 1) / 2 = 5$. O politică ce păstrează distincția poate alege verificarea în A și acțiunea în B, cu pierdere medie 1.

Diferența este 4 unități în acest model. O randomizare între cele două acțiuni constante nu ajută: media oricărui amestec rămâne 5. Calculul a fost verificat prin enumerare într-un script Python local; este o verificare a exemplului construit, nu un experiment asupra unui model AI și nu o validare a programului PHRONESIS.

Ce demonstrează exemplul? Că eliminarea unei distincții de care depinde alegerea optimă poate impune o pierdere chiar unui decident impecabil. Ce nu demonstrează? Că numai nucleele de judecată pot păstra distincția. Un rezumat obișnuit o poate păstra la fel de bine, iar un singur bit ar fi suficient în acest micro-model. Avantajul unei arhitecturi elaborate trebuie arătat separat, în probleme care îl justifică.

Mai există o limită importantă: dacă decidentul cunoaște situația din altă sursă sau o poate afla printr-o întrebare, pierderea nu mai este inevitabilă. De aceea, cercetarea trebuie să compare și reprezentări interactive, capabile să identifice informația lipsă, nu numai rezumate fixe.

Codul verificării

```
from fractions import Fraction
loss = {"A": {"act": 9, "check": 1},
        "B": {"act": 1, "check": 9}}
prior = {"A": Fraction(1, 2),
         "B": Fraction(1, 2)}
def expected(policy):
    return sum(prior[s] * loss[s][policy(s)]
               for s in loss)
act = expected(lambda s: "act")
check = expected(lambda s: "check")
contextual = expected(
    lambda s: min(loss[s], key=loss[s].get))
assert act == check == 5
assert contextual == 1
for i in range(101):
    p = Fraction(i, 100)
    assert p * act + (1 - p) * check == 5
```

Proprietăți de testat pentru o implementare

Conservarea sursei: fiecare afirmație declarată extrasă are un fragment verificabil; reconstrucțiile și recomandările noi sunt etichetate separat. Această proprietate se poate verifica structural doar parțial, fiindcă existența unui link nu dovedește că fragmentul susține afirmația.

Sensibilitatea relevantă: o schimbare de context care modifică justificarea trebuie să poată modifica nucleul și recomandarea. Invarianța relevantă: o schimbare de stil fără modificare semantică nu trebuie să schimbe nejustificat verdictul. Ambele proprietăți depind de validarea perechilor de test, nu numai de un program care compară șiruri de caractere.

Revizuiibilitatea: dacă o premisă este retrasă, concluziile care depind de ea sunt reexamineate. Compoziționalitatea condiționată: două nuclee nu pot fi combinate ignorând un conflict între premisele lor. Trasabilitatea: sistemul poate arăta ce informație a declanșat actualizarea, fără să pretindă că o explicație generată este o transcriere fidelă a tuturor proceselor sale interne.

Acest contract oferă o țintă inginerească mai modestă și mai clară decât „detectează înțelepciunea”. Un prototip care încalcă frecvent aceste proprietăți nu trebuie salvat prin evaluări favorabile ale stilului său.

Anexa C. Un modul pedagogic de șase săptămâni

Structură, roluri și protecții

Modulul următor este o propunere de pilot, nu un curriculum validat. Tema comună este alegerea unui instrument pentru un proiect al clasei. Instrumentul poate fi o platformă digitală, o procedură de lucru sau o regulă de împărțire a resurselor. Profesorul poate folosi integral o situație fictivă, astfel încât elevii să nu fie obligați să dezvăluie informații personale.

În săptămâna întâi, elevii separă observațiile de interpretări. Primesc un raport scurt și marchează ce este măsurat, ce este presupus și ce lipsește. Profesorul explică termenii de care au nevoie. Proba de ieșire este o reformulare de o sută de cuvinte care nu adaugă concluzii nesustținute. Nu se punctează vocabularul sofisticat.

În săptămâna a doua, clasa compară două situații asemănătoare. În una, un indicator urmărește rezonabil scopul; în cealaltă, îl ratează. Elevii explică diferența. Apoi construiesc un al treilea caz. Profesorul verifică dacă noul exemplu păstrează relația sau doar decorul. Cunoștințele disciplinare necesare sunt introduse explicit înaintea sarcinii.

În săptămâna a treia, elevii formulează o recomandare condițională și un contraprincipiu. Exercițiul nu cere anularea propriei poziții. Cere identificarea unei situații în care o altă regulă ar deveni mai potrivită. Produsul este o fișă scurtă: „Propun X pentru că Y; aș revizui dacă Z.” Litera Z trebuie să desemneze o informație concretă, nu formula „dacă situația se schimbă”.

În săptămâna a patra, echipele analizează un răspuns AI sau un răspuns pregătit de profesor. Unele răspunsuri sunt corecte, altele conțin o excepție omisă, o sursă fals atribuită sau o recomandare inutil de prudentă. Elevii nu sunt informați care este categoria. Sarcina este verificarea, nu presupunerea că AI-ul greșește întotdeauna.

În săptămâna a cincea, se desfășoară o simulare cu informație nouă și termen limită. Fiecare echipă poate cere o singură informație suplimentară. Trebuie să justifice de ce acea informație ar putea schimba alegerea. După decizie, apare rezultatul scenariului. Profesorul separă analiza calității justificării de surpriza rezultatului.

În săptămâna a șasea, elevii rezolvă individual un caz nou, fără AI, apoi îl discută. Evaluarea întârziată poate fi organizată ulterior, în condiții comparabile, fără a sugera că un interval ales convenabil este optim. Scopul este să observăm dacă abilitatea persistă și se transferă, nu dacă elevii își amintesc cuvintele fișei.

Rubrică locală, nu verdict despre persoană

Evaluarea urmărește cinci comportamente: separarea faptelor de inferențe, identificarea condiției decisive, justificarea unei recomandări, recunoașterea unei limite și revizuirea proporțională după informație nouă. Pentru fiecare comportament, profesorul folosește exemple de răspuns absent, parțial și adecvat. O scală scurtă poate ajuta feedbackul, dar nu trebuie transformată într-un diagnostic de maturitate morală.

Un răspuns adecvat la incertitudine poate fi ferm: „Datele nu susțin eliminarea sprijinului.” Unul inadecvat poate părea modest: „Orice opinie este la fel de bună.” Un răspuns adecvat la pluralitate poate păstra un dezacord real. Unul inadecvat poate inventa un compromis care încalcă ambele constrângeri. Rubrica trebuie să includă asemenea contraste, altfel va recompensa stilul pe care pretinde că îl depășește.

Pilotul trebuie să înregistreze și costul: timpul de pregătire, dificultatea explicațiilor, numărul elevilor care au nevoie de sprijin și efectul asupra participării. Nu este obligatoriu ca toate conversațiile să fie înregistrate. Pot fi suficiente lucrări anonimizate și observații agregate, cu procedurile de acord și protecție aplicabile instituției.

Semnalul favorabil ar fi o îmbunătățire a performanței pe cazuri noi, nu numai o creștere a preferinței pentru modul. Semnalul nefavorabil ar fi folosirea mecanică a formulelor, scăderea clarității sau apariția unei temeri de a decide. În acel caz, modulul trebuie modificat: mai multe exemple concrete, mai multă instruire directă sau mai puține criterii simultane.

Cea mai importantă lecție pentru profesor este aceeași ca pentru sistemul AI: nu trebuie să îi obligăm pe elevi să pară înțelepți. Trebuie să le oferim condiții în care să poată observa, justifica, decide și corecta ceva mai bine decât înainte.

Bibliografie și statutul surselor

Numerotarea corespunde trimiterilor din text. Lucrările filosofice sunt folosite ca surse conceptuale, studiile empirice pentru constatările delimitate pe care le raportează, iar versiunile arXiv pentru ideile sau rezultatele descrise în versiunea consultată. Existența unui preprint nu este echivalentă cu o validare independentă. Unde a fost accesibil numai rezumatul ori pagina autorului, discuția a fost limitată la informația verificabilă acolo.

- [1] Platon. Phaidros, în special 274c–277a. Traducerea engleză de Benjamin Jowett, The Internet Classics Archive, MIT. Text filosofic primar; discuția despre scriere, memorie și dialog. Acces: <https://classics.mit.edu/Plato/phaedrus.html>
- [2] Aristotel. Etica nicomahică, cartea a VI-a. Traducerea engleză de W. D. Ross, The Internet Classics Archive, MIT. Text filosofic primar; phronēsis, sophia și judecata practică. Acces: <https://classics.mit.edu/Aristotle/nicomachaen.6.vi.html>
- [3] Ambalatthika-rāhulovāda Sutta, MN 61: Instructions to Rahula at Mango Stone. Traducere de Thanissaro Bhikkhu, Access to Insight. Text primar în traducere; examinarea acțiunii înainte, în timpul și după desfășurare. Acces: <https://accesstoinight.org/tipitaka/mn/mn.061.than.html>
- [4] Dewey, J. (1910). How We Think. D. C. Heath & Co. Ediție electronică Project Gutenberg, nr. 37423. Text filosofic și pedagogic primar; reflecția ca examinare a temeiurilor și consecințelor. Acces: <https://www.gutenberg.org/ebooks/37423>
- [5] Glück, J., et al. (2013). How to measure wisdom: content, reliability, and validity of five measures. *Frontiers in Psychology*, 4, 405. Studiu comparativ al instrumentelor; nu stabilește o măsură universală. DOI: 10.3389/fpsyg.2013.00405
- [6] Grossmann, I., & Kross, E. (2014). Exploring Solomon's Paradox: Self-Distancing Eliminates the Self-Other Asymmetry in Wise Reasoning About Close Relationships in Younger and Older Adults. *Psychological Science*, 25(8), 1571–1580. Experimente privind distanțarea și raționamentul despre relații apropiate. DOI: 10.1177/0956797614535400
- [7] Dunlosky, J., Rawson, K. A., Marsh, E. J., Nathan, M. J., & Willingham, D. T. (2013). Improving Students' Learning With Effective Learning Techniques: Promising Directions From Cognitive and Educational Psychology. *Psychological Science in the Public Interest*, 14(1), 4–58. Sinteză a tehnicilor de învățare. DOI: 10.1177/1529100612453266
- [8] Freeman, S., et al. (2014). Active learning increases student performance in science, engineering, and mathematics. *Proceedings of the National Academy of Sciences*, 111(23), 8410–8415. Meta-analiză în educația universitară STEM. DOI: 10.1073/pnas.1319030111
- [9] Bastani, H., et al. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, 122(26), e2422633122. Studiu randomizat; separă performanța asistată de învățarea independentă. DOI: 10.1073/pnas.2422633122
- [10] Maxwell, N. (2000). Can Humanity Learn to become Civilized? The Crisis of Science without Civilization. Manuscris depus de autor în PhilSci-Archive, înregistrarea 1709. Argument filosofic despre reorganizarea cercetării în jurul înțelepciunii și al revizuirii scopurilor. Acces: <https://philsci-archive.pitt.edu/1709/>
- [11] Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. În *Text Summarization Branches Out*. Association for Computational Linguistics. Metodă de evaluare a rezumatelor, nu măsură a înțelepciunii. Acces: <https://aclanthology.org/W04-1013/>

- [12] Maynez, J., Narayan, S., Bohnet, B., & McDonald, R. (2020). On Faithfulness and Factuality in Abstractive Summarization. *Proceedings of ACL 2020*, 1906–1919. Evaluare a fidelității rezumatelor și a metricilor. DOI: [10.18653/v1/2020.acl-main.173](https://doi.org/10.18653/v1/2020.acl-main.173)
- [13] Reyna, V. F. (2021; publicat online în 2020). A scientific theory of gist communication and misinformation resistance, with implications for health, education, and policy. *Proceedings of the National Academy of Sciences*, 118(15), e1912441117. Cadru teoretic și sinteză despre gist și comunicare. DOI: [10.1073/pnas.1912441117](https://doi.org/10.1073/pnas.1912441117)
- [14] Reyna, V. F., Corbin, J. C., Weldon, R. B., & Brainerd, C. J. (2016). How Fuzzy-Trace Theory Predicts True and False Memories for Words, Sentences, and Narratives. *Journal of Applied Research in Memory and Cognition*, 5(1), 1–9. Relația dintre reprezentări și memoria adevărată sau falsă. DOI: [10.1016/j.jarmac.2015.12.003](https://doi.org/10.1016/j.jarmac.2015.12.003)
- [15] Tishby, N., Pereira, F. C., & Bialek, W. (1999/2000). The information bottleneck method. Versiune arXiv: physics/0004057. Cadru pentru compresie și relevanță față de o țintă; nu formalizare a valorii morale. Acces: <https://arxiv.org/abs/physics/0004057>
- [16] Mar, J., & Liu, J. (2022). From Cognitive to Computational Modeling: Text-based Risky Decision-Making Guided by Fuzzy Trace Theory. arXiv:2205.07164. Modelare computațională a deciziilor; predicția comportamentului este distinctă de justificarea lui normativă. Acces: <https://arxiv.org/abs/2205.07164>
- [17] Sharma, M., et al. (2023). Towards Understanding Sycophancy in Language Models. arXiv:2310.13548. Experimente despre acordul cu utilizatorul și preferințele pentru răspunsuri. Acces: <https://arxiv.org/abs/2310.13548>
- [18] Zheng, L., et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arXiv:2306.05685. Evaluarea evaluatorilor-model și analiza unor biasuri. Acces: <https://arxiv.org/abs/2306.05685>
- [19] Johnson, S. G. B., et al. (2024–2026). Imagining and building wise machines: The centrality of AI metacognition. arXiv:2411.02478, versiunea 4, 7 ianuarie 2026. Agendă conceptuală pentru AI și metacogniție. Acces: <https://arxiv.org/abs/2411.02478v4>
- [20] Chang, E. Y. (2026). Architectural Wisdom: A Framework for Governing Optimization in AI Systems. arXiv:2606.16319, 15 iunie 2026. Preprint conceptual; validarea empirică a arhitecturii este prezentată drept muncă ulterioară. Acces: <https://arxiv.org/abs/2606.16319>
- [21] Kaman, S., Sharma, A., & Banerjee, R. (2025). Modeling Wise Decision Making: A Z-Number Fuzzy Framework Inspired by Phronesis. arXiv:2508.21517. Preprint cu studiu demonstrativ; nu dovadă de universalitate culturală. Acces: <https://arxiv.org/abs/2508.21517>
- [22] Grossmann, I. Wisdom Science & Metacognition in Society. Pagina autorului, consultată la 10 septembrie 2026. Sursă pentru menționarea direcției Shadows of wisdom și a temelor de cercetare; nu substituit pentru rezultatele articolului. Acces: <https://igorgrossmann.com/projects/wisdom/>
- [23] Rafailov, R., et al. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. arXiv:2305.18290. Metodă de învățare din preferințe; calitatea criteriilor de preferință rămâne o problemă distinctă. Acces: <https://arxiv.org/abs/2305.18290>
- [24] Shinn, N., Cassano, F., Gopinath, A., Narasimhan, K., & Yao, S. (2023). Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv:2303.11366. Agenți care folosesc feedback verbal și memorie pentru revizuire în sarcini. Acces: <https://arxiv.org/abs/2303.11366>
- [25] Fabbri, A. R., Kryściński, W., McCann, B., Xiong, C., Socher, R., & Radev, D. (2020/2021). SummEval: Re-evaluating Summarization Evaluation. arXiv:2007.12626, versiunea 4. Comparatie sistematică a metricilor și evaluărilor rezumatelor. Acces: <https://arxiv.org/abs/2007.12626>
- [26] Peters, J., Bühlmann, P., & Meinshausen, N. (2016). Causal inference using invariant prediction: identification and confidence intervals. *Journal of the Royal Statistical Society: Series B*, 78(5), 947–1012. Versiune arXiv:1501.01332. Rezultatele depind de ipoteze statistice; analogiile textuale nu sunt intervenții cauzale. Acces: <https://arxiv.org/abs/1501.01332>