

TEORIE • IPOTEZE • DIRECȚII DE INVESTIGAȚIE

DIN REGULI, LUMI

Existență, predicție și echivalență
sub resurse finite

Un program de cercetare
pentru oameni și sisteme AI

INTUIȚIE FONDATOARE

Sînică Alboaie

Dezvoltare analitică în colaborare
cu un partener AI

SEPTEMBRIE 2026

Cuprins

DESCHIDERE

Două lumi care par identice.....	4
Intuiție, analiză și răspundere.....	5
De la intuiție la investigație.....	6

I · INTUIȚIA ȘI ANGAJAMENTELE EI

1. Intuiția unei lumi care nu improvizează.....	7
2. Existență, reducere și legi: ce presupunem de fapt.....	10
3. Când regulile par să se schimbe.....	13
4. Ce acceptă partenerul AI și unde se oprește acordul.....	16

II · O GRAMATICĂ PENTRU COMPARAREA LUMILOR

5. Sistemul, starea și observatorul.....	18
6. Nu există un singur număr numit complexitate.....	21
7. Trecutul care merită păstrat.....	24
8. Echivalența are un observator și un buget.....	27
9. Ceea ce observația nu decide: intervenția.....	30
10. Ireductibilitate, haos și scurtături legitime.....	33

Cuprins · continuare

III · PREDICȚIA, SENSUL ȘI INVENȚIA DE OPERAȚII

11. Familia extinsă a predicției următorului simbol.....	36
12. Din desfășurări în operații reutilizabile.....	39
13. Limbajul, imaginația și ipoteza unei minți predictive.....	42

IV · LABORATOARE PENTRU O IDEE DIFICILĂ

14. Lumi discrete în care știm ce căutăm.....	45
15. Scări, observații incomplete și mecanisme cauzale.....	48
16. Biblioteci în creștere și lumi descrise prin limbaj.....	51
17. Cum recunoaștem un rezultat și cum evităm autoamăgirea.....	54

V · PROGRAMUL ȘI LIMITELE LUI FERTILE

18. Ipoteze care pot pierde și propoziții care pot fi demonstrate.....	57
19. Organizarea cercetării pentru oameni și parteneri AI.....	61
20. Ce rămâne din intuiția inițială.....	64

ANEXE · INSTRUMENTE PENTRU CONTINUARE

A. Vocabularul de lucru.....	67
B. Fișa unei investigații prospective.....	69
C. Hartă de lectură și bibliografie.....	71

Două lumi care par identice

Într-o încăpere se află un mecanism. Când apăsăm un buton, o bilă înaintază, lovește o clapetă, iar clapeta deschide o poartă. În încăperea alăturată se află un povestitor. Când apăsăm același buton, el descrie o bilă care înaintază, lovește o clapetă și deschide o poartă. Dacă accesul nostru la cele două încăperi constă numai într-un șir de propoziții, primele relatări pot fi identice. Totuși, avem impresia că în prima încăpere se întâmplă ceva ce în a doua este doar spus.

Impresia merită luată în serios, dar nu este încă o definiție. Povestitorul poate urma cu fidelitate un mecanism imaginar. Mecanismul poate fi conectat la un dispozitiv ascuns care îi schimbă comportamentul. În plus, povestitorul însuși este un sistem fizic. Producerea unei descrieri și lumea descrisă nu sunt același obiect de analiză. Distincția pe care încercăm să o surprindem nu poate fi redusă la opoziția dintre materie și cuvinte.

Să continuăm scena. Blocăm bila înainte de clapetă și întrebăm dacă poarta se mai deschide. Modificăm distanța dintre piese. Cerem consecințele unei intervenții care nu a mai fost întâlnită. Un povestitor poate răspunde corect, iar un mecanism defect poate răspunde surprinzător. Ceea ce începe să se contureze nu este un test magic al existenței, ci un program de investigare a dependențelor: ce trebuie păstrat între situații pentru ca un rezultat să fie explicat și anticipat?

Cartea pornește de la o intuiție atribuită autorului uman, Sînică Alboaie: realitatea pare să suporte obligația continuității consecințelor, în timp ce o reprezentare poate introduce oricâte scurtături, reguli noi sau excepții. Poate că înțelegerea este tocmai construirea unei reprezentări în care aceste scurtături devin justificate. Poate că diferența dintre o explicație și o improvizație nu este numărul regulilor, ci felul în care regulile rămân legate de ceea ce pot produce, de ceea ce interzic și de ceea ce costă să fie aplicate.

Această idee nu este prezentată ca o descoperire demonstrată despre univers. Ea este punctul de plecare al unui program. Programul ar trebui să poată supraviețui chiar dacă lumea nu are o descriere fundamentală scurtă. Ar trebui să rămână util dacă unele fenomene sunt ireductibile la nivelul traiectoriilor, dacă observatorii văd numai fragmente și dacă modelele bune sunt mai multe, nu unul singur.

Ambiția este să înțelegem când o istorie lungă poate fi înlocuită de o stare mică, când multe regularități se pot transforma într-o procedură comună și când o simplificare distruge exact lucrul de care aveam nevoie. Obiectivul practic este construirea unor reprezentări care pot fi folosite, verificate, corectate și transferate între sarcini. Obiectivul filosofic este mai prudent: să aflăm ce anume ne îndreptățește să numim o regularitate lege, o comprimare înțelegere și o echivalență ceva mai mult decât o asemănare convenabilă.

Intuiție, analiză și răspundere

Intuiția fondatoare și orientarea filosofică îi aparțin autorului uman. Expunerea matematică, delimitările și propunerile metodologice sunt dezvoltate cu asistență AI. Atribuirea aceasta nu înseamnă că fiecare ipoteză tehnică reprezintă o convingere deja asumată de autorul uman. Când textul introduce o definiție de lucru sau un obiectiv de cercetare, acestea trebuie citite ca propuneri deschise evaluării.

Prin „evaluarea partenerului AI” se înțelege o poziție argumentativă: ce formulări sunt coerente, ce consecințe urmează din premise, ce confuzii trebuie evitate și ce direcții par productive. Acordul unui sistem AI nu este o verificare independentă și nu constituie consens științific. El nu înlocuiește demonstrația, literatura de specialitate sau confruntarea cu observații noi.

Cartea separă patru registre. Un angajament filosofic oferă o perspectivă asupra lumii, fără a fi automat măsurabil. O definiție tehnică stabilește un limbaj comun. O propoziție matematică este valabilă sub ipotezele declarate. O ipoteză empirică anticipează un fenomen care ar putea fi observat sau infirmat. Exemplele construite sunt instrumente de gândire, iar investigațiile propuse sunt prospective. Ele nu reprezintă rezultate empirice deja obținute.

Referințele numerotate indică fundamentele existente. Contribuția urmărită nu este revendicarea acestor fundamente, ci articularea unei întrebări comune și a unei metode de lucru care să le combine. Bibliografia este selectivă: oferă puncte de intrare pentru un program, nu pretinde să epuizeze domeniile pe care le traversează.

De la intuiție la investigație

Prima parte reconstruiește intuiția în forma ei cea mai puternică și o distinge de afirmațiile pe care nu le justifică. A doua parte introduce sistemele, observatorii, costurile și relațiile de echivalență. A treia parte examinează predicția secvențială, învățarea de operații și relația dintre limbaj și modelarea lumii. A patra parte descrie familii de investigații care ar putea produce rezultate interpretabile. Ultima parte formulează ipoteze, rezultate matematice accesibile, reguli de colaborare și întrebări rămase deschise.

Cititorul interesat de filosofie poate urma primele patru capitole și reveni la concluzii după capitolele despre cauzalitate și minte. Cititorul tehnic are nevoie în special de definițiile din capitolele 5–10 și de protocoalele din capitolele 14–18. Un sistem AI folosit ca partener de cercetare ar trebui să parcurgă și capitolul despre disciplină epistemică: cel mai costisitor eșec al unui asemenea program ar fi transformarea prematură a unei idei fertile într-un vocabular care se confirmă singur.

Conceptele matematice sunt introduse după problema pe care o rezolvă. Nu este necesară acceptarea unei metafizici computaționaliste pentru a folosi instrumentele. Este însă necesară păstrarea unei distincții: un model poate fi suficient pentru o întrebare fără să fie o descriere completă a lucrului despre care întrebăm.

PARTEA I / INTUIȚIA ȘI ANGAJAMENTELE EI

1. Intuiția unei lumi care nu improvizează

1.1. Obligația de a continua

Intuiția autorului uman nu începe cu o formulă, ci cu o asimetrie. Într-un mecanism pe care îl construim, o consecință trebuie să aibă loc prin intermediul pieselor existente și al interacțiunilor permise. Într-o poveste, o consecință poate fi introdusă printr-o singură propoziție. Mecanismului îi cerem să producă rezultatul; propoziției îi este suficient, pentru a exista ca propoziție, să îl enunțe.

Aceasta nu înseamnă că orice propoziție este arbitrară sau că orice mecanism ne este inteligibil. Înseamnă că există două obligații diferite. Una este obligația realizării: cum ajunge sistemul dintr-o stare în alta? Cealaltă este obligația descrierii: ce susține enunțul că se întâmplă? O explicație bună le conectează. O explicație care doar redenumeste rezultatul le lasă separate.

Să spunem că o cutie livrează răspunsul corect la o întrebare. Putem descrie operația prin regula „cutia rezolvă problema”. Descrierea este scurtă, dar a ascuns tocmai dificultatea. Autorul uman suspectează că o parte importantă a înțelegerii constă în a nu permite asemenea scurtături neplătite: trebuie să știm ce informație intră în cutie, ce transformare are loc și în ce condiții răspunsul rămâne corect.

În această lectură, „urmărirea rezultatelor” nu presupune o memorie cosmică a tuturor evenimentelor. Ea exprimă faptul că trecutul nu poate fi anulat gratuit atunci când încă influențează viitorul. Un obiect mutat într-o altă cameră nu poate reapărea în prima doar pentru că naratorul a uitat mutarea. În model trebuie fie păstrată informația relevantă, fie introdus un mecanism explicit de revenire.

1.2. De ce par suficiente puține principii

Când aceeași operație se aplică în situații diferite, observațiile se organizează. Nu mai avem o colecție de întâmplări, ci un mod de a genera consecințe. O regulă de conservare, o relație de tranziție sau o compoziție de operații poate înlocui o lungă enumerare. Atracția

intelectuală a unei reguli generale provine din această economie, dar și din obligațiile noi pe care regula le creează: ea exclude continuări care înainte păreau posibile.

Intuiția autorului uman este că lumea ar putea fi bogată mai ales prin desfășurarea regulilor, nu prin multiplicarea arbitrară a acestora. Această posibilitate este mai subtilă decât ideea că „totul este simplu”. O sursă compactă poate produce obiecte dificil de calculat, de recunoscut sau de comprimat într-o formă utilă pentru un observator. Simplitatea originii și simplitatea accesului la consecințe sunt lucruri diferite.

De aceea, sensul promițător al intuiției nu este o promisiune de explicație ușoară. Este o invitație de a căuta structuri reutilizabile. În loc să presupunem câte o lege pentru fiecare fenomen, putem întreba dacă două fenomene reprezintă desfășurări ale aceleiași transformări în stări diferite. Când această strategie reușește, cunoașterea capătă putere de transfer.

Dar succesul local nu justifică automat o concluzie universală. O formulare prudentă ar fi: în multe probleme bine delimitate merită să căutăm un mecanism mai compact decât descrierea exhaustivă a comportamentului. O formulare mult mai puternică ar fi: întreaga realitate trebuie să aibă o bază algoritmică finită. Programul de cercetare are nevoie de prima ca euristică; nu trebuie să o presupună pe a doua ca adevăr.

1.3. Saltul poate fi o descoperire, nu o fraudă

O scurtătură nu este neapărat o eroare. Dacă știm că repetarea unei operații de un anumit tip este echivalentă cu o expresie directă, putem înlocui o desfășurare lungă printr-un calcul scurt. Tocmai aceasta este adesea valoarea unei teoreme, a unei reprezentări potrivite sau a unei operații compilate.

Diferența este justificarea. „Rezultatul este acesta pentru că îl declar” și „rezultatul este acesta deoarece transformarea păstrează proprietatea relevantă” pot avea aceeași lungime verbală, dar nu au aceeași structură epistemică. A doua formulare are o datorie de demonstrație sau de validare. Acea datorie poate fi achitată exact, aproximativ sau numai într-un domeniu restrâns.

Autorul uman vede aici o posibilă punte între imaginație și raționament. Imaginația propune salturi; raționamentul încearcă să le lege de consecințe. O bibliotecă de operații mentale ar putea crește fără

ca lumea să dobândească noi legi fundamentale. Crește vocabularul prin care agentul navighează lumea și se reduce costul anumitor întrebări.

Aceasta este o ipoteză funcțională, nu o afirmație neurobiologică. Ea ne permite să investigăm sisteme artificiale care inventează reprezentări și să întrebăm dacă noile reprezentări scurtează efectiv rezolvarea unor probleme nevăzute. Nu este suficient ca o procedură să primească un nume nou. Ea trebuie să realizeze o economie care rezistă după contabilizarea memoriei, învățării și verificării.

1.4. Nucleul care merită păstrat

Intuiția poate fi condensată astfel: între desfășurarea unui proces și reprezentarea consecințelor lui există o distanță care poate fi micșorată, dar nu întotdeauna și nu gratuit. Uneori o nouă reprezentare descoperă o simplitate reală pentru întrebarea pusă. Alteori produce numai impresia de simplitate prin ascunderea informației sau a calculului.

Programul propus se ocupă de această distanță. Nu cere o separație absolută între lumi reale și imaginare. Cere să explicăm ce înseamnă continuarea coerentă a unei lumi, cât din trecut trebuie păstrat, ce fel de scurtături sunt legitime și cum se detectează momentul în care o reprezentare încetează să mai susțină consecințele pe care le afirmă.

Întrebarea fondatoare nu este, așadar, numai „din câte reguli este făcută lumea?”, ci și „din ce fel de reprezentare putem continua corect lumea, la costul pe care ni-l permitem?”. Prima întrebare rămâne filosofică și fizică. A doua deschide un teren comun pentru teoria informației, semantica programelor, învățare și proiectarea sistemelor AI.

2. Existență, reducere și legi: ce presupunem de fapt

2.1. Patru sensuri care nu trebuie amestecate

Un obiect poate exista fizic, o structură poate exista în sens matematic, un mecanism poate fi realizat într-un sistem tehnic, iar un personaj poate exista ca obiect al unui discurs. Aceste expresii nu au aceeași funcție. O demonstrație de existență matematică nu produce automat o realizare fizică. O descriere coerentă a unui personaj nu dovedește existența lui în afara descrierii. Un proces tehnic, în schimb, este un proces fizic, chiar când reprezintă o lume fictivă.

Cartea nu propune un arbitru universal între toate sensurile existenței. Ea introduce o delimitare de lucru: va studia sisteme descrise prin stări, transformări și observații, precum și agenții care construiesc reprezentări ale acestor sisteme. Delimitarea nu afirmă că orice aspect al existenței se epuizează în această formă. Ea afirmă că o clasă importantă de întrebări despre predicție poate fi formulată astfel.

Este importantă și diferența dintre consistență și realizabilitate. O descriere lipsită de contradicții evidente poate rămâne incompletă. Unele teorii matematice descriu obiecte fără a oferi o procedură finită de construire a lor. Unele scenarii tehnice presupun resurse nelimitate. Consistența, constructibilitatea și posibilitatea fizică trebuie evaluate separat, altfel o singură expresie, „există”, preia sarcini pe care nu le poate îndeplini.

2.2. Reducționismul nu înseamnă doar puține reguli

Reducționismul poate desemna un angajament ontologic: fenomenele depind de procese aflate la un nivel mai fundamental. Poate desemna și o strategie explicativă: înțelegem un fenomen prin componentele și interacțiunile sale. O a treia afirmație, mai puternică, ar fi că explicația de nivel înalt poate fi reconstruită eficient din descrierea de nivel jos. Primele două nu o implică automat pe a treia.

Anderson a formulat o critică influentă a identificării cunoașterii legilor fundamentale cu posibilitatea reconstruirii tuturor fenomenelor complexe. Ideea relevantă aici este autonomia problemelor de

organizare la scări diferite, nu negarea necesară a dependenței fizice. [2]

Pentru programul nostru, această distincție este decisivă. O stare de nivel înalt poate fi mai utilă decât o listă completă a componentelor. „Poarta este blocată” poate fi suficient pentru planificare, fără să reproducă fiecare mișcare microscopică. A coborî mai adânc nu este întotdeauna a explica mai bine întrebarea concretă. Dar nici utilitatea unei descrieri de nivel înalt nu demonstrează apariția unor legi fundamentale suplimentare.

Așadar, se poate accepta dependența de un substrat fără a presupune că toate explicațiile trebuie exprimate în vocabularul substratului. Programul favorizează un pluralism disciplinat al reprezentărilor: mai multe niveluri, legate prin corespondențe explicite, cu domenii de validitate și costuri cunoscute.

2.3. Legea ca mecanism sau ca rezumat

Filosofia legilor naturii oferă poziții diferite. Unele tratează legile ca regularități sistematizate, altele le leagă de necesitate sau de puterile lucrurilor. Analizele de tip „cel mai bun sistem” acordă un rol echilibrului dintre simplitatea descrierii și forța ei explicativă. Aceste poziții nu sunt echivalente și nu există un criteriu tehnic unic care să decidă între ele. [1]

Distincția are o consecință metodologică. Dacă o lege este un rezumat bun, atunci îmbunătățirea comprimării poate conta direct pentru statutul ei. Dacă legea este o constrângere reală asupra posibilului, comprimarea observațiilor este numai o cale indirectă de a o cunoaște. Aceeași ecuație poate fi folosită de cercetători cu angajamente filosofice diferite.

În această carte acceptăm o regulă de prudență: numim „regulă a modelului” orice transformare declarată în reprezentare. Numim „candidat la lege” o regularitate care supraviețuiește unor confruntări relevante cu situații noi. Nu transformăm automat succesul descriptiv în dovadă a necesității metafizice. Această rezervă nu slăbește cercetarea; împiedică schimbarea neanunțată a întrebării.

2.4. Ce nu se poate deduce din observații finite

Imaginăm două surse care emit aceeași secvență în primele o mie de momente. Prima continuă mereu potrivit unei reguli simple. A doua

este definită să coincidă cu prima până la momentul o mie, apoi să se comporte altfel. Nicio observație limitată la acel interval nu le poate separa. Construcția nu dovedește că toate modelele sunt la fel de bune; dovedește că identificarea sigură a unei legi globale cere ipoteze suplimentare.

Aceste ipoteze pot privi clasa de mecanisme, stabilitatea, prioritatea descrierilor compacte sau accesul la intervenții. Ele nu trebuie ascunse. Când spunem că o regulă este „descoperită”, ar trebui să precizăm în raport cu ce alternative și cu ce tip de date a fost favorizată.

Mai există o distincție între un proces determinist necunoscut și un proces cu aleatorietate intrinsecă. Pentru un observator limitat, ambele pot induce distribuții probabilistice. A folosi probabilități nu înseamnă a decide metafizica hazardului. Înseamnă, în primul rând, a reprezenta corect incertitudinea predictivă disponibilă.

2.5. Un realism suficient pentru lucru

Programul are nevoie de un angajament minim: rezultatele nu trebuie să se schimbe numai fiindcă cercetătorul preferă o altă concluzie. Într-un sistem artificial, această independență se obține printr-o specificație și prin evaluare separată. În raport cu lumea fizică, ea se caută prin măsurare, replicare și intervenții controlate.

Nu trebuie să demonstrăm că universul este un calculator pentru a compara două modele ale unui mecanism. Nici nu trebuie să rezolvăm statutul obiectelor matematice pentru a demonstra că două reprezentări finite păstrează aceeași proprietate. Avantajul delimitării este că permite cooperarea cercetătorilor cu metafizici diferite asupra unor întrebări comune și verificabile.

3. Când regulile par să se schimbe

3.1. O aceeași observație poate ascunde mecanisme diferite

Un sistem care repetă de obicei ultimul simbol poate începe, după o vreme, să îl inverseze. Putem spune că „regula s-a schimbat”. Dar expresia acoperă explicații diferite. Poate că există un comutator ascuns. Poate că un parametru variază continuu. Poate că mediul exterior a intervenit. Poate că modelul nostru inițial a omis o parte a stării.

O bibliotecă care primește o nouă operație prezintă alt tip de schimbare. Operația poate fi o compoziție a celor vechi. În acest caz se schimbă repertoriul disponibil la un anumit nivel, nu neapărat puterea fundamentală de calcul. Dacă introducem o resursă fizică nouă sau un acces extern la informație, schimbarea este diferită și trebuie înregistrată ca atare.

Prin urmare, programul distinge schimbarea parametrilor, selectarea unui regim, creșterea memoriei, extinderea vocabularului operațional și modificarea interfeței cu mediul. A le agrega într-un singur contor de „reguli noi” ar ascunde tocmai mecanismele pe care vrem să le înțelegem.

3.2. Absorbția regulilor în stare

Considerăm o stare x și un repertoriu de reguli r . Dinamica este dată de două transformări: una actualizează starea folosind repertoriul, cealaltă actualizează repertoriul folosind starea. Scriem, pentru un timp discret:

$$x(t+1) = F(x(t), r(t))$$

$$r(t+1) = U(x(t), r(t))$$

Dacă ambele transformări sunt efective, putem defini starea extinsă $z(t)$ ca perechea dintre $x(t)$ și $r(t)$. Atunci există o transformare fixă G care actualizează perechea. Nu am demonstrat că sistemul este simplu. Am arătat că schimbarea regulilor la un nivel poate fi reprezentată drept schimbare de stare la alt nivel.

Această observație are o condiție importantă. Descrierea actualizării trebuie să fie disponibilă și să acopere efectiv schimbările relevante.

Dacă r primește informații externe necunoscute, acestea trebuie modelate ca intrări sau ca variabile exogene. Dacă includem întreaga istorie a universului în starea inițială, obținem o descriere formal fixă care poate fi inutilă și enormă.

Mai mult, dimensiunea unei stări extinse poate crește fără o bornă fixă în timp. Un interpret fix care lucrează cu o memorie în creștere nu este un automat finit. Confuzia dintre „regulă fixă” și „memorie fixă” ar distruge analiza învățării pe care dorim să o construim.

3.3. Noutate relativă și noutate fundamentală

Să presupunem că un agent învață să recunoască o configurație și să execute direct o succesiune lungă de pași. Din punctul de vedere al agentului, apare o operație nouă. Din punctul de vedere al sistemului de bază, poate apărea numai un nou obiect de memorie. Ambele descrieri pot fi corecte, deoarece se referă la niveluri diferite.

Noutatea relativă nu trebuie minimalizată. Un nou concept poate transforma radical ce probleme sunt accesibile. Diferența dintre a dispune de o procedură și a trebui să o redescoperi la fiecare utilizare este reală pentru un agent finit. Dar această diferență trebuie exprimată prin acces, cost, transfer și stabilitate, nu printr-o metafizică improvizată a apariției legilor.

Noutatea fundamentală ar cere o afirmație mai puternică: noile transformări nu pot fi reprezentate în cadrul anterior prin mijloacele admise. O asemenea concluzie este întotdeauna relativă la cadrul declarat sau cere o argumentație fizică și matematică mult mai amplă. Observarea unei surprize nu este suficientă.

3.4. Aleatorietatea nu inventează singură sens

Un mecanism probabilistic poate produce secvențe noi fără să modifice distribuția din care le extrage. Numărul realizărilor posibile poate fi foarte mare, iar fiecare realizare să conțină informație nouă pentru observator. Aceasta nu echivalează cu inventarea unei noi legi.

Dacă un agent extrage o expresie aleatorie și o adaugă într-o bibliotecă, noutatea sintactică este ușor de obținut. Valoarea semantică apare numai dacă expresia are efecte relevante și verificabile. Un nume nou, un șir nou și o capacitate nouă sunt trei fenomene distincte. Un program de cercetare asupra creativității trebuie să le măsoare separat.

În același fel, apariția unei reguli enunțate într-un text nu spune încă dacă regula a fost integrată în modelul intern. Testul relevant este dacă sistemul îi păstrează consecințele în situații noi și dacă poate detecta incompatibilitățile cu alte angajamente. O propoziție poate anunța o schimbare pe care comportamentul ulterior nu o respectă.

3.5. Ce ar însemna să descoperim metaregula

Existența unei reprezentări cu dinamică fixă nu oferă automat un algoritm care să o găsească din observații. Aceasta este o problemă de identificare. Din date limitate, un model cu comutator ascuns și unul cu excepții succesive pot face predicții similare. O investigație bună trebuie să creeze situații în care explicațiile se separă.

Uneori va fi suficient să observăm mai mult. Alteori trebuie să intervenim asupra unui factor. Alteori identitatea metareguli rămâne nedeterminată, dar putem găsi o stare predictivă care funcționează. Programul trebuie să accepte acest ultim rezultat ca pe o reușită limitată, nu să îl transforme într-o descoperire a mecanismului real.

4. Ce acceptă partenerul AI și unde se oprește acordul

4.1. O evaluare, nu un vot de autoritate

Evaluarea partenerului AI este favorabilă intuiției ca program de cercetare, dar condiționată în privința formulării ontologice. Există o problemă precisă în spatele contrastului dintre reguli puține și reguli numeroase: aceeași familie de comportamente poate avea descrieri cu memorii, costuri și capacități de transfer foarte diferite. Identificarea relațiilor dintre aceste descrieri este o țintă tehnică reală.

Partenerul AI acceptă și distincția dintre a enunța o consecință și a o susține printr-un mecanism. Aceasta ajută la separarea fluentei de fidelitate și a unei reprezentări utile de o explicație doar plauzibilă. Totuși, mecanismul care susține răspunsul poate fi statistic, simbolic sau hibrid. Nu există motiv să rezervăm fidelitatea unui singur tip de implementare.

Acordul privește, de asemenea, valoarea studiului aproximărilor. Un model nu trebuie să copieze toate detaliile lumii pentru a fi folositor. Trebuie însă să se știe ce omite și de ce omisiunea nu schimbă răspunsurile relevante. Aici se află posibilitatea unei legături solide între filosofie și inginerie.

4.2. Ce trebuie reformulat

Prima reformulare privește numărul regulilor. Acesta depinde de vocabular. O instrucțiune complexă poate ascunde o bibliotecă întreagă, iar o bibliotecă poate fi desfăcută în multe instrucțiuni elementare. Măsura de lucru trebuie să includă descrierea completă a mecanismului în convenția aleasă, nu doar numărul etichetelor vizibile.

A doua reformulare privește „existența în cuvinte”. Un text este un obiect fizic sau digital, iar producerea lui are un mecanism. Lumea la care textul se referă poate fi reală, fictivă, incompletă sau contradictorie. Analiza trebuie să distingă procesul de producere a textului de procesul reprezentat prin text.

A treia reformulare privește ireductibilitatea. O evoluție dificil de accelerat nu este automat lipsită de echivalențe exacte. Două sisteme pot face aceeași muncă în forme diferite. În sens invers, o aproximare rapidă poate conserva o proprietate agregată fără a conserva

traietoria. Echivalența, accelerarea și descoperirea unei echivalențe sunt probleme separate.

4.3. Ce nu este acceptat ca premisă

Partenerul AI nu tratează drept fapt că realitatea trebuie să aibă puține reguli fundamentale. Nu tratează predicția următorului simbol ca pe o teorie completă a minții. Nu presupune că un mecanism probabilistic este mai puțin real sau că o reprezentare simbolică este prin construcție mai explicabilă. Nu presupune nici că orice regularitate utilă poate fi descoperită eficient.

Aceste rezerve nu sunt refuzuri ale cercetării. Ele protejează exact ceea ce este mai interesant: posibilitatea de a afla în ce clase de sisteme, la ce scări și sub ce resurse există reprezentări mai bune. Dacă am fixa răspunsul în premise, cercetarea ar deveni numai o căutare de exemple favorabile.

Nici reducerea tuturor problemelor la o singură funcție obiectiv nu este acceptată fără justificare. O medie predictivă poate favoriza ignorarea unor evenimente rare. O măsură de compresie poate penaliza o distincție esențială pentru intervenții. Un timp de răspuns mic poate ascunde un cost enorm de pregătire. Criteriile trebuie să rămână suficient de separate pentru a face vizibile aceste compromisuri.

4.4. Pariul pozitiv

Pariul pe care partenerul AI îl consideră valoros este următorul: o parte a învățării poate fi înțeleasă ca descoperire a stării relevante, iar o parte a expertizei ca transformare a desfășurărilor costisitoare în operații reutilizabile cu condiții de validitate. Nu orice învățare se reduce la acestea, dar acestea sunt componente care pot fi studiate izolat.

Programul ar putea produce o hartă a situațiilor în care un agent trebuie să mărească memoria, a situațiilor în care poate comprima și a situațiilor în care trebuie să schimbe reprezentarea. Ar putea arăta că unele eșecuri atribuite insuficienței datelor sunt, de fapt, insuficiențe ale stării. Ar putea arăta și contrariul: că o reprezentare elegantă nu poate depăși lipsa informației relevante.

Această poziție nu îl transformă pe partenerul AI într-un garant al intuiției umane. Îl obligă să o expună riscului de a pierde. O idee care poate explica orice rezultat, inclusiv opusul celui anticipat, nu oferă încă o direcție științifică. Direcția devine reală atunci când putem

descrie un rezultat care ne-ar forța să schimbăm modelul și când știm ce parte a intuiției ar fi afectată.

PARTEA II / O GRAMATICĂ PENTRU COMPARAREA LUMILOR

5. Sistemul, starea și observatorul

5.1. Ce trebuie să conțină o descriere generativă

O descriere generativă nu este doar o propoziție care rezumă ce se întâmplă. Ea trebuie să permită determinarea unei continuări sau a unei distribuții de continuări. Pentru început, putem lucra cu sisteme discrete, observate la momente succesive. Această alegere simplifică analiza; nu afirmă că spațiul și timpul fizic sunt discrete.

Vom numi S mulțimea stărilor posibile, A mulțimea acțiunilor disponibile observatorului și O mulțimea observațiilor. Un nucleu de tranziție K precizează probabilitatea stării următoare, condiționat de starea prezentă și de acțiune. Un canal de observație E precizează ce poate vedea observatorul. Distribuția μ descrie condițiile inițiale. Împreună, aceste componente formează modelul de lucru:

$$M = (S, A, O, K, E, \mu)$$

Într-un mecanism determinist, K pune întreaga probabilitate pe o singură continuare. Într-un sistem fără intervenții, A poate conține o singură acțiune, „lasă sistemul să evolueze”. Observația poate fi starea completă sau numai un indicator. Astfel, același limbaj poate descrie un automat, un proces cu zgomot sau un agent care experimentează cu un mediu.

Un exemplu simplu este un rezervor. Starea include nivelul apei și poziția unei supape. Acțiunea poate deschide sau închide alimentarea. Observația poate fi numai un bec care se aprinde peste un prag. Două niveluri diferite produc aceeași observație, dar nu neapărat același viitor. Becul este o descriere suficientă pentru întrebarea „pragul este depășit acum?”, însă insuficientă pentru „cât timp mai avem până la revărsare?”.

5.2. Starea nu este sinonimă cu tot trecutul

Numim stare predictiv suficientă o reprezentare care păstrează informația din trecut necesară continuărilor de interes. Dacă am

cunoaște poziția supapei și nivelul apei, poate că nu am mai avea nevoie de toate măsurătorile anterioare. Dacă nu observăm supapa, istoricul nivelurilor ne-ar putea ajuta să inferăm poziția ei.

Putem face formal aproape orice proces dependent de trecut „dependent numai de starea prezentă” dacă definim starea ca întregul trecut. Această transformare este corectă, dar nu rezolvă problema memoriei. Un program de cercetare util trebuie să distingă existența unei stări suficiente de existența unei stări suficiente compacte și ușor de actualizat.

Mai există o cerință adesea omisă. Nu este suficient ca reprezentarea să ofere răspunsul bun la un moment dat. Trebuie să poată fi actualizată după observația următoare. Dacă pentru actualizare avem nevoie din nou de întregul trecut, comprimarea aparentă a mutat costul într-o etapă ascunsă. Reprezentarea operațională trebuie să includă atât răspunsul, cât și o regulă de continuare.

5.3. Observatorul face parte din întrebare

Două modele pot părea identice pentru un senzor și diferite pentru altul. Un observator care vede numai temperatura medie nu distinge toate configurațiile microscopice. Un observator care urmărește o anumită particulă cere alte informații. Nu rezultă că adevărul este arbitrar, ci că echivalența este relativă la accesul și întrebările declarate.

Canalul de observație nu trebuie ales după rezultat pentru a ascunde diferențele. Dacă toate stările sunt transformate în același simbol, orice două sisteme devin observațional identice. Aceasta este o echivalență formală, dar fără valoare pentru sarcina inițială. De aceea, observațiile relevante se fixează înaintea comparației, iar pierderea unor observații trebuie justificată prin scopul cercetării.

Aceeași disciplină se aplică timpului. Un model poate sări direct la un rezultat final, în timp ce altul prezintă toate etapele. Ele pot fi echivalente pentru întrebarea finală și neechivalente pentru monitorizarea permanentă. Unitatea de timp, frecvența observației și ceea ce trebuie emis între intrare și ieșire fac parte din contract.

5.4. Presupoziții tehnice care nu sunt credințe cosmologice

Pentru primele investigații acceptăm descrieri efectiv executabile, mulțimi de observații bine definite și acces controlat la date. Dacă

folosim probabilități, precizăm cum sunt estimate sau furnizate. Dacă presupunem staționaritate, declarăm că mecanismul statistic nu se schimbă în intervalul relevant. Dacă el se schimbă, includem explicit ceasul, regimul sau procesul de schimbare.

Aceste ipoteze nu susțin că universul este un calculator finit, că toate variabilele fizice sunt observabile sau că orice distribuție poate fi învățată. Ele definesc un domeniu în care întrebările au sens precis. Extinderea domeniului trebuie făcută etapizat: observații continue, precizie finită, memorie nelimitată, medii necontrolate și acces parțial la intervenții.

La nivel ingineresc, acceptăm numai comparații în care datele și resursele sunt inventariate. Un model care primește starea ascunsă rezolvă altă problemă decât unul care vede numai textul. Ambele pot fi studiate, dar nu pot fi declarate rivale echitabile fără această diferență. Chiar și alegerea simbolurilor poate comunica o parte a soluției.

5.5. Prima unitate de cercetare

Unitatea de bază nu va fi „o lume”, ci o situație completă: un generator, un canal de observație, un set de intervenții, o familie de întrebări și un buget. Această alegere poate părea modestă față de ambiția ontologică, dar permite acumularea cunoașterii. Putem modifica un singur element și observa ce se schimbă.

De exemplu, păstrăm generatorul și degradăm senzorul. Dacă modelul necesită mai multă memorie, am identificat un cost al observației incomplete, nu o creștere a complexității fundamentale. Sau păstrăm senzorul și extindem orizontul. Dacă apar distincții noi, am identificat un cost al întrebării. A separa aceste efecte este deja o formă de progres teoretic.

6. Nu există un singur număr numit complexitate

6.1. Lungimea regulii și informația ascunsă

Să descriem o lume prin instrucțiunea „afișează următorul element din tabel”. Instrucțiunea este foarte scurtă. Dacă tabelul conține un miliard de rezultate independente, descrierea completă nu este scurtă. Informația a fost mutată din reguli în date. Același lucru se poate întâmpla cu o constantă numerică: o singură valoare, cerută cu o precizie enormă, poate ascunde o cantitate enormă de informație.

Prin urmare, o contabilitate conceptuală trebuie să includă mecanismul, parametrii, starea inițială și informația exogenă. Pentru un model probabilistic, descrierea observațiilor poate fi împărțită între lungimea modelului și costul codificării datelor sub distribuția lui. Aceasta este ideea de bază a principiului lungimii minime a descrierii, care oferă metode statistice precise, nu doar o preferință estetică pentru simplitate. [3, 4]

$$L(\text{total}) = L(\text{model}) + L(\text{date} \mid \text{model})$$

Formula nu afirmă că există o singură codificare naturală. Convenția de descriere, precizia parametrilor și clasa modelelor trebuie precizate. Pentru comparații finite, aceste alegeri pot schimba rezultatul. Un candidat nu trebuie favorizat printr-o instrucțiune specială care îi comprimă exact soluția fără a contabiliza definiția instrucțiunii.

6.2. O lege probabilistică scurtă poate genera istorii lungi

Regula „produce independent zero sau unu cu probabilități egale” este compactă. Totuși, o realizare particulară lungă poate să nu aibă o descriere mult mai scurtă decât ea însăși. Legea descrie distribuția, nu toate rezultatele individuale. Confuzia dintre cele două ar face ca orice sursă aleatoare să pară o contradicție a simplității generative.

Pentru un sistem determinist care folosește o bandă aleatoare externă, banda trebuie inclusă atunci când cerem reproducerea exactă a traiectoriei. Dacă cerem numai reproducerea distribuției, este suficient să specificăm corect sursa de aleatorietate. Sunt două sarcini diferite, cu două contabilități diferite.

Această distincție limitează o concluzie ontologică tentantă. Chiar dacă legile naturii ar avea o formulare scurtă, nu ar urma că toate faptele particulare pot fi comprimate la aceeași lungime. Într-o asemenea situație, legea ar constrânge posibilitățile fără să aleagă singură fiecare realizare.

6.3. Memorie, timp și dificultatea găsirii modelului

Un model cu două stări logice poate avea o implementare mare. Un model cu multe stări poate folosi o reprezentare foarte regulată. Numărul stărilor, memoria ocupată și entropia distribuției asupra stărilor nu sunt aceeași măsură. Dacă stările sunt foarte inegal frecventate, informația medie necesară identificării lor poate fi mică, deși stocarea structurii complete rămâne costisitoare.

Timpul trebuie și el împărțit. Există timpul necesar descoperirii modelului, timpul necesar pregătirii unei interogări și timpul răspunsului. O reprezentare greu de învățat poate fi avantajoasă dacă este reutilizată suficient. O reprezentare care câștigă numai după un număr nerealist de utilizări nu este automat o realizare inginerească relevantă.

Descrierea scurtă și timpul mare apar împreună în studiul profunzimii logice și al complexității dependente de resurse. Aceste noțiuni ne avertizează că „puțină informație” nu înseamnă „puțină muncă”. Ele depind de convenții și parametri tehnici; nu vom folosi o etichetă precum „profund” drept scor intuitiv al valorii unei idei. [6]

6.4. Ce putem măsura fără a pretinde imposibilul

Lungimea celui mai scurt program pentru un obiect este o noțiune matematică utilă, dar nu există un procedeu general care să o calculeze pentru toate obiectele. În practică, lungimea celei mai bune descrieri găsite este o bornă superioară, nu o certificare a minimului absolut. Limitele generale ale calculabilității fac necesară această modestie. [5]

Putem măsura exact dimensiunea unui model serializat într-un format fix. Putem măsura timpul pe o platformă declarată, memoria maximă și numărul unor operații primitive. Putem estima consumul energetic numai cu o metodă adecvată; numărul operațiilor nu este automat o măsurătoare de energie. Putem raporta costul căutării și distribuția latențelor, nu doar o medie convenabilă.

Mai important, putem construi borne inferioare pentru clase restrânse. Dacă o sarcină cere distingerea a m situații care au continuări obligatoriu diferite, o reprezentare deterministă exactă are nevoie de cel puțin m stări distincte. Aceasta nu este o bornă pentru orice sistem probabilistic sau orice sarcină aproximativă, dar este o afirmație precisă, care poate orienta un experiment.

6.5. Frontiera cost–fidelitate

Nu vom căuta neapărat un câștigător unic. Un model poate economisi memorie și consuma mai mult timp; altul poate răspunde rapid, dar pierde fidelitate la intervenții. Reprezentăm fiecare candidat printr-un vector de costuri și erori. Un candidat este dominat dacă altul nu este mai rău pe niciun criteriu relevant și este mai bun pe cel puțin unul.

Modelele nedominate formează o frontieră de compromisuri. Într-un studiu concret vom folosi termenul „frontieră cost–fidelitate”, nu pentru a introduce o teorie nouă printr-un nume, ci pentru a păstra vizibilă pluralitatea obiectivelor. Alegerea unui punct de pe frontieră depinde de aplicație și de riscul acceptabil.

Întrebarea autorului uman primește astfel o formă mai productivă: nu „câte reguli are lumea?”, ci „ce cost minim cunoaștem pentru a păstra aceste consecințe, la acest orizont și în aceste condiții?”. Un răspuns poate fi local și totuși profund. El arată ce anume din complexitate aparține mecanismului și ce anume aparține reprezentării sau cerinței observatorului.

7. Trecutul care merită păstrat

7.1. Două istorii, același viitor posibil

Imaginați-vă un dispozitiv care numără apăsările unui buton modulo trei. Istoriile cu 3, 6 sau 300 de apăsări pot fi diferite ca lungime, dar echivalente pentru continuare dacă dispozitivul nu mai păstrează nicio altă informație. Pentru a prezice semnalul următor, contează restul împărțirii la trei, nu lista tuturor apăsărilor.

Generalizarea este firească. Două istorii sunt predictiv echivalente dacă, în condițiile admise, induc aceeași distribuție asupra tuturor observațiilor viitoare relevante. În varianta fără acțiuni, putem scrie:

$$h_1 \sqsubseteq h_2 \sqsubseteq P(\text{viitor} \mid h_1) = P(\text{viitor} \mid h_2)$$

Aceasta este ideea care fundamentează stările cauzale din mecanica computațională. Teoria caracterizează reprezentări predictive minimale în condițiile sale, nu identitatea metafizică a mecanismului ascuns. Denumirea „cauzal” din această tradiție nu înseamnă automat identificarea efectelor intervențiilor în sensul modelelor cauzale structurale. [9]

Pentru un cercetător, valoarea definiției este că înlocuiește asemănarea superficială cu un criteriu funcțional. Două texte pot fi diferite lexical și identice pentru o anumită sarcină de continuare. Două istorii aproape identice pot necesita stări diferite dacă un detaliu schimbă ce urmează.

7.2. De ce o fereastră mai mare nu rezolvă întotdeauna problema

Să presupunem că dispozitivul emite același simbol la fiecare apăsare și un semnal special numai când este întrebat despre rest. O fereastră care vede ultimele zece apăsări nu poate determina în general restul total. Lungirea ferestrei amână problema, dar nu o elimină pentru istorii arbitrar de lungi. Un contor cu trei valori o rezolvă prin actualizare recurentă.

Acest exemplu nu arată că orice model cu context finit este inutil. El izolează o clasă de dependențe pentru care reprezentarea corectă este o stare acumulată, nu un sufix mai lung. În alte sarcini, contextul local

este exact ceea ce trebuie. Programul ar trebui să descopere diferența, nu să declare o arhitectură universal superioară.

Mai există un contrast. Un proces generat de puține stări ascunse nu garantează că observatorul are nevoie de puține stări predictive. Când observațiile nu dezvăluie starea ascunsă, observatorul poate păstra o distribuție de credință asupra ei. Acea distribuție poate lua foarte multe valori, chiar un continuum. Complexitatea generatorului și complexitatea inferenței despre generator se pot separa radical.

7.3. O comprimare trebuie să poată continua

Dacă două istorii sunt grupate în aceeași stare, după aceeași observație nouă reprezentarea trebuie să le actualizeze compatibil. Altfel, gruparea nu definește un mecanism recurent bine determinat. Aceasta este cerința de închidere a stării sub actualizare.

Un rezumat poate fi excelent pentru o întrebare și inutil pentru întrebarea următoare. „Temperatura este acceptabilă” poate răspunde unei verificări imediate, dar nu păstrează distanța până la prag. După o încălzire mică, nu știm dacă să schimbăm concluzia. Într-un sistem care trebuie să funcționeze continuu, rezumatul trebuie să rețină și informația necesară actualizării.

De aici rezultă o ipoteză tehnică importantă: unele forme de înțelegere pot fi caracterizate prin găsirea unui rezumat care este simultan suficient pentru întrebări și închis sub transformările relevante. Aceasta este o propunere operațională, nu o definiție exhaustivă a înțelegerii umane.

7.4. Aproximarea ca selecție a informației utile

Egalitatea exactă a distribuțiilor viitoare este adesea prea exigentă. Putem tolera o anumită pierdere predictivă pentru a reduce memoria. Metoda information bottleneck formalizează comprimarea unei variabile păstrând informația despre o alta. În problema noastră, prima variabilă poate fi trecutul, iar a doua viitorul de interes. [10]

O formulare de lucru caută o reprezentare Z care minimizează informația reținută despre trecut, sub o limită de distorsiune predictivă:

minimizează $I(\text{trecut}; Z)$, cu distorsiunea predictivă $\leq \delta$

I este informația mutuală, măsurată în biți dacă folosim logaritmul în baza doi. Ea nu este dimensiunea totală a implementării. Distorsiunea

poate fi definită printr-o diferență între distribuțiile viitoare sau prin pierderea la sarcina relevantă. Teoriile de inferență predictivă și de rată-distorsiune cauzală oferă fundamente pentru această alegere. [11, 12]

Programul propus extinde întrebarea practică: o reprezentare informațional compactă poate fi foarte scumpă de calculat sau actualizat. Prin urmare, trebuie să măsurăm separat memoria, descoperirea, actualizarea și fidelitatea intervențională. Nu orice soluție elegantă a problemei informaționale este o soluție inginerescă bună.

7.5. Când „aproape la fel” nu definește clase

Dacă distanța dintre două distribuții este cel mult δ , putem spune că ele sunt apropiate la acea toleranță. Dar apropierea nu este tranzitivă. Prima distribuție poate fi aproape de a doua, a doua de a treia, iar prima prea departe de a treia. Un lanț de fuziuni locale poate produce o clasă cu diametru mare.

Această observație are consecințe directe pentru învățare. Nu putem fuziona succesiv stări doar fiindcă fiecare fuziune pare acceptabilă în momentul ei. Trebuie controlată eroarea întregii clase, propagarea prin tranziții și efectul asupra viitoarelor interogări. Altfel, compactarea poate fabrica o certitudine pe care datele nu o susțin.

Un rezultat valoros ar fi o procedură care propune fuziuni, identifică observațiile care le-ar putea infirma și desface gruparea când apar dovezi noi. O asemenea memorie nu crește numai prin adăugare și nu se micșorează numai prin uitare. Ea își schimbă organizarea în funcție de consecințe.

8. Echivalența are un observator și un buget

8.1. Mai multe întrebări ascunse într-un singur cuvânt

Două mecanisme sunt identice dacă au aceeași structură? Dacă emit aceleași șiruri? Dacă atribuie aceleași probabilități șirurilor? Dacă răspund la fel când le modificăm? Dacă niciun test disponibil nu le poate distinge? Fiecare întrebare definește altă relație.

Echivalența intrare-ieșire poate ignora detaliile interne. Bisimularea cere o corespondență între tranziții și stări, într-un sens mai structural. Simularea poate fi direcționată: un sistem reproduce comportamentele altuia fără ca reciproca să fie adevărată. Metricile de bisimulare pentru procese decizionale arată cum pot fi măsurate diferențe care au consecințe pentru evaluarea deciziilor. [13]

Nu avem nevoie de o relație care să le înlocuiască pe toate. Avem nevoie să alegem relația potrivită afirmației. O compresie a jurnalului de observații nu trebuie prezentată drept descoperire a mecanismului. O corespondență cauzală nu trebuie confundată cu identitatea fizică a implementărilor.

8.2. Un contract comun pentru două modele

Fixăm un spațiu comun de observații, condiții inițiale comparabile, o familie Π de politici de intervenție și un orizont H . O politică poate alege acțiunea următoare în funcție de observațiile deja primite. Notăm cu $P(M, \pi, H)$ distribuția întregii traiectorii observate în modelul M sub politica π .

$$d(M, N) = \sup\{TV(P(M, \pi, H), P(N, \pi, H)) : \pi \in \Pi\}$$

Distanța în variație totală, TV , este cea mai mare diferență de probabilitate pe care cele două distribuții o atribuie aceluiași eveniment observabil. Pentru spații discrete finite, ea este jumătate din suma diferențelor absolute dintre probabilități. Valoarea zero înseamnă identitate distribuțională în contractul fixat; valoarea unu permite separare perfectă printr-un eveniment.

În sens strict, aceasta este în general o pseudometrică pe modele: mecanisme interne diferite pot avea distanța zero. Ea poate deveni o metrică pe clasele care identifică modelele indistinguibile în contractul ales. Cuvântul „distanță” nu trebuie interpretat ca măsură a diferenței ontologice dintre mecanisme.

Înainte de folosirea formulei trebuie aliniate observațiile și intervențiile modelelor. Dacă această aliniere este aleasă diferit pentru fiecare pereche, proprietăți precum inegalitatea triunghiului nu mai sunt automate. Pentru o primă teorie, este mai sigur să fixăm o interfață comună decât să optimizăm simultan și sensul observațiilor.

8.3. Observatorul finit schimbă problema

TV permite, în definiție, orice test asupra traiectoriei. Un observator real are timp, memorie și eșantioane limitate. Putem restrânge comparația la o clasă D de teste care respectă un buget declarat:

$$d(D; M, N) = \sup\{ |P(M; T=1) - P(N; T=1)| : T \in D \}$$

Această formulare are o rudă precisă în criptografie: indistinguibilitatea computațională. Sub ipoteze de dificultate, distribuții generate din semințe scurte pot fi greu de deosebit de aleatorietatea uniformă pentru observatori computațional limitați. Existența construcțiilor generale este condiționată de ipoteze precum existența funcțiilor unidirecționale, nu este o dovadă necondiționată că orice sursă aparent aleatoare ascunde o regulă scurtă. [28]

Un exemplu analitic arată separarea. Un generator determinist transformă o sămânță de m biți într-un șir de n biți, unde n este mai mare decât m . Suportul ieșirilor are cel mult 2 la puterea m elemente. Distribuția uniformă pe toate șirurile de n biți acordă acestui suport probabilitate cel mult 2 la puterea $m-n$. Prin urmare, distanța statistică față de uniformă este cel puțin $1-2$ la puterea $m-n$. Totuși, identificarea eficientă a suportului poate fi dificilă.

Concluzia nu este că realitatea este pseudorandom. Este că simplitatea generatorului, distanța statistică și dificultatea observatorului sunt axe diferite. Un program despre lumi și reprezentări trebuie să le păstreze separate.

8.4. Ceea ce măsoară efectiv un test

O colecție finită de teste poate descoperi o diferență. Dacă un test separă modelele, știm că nu sunt echivalente în clasa care îl conține. Dacă toate testele încercate eșuează, nu știm automat că niciun alt test admis nu ar reuși. Maximul observat este, conceptual, o bornă inferioară pentru supremumul asupra tuturor testelor, nu o bornă superioară.

Pentru afirmații pozitive puternice sunt necesare fie clase de teste enumerate complet, fie garanții matematice, fie limite statistice pentru o clasă controlată. În investigațiile mari, raportarea corectă poate fi mai modestă: „nu am identificat diferențe prin aceste teste, cu această putere de detecție”. Modestia precisă este mai informativă decât o declarație generală de echivalență.

De asemenea, extinderea clasei observațiilor, a politicilor sau a orizontului nu poate micșora distanța definită printr-un supremum, dacă interfețele rămân compatibile. Mai multe posibilități de investigare pot dezvălui diferențe ascunse. Această monotonie elementară oferă un control de consistență pentru metricile implementate într-un studiu.

8.5. O familie de frontiere, nu o scară a existenței

Putem căuta modele care respectă o toleranță ε și minimizează costurile. Dar frontiera rezultată depinde de H , Π , observații și bugetul testelor. Un model ieftin pentru prognoze imediate poate deveni scump când cerem control pe termen lung. O reprezentare compactă pentru un singur observator poate pierde avantajul când trebuie să deservească mai multe întrebări.

Aceste frontiere nu clasifică entitățile în „mai reale” și „mai puțin reale”. Ele clasifică adecvarea reprezentărilor. Beneficiul filosofic este tocmai evitarea unei confuzii: rezistența unei lumi la descrierile noastre poate fi investigată fără a transforma succesul unui model într-o definiție a existenței.

9. Ceea ce observația nu decide: intervenția

9.1. Aceleași date, două mecanisme

Considerăm două becuri, A și B, și un comutator ascuns U, care ia valorile zero și unu cu probabilități egale. În primul mecanism, A este controlat de U, iar B copiază starea lui A. În al doilea, ambele becuri sunt controlate separat de U. Când privim numai becurile, vedem de fiecare dată aceeași stare la amândouă.

Descrierile structurale sunt $A=U$, $B=A$ pentru primul mecanism și $A=U$, $B=U$ pentru al doilea. Distribuțiile observaționale coincid. Totuși, dacă forțăm A să rămână stins, înlocuind mecanismul care îl controlează, primul sistem îl stinge și pe B; în al doilea, B continuă să urmeze comutatorul ascuns.

Acesta este un exemplu construit, nu o constatare experimentală despre un aparat. El dovedește prin enumerare că aceeași distribuție observațională poate fi compatibilă cu efecte intervenționale diferite. Nicio cantitate suplimentară de observații pasive identice nu poate decide între aceste două descrieri fără ipoteze sau acces suplimentar.

9.2. A condiționa nu înseamnă a interveni

„Ce se întâmplă când observ $A=0$?” și „ce se întâmplă când forțez $A=0$?” sunt întrebări diferite. În prima, observația ne spune ceva despre cauzele lui A. În a doua, modificăm mecanismul care produce A și putem rupe acea legătură. Egalitatea dintre cele două operații cere condiții, nu rezultă din notație.

Într-un sistem de învățare, acțiunile pot fi alese tocmai în situațiile în care rezultatul era deja probabil. Dacă ignorăm selecția, atribuim acțiunii un efect pe care nu l-a produs. Pentru experimentele propuse, randomizarea acțiunilor în domenii controlate este o cale simplă de a separa aceste probleme. În medii necontrolate, ipotezele de identificare trebuie documentate.

Un predictor secvențial nu este exclus din această cercetare. El poate învăța distribuții care includ intervenții dacă datele, reprezentarea și ipotezele permit acest lucru. Eroarea ar fi să atribuim unei arhitecturi

incapacitatea de a reprezenta cauzalitatea doar fiindcă un set particular de date nu o identifică.

9.3. Când o lume mică explică o lume mare

O abstracție cauzală leagă un model detaliat de unul agregat. O aplicație τ transformă stările detaliate în stări abstracte. O corespondență ω leagă intervențiile de la cele două niveluri. Cerința intuitivă este ca „intervin și apoi abstractizez” să coincidă, exact sau aproximativ, cu „abstractizez și apoi intervin corespunzător”.

$$\text{intervenție} \rightarrow \text{abstracție} \approx \text{abstracție} \rightarrow \text{intervenție}$$

Literatura despre consistența cauzală și abstracția cauzală aproximativă formalizează tocmai asemenea relații între niveluri. Ea oferă un fundament pentru a discuta echivalențe care păstrează efectele intervențiilor, nu doar corelațiile. [14, 15]

Un exemplu ar putea fi trecerea de la molecule la o variabilă de presiune. O intervenție numită „crește presiunea” poate avea mai multe realizări microscopice. Dacă aceste realizări produc rezultate abstracte foarte diferite, intervenția de nivel înalt este insuficient specificată. Nu este suficient să existe o hartă între stări; trebuie înțeles și ce acțiuni reprezintă harta.

9.4. Costul unei distincții cauzale

O reprezentare care unește cele două mecanisme ale becurilor este perfectă pentru observația pasivă, dar greșită pentru intervenția asupra lui A. Păstrarea distincției cere informație suplimentară. Aceasta sugerează că memoria necesară controlului poate depăși memoria necesară prognozei într-un regim fix.

Nu este o lege universală a numărului de parametri. Uneori structura cauzală simplifică reprezentarea și reduce costul învățării. Ipoteza care merită testată este condițională: atunci când distribuția de observații ascunde diferențe relevante pentru acțiune, o comprimare optimizată exclusiv observațional poate elimina informația pe care controlul ar avea nevoie să o păstreze.

Un studiu bun ar compara frontierele în două regimuri: observație pasivă și intervenție. Dacă frontiera se deplasează, trebuie identificat motivul. Poate că au apărut stări noi, poate că modelul necesită alte

relații, poate că este suficientă o singură variabilă suplimentară. Important este mecanismul deplasării, nu doar un scor mai slab.

9.5. Experimentul ca operație de separare

Când două modele explică aceleași date, următoarea întrebare nu trebuie să fie „care pare mai convingător?”, ci „ce observație sau intervenție le-ar separa?”. Un agent de cercetare ar putea căuta acțiuni care maximizează dezacordul predictiv, sub limite de cost și siguranță.

Un asemenea agent nu descoperă adevărul prin dezacord singur. Modelele pot fi toate greșite sau pot împărtăși aceeași ipoteză ascunsă. De aceea, programul trebuie să includă și acțiuni exploratorii care nu sunt justificate exclusiv de modelele curente. Valoarea experimentului activ constă în reducerea unor ambiguități specificate, nu în garantarea exhaustivității spațiului de explicații.

10. Ireductibilitate, haos și scurtături legitime

10.1. A cunoaște regula nu înseamnă a cunoaște imediat rezultatul

Un mecanism poate fi descris în câteva rânduri și totuși poate necesita mulți pași pentru a produce un rezultat îndepărtat. Noțiunea de ireductibilitate computațională formulată de Wolfram atrage atenția asupra imposibilității, în anumite situații, de a înlocui desfășurarea printr-o scurtătură predictivă generală. Afirmările largi despre prevalența fenomenului trebuie separate de demonstrațiile de dificultate pentru clase și sarcini precise. [7]

Pentru programul nostru, întrebarea corectă este întotdeauna completată: ireductibil pentru ce proprietate, cu ce tip de algoritm, la ce precizie și în raport cu ce resurse? A calcula fiecare celulă a unei configurații poate fi greu, în timp ce estimarea unei densități sau a unei simetrii poate fi ușoară.

Existența unor descrieri agregate predictibile pentru sisteme cu dinamică microscopică dificilă este investigată explicit în lucrările lui Israeli și Goldenfeld. Ele oferă un motiv să nu confundăm complexitatea evoluției detaliate cu imposibilitatea oricărei teorii utile la scară mare. [8]

10.2. Trei dificultăți care nu trebuie amestecate

Prima dificultate este informațională: nu cunoaștem suficient de precis starea inițială. A doua este computațională: cunoaștem datele relevante, dar calculul este costisitor. A treia este inferențială: nu știm care mecanism dintr-o clasă explică observațiile. Ele pot apărea împreună, dar cer remedii diferite.

Sensibilitatea la condițiile inițiale arată că erori mici de stare pot produce diferențe mari mai târziu. Ea nu constituie singură o demonstrație că nu există algoritmi rapizi pentru anumite observabile. În sens invers, o problemă discretă exactă poate fi computațional dificilă fără să existe o eroare de măsurare sau un fenomen de haos în sensul obișnuit.

Într-o investigație, putem varia separat precizia inițială, timpul acordat calculului și cantitatea de date pentru învățare. Dacă performanța se îmbunătățește numai când crește precizia, nu am demonstrat o limită a reprezentării. Dacă modelul corect, furnizat direct, rămâne lent, am separat dificultatea calculului de dificultatea învățării.

10.3. De la eroarea locală la traiectorii

Să presupunem că două modele au, pentru fiecare istorie relevantă, distribuții ale observației următoare aflate la distanță TV cel mult ε . Putem cupla continuările astfel încât probabilitatea primei divergențe la fiecare pas, condiționat de acordul anterior, să fie cel mult ε . În H pași, probabilitatea unei divergențe este cel mult $1 - (1 - \varepsilon)^H$ la puterea H .

$$d(\text{traiectorii de } H \text{ pași}) \leq 1 - (1 - \varepsilon)^H \leq \min(1, H\varepsilon)$$

Aceasta este o bornă elementară, nu o garanție oferită de un log-loss mediu mic. Ipoteza este uniformă asupra istoriilor relevante, inclusiv asupra celor rare care pot apărea în generarea liberă. Un model poate avea o medie excelentă și o eroare mare într-o situație puțin frecventă, dar decisivă.

Borna explică de ce fidelitatea unei continuări lungi trebuie evaluată separat. Nu dovedește că eroarea trebuie să crească liniar; este o limită superioară generală în condițiile date. Structura particulară a procesului poate produce un comportament mai bun sau poate face limita aproape relevantă.

10.4. Când sistemul amortizează erorile

Pentru unele dinamici, apropierea dintre stări poate respecta o relație de forma $\delta(t+1) \leq \rho\delta(t) + \eta$, unde η este eroarea introdusă la un pas, iar ρ este mai mic decât unu. Atunci eroarea de stare rămâne controlată de o sumă geometrică și nu trebuie să crească nelimitat. Aceasta este o proprietate care trebuie demonstrată în metrica aleasă, nu presupusă pentru orice sistem care „pare stabil”.

$$\delta(t) \leq \rho^t \delta(0) + \eta(1 - \rho^t)/(1 - \rho), \text{ pentru } 0 \leq \rho < 1$$

Controlul erorii stării finale nu este identic cu apropierea distribuțiilor întregilor traiectorii. Două procese pot ajunge la distribuții finale

apropiate, după istorii foarte diferite. Dacă sarcina urmărește fiecare eveniment, contracția la final nu șterge diferențele deja observate.

Această distincție sugerează două tipuri de aproximații: unele păstrează evoluția pas cu pas, altele păstrează numai rezultate sau statistici finale. Ambele pot fi valoroase, dar au contracte diferite. O scurtătură legitimă trebuie să spună ce tip oferă.

10.5. Limitele generale nu închid cercetarea

Nu există o procedură universală care decide echivalența tuturor programelor generale. Un argument simplu ar transforma o asemenea procedură într-un decident al opririi: comparăm un mecanism care emite permanent zero cu unul care emite zero până când o altă execuție se termină, apoi emite unu. Identitatea tuturor ieșirilor ar decide dacă acea execuție nu se oprește. Limitele stabilite de teoria calculabilității împiedică această generalitate. [5]

Dar pentru automate finite, orizonturi finite, clase structurale controlate sau proprietăți restrânse putem obține proceduri complete, aproximări cu garanții și certificate. O limită universală ne spune unde trebuie să delimităm problema, nu că problema delimitată este lipsită de valoare.

Programul ar trebui, așadar, să caute insule de echivalență verificabilă și să studieze frontierele lor. Când ieșim dintr-o insulă, putem pierde exactitatea, eficiența sau posibilitatea descoperirii automate. A identifica ce se pierde, și din ce motiv, ar fi o contribuție mai durabilă decât a declara că totul este reductibil ori că nimic nu poate fi scurtat.

PARTEA III / PREDICȚIA, SENSUL ȘI INVENȚIA DE OPERAȚII

11. Familia extinsă a predicției următorului simbol

11.1. Un obiectiv comun, mecanisme diferite

Orice distribuție comună asupra unui șir finit poate fi descompusă în probabilități condiționale succesive. Pentru evenimentele condiționante cu probabilitate pozitivă, regula lanțului oferă identitatea:

$$P(x_1, \dots, x_n) = P(x_1) \cdot P(x_2 | x_1) \cdot \dots \cdot P(x_n | x_1, \dots, x_{n-1})$$

Identitatea nu specifică felul în care sunt calculate probabilitățile. Ele pot proveni dintr-un tabel, dintr-un automat, dintr-un model cu stare ascunsă, dintr-un simulator sau dintr-o rețea neuronală. Predicția următorului simbol este un obiectiv comun, nu o ontologie și nici o arhitectură unică.

Legătura dintre predicție și compresie este tehnică: probabilitățile atribuite secvențelor pot fi folosite pentru codificarea lor, iar performanța predictivă se reflectă în lungimea descrierii. Cercetarea despre modelele de limbaj ca mecanisme de compresie dezvoltă această perspectivă. Ea nu stabilește, singură, dacă reprezentarea internă identifică mecanismele cauzale ale lumii descrise. [20]

Într-un LLM cu ponderi înghețate, procedura care produce distribuția tokenului următor rămâne fixă. Contextul și starea de execuție se schimbă. Dacă se actualizează și ponderile, perechea formată din parametri și stare poate fi inclusă într-o dinamică extinsă. Noutatea propozițiilor generate nu demonstrează apariția unor instrucțiuni fundamentale noi în mecanismul de inferență.

11.2. Memoria prin contexte: vecinul cel mai apropiat

Un model de ordin fix estimează următorul simbol din ultimele k simboluri. Este ușor de interpretat: fiecare context are o distribuție de continuări. Dezavantajul este că numărul contextelor posibile poate crește rapid cu k , iar o dependență recurentă poate rămâne ascunsă dincolo de orice fereastră fixă.

Modelele de context variabil permit unor situații să folosească un trecut scurt și altora unul mai lung. Context-tree weighting combină

modele organizate într-un arbore și are garanții de compresie pentru clasele de surse și convențiile analizate în teoria sa. Aceste garanții nu înseamnă că orice dependență semantică va fi învățată eficient. [17]

Această familie este un reper indispensabil. Înainte de a propune mecanisme sofisticate pentru „înțelegere”, trebuie să vedem cât se poate obține prin reutilizarea statistică a contextelor. Un câștig față de un predictor fără memorie nu este suficient; comparatorul relevant trebuie să beneficieze de memoria pe care problema o permite.

11.3. Memoria prin stare: istorii diferite, același rol

Un automat probabilistic poate avea o stare internă care se actualizează la fiecare observație. Spre deosebire de un arbore de sufixe, el poate reuni istorii foarte diferite în aceeași stare. Aceasta poate permite reprezentarea compactă a unor dependențe recurente, precum numărarea modulară sau alternarea unor faze.

Problema dificilă nu este doar estimarea probabilităților, ci găsirea structurii stărilor. Există algoritmi de descoperire a tiparelor secvențiale care construiesc stări ascunse din date și oferă rezultate de convergență sub ipoteze explicite. Ei reprezintă un punct de plecare pentru un program nou, nu un detaliu istoric de ignorat. [18]

Un studiu ar trebui să compare două moduri de a crește memoria: adăugarea contextelor și descoperirea unei stări recurente. Când apare un avantaj, întrebarea importantă este dacă el provine din împărțirea mai bună a istoriilor, dintr-o ipoteză structurală furnizată de proiectant sau dintr-o diferență de buget. Cele trei explicații au valori științifice diferite.

11.4. Regimuri ascunse, contoare și stive

Modelele cu stări ascunse separă starea generatorului de observațiile vizibile. Filtrarea actualizează o distribuție de credință asupra stării. Modelele de schimbare de regim pot urmări faptul că regularitatea locală s-a modificat; inferența bayesiană online a punctelor de schimbare este o abordare formală pentru această problemă. [19]

Un contor adaugă o formă de memorie care crește numeric. O stivă permite gestionarea structurilor imbricate: o deschidere este reținută până când apare închiderea corespunzătoare. Pentru o familie de secvențe cu imbricare fără limită fixă, stiva exprimă o regularitate pe care o colecție finită de contexte nu o poate reprezenta exact pentru toate lungimile.

Nu rezultă că stivele sunt soluția generală pentru limbaj. Ele oferă un laborator în care știm ce dependență căutăm și putem verifica transferul spre adâncimi nevăzute. Un model poate învăța formatul superficial și totuși poate eșua la o imbricare mai mare. Altul poate primi stiva de la proiectant; succesul lui verifică utilitatea structurii, nu descoperirea ei autonomă.

11.5. Predicția experimentelor, nu numai a simbolurilor

Predictive State Representations propun descrierea stării prin predicții despre rezultatele unor secvențe de acțiuni și observații. În loc să afirmăm direct ce variabilă ascunsă există, păstrăm un set de predicții care poate fi actualizat și folosit pentru anticiparea altor teste. [16]

Aceasta este o rudă deosebit de fertilă a next-token prediction. Întrebarea devine „ce voi observa dacă efectuez această secvență de acțiuni?”, nu doar „ce apare dacă privesc mai departe?”. Pentru programul de cercetare, perspectiva leagă natural memoria, experimentul și controlul.

Totuși, nu trebuie numită automat teorie cauzală completă. Politicile de colectare a datelor, identificabilitatea și acoperirea acțiunilor rămân esențiale. O reprezentare predictivă poate fi corectă numai în domeniul în care a fost definită și instruită. Extinderea acțiunilor poate cere noi distincții interne.

11.6. De ce predicția bună nu certifică respectarea regulilor

Un model poate atribui probabilitate foarte mică unei continuări interzise. Dacă acea probabilitate este pozitivă, generarea repetată poate produce încălcarea. În schimb, o constrângere impusă exact poate elimina continuarea, dar poate fi greșită dacă lumea reală admite excepții.

Trebuie separate calitatea distribuției, fidelitatea secvențelor generate și garanțiile de validitate. Regularizarea sau smoothing-ul pot îmbunătăți estimarea statistică și pot evita probabilități zero premature, dar nu transformă absența unui eveniment în imposibilitate logică. Un sistem care trebuie să respecte un invariant are nevoie de un mecanism suplimentar de validare sau de o clasă generativă care îl conservă prin construcție.

Acest lucru nu stabilește o ierarhie simplă între simbolic și neuronal. Un mecanism simbolic poate conține reguli greșite; un model neuronal poate învăța o structură utilă. Întrebarea este ce parte este estimată, ce

parte este impusă, ce parte este verificată și ce se întâmplă când aceste părți intră în conflict.

12. Din desfășurări în operații reutilizabile

12.1. Două forme de comprimare care se întâlnesc

Putem comprima trecutul într-o stare. Putem comprima și un calcul repetat într-o operație. Prima comprimare răspunde întrebării „ce trebuie să țin minte?”. A doua răspunde întrebării „ce muncă pot evita să refac în aceeași formă?”. Autorul uman vede în întâlnirea lor o posibilă explicație parțială a creșterii competenței.

Să presupunem că un agent învață să calculeze repetat efectul mai multor transformări. La început aplică fiecare pas. Ulterior descoperă că o anumită compoziție are o formă mai simplă, valabilă pentru o clasă de intrări. Dacă păstrează acea formă și condițiile ei de validitate, biblioteca sa crește, iar timpul unor sarcini scade.

Noutatea este reală la nivelul repertoriului agentului, fără a necesita legi fundamentale noi. Dar creșterea bibliotecii nu este automat progres. O mie de proceduri care memorează câte un caz pot costa mai mult decât o singură regulă generală. Trebuie măsurat transferul spre intrări și compoziții care nu au fost folosite la inventarea procedurii.

12.2. Circuitul ca reprezentare a dependențelor

Un circuit de calcul poate fi privit ca o rețea de valori și transformări: o valoare este obținută din alte valori printr-o operație precizată. Această perspectivă face vizibilă proveniența rezultatelor. Dacă un rezultat depinde de o observație, legătura poate fi urmărită. Dacă un subcalcul este reutilizat, nu trebuie confundat cu o nouă dovadă independentă.

Pentru procese cu memorie, putem desfășura circuitul în timp sau putem reprezenta explicit starea și actualizarea ei. Un circuit finit nu capturează automat orice execuție nelimitată într-o dimensiune finită. Un orizont fix și o buclă simbolică sunt obiecte diferite, chiar dacă descriu același tip de tranziție la scări diferite.

Avantajul cercetării prin circuite nu este universalitatea singură. Aproape orice formalism suficient de expresiv poate reprezenta foarte multe calcule. Avantajul potențial constă în inspectarea dependențelor, separarea observațiilor de presupuneri, verificarea locală și înlocuirea

unor subcircuite prin variante echivalente. Aceste avantaje trebuie demonstrate în aplicații, nu presupuse din desenul unei rețele.

12.3. Contractul unei operații noi

O operație promovată în bibliotecă ar trebui să aibă un domeniu de intrare, o semnificație a ieșirii și o relație cu procedura pe care o înlocuiește. Contractul precizează dacă echivalența este exactă sau aproximativă, ce observații intermediare sunt păstrate și ce resurse economisește.

O formulă directă pentru o stare finală nu înlocuiește automat o execuție care trebuie să emită toate stările intermediare. Nici nu poate evita costul scrierii unui rezultat foarte lung atunci când ieșirea cerută este explicită. O operație care produce o reprezentare compactă a rezultatului rezolvă o sarcină diferită de enumerarea rezultatului, cu excepția cazului în care interfața acceptă această reprezentare.

Contractul mai trebuie să spună ce se întâmplă în afara domeniului. Operația poate refuza, poate reveni la calculul detaliat sau poate solicita informații suplimentare. A răspunde cu încredere în afara condițiilor demonstrate nu este o scurtătură inteligentă; este pierderea legăturii dintre afirmație și mecanism.

12.4. Învățarea bibliotecilor și obligația de a contabiliza ajutorul

Învățarea de programe cu biblioteci de abstracții are precedente importante. DreamCoder explorează creșterea unei biblioteci de componente reutilizabile împreună cu mecanisme care ghidează căutarea. Este un exemplu al ideii că învățarea poate schimba vocabularul intern al problemelor, nu doar parametrii unui vocabular fix. [23]

Pentru programul nostru, următoarea întrebare ar fi dacă asemenea operații pot primi contracte predictive și intervenționale explicite. Nu este suficient ca ele să comprime sarcinile de antrenare. Trebuie verificat că nu distrug distincții importante și că economia persistă după includerea costului căutării, stocării și validării.

Un partener AI poate propune operații candidate. În acest caz, cunoașterea sa anterioară este o resursă furnizată sistemului. Nu putem descrie succesul drept descoperire din observațiile locale dacă soluția a fost sugerată dintr-un model antrenat pe un corpus vast. Putem totuși

studia separat utilitatea propunerii și capacitatea verficatorului de a respinge propuneri greșite.

12.5. Două tradiții de verificare

Interpretarea abstractă dezvoltă aproximări semantice folosite pentru analizarea programelor. O aproximare sănătoasă poate include toate comportamentele concrete posibile și, uneori, comportamente suplimentare. Scopul ei poate fi demonstrarea absenței unei erori, nu imitarea frecvențelor observate. Această noțiune de aproximație nu este identică cu o distanță probabilistică mică. [21]

Compilarea verificată formal demonstrează păstrarea unei semantici în condițiile unui limbaj și ale unei implementări precizate. Lucrarea lui Leroy oferă un reper pentru ceea ce înseamnă o obligație semantică reală într-o transformare de programe. Nu trebuie extrapolată la certificarea oricărui rezumat sau a oricărui model al realității. [22]

Programul poate împrumuta din ambele tradiții: conservarea proprietăților când există o specificație formală și măsurarea fidelității când avem distribuții și observații. Când le combină, trebuie să păstreze distincte garanțiile. O dovadă despre model nu dovedește că modelul corespunde lumii; un test favorabil în lume nu certifică toate execuțiile modelului.

12.6. Un obiectiv tehnic mai ambițios

Un sistem matur ar putea păstra pentru fiecare operație o proveniență: din ce observații, reguli sau transformări rezultă; unde a fost verificată; în ce condiții a eșuat; ce cost estimează. Dacă o premisă se schimbă, operațiile dependente pot fi reevaluate. Astfel, biblioteca devine o rețea de angajamente revizuibile, nu un depozit de afirmații fără genealogie.

Aceasta este o arhitectură de cercetare propusă. Nu avem dreptul să presupunem că proveniența rezolvă automat adevărul sau că toate dependențele pot fi extrase corect din limbaj. Dar putem construi sarcini delimitate în care genealogia este verificabilă și putem măsura dacă ea reduce contradicțiile, costul revizuirii sau propagarea unei erori.

13. Limbajul, imaginația și ipoteza unei minți predictive

13.1. O propoziție poate promite mai mult decât realizează

Să afirmăm că un obiect este indestructibil, că un personaj cunoaște viitorul sau că o mașină rezolvă instantaneu orice problemă. Enunțurile sunt ușor de produs. Ele nu furnizează mecanismele care ar realiza proprietățile afirmate. Într-o ficțiune, acest lucru poate fi legitim: enunțul stabilește convențiile lumii. Într-o explicație tehnică, el lasă tocmai problema deschisă.

Prin urmare, existența unui enunț, consistența unei teorii și realizabilitatea mecanismului trebuie separate. O teorie poate fi coerentă în raport cu anumite axiome fără a fi o descriere fizică. O specificație poate fi clară fără a avea o realizare eficientă. Un sistem poate produce răspunsuri plauzibile fără să mențină un model coerent al tuturor consecințelor lor.

Această diferență nu degradează imaginația. Imaginația permite explorarea unei posibilități înainte de a-i cunoaște realizarea. Problema apare când libertatea de a formula este tratată drept dovadă a posibilității sau când coerența locală a unei povestiri este confundată cu închiderea tuturor consecințelor.

13.2. Sensul ca familie de angajamente

O definiție operațională parțială a sensului ar putea privi ce distincții impune o expresie asupra observațiilor și acțiunilor. „Cheia deschide ușa” nu este numai o vecinătate între cuvinte; într-un mediu de test, ea anticipează rezultate ale folosirii cheii și exclude altele. Totuși, sensul uman include convenții sociale, intenții și experiențe pe care această definiție nu le epuizează.

Pentru cercetare, putem restrânge domeniul la lumi interactive controlate. Un text descrie obiecte, relații și transformări. Sistemul trebuie să răspundă la întrebări și să mențină consecințele unor acțiuni. Astfel, evaluăm dacă reprezentarea păstrează angajamentele operaționale ale descrierii, fără a pretinde că am rezolvat întreaga filosofie a sensului.

Distincția dintre formă lingvistică și sens este dezbătută explicit în lucrarea lui Bender și Koller. Ea trebuie citită ca argument teoretic într-o dezbateră, nu ca teoremă generală care ar decide definitiv capacitățile tuturor modelelor de limbaj, indiferent de date, interacțiune sau arhitectură. [27]

13.3. A introduce o regulă într-o poveste

Într-o lume textuală, autorul poate introduce propoziția „de acum, obiectele albastre plutesc”. Pentru cititor, aceasta este o regulă nouă. Pentru mecanismul care interpretează povestea, poate fi doar adăugarea unei condiții într-o structură existentă. Pentru un simulator care nu are conceptul de culoare, poate cere o extensie a reprezentării. Pentru lumea fizică, propoziția nu schimbă automat nimic.

Același enunț traversează, așadar, patru niveluri: actul de formulare, starea reprezentării, mecanismul interpretativ și referentul posibil. Multe confuzii despre „lumi cu reguli dinamice” provin din amestecarea acestor niveluri. Programul ar trebui să măsoare unde apare modificarea și ce resurse sunt necesare pentru a o integra coerent.

Un test interesant ar introduce reguli noi care interacționează cu reguli vechi. Sistemul trebuie să identifice conflicte, priorități și consecințe indirecte. Dacă răspunde doar la exemplele care repetă formularea, nu a demonstrat compoziție. Dacă gestionează combinații nevăzute în domeniul definit, avem un semnal de reutilizare semantică, nu încă o dovadă de înțelegere generală.

13.4. Analogia biologică și limita ei

Predicția este un principiu fertil în modelarea unor procese perceptive. Modelul de codificare predictivă al lui Rao și Ballard propune interacțiuni între predicții și erori pentru explicarea unor proprietăți ale procesării vizuale. Acest tip de rezultat motivează studiul mecanismelor predictive, dar nu identifică întreaga activitate mentală cu predicția următorului cuvânt. [25, 31]

Ipoteza funcțională a cărții este mai restrânsă. Unele competențe ar putea implica învățarea unor stări care rezumă experiența și a unor operații care scurtează deliberarea. Un sistem artificial ar putea testa utilitatea acestei combinații. Chiar dacă ar avea succes, rezultatul ar

demonstra posibilitatea mecanismului, nu faptul că oamenii îl folosesc în aceeași formă biologică.

Pentru a susține o afirmație despre minte ar fi necesare predicții comportamentale sau neurobiologice distinctive. Dacă două mecanisme artificiale produc același comportament, simpla potrivire comportamentală nu decide care mecanism este realizat în creier. Legătura dintre niveluri trebuie investigată, nu decretată prin analogie.

13.5. Ce rămâne în afara definiției operaționale

Conștiința fenomenală, valoarea unei experiențe și sensul existențial al înțelegerii nu sunt rezolvate de o metrică predictivă. Un sistem poate avea o reprezentare utilă fără ca programul să decidă dacă „simte” ceva. De asemenea, o persoană poate considera că a înțeles o situație morală într-un sens care nu se reduce la anticiparea următorului eveniment.

Această limită nu slăbește proiectul tehnic. Dimpotrivă, îl împiedică să colonizeze probleme pentru care nu oferă încă instrumente. Putem studia o componentă a înțelegerii, explicând ce acoperă: păstrarea consecințelor relevante sub transformări și costuri finite. Ceea ce nu acoperă trebuie lăsat explicit deschis.

Partenerul AI acceptă această ipoteză ca direcție funcțională investigabilă. Nu o transformă într-o identitate între minte și algoritm sau între sens și compresie. Autorul uman poate continua să susțină o intuiție mai amplă, dar evaluarea ei trebuie să se sprijine pe argumente suplimentare, nu pe succesul unor modele delimitate.

PARTEA IV / LABORATOARE PENTRU O IDEE DIFICILĂ

14. Lumi discrete în care știm ce căutăm

14.1. De ce să începem cu lumi construite

Simularea unei lumi construite oferă acces la mecanismul generator, la variabilele ascunse și la distribuția condițiilor inițiale. Cercetătorul poate cunoaște adevărul operațional chiar dacă agentul îl vede numai parțial. Această asimetrie permite separarea erorii de observație, a erorii de reprezentare și a erorii de învățare.

Riscul este alegerea unor lumi care avantajează exact metoda propusă. Pentru a-l controla, familiile trebuie să includă cazuri favorabile, cazuri nefavorabile și controale fără structura căutată. Distribuțiile parametrilor și criteriile de succes se stabilesc înaintea evaluării finale. O demonstrație spectaculoasă pe un singur mecanism nu este o hartă a domeniului.

Primele laboratoare nu ar trebui să înceapă cu limbaj natural general. Acolo, erorile de interpretare, cunoaștere și raționament sunt greu de separat. Un alfabet mic și o regulă transparentă pot dezvălui exact de ce o reprezentare funcționează. Complexitatea lingvistică va fi introdusă ulterior, după ce știm ce proprietate urmărim.

14.2. Laboratorul memoriei recurente

Generatorul de bază ar putea fi un contor modulo m , cu acțiuni de incrementare, resetare și interogare. Observatorul vede acțiunile efectuate și răspunsurile, dar nu valoarea internă. Putem varia m , lungimea episoadelor, frecvența resetărilor și raritatea interogărilor. Într-o versiune, toate acțiunile sunt vizibile; în alta, unele sunt ascunse sau corupte de zgomot.

Sarcinile ar fi predicția răspunsului următor, generarea unei secvențe valide și răspunsul după o secvență de acțiuni planificată. Comparatorii ar include un predictor fără memorie, contexte fixe și variabile, un automat învățat și un model care primește structura contorului. Ultimul este un reper al performanței cu reprezentarea corectă furnizată, nu un concurent la descoperirea autonomă.

Ipoteza favorabilă este că descoperirea unei stări recurente permite transferul spre episoade mult mai lungi fără o creștere proporțională a memoriei. Ipoteza alternativă este că această descoperire costă atât de mult sau este atât de fragilă încât un model de contexte rămâne mai avantajos în intervalele practice. Ambele rezultate ar spune ceva important.

Un control ar înlocui răspunsul modular cu o funcție aleatoare a unor istorii, fără o regulă compactă oferită clasei de modele. Dacă metoda continuă să raporteze stări „semnificative”, trebuie verificat dacă inventează structură. Alt control ar redenumi arbitrar simbolurile și ar permuta reprezentările, pentru a detecta dependența de convenții convenabile.

Măsurătorile relevante ar include pierderea predictivă, numărul de încălcări ale regulii, memoria totală, timpul de actualizare și costul învățării. Transferul trebuie testat atât pe lungimi noi, cât și pe valori ale parametrilor care definesc o familie nouă. Reușita pe lungimi mai mari în același modul nu dovedește că agentul a învățat conceptul general de aritmetică modulară.

14.3. Laboratorul structurii imbricate

O a doua familie ar folosi deschideri și închideri de tipuri diferite, cu o regulă clară de imbricare. Sarcina nu este simpla numărare: închiderea trebuie să corespundă ultimei deschideri neînchise. Observatorul poate vedea șirul complet sau o versiune cu elemente lipsă. Putem controla adâncimea, lungimea și distribuția tipurilor.

Comparația decisivă ar separa o stivă furnizată de una descoperită și de o soluție aproximativă bazată pe contexte. Un rezultat favorabil ar fi generalizarea stabilă spre adâncimi nevăzute, însoțită de identificarea mecanismului de memorie. Un rezultat mai modest, dar util, ar fi reducerea erorii numai într-un interval finit, cu o frontieră clară de degradare.

Ar trebui incluse secvențe aproape valide, dar cu o singură încălcare rară. Sistemul trebuie să distingă zgomotul de o schimbare a regulii. Dacă orice excepție este absorbită imediat printr-o regulă nouă, modelul poate pierde puterea de generalizare. Dacă orice excepție este respinsă, modelul poate deveni incapabil să învețe o convenție nouă. Acest compromis oferă o măsură concretă a rigidității și plasticității.

Un test de compoziție ar combina contorul și stiva într-o singură lume, fără să folosească această combinație la antrenare. Reușita ar indica reutilizarea componentelor în domeniul definit. Eșecul ar putea arăta că operațiile învățate sunt legate de contextul lor de origine și nu au devenit încă abstracții independente.

14.4. Laboratorul regulilor care par să se schimbe

A treia familie ar conține regimuri distincte: de exemplu, aceeași intrare este copiată într-un regim, inversată în altul și întârziată într-un al treilea. Regimul se poate schimba după un proces cunoscut cercetătorului. Observatorul nu primește eticheta regimului, dar poate primi indicii mai mult sau mai puțin informative.

Sunt necesare două etape. Mai întâi, numărul și natura regimurilor sunt furnizate, iar sistemul trebuie doar să infereze regimul curent. Apoi, acestea sunt necunoscute, iar sistemul trebuie să propună și să valideze structura. Confundarea etapelor ar transforma un succes de filtrare într-o afirmație nejustificată despre inventarea regulilor.

Putem măsura întârzierea detectării schimbării, rata alarmelor false, memoria păstrată despre regimurile vechi și performanța când un regim revine. Un agent care reînvață de la zero fiecare revenire nu a construit o bibliotecă reutilizabilă. Un agent care clasifică orice fluctuație drept regim nou poate memora zgomotul.

Rezultatul urmărit nu este demonstrarea că regulile dinamice sunt „de fapt” întotdeauna fixe. Această reducere formală are deja condițiile ei. Investigația ar arăta când o descriere prin stare extinsă poate fi găsită eficient din observații și când costul inferenței o face nepractică.

14.5. Ce ar însemna un eșec informativ

Dacă un automat cu structura corectă funcționează, dar învățarea lui eșuează, avem o problemă de descoperire. Dacă nici automatul corect nu prezice bine după ascunderea unor acțiuni, poate exista o limită de informație. Dacă modelul învață, dar ocupă mai multă memorie decât comparatorul, avantajul reprezentării nu a devenit avantaj de sistem.

Fiecare laborator trebuie să poată produce asemenea diagnostice. Obiectivul nu este să ofere o serie de victorii, ci să identifice ce resursă devine critică. Această hartă ar permite alegerea unor arhitecturi adecvate și ar preveni extrapolarea de la o regularitate simplă la promisiuni despre limbaj sau inteligență generală.

15. Scări, observații incomplete și mecanisme cauzale

15.1. Laboratorul scării de descriere

O familie de automate celulare ar permite compararea traiectoriilor microscopice cu proprietăți agregate: densitatea unui simbol, persistența unor regiuni, deplasarea unor tipare sau distribuția dimensiunii componentelor. Regulile locale pot fi cunoscute, în timp ce observatorul primește numai blocuri agregate sau eșantioane rare în timp.

Nu trebuie etichetată drept „ireductibilă” orice regulă care produce imagini complicate. Studiul ar trebui să compare costuri pentru sarcini concrete și să folosească rezultatele teoretice disponibile numai în domeniul lor. Coarse-graining-ul automatelor celulare oferă precedente pentru căutarea unor descrieri de scară mare mai simple decât evoluția detaliată. [8]

Ipoteza favorabilă este existența unor variabile agregate cu dinamică suficient de autonomă pentru predicții utile. Ipoteza alternativă este că agregarea pierde informație care reapare ulterior în observabile. În acel caz, modelul de scară mare ar avea nevoie de memorie, de variabile suplimentare sau de un zgomot dependent de istorie.

Un protocol ar varia dimensiunea blocurilor, intervalul dintre observații și orizontul de predicție. Ar compara un model local fără memorie, unul cu memorie și simularea detaliată. Câștigul trebuie raportat pentru aceeași observabilă, nu prin compararea unei medii aproximative cu o traiectorie exactă pe care cealaltă metodă a fost obligată să o producă.

15.2. Când eliminarea detaliilor creează memorie

Să observăm numai poziția unui obiect care se deplasează, nu și viteza. Două situații cu aceeași poziție pot avea continuări diferite. Un model fără memorie al poziției este insuficient; un istoric scurt poate ajuta la estimarea vitezei. Aparent, regula la nivel observat depinde de trecut, deși dinamica extinsă poate fi simplă.

Această situație generalizează intuiția autorului uman. Uneori „mai multe reguli” sunt prețul eliminării unor variabile. Observatorul compensează informația ascunsă prin excepții condiționate de istorie. O reprezentare mai bună ar putea înlocui excepțiile printr-o variabilă latentă, dar identificarea acelei variabile nu este garantată.

Un experiment ar controla sistematic variabilele ascunse și zgomotul de măsurare. Ar urmări dacă memoria predictivă crește când observarea se degradează și dacă această creștere poate fi explicată prin incertitudinea asupra variabilei eliminate. Un rezultat negativ ar fi important: poate că informația pierdută nu mai este recuperabilă din trecutul observat.

15.3. Descoperirea ecuațiilor ca test al simplității relative

Pentru sisteme dinamice continue, putem porni de la ecuații cunoscute și oferi agentului numai măsurători. Metodele de identificare rară a dinamicii caută combinații compacte de termeni într-o bibliotecă de funcții. SINDy reprezintă un exemplu important, iar identificarea ecuațiilor cu derivate parțiale extinde această direcție spre fenomene distribuite spațial. [29, 30]

Ipoteza de raritate trebuie făcută vizibilă. O ecuație poate fi scurtă în coordonatele naturale și lungă după o transformare neliniară a observațiilor. Dacă biblioteca include exact termenii generatorului, problema este mai favorabilă decât atunci când termenii relevanți lipsesc. Succesul nu trebuie prezentat ca descoperire fără ipoteze a legilor naturii.

O investigație potrivită ar avea trei brațe: coordonate favorabile cunoscute, coordonate transformate și observație parțială. Am putea varia precizia, frecvența eșantionării și zgomotul. Rezultatul important ar fi nu numai ecuația recuperată, ci stabilitatea predicțiilor și a intervențiilor în regiuni nevăzute ale spațiului de stare.

Dacă mai multe ecuații au performanțe similare pe datele disponibile, studiul trebuie să păstreze ambiguitatea. O ecuație scurtă poate fi preferată ca ipoteză, dar alegerea nu dovedește unicitatea mecanismului. Pot fi necesare noi condiții inițiale sau perturbări pentru separare.

15.4. Laboratorul dublelor observaționale

Construim perechi de mecanisme cu aceeași distribuție pasivă și cu efecte diferite ale unor intervenții. Perechea becurilor este forma elementară. Familii mai bogate pot varia numărul variabilelor, dependențele ascunse și tipurile de acțiuni disponibile. Agentul trebuie să aleagă ce experiment ar reduce ambiguitatea.

Comparațiile ar include alegerea aleatoare a intervenției, o politică bazată pe dezacordul dintre modele și o politică ce primește structura cauzală. Ultima oferă un reper al experimentului ideal în clasa dată. Costul intervențiilor și numărul încercărilor trebuie incluse, nu doar corectitudinea finală a modelului.

Un rezultat favorabil ar fi reducerea numărului de intervenții necesare pentru a selecta o clasă cauzală corectă. Un rezultat nefavorabil ar fi concentrarea repetată pe intervenții care separă modelele curente, dar ignoră mecanismul adevărat deoarece acesta lipsește din clasa de candidați. Pentru a detecta această situație, sunt necesare mecanisme de test care nu apar în familia de antrenare.

Acest laborator ar putea produce o legătură precisă între compresie și experiment: reprezentările mai compacte pot facilita căutarea unor intervenții, dar pot și elimina distincțiile care le făceau necesare. Programul nu trebuie să presupună dinainte semnul efectului.

15.5. Aproximări care păstrează controlul

Un model de scară mare ar trebui testat nu numai prin prognoză, ci și prin folosirea lui pentru alegerea acțiunilor. Dacă o aproximare prezice bine în regim pasiv, dar recomandă acțiuni care duc sistemul într-o regiune necunoscută, eroarea de control poate deveni mare. Distribuția sub politica agentului nu este aceeași cu distribuția datelor inițiale.

Un protocol ar evalua performanța în buclă închisă, respectarea limitelor și frecvența revenirii la modelul detaliat. O aproximație ar putea fi valoroasă tocmai pentru că știe când nu mai este valabilă. Detectarea ieșirii din domeniu ar deveni o capacitate măsurabilă, nu doar o avertizare adăugată în documentație.

Nu toate aplicațiile cer control de risc înalt. Primele teste pot folosi medii sintetice fără consecințe externe. Extinderea spre sisteme reale ar necesita validări specifice domeniului, independent de eleganța cadrului general.

16. Biblioteci în creștere și lumi descrise prin limbaj

16.1. Laboratorul invenției de operații

Un mediu ar putea furniza sarcini compoziționale construite dintr-un nucleu mic de transformări. Unele combinații apar frecvent, altele numai la evaluare. Agentul poate propune operații derivate și le poate păstra într-o bibliotecă. Cercetătorul urmărește dacă biblioteca devine un vocabular reutilizabil sau o colecție de soluții memorate.

Trebuie comparate o bibliotecă fixă, o bibliotecă ce crește numai prin memorare și una care permite abstracții parametrizate. Un reper suplimentar ar primi biblioteca utilă de la început. Diferența dintre acesta și agentul care o descoperă estimează costul construirii repertoriului, fără a-l confunda cu utilitatea repertoriului deja disponibil.

Măsurile ar include lungimea sarcinilor după rescriere, timpul total amortizat, numărul reutilizărilor pe sarcini noi și dimensiunea completă a bibliotecii. Dacă o operație este utilizată o singură dată, economia de notație poate ascunde un cost suplimentar. Dacă o abstracție este reutilizată în contexte structurale noi, există un semnal mai puternic de generalizare.

16.2. Noutate lexicală, noutate funcțională, extensie de primitive

Programul trebuie să distingă trei evenimente. Primul este introducerea unui nume nou pentru o operație existentă. Al doilea este descoperirea unei compoziții care rezolvă sarcini anterior inaccesibile în bugetul disponibil. Al treilea este primirea unei primitive externe, cu o capacitate care nu era disponibilă în nucleul declarat.

Al doilea eveniment este deosebit de important. Deși nu mărește computabilitatea teoretică a unui nucleu universal, poate mări puterea practică a agentului. Sub un buget finit, ceea ce poate fi realizat contează mai mult decât ceea ce ar putea fi calculat după un timp nelimitat. Aceasta este o formă precisă de noutate relativă la resurse.

Al treilea eveniment trebuie contabilizat ca aport extern. Dacă agentul primește un serviciu care rezolvă o clasă de probleme, nu a descoperit singur acea capacitate. Poate totuși învăța să o combine eficient. Proiectarea unui sistem deschis nu este o eroare; eroarea ar fi ascunderea deschiderii în evaluare.

16.3. Ce poate însemna creștere deschisă

O lume cu obiecte compuse și reguli de interacțiune poate produce structuri tot mai variate. Cercetarea despre evoluția deschisă discută condițiile în care apar noutăți persistente și relevanța arhitecturii mediului. Aceasta oferă un vocabular pentru întrebarea autorului uman despre repertorii dinamice, fără a demonstra că orice generator de varietate are o capacitate nelimitată de inovație. [26]

Într-un studiu finit, „nu am observat saturarea” nu înseamnă „nu există o limită”. Putem însă defini indicatori locali: rata apariției unor capacități noi, diversitatea consecințelor, transferul între sarcini și costul menținerii vechilor competențe. Indicatorul trebuie să evite recompensarea simplei acumulări de etichete.

Un test puternic ar cere ca noutatea să schimbe o mulțime de probleme rezolvabile sub un buget fix. Un test suplimentar ar verifica dacă noile operații pot fi explicate prin compoziții ale nucleului. Dacă da, am observat extinderea repertoriului practic, nu schimbarea legilor fundamentale. Dacă nu, trebuie verificat mai întâi dacă am omis o sursă de informație sau o operație externă.

16.4. Laboratorul lumilor textuale coerente

O lume textuală de test poate conține obiecte, locuri, posesii, evenimente și reguli condiționale. Starea semantică de referință este cunoscută evaluatorului. Aceeași lume poate fi descrisă prin formulări diferite, iar descrieri asemănătoare pot ascunde diferențe de negație, timp sau condiție. Agentul vede textul și primește întrebări sau acțiuni.

Prima etapă ar separa interpretarea textului de executarea consecințelor. Un braț primește direct reprezentarea semantică; altul trebuie să o extragă. Diferența dintre ele localizează costul limbajului. Un al treilea braț poate primi interpretări candidate și trebuie să păstreze ambiguitatea până când o întrebare sau o observație o rezolvă.

Sarcinile ar include actualizarea locului unui obiect, identificarea unei contradicții, răspunsul la o întrebare contrafactuală și integrarea

unei reguli noi. Trebuie introduse cazuri în care răspunsul corect este „nu rezultă din informațiile disponibile”. Un model care completează întotdeauna golurile poate părea fluent, dar pierde distincția dintre fapt, presupunere și posibilitate.

Rezultatul urmărit ar fi conservarea consecințelor sub parafrază și compoziție, nu asemănarea răspunsului cu o frază de referință. O formulare diferită poate fi perfect corectă; o formulare aproape identică poate inversa o negație. Evaluarea semantică are nevoie de criterii independente de stilul exprimării.

16.5. Revizuirea credințelor fără rescriere arbitrară a lumii

Într-o etapă mai dificilă, agentul primește o informație care infirmă o presupunere anterioară. Trebuie să schimbe concluziile dependente de ea și să păstreze concluziile independente. Proveniența afirmațiilor poate ajuta la localizarea revizuirii, dar trebuie verificat dacă dependențele au fost reprezentate corect.

Putem măsura numărul concluziilor corect retractate, numărul retractărilor inutile, persistența contradicțiilor și costul recalculării. Un model care rescrie toate concluziile poate fi corect, dar inefficient. Un model care păstrează prea mult poate rămâne inconsistent. O bibliotecă de operații ar putea accelera revizuirea numai dacă domeniile de validitate sunt explicate.

Acest laborator se apropie de intuiția unei lumi care trebuie să continue consecvent. Nu presupune că orice poveste are o singură interpretare. Dimpotrivă, poate trata explicit mai multe lumi compatibile cu textul. Ceea ce se cere este ca agentul să nu schimbe tacit lumea de referință doar pentru a produce răspunsul convenabil.

17. Cum recunoaștem un rezultat și cum evităm autoamăgirea

17.1. Fiecare afirmație are propria măsurătoare

„Prezice bine” poate însemna log-loss mic, probabilități calibrate sau alegerea frecventă a simbolului corect. „Generează coerent” poate însemna respectarea unor invarianți pe secvențe lungi. „Înțelege intervenții” poate însemna estimarea corectă a efectelor acțiunilor. Aceste proprietăți trebuie evaluate separat.

Log-loss-ul penalizează probabilitatea mică acordată evenimentului realizat. Calibrarea compară frecvențele observate cu probabilitățile declarate în grupuri de predicții. Acuratețea unei alegeri poate ignora distribuția completă. Niciuna nu înlocuiește automat celelalte, iar agregarea lor într-un singur scor poate ascunde eșecuri importante.

Pentru constrângeri, ar trebui raportate atât frecvența încălcărilor, cât și timpul până la prima încălcare, gravitatea și contextul. Pentru predicții pe termen lung, evaluarea se face la mai multe orizonturi. Pentru sisteme adaptive, trebuie măsurată și perioada de revenire după o schimbare, nu numai performanța după stabilizare.

17.2. Absența încălcărilor nu este o demonstrație

Dacă n încercări independente, cu aceeași probabilitate necunoscută p de eșec, nu produc niciun eșec, probabilitatea acestui rezultat este $(1-p)^n$ la puterea n . O limită superioară unilaterală exactă, la nivel de încredere $1-\alpha$, este $1-\alpha$ la puterea $1/n$. Pentru $\alpha=0,05$ și n mare, aproximarea este aproape $3/n$.

$p(\text{superior}) = 1 - \alpha^{1/n}$, după zero eșecuri în n încercări independente

Aceasta este o limită statistică sub ipotezele enunțate, nu o garanție că p este zero. Dacă încercările sunt puternic dependente, numărul lor brut nu poate fi introdus în formulă ca și cum ar fi independent. Un milion de simboluri dintr-o singură traiectorie nu echivalează automat cu un milion de experimente independente.

Pentru evenimente rare, putem construi teste țintite care le fac accesibile. Dar frecvența eșecurilor în distribuția țintită nu trebuie

raportată ca frecvență naturală fără corecție. Sunt două întrebări: cât de des ajungem în situația critică și cât de bine ne comportăm odată ajunși acolo.

17.3. Separarea datelor și a familiilor

Antrenarea, selecția modelului și evaluarea finală trebuie să folosească informații distincte. Dacă ne uităm repetat la setul final și schimbăm metoda, acel set a devenit parte din dezvoltare. Pentru a susține transferul, avem nevoie de mecanisme, parametri sau combinații păstrate separat, nu doar de alte secvențe produse de aceeași instanță.

Un protocol poate avea trei niveluri: instanțe noi din aceeași distribuție, intervale de parametri noi și familii de mecanisme noi. Fiecare nivel justifică o afirmație diferită. Generalizarea la primul nivel nu implică automat generalizarea la al treilea.

Semințele aleatoare multiple ajută la estimarea variabilității, dar nu repară un eșantion conceptual îngust. O sută de rulări ale aceleiași lumi favorabile nu înlocuiesc controale structurale. Trebuie raportate atât variația între rulări, cât și variația între tipuri de lumi.

17.4. Comparații echitabile și contribuții reale

Comparatorii trebuie să primească acces comparabil la observații și intervenții. Dacă o metodă primește numărul stărilor, schema semantică sau o bibliotecă de primitive, aceste avantaje se declară. Putem include brațe cu informație suplimentară pentru diagnostic, dar nu le amestecăm într-un clasament unic.

Costul total include căutarea hiperparametrilor, construirea reprezentării, transformarea datelor, validarea și răspunsul. Pentru un model preantrenat, costul marginal al utilizării poate fi relevant unei aplicații, dar nu trebuie confundat cu costul descoperirii capacității de la zero. Sunt două perspective legitime care răspund unor întrebări diferite.

O analiză prin eliminarea componentelor ar dezactiva, pe rând, fuziunea stărilor, creșterea bibliotecii, verificarea contractelor și explorarea activă. Dacă performanța nu se schimbă, componenta poate fi inutilă în domeniul testat. Dacă eliminarea îmbunătățește rezultatele, avem un indiciu că mecanismul adăugat introduce cost sau eroare.

17.5. Ce nu poate spune o estimare empirică a echivalenței

În spații foarte mari, distanța TV dintre distribuții întregi nu poate fi estimată arbitrar de precis cu puține observații fără ipoteze suplimentare. Practic, putem evalua evenimente selectate, clase de discriminatori sau statistici de interes. Acestea definesc teste utile, dar mai slabe decât o verificare exhaustivă.

Raportul trebuie să specifice unde există o garanție și unde există doar o încercare de detectare. O demonstrație pentru o clasă finită, o enumerare completă pe un orizont și un test statistic pe date sunt forme diferite de sprijin. Nu le vom numi toate „validare” fără calificare.

În sens invers, eșecul unei căutări nu demonstrează inexistența unei reprezentări compacte. Poate că algoritmul nu a găsit-o, limbajul nu o exprimă eficient sau bugetul a fost insuficient. Un rezultat de imposibilitate cere o demonstrație în clasa declarată. O limită practică poate fi raportată ca limită practică și rămâne valoroasă.

17.6. Un registru al afirmațiilor

Pentru fiecare concluzie ar trebui păstrat un registru cu enunțul exact, ipotezele, dovezile și tipul de test care ar putea-o infirma. O afirmație despre economie de memorie trebuie să arate ce s-a numărat. O afirmație despre descoperirea unei reguli trebuie să distingă ce a fost furnizat de ce a fost inferat. O afirmație despre transfer trebuie să identifice ce anume a fost nou.

Registrul nu este birocrație adăugată cercetării. El împiedică migrarea neobservată a concluziilor: de la „funcționează în această familie” la „explică înțelegerea”, de la „nu am găsit încălcări” la „este sigur” sau de la „am comprimat descrierea” la „am descoperit legile lumii”.

Un rezultat negativ bine localizat poate deveni mai util decât un rezultat pozitiv vag. El arată o variabilă lipsă, o ipoteză greșită sau o frontieră de resurse. Tocmai aceste informații îi permit unui cercetător viitor să continue fără să repete aceeași confuzie.

PARTEA V / PROGRAMUL ȘI LIMITELE LUI FERTILE

18. Ipoteze care pot pierde și propoziții care pot fi demonstrate

18.1. Ipoteza stării care înlocuiește istoria

Prima ipoteză empirică afirmă că, în familii cu dependențe recurente identificabile, descoperirea unei stări actualizabile poate deplasa favorabil frontiera cost-fidelitate față de extinderea contextelor. Afirmatia trebuie legată de familii, bugete și comparatori concreți. Nu spune că starea învățată va fi întotdeauna mai mică și nici că orice proces are o reprezentare finită.

Ar sprijini ipoteza un avantaj care persistă pe istorii mai lungi și după includerea costului învățării. Ar slăbi-o un avantaj care dispare când comparatorul primește același buget sau când simbolurile sunt recodificate. Ar delimita-o un eșec sistematic în regimuri cu observație prea săracă, însoțit de dovada că stări ascunse diferite rămân indistinguibile.

Fenomenul de căutat este o schimbare de regim a reprezentării. Inițial, datele suplimentare pot produce contexte suplimentare. Ulterior, o regularitate descoperită poate permite unirea lor într-o stare comună. Dacă o asemenea comprimare apare, trebuie verificat că nu a fost cumpărată prin pierderea distincțiilor rare.

18.2. Ipoteza costului cauzal al comprimării

A doua ipoteză afirmă că o reprezentare optimizată exclusiv pentru observații pasive poate elimina distincții necesare intervențiilor. În familiile cu duble observaționale, diferența poate fi demonstrată constructiv. Întrebarea empirică este cât de frecvent și cât de grav apare efectul în clase mai largi de probleme.

Ar sprijini ipoteza o deteriorare intervențională controlată de gradul comprimării, în condițiile în care performanța observațională rămâne stabilă. Un rezultat contrar ar arăta că, în familia analizată, structura predictivă reține deja distincțiile cauzale sau că un criteriu suplimentar le conservă cu cost mic.

Aici nu căutăm confirmarea sloganului „corelația nu este cauzalitate”, ci o hartă cantitativă: ce distincții se pierd, ce intervenții le dezvăluie și ce cost are recuperarea lor. O asemenea hartă ar putea ghida alegerea unor reprezentări pentru agenți care trebuie să acționeze, nu doar să descrie.

18.3. Ipoteza scurtăturii amortizate

A treia ipoteză afirmă că învățarea unor operații reutilizabile produce un prag de reutilizare dincolo de care costul total scade. Dacă descoperirea și verificarea costă C , iar fiecare utilizare economisește s unități față de procedura de referință, un model contabil simplificat are pragul C/s , cu s pozitiv.

$$N \cdot s > C \Rightarrow \text{economie totală}$$

Acesta este un calcul contabil, nu o teorie a învățării. În practică, s poate varia între intrări, iar biblioteca adaugă costuri de selecție și întreținere. Ipoteza empirică este că există sarcini în care pragul rămâne realist după includerea acestor costuri și că avantajul se transferă spre utilizări noi.

Un eșec informativ ar fi proliferarea unor operații rareori reutilizate. Altul ar fi o economie aparentă obținută prin schimbarea formatului ieșirii. Rezultatul dorit este o reducere a muncii pentru același contract, nu doar o descriere mai elegantă a muncii ascunse.

18.4. Ipoteza dublei dezvoltări a memoriei

A patra ipoteză afirmă că un sistem de învățare eficient are nevoie atât de expansiune, cât și de reorganizare. Expansiunea păstrează distincții noi; reorganizarea găsește regularități între ele. O memorie care numai crește poate deveni prea costisitoare. O memorie care numai comprimă poate pierde noutăți importante.

Predicția empirică este apariția unor cicluri de diferențiere și reunificare, corelate cu modificarea sarcinilor. Pentru a nu transforma orice fluctuație într-o confirmare, trebuie definit dinainte ce constituie o distincție, ce constituie o fuziune și ce îmbunătățire minimă justifică schimbarea. Costul instabilității structurii trebuie și el măsurat.

Un rezultat negativ ar fi că reorganizarea repetată consumă mai mult decât economisește sau că provoacă uitare sistematică. În acel caz, poate fi preferabilă o bibliotecă mai rigidă, segmentată pe domenii.

Programul nu presupune că plasticitatea maximă este întotdeauna optimă.

18.5. Prima propoziție: închiderea regulilor dinamice

Propoziție. Dacă actualizarea stării și actualizarea regulilor sunt computabile, iar informația necesară este inclusă în starea extinsă sau în intrări explicit modelate, sistemul poate fi descris printr-o singură funcție computabilă fixă de actualizare a stării extinse.

Justificare. Considerăm perechea (x, r) . Evaluăm funcția de tranziție a lui x folosind r și evaluăm funcția de actualizare a lui r folosind datele specificate. Perechea rezultatelor este noua stare extinsă. Compoziția acestor calcule definește funcția fixă G . Dacă actualizările folosesc valori simultane sau o ordine particulară, această convenție este inclusă în G .

Propoziția nu spune că spațiul stărilor este finit, că G poate fi dedus din observații sau că descrierea obținută este eficientă. Ea este o clarificare structurală. Cercetarea începe atunci când întrebăm cât costă reprezentarea și descoperirea lui G într-o clasă concretă.

18.6. A doua propoziție: compunerea erorilor de reprezentare

Propoziție. Dacă două transformări succesive între distribuții folosesc interfețe compatibile și au erori TV cel mult ε_1 și ε_2 în domeniul declarat, eroarea compunerii este cel mult $\varepsilon_1 + \varepsilon_2$. Rezultatul folosește faptul că aplicarea aceleiași transformări probabilistice nu mărește TV și inegalitatea triunghiului.

Justificare. Introducem o distribuție intermediară ideală. Prima diferență este eroarea primei aproximări transportată prin transformarea comună, deci nu poate depăși ε_1 . A doua este eroarea celei de-a doua aproximări, cel mult ε_2 . Suma le limitează pe amândouă. Limita poate fi tăiată la unu, deoarece TV nu depășește unu.

Rezultatul cere ca garanția celei de-a doua operații să se aplice distribuției pe care o primește efectiv. Dacă prima aproximare trimite sistemul în afara domeniului celei de-a doua, compoziția nu este certificată. O extensie ar putea adăuga probabilitatea ieșirii din domeniu la bugetul de eroare. Aceasta oferă o direcție concretă pentru contractele operațiilor învățate.

18.7. A treia propoziție: o stare exactă trebuie să separe continuări incompatibile

Propoziție. Într-un predictor determinist exact, două istorii care admit aceeași secvență de acțiuni viitoare, dar impun răspunsuri diferite la ea, nu pot fi reprezentate prin aceeași stare internă dacă actualizarea și răspunsul depind numai de acea stare și de acțiuni.

Justificare. Pornind din aceeași stare și aplicând aceeași secvență de acțiuni, predictorul determinist ar produce același răspuns. Acesta nu poate coincide cu două răspunsuri obligatoriu diferite. Prin contradicție, stările interne trebuie să difere.

Aceasta oferă o metodă de construire a bornelor de memorie: identificăm istorii separabile prin continuări. Pentru predicții probabilistice aproximative sunt necesare margini de separare și criterii suplimentare. Nu vom extrapola direct numărul stărilor exacte la dimensiunea minimă a oricărui model neuronal sau stocastic.

18.8. O întrebare teoretică accesibilă: cât costă separarea candidaților?

Presupunem o familie finită de m modele și un test cu rezultat binar pentru fiecare pereche relevantă. Presupunem că probabilitățile de acceptare diferă cu cel puțin Δ pentru modelele pe care vrem să le separăm și că putem repeta independent testele. Atunci concentrarea mediilor empirice permite delimitarea unui număr de observații suficient, dependent de Δ , de numărul testelor și de nivelul de eroare tolerat.

De exemplu, pentru k teste fixe, probabilitatea ca oricare medie empirică să se abată de la valoarea sa cu mai mult de $\Delta/4$ este cel mult $2k \exp(-n\Delta^2/8)$, folosind o bornă Hoeffding și reuniunea evenimentelor. Prin urmare, $n \geq (8/\Delta^2) \ln(2k/\alpha)$ este suficient pentru ca toate aceste estimări să fie simultan în toleranță cu probabilitate cel puțin $1-\alpha$. [32]

Această afirmație privește estimarea testelor, nu recuperarea automată a oricărui model. Pentru identificare mai trebuie ca testele să separe efectiv candidații, ca probabilitățile prezise de candidați să fie cunoscute suficient de precis și ca modelul relevant să fie inclus în familie. Accesul la încercări independente poate avea un cost mare sau poate fi imposibil.

O contribuție de cercetare ar putea extinde asemenea rezultate la teste active, costuri diferite ale intervențiilor și biblioteci care se modifică în timpul învățării. În locul unei promisiuni universale de descoperire, am obține condiții verificabile în care o ambiguitate poate fi redusă.

19. Organizarea cercetării pentru oameni și parteneri AI

19.1. Etape definite prin dovezi, nu prin entuziasm

Prima etapă ar stabili vocabularul operațional și ar verifica exemplele analitice. Echipa trebuie să poată spune ce este o stare, ce cost măsoară și ce tip de echivalență afirmă. Trecerea la etapa următoare cere acord asupra acestor contracte, nu acord asupra metafizicii autorului.

A doua etapă ar studia familiile discrete. Scopul este localizarea mecanismelor care produc avantajele sau eșecurile. Nu este necesară o arhitectură complexă unificată. Dimpotrivă, componentele izolate permit diagnosticarea. Trecerea mai departe ar cere rezultate robuste la controale structurale și o contabilitate completă a resurselor.

A treia etapă ar adăuga intervenții, observații incomplete și variația scării. Aici se verifică dacă reprezentările rămân utile când agentul schimbă distribuția prin acțiunile sale. Numai după această etapă ar fi justificată integrarea cu lumi textuale mai bogate și cu biblioteci de operații propuse de sisteme AI.

19.2. Ce roluri pot fi delegate

Un partener AI poate propune modele, poate identifica analogii cu literatura, poate formula cazuri-limită și poate sugera intervenții care separă ipoteze. Un alt rol este verificarea locală a derivărilor și căutarea contraexemplurilor. Aceste sarcini sunt valoroase tocmai pentru că pot fi evaluate prin produse verificabile.

Un sistem care formulează ipoteza nu ar trebui să fie singurul evaluator al succesului ei. Mai multe sisteme AI nu constituie automat evaluatori independenți: pot împărtăși surse, presupuneri și erori. Independența trebuie construită prin metode diferite, acces separat la informații și verificatoare care nu se bazează numai pe consens verbal.

Cercetătorii umani rămân responsabili de sensul întrebării, de alegerea consecințelor relevante și de utilizarea concluziilor. Această responsabilitate nu dispare când calculul sau redactarea sunt delegate. La rândul lor, oamenii pot fi părținitori; de aceea, procesul trebuie

proiectat pentru critică reciprocă, nu pentru protejarea intuiției fondatoare.

19.3. Un dosar pentru fiecare operație intelectuală importantă

O ipoteză ar trebui să aibă un dosar scurt: motivul formulării, legătura cu lucrările existente, premisele, predicția distinctivă și rezultatul care ar determina revizuirea. O abstracție ar trebui să aibă un contract. O concluzie empirică ar trebui să aibă un protocol și o delimitare a generalizării.

Acest dosar poate fi folosit de cercetători viitori, umani sau AI, pentru a continua investigația fără a reconstrui intențiile inițiale. Documentația trebuie să explice nu doar ce s-a ales, ci și de ce alternativele au fost respinse. Un eșec neexplicat invită repetarea lui; un eșec contextualizat devine cunoaștere reutilizabilă.

La nivel conceptual, dosarul este el însuși o aplicație a programului: comprimă o istorie de cercetare într-o stare suficientă pentru continuarea responsabilă. Nu trebuie să păstreze fiecare detaliu, dar trebuie să păstreze premisele și fragilitățile care pot schimba următorul pas.

19.4. Unde ar putea apărea o contribuție originală

Noțiunile de stare predictivă, rată–distorsiune, bisimulare, abstracție cauzală și învățare a bibliotecilor există deja. Simplul fapt că sunt aduse împreună nu garantează noutatea științifică. O contribuție originală trebuie identificată printr-un rezultat: o nouă condiție de compunere, un algoritm cu proprietăți demonstrate, un diagnostic reproductibil sau o familie de contraexemple care schimbă o presupunere.

O direcție promițătoare ar combina stări predictive actualizabile cu operații reutilizabile având contracte de fidelitate și cost. Alta ar studia cum alegerea intervențiilor schimbă frontiera memorie–predicție. O a treia ar investiga certificate locale care permit unui sistem să treacă de la o aproximare rapidă la un mecanism detaliat atunci când riscul crește.

Abstracția cauzală este deja folosită ca fundament pentru interpretabilitatea mecanistică a modelelor AI. Orice proiect care leagă stările și operațiile interne de explicații cauzale trebuie să se poziționeze explicit față de această literatură. [24]

19.5. Reguli de oprire și reguli de continuare

O direcție ar trebui restrânsă când avantajul dispare după contabilizarea resurselor sau când nu se transferă dincolo de exemplele care au inspirat-o. Restrângerea nu înseamnă că intuiția generală a fost infirmată în toate formele; înseamnă că o anumită instanțiere nu și-a susținut promisiunea.

O direcție merită continuată când produce distincții noi și verificabile, chiar înainte de a depăși toate metodele existente. Descoperirea unei limite de observație, a unei condiții de eșec al fuziunii sau a unei separări între fidelitatea pasivă și cea intervențională poate justifica un program propriu.

Criteriul de maturitate nu este capacitatea cadrului de a redenumi orice fenomen. Este capacitatea de a recomanda o investigație precisă, de a anticipa rezultate diferite pentru ipoteze rivale și de a transforma un rezultat neașteptat într-o modificare explicită a teoriei.

20. Ce rămâne din intuiția inițială

20.1. O lume nu este obligată să semene cu explicația noastră

La început, intuiția autorului uman opune consistența realității libertății reprezentării. La sfârșitul analizei, opoziția rămâne fertilă, dar nu în forma unei clasificări absolute. Un text este un proces real, o ficțiune poate fi guvernată de reguli stricte, iar un fenomen real poate rămâne greu de comprimat pentru observatorul său.

Ceea ce supraviețuiește este ideea obligației de a păstra consecințele. Un model explicativ nu poate introduce gratuit rezultatul dorit fără să declare o premisă, o operație sau o sursă de informație. O scurtătură trebuie să arate ce înlocuiește. O regulă nouă trebuie să spună dacă este o definiție, o inferență, o convenție sau o modificare efectivă a mecanismului.

Această disciplină nu demonstrează că universul are un nucleu mic de legi. Ea ne oferă însă o metodă pentru a nu confunda simplitatea exprimării cu simplitatea producerii. „Este așa” și „rezultă astfel” pot avea aceeași formă gramaticală, dar au obligații diferite.

20.2. Înțelegerea ca putere de continuare

O formulare de lucru, acceptată de partenerul AI ca ipoteză investigabilă, este că o componentă a înțelegerii constă în construirea unei reprezentări care poate continua corect sub întrebări și transformări relevante, folosind resurse finite. Această componentă implică selectarea stării, păstrarea dependențelor și recunoașterea domeniului de validitate.

Formularea nu spune că înțelegerea este numai predicție sau numai calcul. Ea izolează o proprietate pe care o putem testa. Un sistem care repetă o explicație, dar nu poate actualiza consecințele unei schimbări simple, nu manifestă această proprietate în domeniul respectiv. Un sistem care o manifestă nu este prin aceasta dovedit conștient sau înțelept.

Autorul uman propune o intuiție mai largă: poate că ceea ce numim inteligență este, în parte, capacitatea de a construi lumi interne în care salturile devin justificate. Cercetarea trebuie să descompună această propoziție în operații observabile, fără a-i pierde întrebarea centrală și fără a-i transforma amplitudinea într-o dovadă.

20.3. Aproximarea nu este o versiune rușinoasă a adevărului

O aproximare este legitimă când spune ce distincții nu mai face și de ce ele nu afectează sarcina în condițiile declarate. Uneori, eliminarea detaliilor este exact ceea ce permite identificarea unei regularități. Alteori, detaliul eliminat controlează un eveniment rar decisiv. Nicio preferință generală pentru simplitate nu decide singură între aceste situații.

De aceea, teoria căutată nu ar trebui să ofere o singură reprezentare finală. Ar trebui să permită navigarea între reprezentări: mai detaliată când apar întrebări noi, mai compactă când repetăm sarcini cunoscute, mai prudentă când intervențiile ies din domeniul verificat. Schimbarea nivelului de descriere poate fi o competență în sine.

Aici aproximarea devine o problemă profundă: ce putem uita fără să pierdem puterea de a continua? Răspunsul depinde de viitorul pe care îl considerăm posibil, de acțiunile pe care le permitem și de costurile pe care le putem suporta. Nu este relativism arbitrar, ci o relație precisă între lume, observator și scop.

20.4. Ceea ce nu știm încă

Nu știm în general când un agent poate descoperi eficient starea predictivă potrivită. Nu știm cât de departe poate fi extinsă automatizarea contractelor pentru operații învățate din limbaj. Nu știm dacă un cadru unificat va produce avantaje practice suficient de mari pentru a justifica propriul cost. Aceste incertitudini sunt probleme de cercetare, nu motive pentru a afirma anticipat succesul sau eșecul.

Nici întrebarea ontologică nu dispare. Poate că lumea are o descriere generativă compactă. Poate că această compactitate este locală, dependentă de nivel sau insuficientă pentru faptele particulare. Un program experimental nu poate tranșa singur toate aceste posibilități, dar poate clarifica ce consecințe ar avea fiecare pentru observatori finiți.

O teorie utilă ar putea rezulta dintr-o convergență de mici rezultate: o stare recuperată, o abstracție infirmată, o limită demonstrată, o intervenție aleasă mai bine, o operație verificată și reutilizată. Niciunul nu ar explica singur existența. Împreună, ar putea explica mai bine cum construim reprezentări care merită încredere.

20.5. Întrebarea de lăsat cercetătorilor viitori

Nu este necesar să începeți prin a accepta că totul este calcul sau că orice lume se reduce la puține reguli. Este suficient să alegeți un sistem, un observator și o familie de consecințe. Întrebați ce informație trebuie păstrată, ce transformări pot fi scurtate și ce rezultat v-ar demonstra că ați simplificat prea mult.

Dacă o reprezentare mai mică păstrează mai mult decât vă așteptați, căutați motivul. Dacă eşuează într-un detaliu rar, nu ascundeți detaliul în medie. Dacă o regulă nouă apare, întrebați unde s-a aflat înainte costul ei: în experiență, în căutare, în nucleul de operații sau într-o sursă externă.

Intuiția autorului uman nu cere să fie protejată de aceste întrebări. În forma ei cea mai valoroasă, le cere. O lume inteligibilă nu este una despre care putem spune orice, ci una în care unele treceri dintre afirmații și consecințe pot fi justificate. Programul acestei cărți începe acolo unde încercăm să aflăm cât ne costă acea justificare și cât din ea putem face explicit.

ANEXE / INSTRUMENTE PENTRU CONTINUARE

Vocabularul de lucru

A.1. Termeni care trebuie păstrați distincți

Regulă generativă. O transformare care determină o continuare sau o distribuție de continuări, în condiții precizate. O regulă nu este evaluată numai după lungimea numelui ei, ci după descrierea mecanismului pe care îl invocă.

Metaregulă. O regulă care modifică alte reguli sau reprezentările lor. Dacă modificarea este computabilă, ea poate fi inclusă într-o dinamică fixă a unei stări extinse, fără garanția că acea stare este finită sau ușor de inferat.

Regulă derivată. O operație definită prin compunerea ori transformarea unor operații existente. Poate extinde repertoriul practic al agentului fără a extinde clasa funcțiilor computabile de nucleul său.

Stare generativă. Informația folosită de mecanism pentru a determina tranziția următoare. Nu trebuie să fie direct accesibilă observatorului.

Stare predictivă. Informația pe care observatorul o păstrează pentru a anticipa continuările. Poate fi o distribuție asupra stărilor generative și poate avea o complexitate foarte diferită de a acestora.

Suficiență. Proprietatea unei reprezentări de a păstra informația necesară unei clase declarate de întrebări. Nu înseamnă păstrarea tuturor proprietăților sistemului.

Închidere sub actualizare. Posibilitatea de a calcula noua reprezentare din reprezentarea curentă și din intrările admise, fără a recupera tacit informația pretins eliminată.

Echivalență observațională. Identitatea distribuțiilor observațiilor în regimul specificat. Nu implică automat identitatea efectelor intervențiilor.

Echivalență intervențională. Acordul asupra observațiilor rezultate dintr-o familie declarată de intervenții, cu o corespondență bine definită între modelele comparate.

Apropiere aproximativă. O distanță sub un prag. Nu formează automat clase de echivalență, deoarece tranzitivitatea poate eșua.

Indistinguibilitate sub resurse. Imposibilitatea sau dificultatea demonstrată de a separa două surse printr-o clasă precizată de teste limitate. Eșecul câtorva teste nu este o demonstrație pentru întreaga clasă.

Contract de abstracție. Descrierea observațiilor, intervențiilor, domeniului și toleranței pe care o reprezentare simplificată se angajează să le conserve.

Invariant. O proprietate care trebuie păstrată de toate evoluțiile admise ale unui model. Faptul că nu am observat o încălcare nu certifică, singur, statutul de invariant.

Noutate funcțională. Extinderea capacităților realizabile într-o familie de sarcini și într-un buget. Introducerea unor etichete noi, fără consecințe noi, nu este suficientă.

Frontieră cost-fidelitate. Mulțimea compromisurilor nedominate între costurile și erorile declarate. Ea depinde de interfață, orizont, familie de sarcini și metodă de contabilizare.

A.2. Notății

M desemnează un model; S, spațiul stărilor; A, acțiunile; O, observațiile. K este nucleul de tranziție, E canalul de observație, iar μ distribuția inițială. Același simbol nu trebuie reutilizat pentru o altă mărime în interiorul aceluiași protocol.

h desemnează o istorie observată; Z, o reprezentare a ei; H, orizontul de predicție. π este o politică de alegere a acțiunilor, iar Π o familie de politici. D este o clasă de teste sau discriminatori.

L este o lungime de descriere în convenția declarată. I este informația mutuală. TV este distanța în variație totală. ε și δ sunt toleranțe de eroare, iar α este o probabilitate de eroare statistică admisă. Ele nu sunt interschimbabile: o eroare a modelului și o incertitudine asupra estimării acelei erori sunt lucruri diferite.

τ leagă stări detaliate de stări abstracte, iar ω leagă intervențiile. C desemnează un cost de pregătire sau descoperire, s o economie per utilizare, iar N numărul utilizărilor, când este folosit modelul simplificat de amortizare.

Fișa unei investigații prospective

B.1. Întrebarea și promisiunea limitată

Fișa începe cu o întrebare care poate primi răspunsuri diferite. De exemplu: „În familia de procese aleasă, o stare recurentă învățată reduce memoria totală necesară pentru o eroare predictivă dată, comparativ cu un model de contexte variabile?”. Termeni precum „înțelegere reală” sau „inteligentă emergentă” nu sunt suficiente ca obiective primare fără o operaționalizare.

Se formulează apoi ipoteza favorabilă, o ipoteză rivală și un rezultat care ar determina revizuirea. Dacă ambele sensuri ale rezultatului sunt interpretate imediat ca susținere a aceleiași idei, fișa nu este încă gata pentru investigație.

B.2. Lumea și accesul observatorului

Se descriu generatorul, variabilele ascunse, distribuția inițială, sursa de aleatorietate și condițiile de schimbare a regimului. Se precizează dacă agentul vede toate acțiunile, dacă poate interveni și dacă are acces la resetarea mediului. Pentru o simulare, se separă adevărul cunoscut evaluatorului de informația furnizată agentului.

Se declară familia parametrilor și motivul alegerii ei. Se notează ce convenții pot favoriza un model: simboluri sugestive, coordonate în care ecuația este rară, exemple care dezvăluie structura sau un număr de stări cunoscut. Acestea pot fi deliberate, dar trebuie să fie vizibile.

B.3. Reprezentările și resursele

Pentru fiecare candidat se inventariază mecanismele furnizate, parametrii învățați, structura care poate crește și criteriul de selecție. Se descrie cum se actualizează starea și dacă este păstrat istoricul brut. Se precizează cine poate propune operații noi și ce cunoaștere externă este disponibilă.

Bugetul include pregătirea, căutarea, stocarea, actualizarea, răspunsul și verificarea. Când un cost nu poate fi măsurat fidel, el se declară necunoscut sau se raportează printr-un proxy explicit. Nu se transformă un proxy într-o măsurătoare fizică fără justificare.

B.4. Contractul și metricile

Se fixează observațiile relevante, intervențiile admise, orizonturile și toleranțele. Se declară dacă se compară traiectorii complete, rezultate

finale, statistici agregate sau decizii. Pentru abstracții se definește corespondența dintre interfețe înaintea evaluării.

Fiecare afirmație principală primește o măsură. Predicția poate fi evaluată prin log-loss și calibrare. Coerența poate fi evaluată prin proprietăți specificate. Controlul poate fi evaluat prin efecte și costuri ale acțiunilor. Transferul cere sarcini care diferă în mod declarat de cele folosite pentru învățare.

B.5. Datele și controalele

Se separă dezvoltarea, alegerea modelului și testarea finală. Se precizează unitatea independentă de evaluare: episod, instanță de generator sau altă unitate justificată. Pentru procese dependente temporal, se documentează metoda de estimare a incertitudinii.

Controalele includ mecanisme fără regularitatea căutată, recodificarea simbolurilor, variația accesului la informație și eliminarea componentelor metodei. Un reper cu structura corectă furnizată poate separa dificultatea reprezentării de dificultatea învățării, dar este etichetat ca atare.

B.6. Interpretarea înaintea rezultatului

Fișa precizează ce ar însemna fiecare clasă de rezultat. Avantajul numai la antrenare sugerează adaptare locală, nu transfer. Avantajul numai când structura este furnizată arată utilitatea reprezentării, nu descoperirea ei. Pierderea controlului după compresie indică o limită a criteriului observațional. Un cost total mai mare poate anula avantajul latenței.

Se definește și o regulă de continuare: ce întrebare nouă ar deveni justificată dacă ipoteza primește sprijin? De exemplu, trecerea de la observație completă la observație parțială sau de la o operație izolată la compoziții nevăzute. Continuarea trebuie să mărească dificultatea într-un mod interpretabil, nu doar dimensiunea demonstrației.

B.7. Raportarea pentru următorul cercetător

Raportul final ar trebui să spună, în limbaj direct, ce este demonstrat, ce este susținut empiric, ce este infirmat în domeniul studiat și ce nu a fost încă testat. Ipotezele schimbate după observarea datelor se disting de cele formulate înainte. Se păstrează cazurile de eșec relevante, nu numai exemplele reușite.

O concluzie bună are o rază de acțiune clară. „În această familie, la aceste bugete, reprezentarea recurentă a păstrat aceste proprietăți mai ieftin” este mai valoroasă decât „am creat un sistem care înțelege”. Prima poate fi verificată și extinsă. A doua poate ascunde orice rezultat.

Hartă de lectură și bibliografie

C.1. Cum se leagă tradițiile existente

Pentru întrebarea filosofică, intrările utile sunt dezbaterile despre legile naturii și distincția dintre reducerea fundamentală și reconstrucția fenomenelor de nivel superior. [1, 2] Aceste lecturi nu oferă o concluzie comună obligatorie; ele ajută la recunoașterea angajamentelor ascunse în expresii precum „lege” și „explicație”.

Pentru simplitate și cost, principiul MDL trebuie citit împreună cu limitele calculabilității și cu noțiuni dependente de timp. [3–6] Astfel se evită atât numărarea superficială a regulilor, cât și presupunerea că descrierea cea mai scurtă este întotdeauna cea mai utilă.

Pentru memoria predictivă, traseul recomandat merge de la stări cauzale și informație relevantă la rată-distorsiune și algoritmi de descoperire a stărilor. [9–12, 18] Pentru acțiune și comparația nivelurilor, se adaugă reprezentări predictive de stare, bisimulare și abstracție cauzală. [13–16]

Pentru operații reutilizabile, trebuie puse în dialog învățarea bibliotecilor, interpretarea abstractă și compilarea verificată. [21–23] Prima caută structuri noi; celelalte două arată ce înseamnă o obligație semantică precisă. Legătura cu interpretabilitatea AI poate fi investigată prin abstracție cauzală. [24]

Pentru scări și lumi fizice, ireductibilitatea, coarse-graining-ul și descoperirea ecuațiilor oferă trei perspective complementare. [7, 8, 29, 30] Pentru limbaj și minte, lecturile despre compresie, sens și codificare predictivă trebuie păstrate distincte, fără a transforma analogia dintre ele într-o identitate demonstrată. [20, 25, 27, 31]

C.2. Referințe

- [1] Carroll, J. W. „Laws of Nature”. Stanford Encyclopedia of Philosophy. Intrare de sinteză filosofică; versiunea consultată la 11 septembrie 2026. Temă: regularități, necesitate și teoriile sistemului optim al legilor.
- [2] Anderson, P. W. (1972). „More Is Different”. *Science*, 177(4047), 393–396. DOI: 10.1126/science.177.4047.393.
- [3] Grünwald, P. (2004). „A tutorial introduction to the minimum description length principle”. Manuscris, arXiv:math/0406077.

- [4] Grünwald, P.; Roos, T. (2019). „Minimum Description Length Revisited”. Manuscris, arXiv:1908.08484. Se indică aici versiunea de manuscris, pentru identificare neambiguă.
- [5] Turing, A. M. (1936–1937). „On Computable Numbers, with an Application to the Entscheidungsproblem”. Proceedings of the London Mathematical Society, s2-42(1), 230–265. DOI: 10.1112/plms/s2-42.1.230.
- [6] Antunes, L.; Bauwens, B.; Souto, A.; Teixeira, A. (2013). „Sophistication vs Logical Depth”. Manuscris, arXiv:1304.8046. Versiunea revizuită este relevantă pentru dependența noțiunilor de complexitate față de timp și toleranță.
- [7] Wolfram, S. (2002). A New Kind of Science. Wolfram Media. Secțiunea despre computational irreducibility, începând la p. 737. Tezele generale trebuie delimitate de rezultatele demonstrate pentru sisteme specifice.
- [8] Israeli, N.; Goldenfeld, N. (2003). „On computational irreducibility and the predictability of complex physical systems”. Manuscris, arXiv:nlin/0309047; publicat ulterior în Physical Review Letters, 92, 074105 (2004).
- [9] Shalizi, C. R.; Crutchfield, J. P. (1999). „Computational Mechanics: Pattern and Prediction, Structure and Simplicity”. Manuscris, arXiv:cond-mat/9907176; publicat ulterior în Journal of Statistical Physics (2001).
- [10] Tishby, N.; Pereira, F. C.; Bialek, W. (2000). „The information bottleneck method”. Manuscris, arXiv:physics/0004057, corespunzând lucrării prezentate în 1999.
- [11] Still, S.; Crutchfield, J. P.; Ellison, C. J. (2007). „Optimal Causal Inference: Estimating Stored Information and Approximating Causal Architecture”. Manuscris, arXiv:0708.1580.
- [12] Marzen, S.; Crutchfield, J. P. (2014). „Circumventing the Curse of Dimensionality in Prediction: Causal Rate-Distortion for Infinite-Order Markov Processes”. Manuscris, arXiv:1412.2859. Titlul indică versiunea consultată.
- [13] Ferns, N.; Panangaden, P.; Precup, D. (2012). „Metrics for Finite Markov Decision Processes”. Manuscris disponibil ca arXiv:1207.4114; lucrare din UAI 2004. Distincția dintre data lucrării și data arhivării este intenționată.
- [14] Rubenstein, P. K.; Weichwald, S.; Bongers, S.; Mooij, J. M.; Janzing, D.; Grosse-Wentrup, M.; Schölkopf, B. (2017). „Causal Consistency of Structural Equation Models”. UAI 2017. arXiv:1707.00819.
- [15] Beckers, S.; Eberhardt, F.; Halpern, J. Y. (2019). „Approximate Causal Abstraction”. UAI 2019. arXiv:1906.11583.

- [16] Littman, M. L.; Sutton, R. S.; Singh, S. (2001). „Predictive Representations of State”. *Advances in Neural Information Processing Systems* 14, 1555–1561.
- [17] Willems, F. M. J.; Shtarkov, Y. M.; Tjalkens, T. J. (1995). „The context-tree weighting method: basic properties”. *IEEE Transactions on Information Theory*, 41(3), 653–664. DOI: 10.1109/18.382012.
- [18] Shalizi, C. R.; Shalizi, K. L.; Crutchfield, J. P. (2002). „An Algorithm for Pattern Discovery in Time Series”. *Manuscris*, arXiv:cs/0210025, versiunea 3.
- [19] Adams, R. P.; MacKay, D. J. C. (2007). „Bayesian Online Change-point Detection”. *Manuscris*, arXiv:0710.3742.
- [20] Delétang, G. și colaboratorii (2023). „Language Modeling Is Compression”. *Manuscris*, arXiv:2309.10668.
- [21] Cousot, P.; Cousot, R. (1977). „Abstract interpretation: a unified lattice model for static analysis of programs by construction or approximation of fixpoints”. *Proceedings of POPL*, 238–252.
- [22] Leroy, X. (2009). „A formally verified compiler back-end”. *Journal of Automated Reasoning*, 43(4), 363–446. DOI: 10.1007/s10817-009-9155-4. arXiv:0902.2137.
- [23] Ellis, K. și colaboratorii (2020). „DreamCoder: Growing generalizable, interpretable knowledge with wake-sleep Bayesian program learning”. *Manuscris*, arXiv:2006.08381. Se indică titlul versiunii de manuscris.
- [24] Geiger, A. și colaboratorii (2023). „Causal Abstraction: A Theoretical Foundation for Mechanistic Interpretability”. *Manuscris*, arXiv:2301.04709; versiune consultată la 11 septembrie 2026.
- [25] Rao, R. P. N.; Ballard, D. H. (1999). „Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects”. *Nature Neuroscience*, 2, 79–87. DOI: 10.1038/4580.
- [26] Taylor, T. (2015). „Requirements for Open-Ended Evolution in Natural and Artificial Systems”. *Manuscris*, arXiv:1507.07403.
- [27] Bender, E. M.; Koller, A. (2020). „Climbing towards NLU: On Meaning, Form, and Understanding in the Age of Data”. *Proceedings of ACL*, 5185–5198. DOI: 10.18653/v1/2020.acl-main.463. Lucrare de poziție și argumentare teoretică.
- [28] Håstad, J.; Impagliazzo, R.; Levin, L. A.; Luby, M. (1999). „A Pseudorandom Generator from any One-way Function”. *SIAM Journal on Computing*, 28(4), 1364–1396. DOI: 10.1137/S0097539793244708.

- [29] Brunton, S. L.; Proctor, J. L.; Kutz, J. N. (2015). „Discovering governing equations from data: Sparse identification of nonlinear dynamical systems”. Manuscris, arXiv:1509.03580; publicat în PNAS (2016). DOI: 10.1073/pnas.1517384113.
- [30] Rudy, S. H.; Brunton, S. L.; Proctor, J. L.; Kutz, J. N. (2016). „Data-driven discovery of partial differential equations”. Manuscris, arXiv:1609.06401; publicat ulterior în Science Advances (2017).
- [31] Jiang, L. P.; Rao, R. P. N. (2021). „Predictive Coding Theories of Cortical Function”. Manuscris, arXiv:2112.10048; contribuție în Oxford Research Encyclopedia of Neuroscience (2022), versiune revizuită în 2023. DOI: 10.1093/acrefore/9780190264086.013.328.
- [32] Hoeffding, W. (1963). „Probability Inequalities for Sums of Bounded Random Variables”. Journal of the American Statistical Association, 58(301), 13–30. DOI: 10.1080/01621459.1963.10500830.

C.3. Limita bibliografiei

Această bibliografie este o bază de lucru, nu un audit exhaustiv al noutății fiecărei propuneri. Înaintea revendicării unei contribuții originale, cercetătorii trebuie să extindă căutarea în subdomeniul concret: identificarea sistemelor, învățarea automatelor, semantică, abstracție cauzală, complexitate sau interpretabilitate. O convergență conceptuală interesantă nu anulează precedența rezultatelor tehnice.

Când o sursă este citată ca manuscris, identificatorul permite găsirea versiunii relevante chiar dacă titlul ori data publicării ulterioare diferă. Referințele nu certifică ipotezele prospective ale cărții. Ele indică instrumentele pe care un program riguros trebuie să le înțeleagă înainte de a încerca să le extindă.