

Noutatea care seamănă cu trecutul

Pot modelele lingvistice să recunoască
ceea ce nu au mai întâlnit?

Fundamente, limite informaționale
și validare experimentală

O analiză a diferenței dintre noutate reală,
familiaritate și aparența originalității.

SEPTEMBRIE 2026

Cuprins

Capitole, secțiuni și anexe

Prefață. Problema unui evaluator educat de trecut.....	4
Capitolul 1. Ce afirmă, de fapt, ipoteza.....	6
1.1. De la suspiciune intuitivă la propoziții separabile.....	6
1.2. Noutatea nu este raritate, adevăr sau valoare.....	8
1.3. Referința, criteriul și timpul fac parte din problemă.....	10
Capitolul 2. Probabilitate, informație și surpriză.....	13
2.1. De ce probabilitatea mică nu înseamnă noutate mare.....	13
2.2. Ce optimizează învățarea și ce nu promite.....	15
2.3. Informația relevantă și limitele comprimării.....	17
Capitolul 3. Ce învață un model lingvistic și cum ajunge să judece.....	20
3.1. De la tokeni la o procedură condiționată.....	20
3.2. Generalizare, memorare și priorități introduse prin postantrenare.....	22
3.3. Eșecuri ale evaluatorului care seamănă între ele numai la suprafață.....	24
Capitolul 4. O semantică operațională a contribuțiilor.....	27
4.1. Ideea ca structură de afirmații, nu ca temă.....	27
4.2. Echivalență, anticipare și diferență reziduală.....	28
4.3. Când ideea schimbă chiar vocabularul comparației.....	31
Capitolul 5. Cum poate familiaritatea să devină un substitut pentru noutate.....	33
5.1. Indicii convenabile și scurtături ale evaluării.....	33
5.2. Netezirea semantică: când interpretarea repară tocmai excepția.....	35
5.3. Atracția către antecedente și buclele de confirmare.....	37
Capitolul 6. Imposibilități reale, condiții de posibilitate și demonstrații.....	40
6.1. Lipsa informației și imposibilitatea priorității absolute.....	40
6.2. Teorema didactică a reprezentării suficiente.....	41
6.3. Calculabilitate, generalizare și contraexemple constructive.....	44
Capitolul 7. Ce arată literatura și ce nu poate demonstra.....	47
7.1. Familiaritate, autoevaluare și creativitate percepută.....	47
7.2. Benchmarkurile de noutate și problema adevărului de referință.....	49
7.3. Dovezi conexe și limitele transferului dintre domenii.....	51
Capitolul 8. Cum se identifică experimental un bias de familiaritate.....	53
8.1. Ipoteze, intervenții și explicații alternative.....	53
8.2. Măsurare: de la scoruri la contribuții recuperate.....	55
8.3. Testarea frecvenței de antrenare și puterea statistică.....	57
Capitolul 9. Laboratorul controlat: noutate cu adevăr de referință exact.....	59
9.1. De ce circuitele finite sunt un laborator potrivit.....	59
9.2. Diferențe rare, coliziuni și familii de test.....	60
9.3. Ce ar demonstra un rezultat pozitiv sau negativ.....	62

Capitolul 10. Validarea pe cercetare reală.....	65
10.1. Reconstrucția temporală și limitele testelor retrospective.....	65
10.2. Experți, dezacord și etichete verificabile.....	66
10.3. Un studiu longitudinal care poate schimba concluziile.....	68
Capitolul 11. Arhitectura unui evaluator bazat pe dovezi.....	70
11.1. Păstrarea obiectului evaluat și separarea operațiilor.....	70
11.2. Regăsire diversă, comparație precisă și întoarcere la sursă.....	72
11.3. Incertitudine, audit și criterii de acceptare a arhitecturii.....	74
Capitolul 12. Filtrarea ideilor rare ca problemă de decizie.....	76
12.1. A recunoaște nu este același lucru cu a selecta.....	76
12.2. Cum observăm erorile asupra ideilor respinse.....	77
12.3. Dinamica selecției și riscul uniformizării.....	79
Capitolul 13. Obiecțiile cele mai puternice, în ambele direcții.....	81
13.1. Cazul sceptic: modelul poate învăța reputația inovației, nu inovația.....	81
13.2. Cazul optimist: procedurile vechi pot detecta obiecte noi.....	82
13.3. O poziție intermediară care nu este un compromis comod.....	84
Capitolul 14. Programul de cercetare și criteriile unui progres real.....	86
14.1. Un nucleu experimental minimal, dar decisiv.....	86
14.2. De la mecanism la arhitectură și la utilitate.....	88
14.3. Ce ar însemna validarea sau invalidarea intuiției inițiale.....	89
Anexa A. Demonstrații și exemple matematice desfășurate.....	91
A.1. De la frecvențe la decizie: trei calcule care nu trebuie confundate.....	91
A.2. Riscul Bayes, coliziunea și beneficiul posibil al unui rezumat.....	93
A.3. Diferențe rare și modele de selecție: calcule exacte.....	95
Anexa B. Protocol de preregistrare și registru al dovezilor.....	97
B.1. Fișa studiului și contractul inferențial.....	97
B.2. Registrul unui caz și traseul de la text la verdict.....	99
B.3. Raportarea rezultatului și decizia de continuare.....	100
Anexa C. Un exemplu executabil de noutate relativă.....	102
C.1. Ce verifică programul și ce nu verifică.....	102
C.2. Implementarea completă.....	103
C.3. Ieșirea verificată și extensii legitime.....	104
Anexa D. Vocabularul tehnic și cunoștințele prealabile.....	105
D.1. Probabilitate, informație și statistică.....	105
D.2. Modele lingvistice, reprezentări și regăsire.....	109
D.3. Semantică, circuite, compilatoare și verificare.....	112
D.4. Epistemologie operațională și design experimental.....	115
Referințe și hartă de lectură.....	118
Surse primare consultate.....	118
Cum se leagă sursele de argumentul cărții.....	121

Prefață. Problema unui evaluator educat de trecut

Un sistem este pus să citească o mie de propuneri și să păstreze zece idei realmente noi. A fost antrenat pe texte din trecut, a învățat regularități ale discursului științific și recunoaște expresii precum „o nouă perspectivă”, „un cadru unificat” sau „o combinație neexplorată”. Întrebarea incomodă nu este dacă sistemul poate produce zece justificări elegante. Întrebarea este dacă, printre lucrurile pe care le respinge, se află tocmai contribuția care nu seamănă încă suficient cu ceea ce comunitatea numește inovație.

Această carte cercetează o suspiciune precisă: modelele lingvistice ar putea confunda noutatea cu familiaritatea unor tipare ale noutății. Ipoteza nu este ridiculizată prin invocarea abstractă a „generalizării”, dar nici transformată într-o teoremă numai pentru că sună plauzibil. Ea este desfăcută în afirmații diferite, cu condiții de adevăr diferite. Unele descriu riscuri experimentale. Altele sunt limite informaționale demonstrabile. Altele sunt prea tari și admit contraexemple constructive.

Poziția susținută aici este că un model instruit din trecut nu este, numai din acest motiv, incapabil să recunoască o diferență nouă. În schimb, un sistem care a pierdut diferența relevantă înaintea evaluării nu o mai poate recupera din reprezentarea rămasă, dacă nu primește informație suplimentară. Între aceste două afirmații se află aproape întreaga problemă practică. Trebuie aflat ce informație vede evaluatorul, ce comparație execută, ce înțelege prin antecedent și ce dovezi îi permit să treacă de la asemănare la identitate sau de la diferență la contribuție.

Textul este destinat cercetătorilor și programatorilor care vor să proiecteze instrumente de analiză a ideilor, selecție a propunerilor, examinare a literaturii sau automatizare a cercetării. Nivelul urmărit este avansat, dar noțiunile necesare sunt introduse înainte de a fi

folosite. Nu se presupune familiaritatea cu teoria informației, inferența cauzală sau calculabilitatea. Se presupune disponibilitatea cititorului de a urmări argumente, de a separa definițiile de descoperiri și de a accepta că un rezultat negativ riguros poate fi mai util decât un scor impresionant.

O distincție editorială este esențială. Relatările despre experimente publicate sunt însoțite de referințe numerotate. Definițiile de lucru, demonstrațiile elementare, exemplele construite și protocoalele propuse apar ca atare. Cartea nu raportează un nou benchmark executat pe modele comerciale sau deschise. Micile calcule și exemple logice sunt verificări didactice; ele nu sunt prezentate ca rezultate empirice despre capacitățile unui LLM. Propunerile arhitecturale sunt proiecte de cercetare, nu descrieri ale unui produs deja validat.

Literatura este o selecție critică de surse primare, verificată până la 11 septembrie 2026, nu o revizuire sistematică exhaustivă. Versiunile consultate sunt identificate în bibliografie. Rezultatele despre anumite modele, seturi de date și proceduri nu sunt generalizate automat la toate modelele viitoare. Tot astfel, acordul cu un recenzent nu este tratat drept identitate cu adevărul istoric, iar lipsa unui antecedent în rezultatele unui motor de căutare nu este tratată drept dovada absenței sale.

Cartea poate fi citită succesiv, de la fundamente către experiment, sau utilizată ca manual de proiectare. Capitolele despre informație și calculabilitate stabilesc ce se poate cere în mod coerent unui evaluator. Capitolele metodologice arată cum poate fi identificat un mecanism de eșec. Capitolele finale discută cum poate fi construit un sistem care își păstrează posibilitatea de a fi corectat. Anexele oferă demonstrații suplimentare, un protocol de preregistrare, un exemplu executabil și un vocabular tehnic.

Miza nu este apărarea sau condamnarea unei clase de modele. Miza este protejarea unei operații intelectuale fragile: observarea unei diferențe înainte ca limbajul, statisticile, criteriile sau instituția care o evaluează să o reducă la ceva deja cunoscut.

Capitolul 1. Ce afirmă, de fapt, ipoteza

1.1. De la suspiciune intuitivă la propoziții separabile

Formula „un LLM găsește numai ce a mai întâlnit” amestecă cel puțin două sensuri ale verbului a găsi. Un sistem poate regăsi un exemplu stocat, dar poate și aplica o regulă învățată unei instanțe care nu a existat în antrenare. Pentru a recunoaște că două numere diferă nu trebuie să fi memorat anterior perechea lor. Pentru a constata că un program produce un rezultat absent dintr-o bibliotecă finită nu trebuie să fi întâlnit programul respectiv. Din faptul că o competență a fost învățată din trecut nu rezultă că obiectele asupra cărora poate opera sunt limitate la trecut.

Această observație nu rezolvă problema modelelor lingvistice. Ea elimină numai o inferență nevalidă. Rămâne de stabilit dacă modelul aplică efectiv o procedură de comparație sau dacă răspunde pe baza unor regularități superficiale. O arhitectură ar putea permite o operație fără ca procedura de antrenare să o inducă suficient de bine. O competență ar putea exista pe probleme simple și s-ar putea pierde pe texte lungi. O diferență ar putea fi recunoscută corect, dar interpretată greșit drept lipsită de importanță. De aceea, posibilitatea logică și performanța efectivă trebuie examinate separat.

Forma comportamentală a ipotezei spune că evaluatorul favorizează ideile exprimate prin tipare familiare ale inovării, chiar atunci când contribuția semantică este ținută constantă. Forma cauzală afirmă că această preferință este produsă de frecvențele sau corelațiile din antrenare. Forma informațională afirmă că anumite reprezentări intermediare șterg diferențele necesare pentru clasificare. Forma universală afirmă că niciun LLM nu poate detecta o contribuție realmente nouă. Aceste propoziții nu sunt echivalente. O demonstrație a formei informaționale pentru o anumită reprezentare nu demonstrează forma universală. O corelație între perplexitate și scor nu identifică singură procesul de antrenare drept cauză.

Mai există o formă instituțională a suspiciunii: sistemele de selecție pot transforma o preferință modestă într-un efect cumulativ important. Dacă un filtru respinge mai des ideile cu vocabular neobișnuit, iar numai ideile acceptate sunt apoi discutate, citate și folosite la instruirea altor filtre, spațiul viitoarelor exemple se poate îngusta. Aceasta este o ipoteză despre un proces dinamic, nu o proprietate demonstrată prin simpla analiză a unui singur răspuns. Ea cere observații asupra selecției, resurselor alocate și informației care revine în sistem.

Pentru a evita ambiguitatea, vom numi familiaritate potrivirea cu regularități deja învățate sau frecvente într-o reprezentare; vom numi noutate diferența relevantă față de un corp de referință explicit. Familiaritatea poate fi lingvistică, conceptuală, metodologică sau socială. Noutatea poate privi mecanismul, rezultatul, condițiile de aplicabilitate sau dovada. O formulare foarte familiară poate descrie o contribuție nouă. O formulare stranie poate ascunde o idee banală. Nici termenul „familiar”, nici termenul „nou” nu trebuie folosit fără a preciza obiectul comparației.

Un exemplu construit arată de ce această disciplină contează. Prima propunere spune că un protocol funcționează atunci când mai puțin de o treime dintre participanți se comportă adversarial. A doua pretinde aceeași garanție sub o ipoteză diferită despre sincronizare. Un sumar tematic poate reprezenta ambele texte ca „protocol distribuit tolerant la participanți rău intenționați”. La acest nivel par identice. La nivelul ipotezelor și garanțiilor pot exista diferențe decisive. Nu este necesar să presupunem că a doua propunere este corectă. Pentru detectarea contribuției pretinse este suficient să observăm că afirmațiile nu sunt aceleași.

Exemplul introduce o separare care va reveni în întreaga carte. Identificarea diferenței declarate, verificarea existenței unui antecedent pentru acea diferență și demonstrarea validității ei sunt operații distincte. Dacă un evaluator le comprimă într-un verdict unic, o eroare nu mai poate fi diagnosticată. „Nu este nou” poate însemna că mecanismul este vechi, că modelul nu a înțeles mecanismul, că nu

crede demonstrația sau că preferă o problemă mai populară. Un scor fără descompunere poate ascunde toate aceste situații.

O ipoteză bună trebuie să precizeze și ce rezultat ar slăbi-o. Dacă un model primește două contribuții noi pentru el, antecedentele corecte și un criteriu exact, apoi identifică în mod robust diferența sub reformulări controlate, afirmația imposibilității generale devine nesustenabilă. Dacă însă noutatea este detectată numai când textul conține expresii convenționale de originalitate, suspiciunea comportamentală capătă forță. Dacă schimbarea frecvențelor din antrenare produce schimbarea evaluărilor, fără modificarea adevărului de referință, se apropie și o explicație cauzală.

Poziția metodologică a cărții poate fi formulată simplu: nu este suficient să întrebăm dacă modelul „înțelege noutatea”. Trebuie să construim situații în care o explicație bazată pe înțelegerea diferenței și una bazată pe recunoașterea ambalajului fac predicții diferite. Numai atunci experimentul separă mecanismele.

1.2. Noutatea nu este raritate, adevăr sau valoare

Raritatea este o proprietate a distribuției. Noutatea este o relație față de antecedente. O metodă veche, ignorată de comunitatea curentă, poate fi rară în corpusul analizat și totuși să nu fie nouă istoric. O descoperire recentă poate fi repetată în mii de documente și totuși să rămână nouă față de starea cunoașterii de anul trecut. Frecvența din corpus, expunerea din antrenare și prioritatea istorică sunt variabile diferite. Confundarea lor poate produce atât entuziasm pentru redescoperiri, cât și respingerea descoperirilor devenite deja vizibile.

Noutatea lingvistică privește forma expresiei. Noutatea conceptuală privește ceea ce se afirmă sau mecanismul propus. Noutatea operațională privește o capacitate nouă de a face ceva. Noutatea epistemică privește ceea ce devine cunoscut sau justificat pentru un agent ori o comunitate. Noutatea istorică privește absența unui antecedent relevant înainte de un moment. Aceste distincții sunt

definiții de lucru ale cărții. Ele nu pretend că există o taxonomie unică, acceptată de toate disciplinele.

O nouă demonstrație a unei teoreme cunoscute ilustrează independența dimensiunilor. Concluzia poate fi veche, metoda demonstrativă nouă, iar timpul de verificare mai mic. Un algoritm poate calcula aceeași funcție, dar cu altă complexitate, alte cerințe de memorie sau alte proprietăți de confidențialitate. Dacă evaluatorul reduce contribuția la relația intrare-ieșire, va declara în mod legitim absența noutății funcționale, dar va greși dacă extinde concluzia la noutatea algoritmică în general. Obiectul semantic ales stabilește ce poate fi observat.

Adevărul constituie o altă axă. O ipoteză poate fi originală și falsă. O observație poate fi adevărată și bine cunoscută. O propunere poate fi originală în forma ei precisă, dar imposibilă în condițiile declarate. Într-un instrument de cercetare, identificarea unei contribuții pretinse nu trebuie suspendată până la validarea completă a acesteia. Este util să știm exact ce pretinde autorul că schimbă înainte să verificăm dacă schimbarea este realizabilă. În același timp, originalitatea unei afirmații false nu trebuie convertită automat în merit științific.

Valoarea depinde de scopuri și consecințe. O variație minoră poate avea o valoare practică mare dacă elimină un cost dominant într-o aplicație. O construcție foarte originală poate avea momentan o utilitate redusă. Aceste judecăți pot fi perfect compatibile. Problema apare când evaluatorul numește „noutate” tot ceea ce îi place sau „lipsă de noutate” tot ceea ce i se pare inutil. În acel moment, criteriul devine o preferință globală, iar precizia conceptuală dispare.

Originalitatea are și o dimensiune de proveniență. Două persoane pot produce independent aceeași idee. Contribuția celei de-a doua poate fi originală psihologic, fără a avea prioritate istorică. Invers, un text poate prezenta o idee necunoscută evaluatorului, dar preluată dintr-o sursă omisă. Detectarea antecedentului nu stabilește automat intenția autorului. A acuza plagiatul presupune întrebări despre acces, atribuție

și practici de utilizare a surselor, care nu se reduc la identitatea semantică a două texte.

Boden distinge forme combinatorii, exploratorii și transformaționale ale creativității. Această perspectivă este utilă deoarece o modificare a regulilor spațiului de căutare nu este același lucru cu găsirea unei alte soluții în interiorul regulilor existente. Totuși, tipologia creativității nu furnizează singură un detector al priorității istorice. Ea ajută la formularea tipului de schimbare pe care ar trebui să îl căutăm. [R01]

Putem defini, în consecință, un profil al contribuției în locul unui scor unic. Profilul poate separa rezultatul, mecanismul, ipotezele, procedura de justificare și domeniul de aplicare. Nu este obligatoriu ca toate dimensiunile să fie numerice. Uneori o propoziție comparativă este mai informativă decât un număr: „aceeași garanție, dar fără ipoteza de independență” sau „aceeași funcție, dar cu memorie subliniară în parametrul declarat”. Asemenea formulări obligă evaluatorul să precizeze diferența pe care o recunoaște.

1.3. Referința, criteriul și timpul fac parte din problemă

Vom nota o judecată de noutate prin expresia următoare, în care toate argumentele contează:

$$N(x; K_t, C, B).$$

Aici, x este contribuția evaluată, K_t este corpul de cunoaștere disponibil până la momentul t , C reprezintă criteriul de echivalență sau relevanță, iar B descrie bugetul de acces, calcul și verificare. Nu propunem prin această notație o formulă magică. Ea servește la prevenirea omisiunilor. O afirmație de noutate fără corp de referință, fără criteriu și fără resurse declarate este de regulă mai ambiguă decât pare.

Criteriul C poate spune că două contribuții sunt echivalente dacă au aceeași funcție pe același domeniu. În altă aplicație, echivalența poate cere aceleași ipoteze de securitate, aceeași complexitate și același

model adversarial. O modificare care dispare sub primul criteriu poate rămâne esențială sub al doilea. În acest sens, noutatea nu este arbitrară, dar este dependentă de întrebarea adresată. Odată criteriul fixat, comparația poate deveni foarte precisă.

Corpul K_t trebuie distins de lumea întreagă. Biblioteca indexată, documentele accesibile evaluatorului și toate antecedentele existente nu sunt aceeași mulțime. Un articol neindexat, o teză într-o altă limbă sau o versiune anterioară a unui raport pot modifica verdictul istoric. Sistemul nu trebuie condamnat pentru că nu posedă informație inaccesibilă. Trebuie însă împiedicat să transforme accesul limitat într-o certitudine nelimitată.

Timpul introduce o dificultate suplimentară. Când evaluăm retrospectiv o idee, modelul poate cunoaște versiuni ulterioare, replicări, controverse sau aprecierea comunității. Chiar dacă eliminăm numele autorilor, informația despre rezultat poate supraviețui în formulare. Un test care cere „cât de nouă era această contribuție în anul t ?” nu este automat valid dacă modelul a fost antrenat pe documente de după t . El poate recunoaște reputația descoperirii în loc să reconstruiască situația de atunci.

Bugetul B este inclus deoarece a putea verifica în principiu nu înseamnă a putea verifica în resursele disponibile. Un antecedent poate fi recuperabil după o căutare de două zile, dar nu în cele treizeci de secunde acordate filtrării. O echivalență poate fi decidabilă, dar prea costisitoare pentru un milion de candidați. Compararea sistemelor fără egalizarea bugetului riscă să transforme avantajul de acces sau de calcul într-o pretinsă superioritate conceptuală.

Se poate obiecta că adăugarea acestor parametri diluează noțiunea de noutate. Obiecția este legitimă dacă orice eșec este scuzat prin schimbarea convenabilă a definiției. De aceea, parametrii trebuie fixați înaintea evaluării. Relativizarea nu servește la evitarea testării, ci la a face verdictul testabil. „Nou față de biblioteca K , după criteriul C , cu antecedentele decisive furnizate” este o afirmație mai restrânsă, dar mai puternică metodologic decât „modelul înțelege originalitatea”.

Un detector practic poate produce trei tipuri de concluzii. Poate identifica un antecedent care anticipează contribuția. Poate identifica o diferență față de antecedentele examinate. Poate constata că datele sunt insuficiente pentru o concluzie. Acestea nu trebuie aranjate artificial pe o singură scală ordinală. Absența informației nu este o noutate medie, iar existența unei diferențe nevalidate nu este o dovadă de importanță.

La sfârșitul acestei clarificări, ipoteza inițială devine mai productivă. Întrebarea nu mai este dacă trecutul interzice viitorul. Întrebarea este dacă procedura învățată din trecut conservă și examinează acele diferențe prin care viitorul ar putea să nu fie doar o reformulare a trecutului. Această întrebare permite atât demonstrații de imposibilitate condiționată, cât și construcții care arată posibilitatea.

Capitolul 2. Probabilitate, informație și surpriză

2.1. De ce probabilitatea mică nu înseamnă noutate mare

Un model probabilistic atribuie ponderi unor rezultate posibile. Dacă avem o distribuție p peste un vocabular, $p(w)$ descrie probabilitatea unui simbol w în condițiile modelate. Într-un model lingvistic, distribuția este condiționată de context: probabilitatea unui cuvânt după „capitala Franței este” diferă de probabilitatea sa în întregul corpus. Această diferență elementară este crucială. Frecvența globală a unei expresii nu determină singură probabilitatea ei într-o întrebare de comparație între două idei.

Pentru o secvență de simboluri, regula lanțului permite factorizarea probabilității comune într-un produs de probabilități condiționate. Factorizarea nu este o teorie a sensului; este o identitate probabilistică. O implementare autoregresivă încearcă să estimeze fiecare factor folosind prefixul disponibil. [R02, R03]

$$p(x_1, \dots, x_T) = \prod_{i=1}^T p(x_i \mid x_1, \dots, x_{i-1}).$$

O secvență lungă poate avea probabilitate foarte mică chiar dacă fiecare pas este banal. Dacă fiecare alegere are probabilitatea o jumătate, o secvență de o sută de alegeri are probabilitatea 2^{-100} la puterea minus o sută. Din improbabilitatea întregii secvențe nu rezultă că ea conține o descoperire. Acesta este motivul pentru care surpriza brută a documentului nu poate fi comparată fără a controla lungimea și granularitatea reprezentării.

Surpriza informațională a unui rezultat este minus logaritmul probabilității sale. Alegerea logaritmului în baza doi exprimă informația în biți. Un rezultat cu probabilitate o jumătate are un bit de surpriză; unul cu probabilitate o mie dintr-un milion are aproximativ

zece biți. Aceste valori descriu raritatea față de distribuția aleasă, nu importanța epistemică sau morală a rezultatului. Shannon a formulat teoria comunicației tocmai separând problema transiterii de interpretarea semantică a mesajelor. [R02]

$$s(x) = -\log_2 p(x).$$

Un identificator aleator poate avea surpriză mare fără să spună ceva interesant despre lume. O ecuație simplă poate avea surpriză textuală mică și consecințe importante. Mai mult, o propoziție falsă sau o eroare tipografică poate fi improbabilă. Prin urmare, un detector bazat numai pe surpriză ar favoriza și zgomotul. Eliminarea zgomotului necesită criterii suplimentare; în acel moment detectorul nu mai măsoară doar probabilitatea.

Perplexitatea este exponențiala pierderii logaritmice medii pe simboluri. Ea normalizează parțial efectul lungimii și este utilă pentru evaluarea predicției. Dar comparațiile între modele cu tokenizări diferite cer prudență: o medie pe tokeni nu are aceeași unitate efectivă când un model fragmentează un cuvânt în două părți, iar altul în cinci. În plus, perplexitatea este dependentă de contextul sub care a fost calculată. A spune că o idee are „perplexitate mică” fără a preciza textul, tokenizarea și condiționarea este insuficient pentru o analiză reproductibilă.

Problema noutății este adesea clasificatorie, nu generativă. Dorim probabilitatea unei etichete sau a unei relații după ce am văzut contribuția și antecedentele. Aceasta este o distribuție diferită de probabilitatea contribuției în limbajul obișnuit. Un text poate fi foarte improbabil și totuși să fie clasificat corect drept incoerent. Un text foarte previzibil poate conține o diferență mică, dar detectabilă, față de un antecedent explicit.

$$D_{\theta}(x, K, C) = P_{\theta}(Y = 1 \mid x, K, C).$$

$$G_{\theta}(x) = P_{\theta}(X = x \mid \text{prompt de generare}).$$

Cele două expresii definesc obiecte probabilistice diferite, care nu pot fi substituie unul altuia. Valorile lor ar putea coincide accidental; această coincidență nu ar face sarcinile identice. Distribuția generării pune o pondere pe texte; distribuția clasificării pune o pondere pe etichete condiționat de text și referință. Argumentul potrivit căruia un generator preferă continuări familiare nu demonstrează, fără pași suplimentari, că același sistem nu poate compara o contribuție cu o bibliotecă.

Bayes arată și de ce un semnal de noutate poate induce în eroare când descoperirile sunt rare. Să presupunem, într-un exemplu construit, că o mie dintr-un milion de candidați sunt realmente noi după criteriul ales. Detectorul păstrează nouă sute dintre aceștia, dar clasifică greșit drept noi unu la sută dintre cei nouă sute nouăzeci și nouă de mii de candidați vechi. Obținem nouă sute de cazuri corecte și nouă mii nouă sute nouăzeci de alarme false. Numai aproximativ 8,26% dintre selecții sunt noutăți reale.

$$PPV = \frac{\pi TPR}{\pi TPR + (1 - \pi) FPR}.$$

Aici π este prevalența noutății, TPR este rata detectării cazurilor noi, iar FPR rata alarmelor false printre cazurile vechi. Formula rezultă direct din probabilitățile comune. Nu spune că detectorul este inutil, ci că performanța trebuie judecată în raport cu prevalența și capacitatea de verificare. Într-un filtru de descoperire, costul câtorva alarme false poate fi acceptabil dacă împiedică pierderea unei contribuții rare. Alegerea pragului este o decizie operațională, nu o consecință automată a scorului.

2.2. Ce optimizează învățarea și ce nu promite

Considerăm o distribuție reală P și o distribuție estimată Q . Dacă evaluăm predicțiile prin pierdere logaritmă, costul mediu al lui Q se descompune în entropia lui P și divergența Kullback–Leibler dintre P și Q . Demonstrația este algebrică: adunăm și scădem logaritmul lui P în

suma care definește pierderea. Termenul de entropie nu depinde de Q ; termenul de divergență este nenegativ.

$$E_{X \sim P}[-\log Q(X)] = H(P) + D_{KL}(P \parallel Q).$$

În cazul ideal în care familia de modele conține distribuția corectă și optimizarea o găsește, soluția este $Q=P$. Ea nu pune toată masa pe cel mai frecvent rezultat. Dimpotrivă, reproduce și probabilitățile evenimentelor rare. A confunda minimizarea pierderii logaritmice cu memorarea exclusivă a modului distribuției înseamnă a confunda estimarea distribuției cu o regulă de decizie care alege doar rezultatul cel mai probabil.

Situația practică este mai dificilă. Datele sunt finite, capacitatea modelului este limitată, optimizarea este imperfectă, iar distribuția testului poate diferi de cea a antrenării. Un eveniment rar poate primi prea puține exemple pentru ca modelul să învețe structura relevantă. Într-un obiectiv mediat pe toate exemplele, îmbunătățirea cazurilor frecvente poate domina numeric îmbunătățirea unei clase rare. Această observație este un argument de alocare a erorii, nu o teoremă potrivit căreia rarele sunt imposibil de învățat.

Un model poate învăța o regulă comună care acoperă și cazuri rare. Dacă exemplele frecvente îi permit să învețe adunarea, el poate calcula o sumă care nu apare în date. Dacă învață numai asocieri locale între expresii și etichete, generalizarea va fi mai slabă. Diferența nu poate fi dedusă exclusiv din obiectiv. Același obiectiv poate admite soluții cu strategii interne diferite. Pentru a identifica strategia trebuie proiectate teste care împiedică rezolvarea prin corelații superficiale.

Mai trebuie separată distribuția modelului de procedura de decodare. Alegerea celui mai probabil simbol la fiecare pas, eșantionarea și căutarea cu mai multe ipoteze pot produce comportamente diferite plecând de la aceleași probabilități. Alegerea locală a celui mai probabil simbol nu garantează obținerea celei mai probabile secvențe globale. Creșterea temperaturii poate diversifica rezultatele, dar nu transformă

distribuția într-un verficator de noutate. Diversitatea textuală și validarea diferenței sunt probleme separate.

Un evaluator care răspunde cu „nou” sau „vechi” produce, tehnic, tokeni. Din această observație nu rezultă că nu poate executa o comparație. Și un program de verificare a echivalenței produce în final biți, fără ca natura ieșirii să epuizeze natura calculului. Întrebarea relevantă este ce informație și ce operații determină ieșirea. Reducerea unei competențe la forma ultimei sale instrucțiuni nu constituie o analiză funcțională suficientă.

În același timp, probabilitatea mare a tokenului „nou” nu trebuie confundată cu o probabilitate epistemică bine calibrată a priorității istorice. Ea poate reflecta convențiile promptului, preferințele introduse prin postantrenare sau faptul că răspunsurile ezitante au fost mai puțin recompensate. Calibrarea trebuie măsurată pe evenimente clar definite. Cercetarea lui Guo și colaboratorilor arată, într-un context de clasificare neuronală, că încrederea numerică și corectitudinea empirică pot diverge și că postprocesarea poate îmbunătăți calibrarea. Nu rezultă de aici o garanție pentru judecățile de noutate ale LLM-urilor. [R18]

Un protocol riguros păstrează separat scorul intern, verdictul textual și calitatea justificării. Poate exista un răspuns corect cu încredere prost calibrată, un răspuns greșit cu justificare fluentă sau o justificare care identifică diferența corectă, dar o agregă într-un scor nepotrivit. Reducerea tuturor acestor dimensiuni la un singur procent împiedică înțelegerea mecanismului de eșec.

2.3. Informația relevantă și limitele comprimării

Entropia măsoară incertitudinea medie a unei variabile. Informația mutuală măsoară cât reduce observarea unei variabile incertitudinea despre alta. În problema noastră, X poate reprezenta documentul original, Y eticheta de noutate după un criteriu fix, iar Z reprezentarea pe care o construiește sistemul. Nu ne interesează numai cât de mult

păstrează Z despre X. Ne interesează dacă păstrează ceea ce este necesar pentru Y.

O reprezentare poate elimina aproape toate detaliile documentului și totuși să fie suficientă pentru o întrebare îngustă. Dacă vrem să știm dacă un circuit produce vreodată valoarea unu, un bit calculat corect poate rezuma răspunsul. Dacă vrem ulterior să aflăm pe ce intrări produce unu, acel bit nu mai este suficient. Compresia bună nu este o proprietate absolută. Ea depinde de familia de întrebări viitoare.

Pentru un lanț în care Z este derivat numai din X, iar decizia folosește numai Z, prelucrarea nu poate crea informație despre Y care lipsea din observația originală. Intuiția poate fi demonstrată fără metafizică: orice regulă care operează pe Z poate fi simulată de o regulă care primește X și calculează mai întâi Z. Prin urmare, cel mai bun evaluator care are acces la X nu poate fi mai slab decât cel mai bun evaluator limitat la Z, dacă resursele și clasele de decizie nu impun alte restricții.

Această formulare lasă loc unui fapt aparent paradoxal. Un model concret poate performa mai bine pe un rezumat decât pe textul integral. Nu a fost creată informație suplimentară despre adevărul etichetei; a fost schimbată accesibilitatea ei pentru un evaluator limitat. Rezumatul poate elimina distrageri, poate rearanja premisele și poate reduce costul de calcul. Diferența dintre performanța unui algoritm concret și performanța optimă permisă de informație este fundamentală.

Riscul apare când rezumatul elimină nu zgomotul, ci diferența relevantă. Să presupunem că două propuneri au aceeași descriere tematică și diferă numai printr-un cuantificator: „pentru fiecare intrare” față de „pentru aproape toate intrările”. Dacă reprezentarea păstrează tema și rezultatul generic, cele două devin identice. Nu mai este vorba doar despre o preferință a evaluatorului. Informația necesară distincției a dispărut din canalul pe care acesta îl primește.

La nivel de inginerie, această observație sugerează că simpla creștere a dimensiunii vectorului nu este o soluție completă. O reprezentare mare

poate ignora o variabilă relevantă, iar una mică o poate păstra explicit. Contează obiectivul de reprezentare, invarianta urmărită și existența unei căi de întoarcere la sursă. Un sistem de noutate ar trebui să poată spune nu doar „aceste documente sunt similare”, ci și „în ce privințe am decis să le consider similare și ce am eliminat în acest proces”.

Acesta este punctul în care teoria informației devine o disciplină de proiectare. Ea nu ne oferă o metrică universală a originalității, dar ne obligă să întrebăm ce diferențe sunt conservate, ce întrebări rămân rezolvabile și unde este necesar accesul suplimentar la documentele originale. Noutatea nu poate fi dedusă din numărul de biți ai surprizei. În schimb, pierderea anumitor biți semantic decisivi poate face detectarea ei imposibilă pentru o arhitectură dată.

Capitolul 3. Ce învață un model lingvistic și cum ajunge să judece

3.1. De la tokeni la o procedură condiționată

Un model lingvistic nu primește ideile ca obiecte ideale, deja separate de formularea lor. Primește o secvență de unități discrete, numite tokeni. Tokenizarea poate fragmenta cuvinte, poate păstra simboluri matematice separat și poate reprezenta diferit două formulări apropiate. Înainte de orice judecată asupra originalității există, așadar, un canal de codificare. Această observație nu implică automat pierderea sensului, dar introduce o primă variabilă de control: dificultatea unei sarcini nu trebuie confundată cu dificultatea reprezentării textului în tokenizarea utilizată.

Tokenii sunt transformați în vectori. În arhitectura Transformer, mecanismele de atenție permit combinarea informației din poziții diferite, folosind ponderi dependente de reprezentările curente. Straturile succesive modifică aceste reprezentări, iar ieșirea produce scoruri pentru continuări. Lucrarea care a introdus Transformerul descrie această organizare în contextul modelării secvențelor. Ea nu demonstrează prin arhitectură competențe generale de raționament sau evaluare a originalității. [R03]

Pentru problema noastră, atenția trebuie înțeleasă funcțional. Ea poate permite ca o condiție dintr-un paragraf să influențeze interpretarea unei garanții din alt paragraf. Dar existența unei căi de comunicare între poziții nu garantează că modelul urmărește condiția corectă. O arhitectură poate exprima un calcul fără ca ponderile învățate să îl implementeze fiabil. A spune „modelul poate acorda atenție întregului document” este o afirmație despre accesul structural; a spune „modelul compară toate ipotezele relevante” este o afirmație despre comportament.

Un programator poate privi un LLM ca pe un interpret aproximativ al unei sarcini formulate în text. Promptul specifică un contract incomplet, exemplele și contextul furnizează date, iar modelul produce o ieșire conform regularităților învățate. Această analogie este utilă, cu condiția să nu fie luată literal. Nu există neapărat o separare internă stabilă între parser, planificator, memorie și verficator. Totuși, în evaluarea externă putem construi teste distincte pentru înțelegerea instrucțiunii, extragerea afirmațiilor, regăsirea antecedentelor și aplicarea criteriului.

Învățarea din context reprezintă adaptarea comportamentului folosind exemplele din prompt, fără actualizarea parametrilor în timpul acelei interacțiuni. Brown și colaboratorii au documentat rezultate importante de tip few-shot pentru un model autoregresiv mare. Aceste rezultate arată că performanța nu este descrisă complet de întrebarea „a existat exact acest exemplu în antrenare?”. Nu garantează însă învățarea oricărei reguli noi din câteva exemple. [R04]

Într-un test de noutate, contextul poate defini chiar lumea de referință. Putem furniza o bibliotecă de trei mecanisme și cere modelului să determine dacă un al patrulea este echivalent cu unul dintre ele. Dacă numele mecanismelor sunt generate aleator după fixarea modelului, recunoașterea după reputație devine mai dificilă. Modelul trebuie să folosească definițiile locale. Reușita ar demonstra o competență de comparație într-o lume controlată; eșecul ar indica un obstacol concret, fără a spune imediat care strat intern îl produce.

Termenul „reprezentare semantică” trebuie folosit cu modestie. Un vector poate corela puternic cu sensuri sau relații utile fără să constituie o descriere completă, stabilă și interpretabilă a ideii. Într-un sistem de regăsire, ne interesează dacă vecinătatea vectorială aduce documentele relevante. Într-un verficator, ne interesează dacă diferențele dintre ipoteze și concluzii sunt conservate. Aceeași reprezentare poate fi adecvată primei operații și insuficientă celei de-a doua.

O greșeală de proiectare ar fi să tratăm vectorul tematic drept identitatea contribuției. Două lucrări despre aceeași problemă trebuie să fie apropiate pentru ca regăsirea să funcționeze. Tocmai de aceea, apropierea lor nu ar trebui utilizată direct ca dovadă că nu există diferență. Reprezentarea optimizată pentru a aduce împreună documente relevante poate comprima distincții pe care comparația finală trebuie să le reintroducă. Un bun vecin semantic nu este automat un antecedent care anticipează contribuția.

În consecință, evaluarea LLM-urilor trebuie să înceapă cu o diagramă funcțională a informației disponibile, nu cu presupuneri despre ce „știe” modelul. Ce text primește? Ce părți sunt trunchiate? Ce instrucțiune definește noutatea? Ce surse sunt adăugate? Ce formă de ieșire este cerută? Un răspuns greșit poate proveni din fiecare dintre aceste locuri. Fără această descompunere, explicația „modelul repetă trecutul” riscă să devină o etichetă universală aplicată unor eșecuri foarte diferite.

3.2. Generalizare, memorare și priorități introduse prin postantrenare

Memorarea și generalizarea nu sunt două stări mutual exclusive ale unui model. Un sistem poate memora anumite secvențe și, în același timp, poate învăța regularități aplicabile unor secvențe noi. Pentru detectarea noutății, ambele capacități pot fi utile sau problematice. Memorarea unui antecedent ajută la respingerea unei redescoperiri. Memorarea reputației unei lucrări poate contamina un test retrospectiv. Generalizarea unei reguli de comparație ajută la identificarea diferențelor; generalizarea excesivă a unei categorii poate șterge tocmai excepția relevantă.

Nu este suficient să arătăm că modelul poate produce fragmente familiare pentru a concluziona că orice verdict este o recuperare a unor fragmente. Dar nici absența unei reproduceri literale nu dovedește existența unei comparații conceptuale. Un model poate reformula o asocierie memorată. Evaluarea trebuie să construiască

situații în care memorarea și compararea fac predicții diferite: nume schimbate, relații inversate, ipoteze mutate între candidați și antecedente, cazuri în care formularea cunoscută ascunde concluzia greșită.

Un test util este inversarea controlată a lumii. Într-o condiție, biblioteca conține metoda A, iar candidatul propune B. În alta, aceeași pereche este inversată, iar biblioteca conține B. Dacă eticheta depinde de referință, verdictul trebuie să se schimbe în mod coerent. Un evaluator care declară permanent B mai nou deoarece B are un vocabular sofisticat nu respectă definiția locală a sarcinii. Această manipulare este mai informativă decât simpla cerere de explicații suplimentare.

Modelele utilizate ca asistenți nu sunt de regulă descrise complet de preantrenarea autoregresivă. Pot exista etape de ajustare supravegheată și optimizare pe preferințe. Ouyang și colaboratorii descriu o procedură care combină demonstrații umane, comparații de răspunsuri și învățare din feedback. Rafailov și colaboratorii propun o metodă de optimizare directă a preferințelor, fără a construi în aceeași manieră întregul circuit de învățare prin recompensă. Aceste lucrări arată că politica finală poate fi modificată pentru a favoriza anumite tipuri de răspuns. Ele nu stabilesc că preferințele introduse sunt în mod necesar ostile noutății. [R05, R06]

În problema noastră, postantrenarea este un candidat cauzal care trebuie separat de preantrenare. Dacă evaluatorii umani preferă formulările prudente, explicite și convenționale, sistemul poate învăța să le producă sau să le aprecieze. Dacă exemplele de evaluare recompensează menționarea unor termeni standard, acești termeni pot deveni indicii. Dar acestea sunt ipoteze despre date și obiective. Nu pot fi demonstrate doar observând că un răspuns este conservator.

Am putea compara un model de bază și versiunea sa ajustată, dar comparația nu izolează automat un singur mecanism. Se pot modifica simultan capacitatea de a urma instrucțiuni, stilul, lungimea răspunsului și modul de utilizare a contextului. O evaluare cauzală cere fie intervenții mai controlate, fie o interpretare limitată: „diferență

între două proceduri de antrenare”, nu „efect pur al preferinței pentru conformism”.

Explicațiile generate de model sunt utile ca obiecte de verificat, nu ca acces direct la cauza internă a verdictului. Un model poate produce o explicație plauzibilă după ce a ales scorul din alte indicii. Pentru a testa dacă un antecedent a fost decisiv, putem elimina sau modifica antecedentul și observa schimbarea comportamentului. Pentru a testa dacă o diferență a fost înțeleasă, putem cere o predicție care depinde de ea. Intervenția asupra informației este mai puternică decât simpla introspecție textuală.

O strategie de verificare constă în separarea verdictului de martor. Modelul trebuie să indice un pasaj anterior care anticipează contribuția sau un caz în care candidatul și antecedentul au comportamente diferite. Martorul poate fi verificat independent. Dacă scorul spune „nou”, dar martorul este fals, avem o eroare detectabilă. Dacă martorul este corect, dar scorul este prea mic, problema se mută către criteriul de relevanță sau agregare. Această separare reduce dependența de fluența explicației.

În sfârșit, competența unui model nu trebuie atribuită automat întregului sistem sau invers. Un LLM cu acces la căutare, calcul și verificatoare poate performa diferit de același LLM izolat. O contribuție găsită de un verificator simbolic nu dovedește că modelul a rezolvat singur problema. Dar nici utilizarea unui verificator nu invalidează utilitatea sistemului. Raportarea trebuie să precizeze cine a propus comparația, cine a executat-o și cine a certificat rezultatul.

3.3. Eșecuri ale evaluatorului care seamănă între ele numai la suprafață

Un evaluator poate rata o idee deoarece antecedentele lipsesc. Acesta este un eșec de acoperire. Poate primi antecedentele, dar poate omite paragraful relevant. Acesta este un eșec de acces efectiv la context. Poate citi paragraful și poate confunda cuantificatorii. Acesta este un

eșec de interpretare. Poate identifica diferența și poate considera greșit că nu contează. Acesta este un eșec de aplicare a criteriului. Poate produce toate elementele corecte, dar un scor final inconsistent. Acesta este un eșec de agregare sau de instrucțiune.

Distincțiile sunt importante deoarece remediile diferă. Extinderea motorului de căutare poate ajuta acoperirea, dar nu rezolvă confuzia între „există” și „pentru toate”. Un prompt mai explicit poate ajuta respectarea criteriului, dar nu aduce documentul lipsă. Un model mai mare poate reduce unele erori, dar nu poate recupera informație eliminată definitiv de un rezumat intermediar. Fără diagnostic, creșterea costului de inferență riscă să producă doar explicații mai ample ale aceleiași erori.

Există și eșecuri de poziționare a informației. Lucrarea *Lost in the Middle* a raportat, pentru modelele și sarcinile testate, performanțe dependente de poziția informației relevante în contexte lungi. Aceasta nu demonstrează că toate modelele viitoare vor avea aceeași problemă. Oferă însă un motiv concret pentru a controla ordinea documentelor și localizarea antecedentului decisiv în experimente. [R16]

Un filtru de noutate este deosebit de expus deoarece diferența importantă poate fi mică în raport cu lungimea totală a textului. Dacă documentul conține zece pagini de context familiar și o propoziție care schimbă domeniul garanției, succesul depinde de atenția operațională acordată acelei propoziții. Nu este suficient ca sistemul să summarizeze corect majoritatea documentului. O eroare locală poate inversa verdictul global.

Să construim un caz simplu. Antecedentul sortează o colecție în memorie, iar candidatul pretinde aceeași ordine folosind acces secvențial la date externe. Un evaluator tematic poate observa că ambele sunt algoritmi de sortare. Un evaluator operațional trebuie să compare modelul de acces și resursele. Dacă sarcina cere noutate în funcția calculată, ambele pot fi echivalente. Dacă cere noutate în modelul de execuție, diferența poate fi centrală. Verdictul nu poate fi judecat fără a cunoaște contractul evaluării.

Un alt caz construit privește negarea unei presupunerii. Un text spune că procedura necesită un canal autenticat. Altul susține că necesitatea poate fi înlocuită de o ipoteză diferită. Un model care normalizează a doua formulare la prima poate face textul mai familiar, dar mai puțin fidel. Această „corectare” nu este neapărat intenționată. Poate fi o consecință a interpretării celei mai probabile. Totuși, pentru detecția contribuțiilor neobișnuite, intenția este secundară; importantă este conservarea diferenței.

Trebuie controlată și tendința de a produce evaluări conforme tonului utilizatorului. Dacă promptul întreabă „de ce este revoluționară această idee?”, sarcina implică deja un verdict. Dacă întreabă „de ce este doar o variație banală?”, creează altă presiune. Un benchmark care compară numai variante afirmative ale aceleiași întrebări nu măsoară stabilitatea epistemică. Formulările favorabile, neutre și sceptice trebuie testate pe același conținut, fără a sugera că una dintre ele reprezintă adevărul.

Concluzia acestui capitol este funcțională. „LLM-ul judecă noutatea” nu este o operație elementară. Este un lanț de transformări și alegeri, unele implementate de model, altele de aplicația din jurul său. Ipoteza familiarității devine științific utilă numai când este localizată într-un asemenea lanț și când există o intervenție capabilă să distingă mecanismul propus de explicații alternative.

Capitolul 4. O semantică operațională a contribuțiilor

4.1. Ideea ca structură de afirmații, nu ca temă

O temă este un teritoriu al discursului. O contribuție este o modificare determinată în interiorul aceluși teritoriu sau o schimbare a regulilor lui. „Inteligență artificială pentru cercetare” numește o temă. „Un verificador care detectează contradicții între ipotezele declarate ale două experimente” descrie o funcție. „Un verificador care face aceasta fără acces la datele brute, în condițiile X” introduce o posibilă diferență. Pentru evaluarea noutății, trecerea de la temă la structură este obligatorie.

O reprezentare operațională poate descrie problema, ipotezele, mecanismul, garanțiile, costurile și dovezile. Nu toate câmpurile trebuie completate în orice document. Absența unui câmp este ea însăși informație: dacă o propunere nu declară ipotezele, evaluatorul nu ar trebui să le inventeze pentru a o face comparabilă. Poate formula mai multe interpretări și poate marca ce verdict depinde de fiecare.

Vom scrie, schematic, o contribuție ca un obiect structurat. Notația este un instrument de analiză, nu o cerință ca orice idee să intre într-un singur formular universal.

$$x = (P, A, M, G, R, E).$$

P desemnează problema, A ipotezele, M mecanismul, G garanțiile sau rezultatele pretinse, R resursele și E evidența furnizată. Diferența dintre două contribuții poate apărea în orice componentă sau în relația dintre componente. Aceeași garanție sub ipoteze mai slabe nu este aceeași afirmație. Același mecanism cu altă dovadă poate constitui alt tip de contribuție. Aceleași rezultate obținute cu mai puține resurse pot avea noutate operațională chiar dacă funcția finală rămâne identică.

Pentru a evita transformarea schemei într-o ontologie rigidă, fiecare câmp trebuie legat de pasaje originale. Reprezentarea nu trebuie să înlocuiască documentul fără posibilitatea de audit. Un evaluator poate spune: „am extras ipoteza A din acest pasaj” și poate păstra o variantă alternativă dacă textul este ambiguu. Scopul structurării este conservarea diferențelor, nu forțarea lor într-un vocabular familiar.

Negarea, modalitatea și cuantificarea sunt deosebit de importante. „Poate îmbunătăți” nu este echivalent cu „îmbunătățește pentru toate cazurile”. „Există un set de parametri” nu este echivalent cu „pentru orice set de parametri”. „Sub ipoteza independenței” nu este o notă stilistică. Aceste elemente pot fi scurte în text și mari în consecințe. Un rezumat care păstrează substantivele, dar pierde operatorii logici poate rămâne tematic corect și semantic inutil pentru noutate.

O structură de contribuție poate fi privită ca un mic graf. Nodurile reprezintă afirmații, ipoteze, rezultate și surse. Muchiile pot indica dependența, justificarea, contradicția sau transformarea unei ipoteze. Graful nu trebuie confundat cu o dovadă: faptul că două noduri sunt legate printr-o muchie „justifică” nu certifică validitatea relației. Dar oferă locuri precise unde un verficator sau un expert poate interveni.

Această reprezentare permite întrebări mai bune decât „este ideea nouă?”. Ce garanție nu este prezentă în antecedent? Ce ipoteză a fost eliminată? Ce observație ar diferenția mecanismele? Ce afirmație este numai o reformulare? Ce parte a contribuției depinde de o presupunere neverificată? Fiecare răspuns poate fi evaluat separat. Nu obținem automat adevărul, dar obținem o suprafață mai bună pentru corectare.

4.2. Echivalență, anticipare și diferență reziduală

Echivalența este o relație mai puternică decât asemănarea. Două obiecte pot semăna fără a fi echivalente; pot fi echivalente sub un criteriu și diferite sub altul. Pentru funcții pe un domeniu finit, echivalența extensională înseamnă identitatea ieșirilor pentru toate intrările din acel domeniu. Pentru articole științifice, criteriul poate fi

mult mai complex. De aceea, o distanță mică într-un spațiu vectorial nu poate fi tratată direct ca dovadă de echivalență conceptuală.

Vom nota prin x echivalent_C y faptul că două contribuții sunt echivalente după criteriul C . Dacă relația este într-adevăr de echivalență, ea trebuie să fie reflexivă, simetrică și tranzitivă. Multe scoruri de similaritate nu satisfac aceste cerințe în forma praguită. Putem avea A similar cu B și B similar cu C , fără ca A să fie similar cu C . A construi clase de idei prin închiderea tranzitivă a unei asemenea relații poate reuni contribuții care nu ar fi trebuit confundate.

Anticiparea este adesea asimetrică. Un antecedent poate conține deja toate elementele relevante ale candidatului, chiar dacă include și rezultate suplimentare. În acest caz, candidatul nu trebuie să fie identic cu antecedentul pentru ca pretenția de noutate să fie slăbită. Putem reprezenta relația printr-o incluziune a conținutului relevant, cu condiția să precizăm ce înseamnă conținut și ce reguli de inferență sunt permise.

$$novel_C(x, K) = 1 \Leftrightarrow \neg \exists k \in K : Ant_C(k, x).$$

Aici, $Ant_C(k, x)$ înseamnă că antecedentul k anticipează contribuția x după criteriul C . Aceasta este o definiție de lucru într-o lume închisă, nu o definiție juridică a noutății și nici o garanție asupra întregii istorii a ideilor. În aplicații reale, mai multe surse pot contribui împreună la ceea ce pare nou într-un candidat. Dacă permitem orice combinație de antecedente, trebuie stabilit când combinația este considerată deja disponibilă și când construirea ei este ea însăși contribuția. În lipsa unei asemenea reguli, evaluatorul poate declara orice idee „o combinație de lucruri cunoscute”, ceea ce nu mai discriminează nimic.

Un concept util este diferența reziduală. După identificarea celor mai apropiate antecedente, extragem ce rămâne neanticipat după criteriul declarat. Diferența poate fi vidă, clară sau incertă. Poate consta într-o condiție eliminată, într-un tip de obiect introdus sau într-o nouă relație între componente vechi. „Rezidual” nu înseamnă minor; înseamnă ceea ce rămâne după o comparație explicită.

Un exemplu construit: antecedentul A rezolvă problema P pentru intrări fără cicluri. Antecedentul B tratează cicluri, dar numai într-un caz restrâns. Candidatul C susține o soluție pentru toate intrările dintr-o clasă mai mare. Un rezumat „combină A și B” nu este suficient pentru a nega noutatea. Trebuie arătat fie că aplicarea compusă a antecedentelor produce deja garanția lui C, fie că C nu oferă în realitate garanția pretinsă. În primul caz, pretenția de noutate este anticipată; în al doilea, validitatea este contestată. Sunt argumente diferite.

În matematica formală apare o dificultate instructivă. Dacă definim cunoașterea prin toate consecințele logice ale axiomelor acceptate, orice teoremă demonstrabilă era deja implicit conținută în axiome. Atunci nicio demonstrație nouă nu ar extinde mulțimea consecințelor. Această definiție poate fi utilă logic, dar nu descrie bine progresul epistemic al unui agent cu resurse limitate. A avea o consecință implicită nu este același lucru cu a o fi identificat sau demonstrat într-un timp practic.

Putem introduce o închidere dependentă de resurse: consecințele pe care procedurile specificate le pot obține din K în bugetul B. Noua demonstrație poate extinde ceea ce este accesibil, chiar dacă nu extinde consecința logică ideală. Această idee trebuie folosită cu precauție deoarece rezultatul depinde de procedură și de reprezentare. Totuși, ea face vizibil un tip de noutate pe care simpla incluziune semantică îl ratează: transformarea unei posibilități abstracte într-o cunoaștere efectiv utilizabilă.

În informatică, același fenomen apare când o metodă de compilare transformă un calcul corect, dar impracticabil, într-unul eficient. Funcția calculată poate rămâne identică, iar contribuția să fie substanțială. Un detector care identifică numai funcții noi ar rata-o prin definiție, nu prin lipsă de inteligență. Alegerea criteriului trebuie deci făcută în raport cu tipul de progres pe care dorim să îl observăm.

4.3. Când ideea schimbă chiar vocabularul comparației

Cea mai dificilă situație nu este întotdeauna o nouă valoare într-un câmp cunoscut. Uneori contribuția contestă câmpurile. În loc să propună un mecanism mai bun pentru problema acceptată, redefinește problema. În loc să optimizeze o garanție, sugerează că garanția este nepotrivită. În loc să adauge o categorie, schimbă criteriul după care categoriile au fost construite. Un evaluator care cere tuturor ideilor să se conformeze aceleiași scheme poate rata exact acest tip de schimbare.

Nu rezultă că orice refuz al vocabularului existent este profund. Unele reformulări nu produc predicții, operații sau clarificări suplimentare. Altele ascund incoerență. Dificultatea reală este că testul de noutate trebuie să permită contestarea criteriului fără să renunțe la verificare. Soluția propusă aici este evaluarea pe două niveluri: comparația în cadrul curent și examinarea motivată a schimbării cadrului.

La primul nivel, sistemul poate spune că propunerea nu introduce o funcție nouă după criteriul existent. La al doilea, poate întreba dacă propunerea arată o limită a criteriului, oferă exemple pe care cadrul nu le distinge și introduce o alternativă cu consecințe verificabile. O schimbare de cadru devine mai mult decât o metaforă când arată ce poate fi observat sau făcut diferit. Astfel, originalitatea conceptuală nu este redusă la o distanță lexicală, dar nici scutită de obligația de a produce diferențe inteligibile.

Un exemplu construit pentru programatori este schimbarea modelului de cost. Două algoritmi pot fi echivalente dacă numărăm numai operațiile aritmetice, dar diferite dacă transferul datelor este costul dominant. Propunerea unui alt model de cost nu schimbă funcția calculată; poate schimba însă întrebarea de optimizare și ordinea soluțiilor preferate. Evaluatorul trebuie să distingă o simplă schimbare convenabilă a metricii de o schimbare justificată de condițiile aplicației.

Un alt exemplu privește confidențialitatea. Dacă sistemul descrie două proceduri numai prin acuratețe și timp, nu poate evalua diferența dintre ele în privința informației dezvăluite. Introducerea unui model

explicit al adversarului poate arăta că vechea reprezentare era insuficientă. Nu este nevoie să afirmăm că orice nou model adversarial este original istoric. Exemplul arată numai că noutatea poate consta în adăugarea unei dimensiuni relevante, nu într-o nouă valoare pe dimensiunile vechi.

Într-un sistem automat, schimbarea ontologiei trebuie gestionată fără a rescrie retroactiv datele. O soluție este păstrarea mai multor interpretări și a unei relații de traducere între ele. Contribuția rămâne legată de formularea originală, iar evaluatorul poate compara rezultatele sub criterii alternative. Dacă toate interpretările sunt comprimate într-una singură la început, posibilitatea de revizuire dispare. Dacă sunt păstrate fără limită, costul devine incontrollabil. Problema este una de alocare a bugetului între interpretări plauzibile.

Aici apare o direcție de cercetare importantă: detectarea insuficienței reprezentării înainte de detectarea noutății. Un sistem ar putea observa că două texte sunt foarte apropiate în reprezentarea curentă, dar conțin afirmații incompatibile sau diferențe explicite pe care schema nu le poate codifica. În loc să le declare identice, ar putea cere extinderea schemei sau verificare umană. Aceasta este o propunere arhitecturală, nu o capacitate demonstrată în această carte.

Un asemenea mecanism trebuie testat și împotriva abuzului. Dacă fiecare diferență lexicală declanșează o ontologie nouă, sistemul devine inutil. Criteriul de escaladare ar trebui să depindă de existența unei întrebări concrete la care interpretările dau răspunsuri diferite. În felul acesta, schimbarea reprezentării rămâne conectată la consecințe, nu la impresia vagă de profunzime.

Încheierea acestui capitol este o avertizare și o oportunitate. Nu putem detecta toate tipurile de noutate într-un spațiu care a eliminat de la început diferențele lor constitutive. Dar putem construi sisteme care își declară criteriile, păstrează sursele și permit revizuirea reprezentării. O asemenea disciplină nu promite recunoașterea infailibilă a revoluțiilor conceptuale. Ea împiedică măcar confundarea limitelor unei scheme cu limitele a ceea ce poate fi nou.

Capitolul 5. Cum poate familiaritatea să devină un substitut pentru noutate

5.1. Indicii convenabile și scurtături ale evaluării

Să presupunem că, în datele unui evaluator, contribuțiile apreciate drept originale sunt mai des prezentate cu o anumită structură: problemă importantă, limită a lucrărilor anterioare, mecanism nou, rezultate convingătoare. Structura poate fi o bună practică de comunicare. Dar ea poate deveni și un indiciu statistic pentru eticheta „original”. Un model care învață indiciul poate reuși frecvent fără să compare efectiv mecanismul cu antecedentele. Când indiciul și adevărul se despart, performanța se poate deteriora.

Acesta este un mecanism ipotetic de învățare prin scurtături. Nu implică faptul că structura retorică este inutilă sau că modelul nu utilizează deloc conținutul. Cel mai probabil, într-o aplicație concretă trebuie investigate combinații de indicii. Un scor poate depinde parțial de diferența reală și parțial de fluentă, vocabular, lungime, autoritate sau potrivirea cu un domeniu familiar. Întrebarea experimentală este cât contribuie fiecare factor și în ce condiții unul îl înlocuiește pe altul.

Retorica noutății poate fi separată de noutatea declarată. Într-o pereche controlată, același conținut poate fi prezentat prin „introducem un cadru revoluționar” sau prin „procedura diferă de precedent prin condiția următoare”. Dacă scorul se schimbă fără modificarea afirmațiilor, există sensibilitate la ambalaj. Această sensibilitate nu trebuie numită imediat efect al frecvenței de antrenare. Ea poate proveni din instrucțiuni, postantrenare, criterii implicite de claritate sau preferințe de stil. Identificarea cauzei cere intervenții suplimentare.

Un alt indiciu este densitatea terminologică. O propunere care combină termeni la modă poate părea mai avansată decât o explicație simplă a aceleiași operații. Dar eliminarea tuturor termenilor tehnici nu este o

soluție bună: unii sunt necesari pentru precizie. Manipularea experimentală trebuie să păstreze informația, nu doar impresia generală. Două versiuni declarate „echivalente” de același LLM evaluat pot conține diferențe subtile. Echivalența manipulării trebuie verificată independent sau construită într-un domeniu formal.

Familiaritatea poate funcționa și în sens invers. Un text neobișnuit poate primi un scor mare tocmai pentru că pare diferit. Un evaluator superficial poate confunda straniețea cu originalitatea, nu doar originalitatea cu familiaritatea. Ipoteza trebuie formulată astfel încât să permită această posibilitate. Nu există o singură direcție obligatorie a biasului. Un model poate prefera claritatea familiară într-un context și extravaganta într-altul, în funcție de ce a învățat că se cere prin „creativ”.

Prestigiul sursei este încă o variabilă distinctă. Dacă numele autorului sau instituției schimbă verdictul pentru același text, avem un efect de atribuire. Nu este identic cu efectul frecvenței ideii. Un autor poate fi familiar fără ca mecanismul să fie vechi. Un model poate folosi numele ca prior despre calitatea probabilă, iar acest prior poate fi rezonabil pentru anumite sarcini și nepotrivit pentru evaluarea anonimă a noutății. Contractul evaluării trebuie să spună dacă asemenea informații sunt admise.

Problema indicilor convenabili nu este specifică ontologic inteligenței artificiale. Orice evaluator limitat poate folosi euristici. Diferența practică a automatizării este că aceeași euristică poate fi aplicată la scară mare și cu un stil uniform de justificare. Această afirmație este o deducție despre multiplicarea unei reguli de decizie, nu o estimare empirică a comportamentului comunităților umane. Pentru a compara oameni și modele avem nevoie de aceleași texte, aceleași surse și aceleași resurse de verificare.

O consecință importantă este că robustețea la reformulare nu trebuie măsurată numai pe parafraze confortabile. Dacă toate variantele sunt produse de același model în același stil, testul poate confirma invarianta față de un spațiu foarte îngust. Sunt necesare variante

tehnice, neutre, minimale și explicative, plus schimbări controlate ale ordinii și terminologiei. În același timp, nu trebuie să transformăm rezistența la proză defectuoasă în definiția noutății. Un detector poate avea nevoie legitimă de clarificări.

5.2. Netezirea semantică: când interpretarea repară tocmai excepția

Vom folosi termenul netezire semantică, sau *smoothing semantic*, pentru o familie de transformări care reduc variația dintre texte. Unele elimină variații irelevante, precum ordinea unor explicații echivalente. Altele normalizează terminologia. Altele aleg interpretarea cea mai probabilă a unui pasaj ambiguu. Netezirea nu este prin definiție un defect. Fără anumite invarianțe, sistemul ar confunda fiecare parafrază cu o contribuție nouă.

Riscul apare când sistemul netezește o variație relevantă. Un text afirmă că mecanismul funcționează fără o condiție obișnuită. Pentru că această afirmație este neobișnuită, modelul o poate interpreta ca pe o omisiune sau o formulare imprecisă și poate reintroduce condiția în rezumat. Rezultatul devine mai plauzibil, dar mai puțin fidel. Exact afirmația care trebuia evaluată a fost transformată într-o versiune convențională.

Putem descrie acest fenomen ca o competiție între fidelitate și priorul de plauzibilitate. În interpretarea unui text zgomotos, alegerea sensului probabil este adesea utilă. În evaluarea unei idei care pretinde să depășească o limită, aceeași alegere poate fi periculoasă. Sistemul trebuie să distingă între „autorul probabil a vrut să spună ceva obișnuit” și „autorul afirmă explicit ceva neobișnuit, care trebuie verificat”. A doua variantă păstrează obiectul criticii; prima îl poate elimina.

Un exemplu construit folosește un cuantificator. Antecedentul garantează că pentru fiecare intrare există un parametru potrivit. Candidatul garantează existența unui singur parametru care

funcționează pentru toate intrările. Cele două propoziții pot conține aceleași substantive și aproape aceleași cuvinte. Ordinea cuantificatorilor schimbă însă radical pretenția. Un rezumat de tipul „există parametri care asigură funcționarea” le poate face indistincte. Nu este o pierdere ornamentală; este o pierdere logică.

Un al doilea exemplu privește cauzalitatea. Un antecedent raportează o asociere între două variabile. Candidatul susține că o intervenție asupra uneia modifică cealaltă în anumite condiții. Un sumar care spune „arată o relație între variabile” păstrează tema și elimină diferența dintre asociere și intervenție. Candidatul poate fi greșit în pretenția sa cauzală. Dar dacă diferența este ștearsă, sistemul nici nu mai știe ce ar trebui validat.

Un al treilea exemplu privește domeniul. Două metode au aceeași formulă, dar una este definită pe obiecte finite, iar cealaltă pretinde o extensie la un spațiu infinit. Dacă reprezentarea păstrează formula și ignoră domeniul, va supraestima echivalența. Din nou, nu trebuie să presupunem că extensia este corectă pentru a constata că afirmațiile diferă. Detectarea contribuției pretinse și validarea acesteia trebuie menținute separat.

Netezirea poate apărea în extragerea afirmațiilor, în sumarizare, în traducere, în embeddings, în alegerea cuvintelor-cheie și în reformularea interogărilor de căutare. Într-un lanț cu mai multe etape, o diferență mică poate fi pierdută de mai multe ori. Un model final mai puternic nu o poate recupera sigur dacă toate reprezentările pe care le primește sunt deja identice. De aceea, evaluarea numai a ultimului răspuns poate ascunde originea erorii.

Un test adecvat compară trei trasee. Primul păstrează textul original. Al doilea furnizează numai reprezentarea comprimată. Al treilea furnizează reprezentarea și accesul la pasajele originale decisive. Dacă performanța scade în al doilea și revine în al treilea, există dovezi că pierderea sau inaccesibilitatea informației intermediare contează. Pentru a atribui scăderea exact unei coliziuni semantice, trebuie

verificat că reprezentarea nu mai codifică diferența, nu doar că evaluatorul o folosește mai greu.

Este utilă și o sarcină auxiliară: după comprimare, poate un verificator să recupereze răspunsul la întrebarea care distinge candidatul de antecedent? Pentru exemplul cuantificatorilor, întrebarea este dacă parametrul poate depinde de intrare. Dacă rezumatul nu permite un răspuns, avem o măsură directă a pierderii informației relevante. Un scor generic de fidelitate a rezumatului poate rata acest defect, deoarece majoritatea conținutului a fost păstrată corect.

Nu orice pierdere detectată justifică abandonarea compresiei. Trebuie comparat costul păstrării integrale cu valoarea diferenței și cu frecvența cazurilor. O arhitectură poate păstra rezumate pentru navigare și sursele pentru verificare, poate include câmpuri speciale pentru ipoteze și excepții sau poate escalada cazurile în care două interpretări produc consecințe diferite. Scopul nu este absența oricărei abstracții, ci controlul explicit al abstracțiilor care afectează verdictul.

5.3. Atracția către antecedente și buclele de confirmare

Regăsirea documentelor apropiate pare soluția firească la problema noutății. Dar un sistem poate căuta printr-o reformulare care a eliminat deja diferența candidatului. Atunci va recupera exact literatura familiară și va confirma propria interpretare inițială. Nu pentru că literatura ar demonstra identitatea, ci pentru că interogarea a exclus ceea ce trebuia cercetat. Aceasta este o buclă de confirmare posibilă în arhitectură, nu o proprietate inevitabilă a oricărui motor de căutare.

Să presupunem că propunerea vorbește despre o garanție fără sincronizare globală. Interogarea generată devine „garanție în sisteme sincronizate”, deoarece aceasta este categoria familiară. Rezultatele recuperate conțin numeroase antecedente apropiate tematic. Evaluatorul concluzionează că ideea este bine cunoscută. Eroarea finală pare o judecată de noutate, dar cauza a apărut în traducerea

cererii de căutare. Un jurnal de proveniență trebuie să păstreze și interogările, nu numai documentele finale.

Există și un risc simetric. Dacă interogarea folosește exclusiv vocabularul neobișnuit al candidatului, motorul poate rata antecedente descrise prin altă terminologie. Sistemul declară noutate pentru că nu a găsit potriviri lexicale. Soluția nu este alegerea exclusivă a căutării literale sau semantice, ci menținerea mai multor piste: termeni exacți, sinonime, mecanism, ipoteze, relații și consecințe. Fiecare pistă trebuie evaluată pentru contribuția sa la acoperire.

Un consens între mai multe modele nu rezolvă automat problema. Dacă toate primesc același rezumat sau folosesc același index, erorile lor pot fi corelate. Diversitatea numelor modelelor nu garantează diversitatea informației sau a criteriilor. Un ansamblu poate reduce variația aleatorie și poate consolida un bias comun. Pentru a demonstra un beneficiu trebuie măsurată complementaritatea erorilor, nu doar acordul final.

Un rol adversarial poate fi util: un evaluator caută antecedente, altul încearcă să construiască un caz care diferențiază candidatul. Totuși, disputa nu trebuie tratată ca metodă magică de producere a adevărului. Doi agenți pot genera argumente persuasive, dar false. Valoarea apare când argumentele conțin obiecte verificabile: surse, citate localizabile, calcule, contraexemple sau presupuneri explicit separate. Dezbateră fără martori riscă să fie doar competiție retorică.

Bucula instituțională apare atunci când verdictele sunt reutilizate drept date. Dacă ideile acceptate devin exemple pozitive fără audit, sistemul poate învăța propriile preferințe. Dacă ideile respinse nu sunt păstrate, nu mai există posibilitatea de a estima ce s-a pierdut. Într-un asemenea proces, lipsa erorilor observate poate reflecta lipsa observației, nu corectitudinea selecției. De aceea, arhivarea respingerilor și reevaluarea aleatorie sunt componente epistemice, nu simple funcții administrative.

Nu trebuie dedus că orice utilizare a datelor sintetice produce inevitabil colaps. Studiile despre antrenarea recursivă arată dependențe importante de regimul înlocuirii sau acumulării datelor. Aceste rezultate vor fi discutate separat. Aici argumentul este mai restrâns: o evaluare care devine propriul său adevăr de referință își poate pierde capacitatea de corectare. Această posibilitate există chiar fără reantrenare, dacă deciziile anterioare sunt tratate drept antecedente autoritative în fiecare rundă nouă.

Ipoteza familiarității trebuie, prin urmare, extinsă de la model la circuitul informațional. Uneori problema este un prior învățat. Alteori este o interogare de căutare, o reprezentare comprimată, o regulă de agregare sau o politică de păstrare a datelor. Un sistem responsabil nu atribuie toate erorile „halucinației modelului”, ci păstrează suficiente urme pentru a identifica transformarea care a făcut diferența invizibilă.

Capitolul 6. Imposibilități reale, condiții de posibilitate și demonstrații

6.1. Lipsa informației și imposibilitatea priorității absolute

Să definim riguros un evaluator ca o procedură care primește observații O și produce un verdict. Observațiile pot include documentul candidat, sursele accesibile, răspunsurile unui motor de căutare și rezultatele unor instrumente. Lumea completă poate conține și documente inaccesibile. Dacă două lumi produc exact aceleași observații pentru evaluator, procedura nu le poate distinge pe baza acelor observații. Aceasta este o limită elementară de identificabilitate.

Construim două lumi. În lumea W_0 , contribuția x nu are antecedent înainte de momentul t . În lumea W_1 , există un antecedent într-un document pe care evaluatorul nu îl poate accesa. Toate documentele accesibile sunt identice în cele două lumi. Istoria antrenării și starea evaluatorului sunt, de asemenea, identice. Verdictul istoric corect diferă, dar intrarea procedurii nu diferă. Un evaluator determinist va produce același răspuns în ambele lumi și va greși în cel puțin una.

Randomizarea nu elimină problema. Un evaluator aleator va produce aceeași distribuție de răspunsuri în cele două lumi, deoarece observațiile sale au aceeași distribuție. Nu poate avea probabilitate unu de corectitudine în ambele. Dacă acordăm probabilități egale celor două lumi, cel mai bun verdict fără alte informații nu poate depăși probabilitatea o jumătate de a identifica lumea corectă. Cu alte prioruri, poate favoriza lumea mai probabilă, dar nu obține certitudine informațională.

Această demonstrație nu spune că cercetarea antecedentelor este inutilă. Spune că o garanție absolută cere ipoteze despre completitudinea accesului. Într-o bibliotecă finită, enumerată integral, putem verifica absența unui element după un criteriu decidabil. Într-o istorie deschisă a cunoașterii, putem produce o concluzie condiționată

de sursele examinate. Diferența dintre aceste două situații trebuie exprimată în raportul final, nu ascunsă în fine print.

Limita se aplică oamenilor, motoarelor de căutare și sistemelor hibride. Nu este o proprietate specială a modelelor lingvistice. Prin urmare, nu poate fi folosită pentru a demonstra că LLM-urile sunt mai slabe decât oamenii. Pentru o comparație relativă trebuie oferite aceleași surse și același buget sau trebuie măsurat separat avantajul de acces. Altfel, competența și informația sunt confundate.

Se poate formula o garanție mai modestă: „nu am găsit un antecedent în K prin procedura P , iar acoperirea procedurii a fost evaluată pe o familie de cazuri similare”. Aceasta este o afirmație verificabilă. Nu echivalează cu absența istorică, dar poate fi suficientă pentru o decizie practică. Nivelul de încredere depinde de domeniu, de indexare și de capacitatea procedurii de a găsi antecedente cu vocabular diferit.

Un rezultat negativ de căutare are valoare numai în raport cu sensibilitatea căutării. Dacă procedura ratează frecvent antecedente cunoscute, faptul că nu a găsit nimic pentru candidat este slab informativ. Un test util constă în ascunderea controlată a identității unor lucrări și verificarea regăsirii lor pornind de la contribuție. Acest test nu dovedește completitudinea istorică, dar estimează o componentă necesară pentru interpretarea absenței rezultatelor.

Concluzia formală este restrânsă și puternică: niciun evaluator nu poate certifica universal absența unui antecedent inaccesibil fără ipoteze suplimentare. Din această propoziție nu rezultă imposibilitatea recunoașterii unei diferențe noi în raport cu o bibliotecă accesibilă. Trecerea nejustificată de la prima la a doua ar transforma o limită a informației într-o negare a comparației.

6.2. Teorema didactică a reprezentării suficiente

Considerăm o mulțime X de obiecte, o etichetare deterministă $Y: X \rightarrow \{0,1\}$ și o reprezentare $\varphi: X \rightarrow Z$. Întrebarea este dacă există un clasificator $g: Z \rightarrow \{0,1\}$ care decide perfect eticheta folosind numai reprezentarea.

Rezultatul următor este elementar și nu este prezentat ca o teoremă nouă a acestei cărți. El face explicit mecanismul pierderii diferenței.

Propoziție. Există un clasificator perfect g cu $Y=g\circ\varphi$ dacă și numai dacă Y este constantă pe fiecare fibră a lui φ . O fibră este mulțimea tuturor obiectelor care primesc aceeași reprezentare.

$$\varphi(x)=\varphi(x')\Rightarrow Y(x)=Y(x').$$

Demonstrația necesității este imediată. Dacă două obiecte au aceeași reprezentare, g primește aceeași intrare și produce aceeași ieșire. Pentru a fi corect pe ambele, etichetele lor trebuie să fie egale. Demonstrația suficienței construiește g : pentru fiecare reprezentare z , alegem eticheta comună a obiectelor din fibra sa. Ipoteza că eticheta este constantă garantează că definiția nu depinde de obiectul ales. Pe reprezentările neatinse de φ , g poate fi definit arbitrar.

Propoziția este informațională: existența funcției g nu garantează că aceasta este calculabilă sau eficientă pe un domeniu infinit. În cazul finit putem construi un tabel de decizie. În cazul general, problema calculabilității rămâne separată de condiția conservării informației.

Consecința pentru noutate este precisă. Dacă o contribuție nouă și una veche, după același criteriu și aceeași referință, sunt mapate la aceeași reprezentare, niciun evaluator limitat exclusiv la acea reprezentare nu poate fi perfect pe ambele. Nu contează cât de fluent este, câți parametri are sau cât timp reflectează. Poate ghici mai bine folosind prevalențe, dar nu poate recupera distincția pierdută dintr-un semnal identic.

Există însă o condiție adesea omisă: simpla neinjectivitate a reprezentării nu demonstrează eșecul. O reprezentare poate reuni multe texte parafrazate, toate cu aceeași etichetă, fără a pierde nimic relevant pentru sarcină. Dacă φ elimină numai variații irelevante, clasificarea poate rămâne perfectă. Problema nu este că două texte diferite au același vector. Problema este că două texte cu etichete diferite au aceeași informație disponibilă pentru decizie.

Mai mult, criteriul și biblioteca trebuie incluse în intrarea totală. Aceeași contribuție poate fi nouă față de K1 și veche față de K2. O reprezentare a candidatului, oricât de bună, nu este suficientă dacă evaluatorul nu primește referința. Putem defini obiectul total ca $u=(x,K,C)$. Teorema se aplică reprezentării lui u . Această precizare împiedică o eroare frecventă: tratarea noutății ca etichetă fixă a textului, independentă de context.

Pentru un exemplu finit, să avem patru obiecte echiprobabile. Primele două sunt vechi, următoarele două sunt noi. Reprezentarea Z are două valori: una reunește primul obiect vechi cu primul obiect nou, cealaltă reunește celelalte două. În fiecare fibră, etichetele sunt amestecate egal. Orice clasificator bazat numai pe Z greșește pe jumătate dintre obiecte. Dacă reprezentarea este schimbată astfel încât fiecare fibră conține numai obiecte cu aceeași etichetă, eroarea minimă devine zero, deși reprezentarea continuă să fie comprimată.

În cazul probabilistic discret, riscul Bayes minim pentru clasificarea binară din Z este suma, peste reprezentări, a masei clasei minoritare din fiecare fibră. Formula include simultan pierderea reprezentării și eventualul zgomot al etichetei.

$$R_Z^{opt} = \sum_z \min \{ P(Y=0, Z=z), P(Y=1, Z=z) \}.$$

Pentru prioruri egale ale claselor, aceeași limită poate fi exprimată prin distanța de variație totală dintre distribuțiile reprezentării condiționate de clasă. Variația totală măsoară cât de diferite sunt distribuțiile; dacă ele sunt identice, nu există semnal discriminativ.

$$R_Z^{opt} = \frac{1 - TV(P_{Z|Y=0}, P_{Z|Y=1})}{2}.$$

Aceste formule nu permit estimarea automată a erorii unui LLM dintr-un vector arbitrar. Distribuțiile relevante trebuie cunoscute sau estimate, iar reprezentările interne sunt de regulă complexe. Ele oferă însă o țintă conceptuală pentru experimente: căutăm transformări care

reduc separabilitatea etichetelor, nu doar lungimea textului. Putem măsura direct această reducere în lumi finite controlate.

Un corolar privește bugetul de reprezentare. Cu B biți putem distinge cel mult 2^B la puterea B stări. Dacă familia de întrebări viitoare cere distingerea a mai multor clase relevante, unele trebuie reunite. Dar o singură întrebare binară poate necesita mult mai puțină informație decât reconstrucția completă a documentului. De aceea, nu există o relație simplă de tipul „rezumat scurt, deci noutate imposibilă”. Limita depinde de câte distincții trebuie păstrate pentru sarcinile admise.

În sfârșit, accesul la sursă schimbă problema. Dacă evaluatorul primește Z și poate cere pasaje din X , nu mai este limitat la Z . Teorema nu îi interzice recuperarea diferenței printr-o observație nouă. Această observație este fundamentul arhitecturii propuse mai târziu: compresia pentru navigare poate fi combinată cu accesul verificabil la original pentru decizii care depind de detalii.

6.3. Calculabilitate, generalizare și contraexemple constructive

Unele limite ale noutății provin din calcul, nu din absența documentelor. Dacă ideile sunt programe arbitrare și criteriul cere echivalența comportamentului pentru toate intrările, intrăm în probleme generale de semantică a programelor. Rezultatele de tip Rice privesc imposibilitatea deciziei algoritmice totale pentru proprietăți semantice netriviale ale funcțiilor calculabile parțiale. Lucrarea lui Hemaspaandra și Rothe discută explicit diferența dintre asemenea rezultate și analogii de complexitate pentru clase restrânse. [R25]

Este esențială delimitarea. Indecidabil nu înseamnă că nicio instanță nu poate fi rezolvată. Înseamnă că nu există un algoritm care să se oprească și să decidă corect fiecare instanță din clasa generală. Multe programe concrete pot fi comparate, multe proprietăți pot fi demonstrate, iar clase restrânse pot fi decidabile. Invocarea calculabilității pentru a declara inutil orice detector de noutate ar fi o extindere nevalidă a rezultatului.

Putem vedea dificultatea printr-o construcție simplă. Dintr-un program arbitrar M și o intrare w , construim programul P care simulează $M(w)$ și, dacă simularea se termină, returnează zero. Dacă nu se termină, P nu produce rezultat. Un evaluator universal capabil să decidă dacă P este echivalent cu funcția constantă zero pe toate intrările ar decide dacă $M(w)$ se oprește. Astfel, o întrebare generală de echivalență poate ascunde problema opririi. Construcția explică limita fără a pretinde că toate sarcinile de noutate au aceeași dificultate.

Pentru circuite booleene cu un număr finit de intrări, situația este diferită. Putem evalua toate cele 2 la puterea n intrări și compara tabelele de adevăr. Procedura se oprește întotdeauna. Costul poate fi mare, dar problema este decidabilă. Dacă biblioteca este finită, putem verifica dacă funcția candidatului coincide cu vreuna dintre funcțiile stocate. Acesta este un contraexemplu constructiv la afirmația că detectarea noutății relative este imposibilă în principiu.

Mai trebuie distins sistemul de componenta sa lingvistică. Un LLM poate traduce o descriere într-un circuit, iar un verificator exact poate decide echivalența. Succesul întregului sistem arată că LLM-urile pot participa util la detectarea noutății, nu că traducerea lor este infailibilă sau că modelul singur a demonstrat tot. Putem evalua separat fidelitatea traducerii și corectitudinea vericatorului. Această separare face experimentul mai informativ decât un verdict monolitic.

Există și un contraargument simplu la teza că un model poate recunoaște numai obiecte întâlnite. O regulă de comparație învățată pe perechi vechi poate fi aplicată unor perechi generate ulterior. Dacă un model citește corect tabele de adevăr și identifică o linie diferită, nu este necesar ca acea pereche exactă să fi existat în antrenare. Nu afirmăm că orice LLM face aceasta robust; afirmăm că originea istorică a învățării nu constituie o demonstrație a imposibilității.

Rezultatele de tip no-free-lunch sunt adesea invocate prea larg. Într-o lume în care etichetele necunoscute sunt arbitrare și independente de observațiile anterioare, nicio regulă nu poate generaliza sistematic mai bine decât alta în medie peste toate etichetările. Dar problemele reale

nu sunt distribuite uniform peste toate funcțiile posibile. Au structură, regularități și criterii. Concluzia corectă este că generalizarea cere ipoteze inductive, nu că generalizarea este imposibilă.

Pentru noutate, ipoteza inductivă dorită nu este „viitorul seamănă întotdeauna cu trecutul”. Poate fi „regula de comparație rămâne valabilă și pentru obiecte noi”. Un comparator de circuite nu presupune că noul circuit este identic cu unul vechi; presupune că semantica porților și domeniul intrărilor sunt stabile. Această diferență între regularitatea procedurii și regularitatea rezultatului este centrală. Un sistem poate utiliza reguli cunoscute pentru a identifica o diferență necunoscută.

Rezultă o hartă clară a limitelor. Fără informație despre antecedente inaccesibile, prioritatea absolută nu este identificabilă. După pierderea unei distincții relevante, clasificarea perfectă din reprezentarea rămasă este imposibilă. Pentru programe generale, anumite comparații semantice sunt indecidabile. În schimb, în lumi finite și cu criterii explicite, noutatea relativă poate fi decisă exact. Întrebarea empirică despre LLM-uri începe între aceste limite: cât de bine traduc, compară, caută și conservă informația în sarcini unde un verdict corect este posibil?

Capitolul 7. Ce arată literatura și ce nu poate demonstra

7.1. Familiaritate, autoevaluare și creativitate percepută

Studiul Self-Preference Bias în LLM-as-a-Judge al lui Wataoka, Takahashi și Ri investighează preferința evaluatorilor pentru răspunsuri familiare din perspectiva modelului. Autorii raportează o asocieră între perplexitatea mai mică și evaluări mai favorabile, mai pronunțată decât în judecățile umane, inclusiv dincolo de simpla origine a textului în același model. Rezultatul susține investigarea familiarității ca factor de evaluare. Nu demonstrează direct respingerea ideilor științifice radical noi și nu identifică singur frecvența din preantrenare drept cauza unică. [R07]

Această limită de interpretare este importantă. Preferința pentru un răspuns ușor de anticipat poate reflecta, în anumite sarcini, claritate sau corectitudine. Pentru a demonstra un bias față de noutate trebuie să avem cazuri în care familiaritatea se modifică, iar calitatea și diferența conceptuală rămân controlate. Un rezultat despre preferința globală a evaluatorului este o piesă din argument, nu întregul argument.

Zheng și colaboratorii, în lucrarea despre MT-Bench și Chatbot Arena, examinează evaluarea prin LLM și discută efecte de poziție, verbositate și auto-favorizare, alături de limite de raționament. Studiul arată atât utilitatea practică a evaluatorilor în configurațiile testate, cât și necesitatea controlării unor biasuri. Un acord ridicat cu judecători umani într-un benchmark conversațional nu poate fi transferat automat la prioritatea istorică sau la evaluarea unei demonstrații. [R08]

Un design experimental poate folosi aceste rezultate ca punct de plecare fără a le exagera. Dacă ordinea răspunsurilor schimbă preferința într-o comparație, trebuie randomizată ordinea candidaților și a antecedentelor. Dacă lungimea influențează scorul, trebuie

controlată separat de completitudinea informației. Dacă modelul își favorizează propriul stil, comparațiile între idei generate de oameni și de modele trebuie să separe conținutul de sursa sau forma redactării.

Si, Yang și Hashimoto au realizat un studiu cu peste o sută de cercetători NLP, în care ideile generate cu ajutorul LLM-urilor au fost apreciate, în evaluarea umană oarbă utilizată, ca mai noi decât ideile umane, cu un rezultat raportat drept semnificativ statistic. Autorii discută și limite legate de fezabilitate, diversitate și autoevaluare. Rezultatul contrazice o versiune simplistă a afirmației că modelele pot produce numai texte percepute ca banale. Nu stabilește prioritatea istorică a tuturor ideilor și nu este un test direct al capacității de a detecta noutatea. [R09]

Aici se află o distincție metodologică majoră: o idee poate fi apreciată ca originală într-o lectură oarbă și totuși să aibă un antecedent obscur. Nu este o contradicție între rezultatele celor două proceduri. Ele măsoară operații diferite. Evaluarea impresiei de noutate poate fi relevantă pentru comunicare sau selecția inițială; verificarea antecedentelor este necesară pentru afirmații mai puternice.

Gupta și Pruthi au examinat, cu treisprezece experți, cincizeci de documente de cercetare generate de AI. În eșantionul lor, 24% au fost identificate ca parafrazări sau împrumuturi substanțiale din lucrări existente, cu verificări suplimentare ale legăturilor identificate. Studiul ilustrează diferența dintre aspectul original și examinarea explicită a antecedentelor. Procentul nu trebuie extrapolat la toate sistemele sau toate tipurile de generare. Similaritatea substanțială nu permite, singură, inferarea unei intenții psihologice de fraudă. [R10]

Citite împreună, aceste rezultate nu impun un verdict unic despre „creativitatea AI”. Ele arată că generarea, percepția originalității, regăsirea antecedentelor și atribuirea meritelor trebuie evaluate separat. O carte despre detectarea noutății ar greși dacă ar folosi succesul generării drept dovadă a unui detector bun sau dacă ar folosi un caz de împrumut drept dovadă că orice idee generată este derivativă în același sens.

7.2. Benchmarkurile de noutate și problema adevărului de referință

RINoBench, prezentat de Schopf și Färber în 2026, conține 1.381 de idei de cercetare și instrumente de evaluare a scorurilor și justificărilor. Versiunea consultată este indicată ca acceptată la LREC 2026. Autorii raportează că asemănarea justificărilor produse de modele cu raționamentele de referință nu asigură acordul asupra scorurilor. Construcția setului folosește evaluări OpenReview, filtrarea unor dezacorduri și prelucrarea cu LLM a ideilor și justificărilor. Dimensiunile de origine combină noutatea cu semnificația tehnică sau empirică. Aceste alegeri sunt relevante pentru interpretarea constructului măsurat. [R11]

NovBench, al lui Wu și colaboratorilor, are 1.684 de perechi lucrare–evaluare și este asociat în metadatele versiunii consultate cu ACL 2026. Include descrieri ale noutății extrase din introduceri și evaluări ale experților. Cadrul urmărește relevanța, corectitudinea, acoperirea și claritatea evaluărilor generate. Autorii raportează limite ale modelelor testate în înțelegerea noutății și dificultăți de urmărire a instrucțiunilor pentru unele modele ajustate. Interpretarea trebuie să țină cont că introducerea nu conține obligatoriu toate detaliile necesare comparării contribuției. [R12]

Liu și colaboratorii propun o abordare care combină descrieri conceptuale ale contribuțiilor, regăsirea antecedentelor și evaluarea prin modele lingvistice. Pe benchmarkurile lor de detectare a noutății, raportează îmbunătățiri prin utilizarea regăsirii adaptate la idei. Rezultatul este o dovadă de posibilitate practică într-o configurație specifică, nu o certificare universală a originalității. El susține evaluarea întregii proceduri de acces și comparație, în locul presupunerii că modelul trebuie să decidă numai din memoria parametrilor. [R13]

Problema generală a oricărui asemenea benchmark este separarea între eticheta disponibilă și proprietatea vizată. O recenzie poate

combina originalitatea cu importanța, claritatea sau credibilitatea. Un scor poate reprezenta impresia unui expert după o lectură limitată, nu o verificare exhaustivă a antecedentelor. Un set de date poate rămâne foarte util chiar dacă nu măsoară prioritatea istorică absolută, cu condiția ca această limită să fie explicită.

Mai apare un risc atunci când obiectul evaluat este el însuși produs prin reformulare automată. Dacă un model extrage contribuția din articol, un alt model judecă reprezentarea extrasă. Un eșec poate proveni din extracție, iar un succes poate reflecta conformitatea cu stilul extractorului. Aceasta este o observație metodologică generală, nu dovada că un benchmark anume este invalid. Pentru a estima efectul sunt necesare comparații între originale, extrageri umane și extrageri automate, păstrând aceleași cazuri.

Filtrarea dezacordului poate îmbunătăți consistența etichetelor, dar poate schimba populația studiată. Dacă eliminăm cazurile asupra cărora experții nu sunt de acord, evaluăm un subset mai consensual. Nu știm automat cum ar performa sistemul pe idei care contestă un cadru sau necesită expertiză neobișnuită. Un benchmark poate avea un strat consensual pentru comparații stabile și un strat contestat pentru studiul limitelor. Ambele sunt informative, dar răspund la întrebări diferite.

Trebuie evitată și circularitatea evaluatorilor. Dacă un LLM produce justificarea de referință, alt LLM notează justificarea candidatului, iar criteriul principal este asemănarea semantică dintre ele, rezultatul poate reflecta o cultură stilistică comună. Acest risc nu interzice evaluarea automată. Cere verificări independente: antecedente concrete, diferențe verificabile, subseturi analizate de experți și măsurarea erorilor evaluatorului automat însuși.

Un benchmark puternic ar trebui să publice nu doar scoruri, ci și genealogia fiecărui caz: documentul original, momentul de referință, transformările, criteriul, antecedentele decisive și motivele dezacordului. Fără această genealogie, scorurile sunt greu de interpretat când apar diferențe între modele. Un sistem poate avea o

performanță mai mică pentru că detectează o ambiguitate reală pe care eticheta unică o ascunde.

7.3. Dovezi conexe și limitele transferului dintre domenii

Cercetarea despre detectarea observațiilor în afara distribuției oferă o avertizare relevantă, dar nu identică problemei noastre. Nalisnick și colaboratorii arată că anumite modele generative pot atribui verosimilitate ridicată datelor dintr-o distribuție diferită de cea de antrenare. Ren și colaboratorii investighează folosirea rapoartelor de verosimilitate pentru a controla efecte ale statisticilor de fundal. Aceste rezultate slăbesc identificarea naivă a densității probabilistice cu apartenența semantică. Nu transformă detecția out-of-distribution într-un detector de contribuții științifice. [R17, R21]

Diferența conceptuală este importantă. O idee poate fi nouă și formulată într-un limbaj perfect obișnuit, deci fără a părea în afara distribuției lingvistice. Un text poate fi în afara distribuției prin limbă sau formare și să descrie o idee veche. Un sistem care detectează anomalii poate fi util pentru a trimite cazuri la verificare, dar nu poate numi automat anomalia „descoperire”.

Uzzi și colaboratorii au analizat combinații de referințe în literatura științifică și au observat o asociere între impactul prin citări și combinații care îmbină o bază convențională cu elemente atipice. Studiul oferă o perspectivă asupra relației dintre familiaritate și neobișnuit în știință. Nu dovedește că o anumită combinație este adevărată, originală sau cauzal responsabilă pentru impact. Citările nu sunt identice cu valoarea epistemică. [R22]

Pentru arhitectura unui detector, lecția nu este să recompensăm mecanic combinațiile rare. O combinație poate fi rară deoarece este nepotrivită. Dar nici nu trebuie presupus că o contribuție nouă trebuie să fie stranie în toate componentele. Un mecanism nou poate avea nevoie de o prezentare convențională pentru a fi verificabil. Testele

trebuie să permită amestecul dintre bază familiară și diferență locală, nu doar opoziția artificială între banalitate și extravaganta.

Shumailov și colaboratorii au studiat degradarea modelelor în regimuri de antrenare recursivă pe date generate și pierderea unor aspecte ale distribuției originale. Gerstgrasser și colaboratorii arată că regimul acumulării datelor reale și sintetice poate evita anumite forme de colaps observate când datele sunt înlocuite. Rezultatele nu autorizează concluzia că orice utilizare a datelor sintetice distruge diversitatea. Ele cer specificarea mecanismului de reciclare a datelor și a accesului continuu la observații externe. [R23, R24]

În problema evaluării noutății, un scenariu analog poate fi formulat, dar trebuie testat separat. Dacă numai ideile acceptate revin ca exemple pozitive, iar cele respinse dispar, distribuția vizibilă poate deveni mai îngustă. Totuși, efectul depinde de politica de selecție, de aportul de idei externe și de păstrarea arhivei. Nu trebuie prezentat drept consecință inevitabilă a modelului lingvistic. Este o ipoteză despre ecosistemul de decizie.

Bilanțul literaturii este, așadar, asimetric. Există dovezi că judecătorii LLM pot avea biasuri, că evaluarea noutății rămâne dificilă și că explicațiile clare nu garantează comparații corecte. Există și rezultate care arată utilitatea generării și a regăsirii asistate. Niciunul dintre aceste grupuri nu demonstrează o teză universală despre toate modelele și toate criteriile. Ceea ce justifică literatura este un program de validare mai exigent, nu o sentință metafizică.

Capitolul 8. Cum se identifică experimental un bias de familiaritate

8.1. Ipoteze, intervenții și explicații alternative

Un experiment bun începe prin definirea afirmației care ar putea fi greșită. „Modelele preferă familiarul” este prea larg dacă nu precizăm familiaritatea și sarcina. Putem defini o ipoteză comportamentală: pentru aceeași contribuție și aceleași antecedente, o formulare convențională primește un scor de noutate mai mare decât o formulare neobișnuită, în condiții de claritate comparabilă. Putem defini o ipoteză informațională: o anumită etapă de comprimare reduce recuperarea diferenței semantice decisive. Putem defini o ipoteză cauzală despre antrenare: creșterea expunerii la un tipar de contribuție, cu ceilalți factori controlați, modifică evaluarea lui independent de noutatea reală.

Aceste ipoteze cer experimente diferite. Reformularea promptului nu intervine asupra preantrenării. Compararea a două modele comerciale nu izolează frecvența datelor, deoarece modelele pot diferi prin arhitectură, capacitate, postantrenare și instrumente. Observarea unei corelații între perplexitate și scor nu separă claritatea, corectitudinea și familiaritatea. Un studiu trebuie să declare nivelul la care pretinde o concluzie.

Putem reprezenta informal un mecanism cauzal prin variabile. F este expunerea în antrenare, S stilul, N noutatea de referință, D dificultatea semantică, R accesul la antecedente, Z reprezentarea intermediară și J verdictul. F poate influența atât Z, cât și J. S poate influența dificultatea și impresia de calitate. N nu este neapărat observată direct; uneori avem numai o etichetă expertă Y, influențată și de alți factori. Un experiment care ignoră aceste relații poate atribui noutății ceea ce aparține stilului sau dificultății.

Designul factorial permite variația independentă a unor factori. Putem combina contribuții vechi și noi cu formulări familiare și neobișnuite, apoi cu antecedente absente, regăsite automat sau furnizate de un oracol experimental. Într-un alt bloc putem compara textul integral cu un rezumat. Nu este necesar să executăm imediat toate combinațiile. Dar trebuie să înțelegem ce interacțiuni ar putea modifica rezultatul. Un efect de stil poate apărea numai când antecedentele lipsesc; atunci problema este diferită de un bias care persistă cu informație completă.

Oracolul experimental nu este un agent omniscient. Este condiția în care experimentatorul furnizează exact antecedentul decisiv și informația necesară comparației. Într-o lume finită, această informație poate fi verificată exhaustiv. Într-un studiu real, „oracol” trebuie folosit mai modest: pachet de antecedente adjucecat de experți. Rolul condiției este să separe eșecul de căutare de eșecul de comparație.

Un contrast causal simplu este diferența dintre scorurile aceleiași idei sub două stiluri, cu alocarea aleatorie a ordinii și a instanțelor. Pentru ideea i , putem nota rezultatele potențiale $J_i(1)$ și $J_i(0)$, unde 1 și 0 desemnează tratamentul stilistic. Efectul mediu vizat este media diferenței. Definiția nu rezolvă automat identificarea: trebuie evitate efectele de memorie între evaluări și trebuie asigurată echivalența conținutului.

$$\tau_s = E[J_i(1) - J_i(0)].$$

În practică, aceeași sesiune de conversație poate crea dependențe între condiții. Dacă modelul a văzut deja varianta originală, evaluarea parafrazei nu mai este independentă. Putem folosi sesiuni separate și randomizare. Dacă o interfață păstrează memorie sau schimbă dinamic modelul, aceste condiții trebuie documentate. Un experiment repetabil are nevoie de versiune, dată, parametri și jurnalul complet al intrărilor și ieșirilor.

Ipotezele trebuie însoțite de criterii de infirmare locală. Dacă efectul de stil este mai mic decât un prag practic preregistrat, cu incertitudine suficient de mică, ipoteza unui efect relevant în acea configurație este

slăbită. Un rezultat nesemnificativ într-un eșantion mic nu este o înfirmare. În mod similar, un efect semnificativ, dar minuscul, poate avea importanță redusă pentru selecție. Mărimea efectului și costul deciziei trebuie discutate împreună.

8.2. Măsurare: de la scoruri la contribuții recuperate

Acuratețea globală este insuficientă atunci când noutățile sunt rare. Un clasificator care numește toate ideile „vechi” poate avea acuratețe mare și utilitate nulă pentru descoperire. Saito și Rehmsmeier discută de ce curbele precizie–recall sunt adesea mai informative decât curbele ROC pentru evaluarea pe clase dezechilibrate. În aplicația noastră, alegerea metricii trebuie legată explicit de obiectivul filtrării. [R19]

Recall-ul măsoară proporția contribuțiilor realmente noi care sunt păstrate. Precizia măsoară proporția selecțiilor care sunt realmente noi. Ele exprimă costuri diferite. Pentru o echipă care poate analiza douăzeci de propuneri pe săptămână, întrebarea practică poate fi câte contribuții noi se află în primele douăzeci. Pentru un sistem de avertizare, poate fi important să nu piardă aproape niciun caz, chiar cu multe alarme false. Nu există un prag universal optim.

O metrică adecvată este recall-ul la buget fix. Pentru fiecare metodă, permitem același număr de candidați trimiși la expert. Comparăm câte noutăți sunt recuperate. Putem adăuga costul total al tokenilor, al căutărilor și al timpului expert. Un sistem care detectează cu cinci procente mai multe contribuții, dar consumă de zece ori mai multă verificare, poate fi superior sau inferior în funcție de aplicație. Costul nu trebuie ascuns în spatele unei singure curbe.

Calitatea diferenței identificate trebuie măsurată separat. Modelul poate selecta corect un candidat, dar pentru un motiv fals. Putem evalua dacă pasajul citat există, dacă antecedentul este relevant, dacă relația de anticipare este validă și dacă martorul diferenței funcționează. O selecție corectă cu explicație falsă nu este echivalentă

cu o selecție susținută de dovezi, mai ales când rezultatul va fi reutilizat de alte sisteme.

Abținerea trebuie tratată explicit. Un evaluator poate răspunde „informație insuficientă”. Dacă numărăm orice abținere ca eroare, favorizăm sistemele care ghicesc. Dacă o excludem complet, un sistem se poate abține pe toate cazurile dificile și poate raporta o precizie artificială. Trebuie raportate simultan acoperirea, riscul pe cazurile decise și costul cazurilor escaladate. Un sistem selectiv bun este cel care își alocă incertitudinea util, nu cel care o ascunde.

Calibrarea poate fi evaluată prin comparația dintre probabilități și frecvențe observate. Dar o calibrare bună în medie poate ascunde erori mari pe contribuții rare, pe limbi slab reprezentate sau pe idei care schimbă ipotezele. Este necesară analiza pe subgrupuri definite înaintea testului. Nu trebuie create zeci de subgrupuri după observarea rezultatelor și raportate numai cele care susțin ipoteza preferată.

Metodele de predicție conformală pot oferi garanții marginale sub ipoteze precum schimbabilitatea datelor. Introducerea lui Angelopoulos și Bates explică aceste mecanisme și limite. Într-un flux de descoperiri, distribuția se poate schimba tocmai deoarece apar contribuții noi. De aceea, o garanție calibrată pe trecut nu trebuie prezentată ca o certificare individuală a noutății istorice sau ca o protecție automată sub schimbare de distribuție. [R20]

Unitatea statistică trebuie aleasă corect. Zece parafraze ale aceleiași idei nu sunt zece descoperiri independente. O sută de rulări ale aceluiași model pe aceeași pereche nu sunt o sută de replicări ale efectului antrenării. Datele au structură ierarhică: familii de probleme, idei, variante, modele și seed-uri. Intervalele de încredere trebuie să reflecte această dependență, prin agregare la nivelul ideii, bootstrap pe clustere sau modele ierarhice adecvate.

Un model statistic posibil, prezentat aici ca instrument de planificare, folosește o regresie logistică pentru corectitudinea verdictului, cu efecte ale noutății, stilului, accesului și compresiei, plus interacțiuni

preregistrate și interceptări aleatoare pe familie și idee. Modelul nu transformă observația în cauzalitate. Interpretarea cauzală vine din designul intervențiilor; regresia estimează contrastele și incertitudinea în cadrul ipotezelor sale.

8.3. Testarea frecvenței de antrenare și puterea statistică

Pentru a testa explicația exactă a ipotezei inițiale, este necesar controlul expunerii. Putem construi un domeniu artificial în care anumite forme de contribuție sunt prezentate mai des drept inovatoare, iar altele mai rar. În test, noutatea este determinată independent de aceste frecvențe. Dacă evaluările urmează frecvența etichetei „inovator” în pofida adevărului controlat, avem dovezi pentru mecanismul cauzal propus în acel regim.

Trebuie separate două manipulări. Prima schimbă frecvența conținutului unei idei. A doua schimbă frecvența cu care o formă de idee este asociată cu aprecierea de noutate. Acestea pot avea efecte opuse. Repetarea unei idei poate ajuta modelul să o recunoască drept veche. Repetarea laudelor pentru un tipar poate face modelul să îl considere inovator. Ipoteza inițială este mai interesantă în a doua formă, deoarece privește învățarea unui concept evaluativ, nu doar memorarea unui conținut.

Numărul total de tokeni, pașii de optimizare, distribuția dificultății și proporția etichetelor trebuie controlate. Altfel, o condiție cu expunere mai mare poate primi pur și simplu mai mult antrenament util. Putem redistribui aceleași resurse între categorii și putem utiliza mai multe inițializări independente. Compararea unei singure perechi de modele nu permite separarea robustă a efectului de variația optimizării.

Modelele mici sau adaptările locale pot oferi un laborator cauzal accesibil. Un rezultat într-un asemenea laborator nu trebuie transferat automat la preantrenarea unui model foarte mare. El poate demonstra existența mecanismului și condițiile în care apare. Următorul pas este testarea transferului către capacități, obiective și regimuri de date

diferite. Această progresie este mai solidă decât încercarea de a deduce datele de antrenare ale unui sistem opac din câteva răspunsuri.

Planificarea eșantionului trebuie să pornească de la efectul minim relevant. Pentru un contrast pereche între două stiluri, informația vine mai ales din cazurile în care verdictele diferă. Dacă aproape toate perechile produc același verdict, un eșantion mai mare poate fi necesar pentru a estima o diferență mică. Pentru scoruri ordinale, trebuie decis dacă distanța dintre note este tratată ca egală sau dacă se folosește un model ordinal. Alegerea nu trebuie făcută după ce vedem care analiză produce rezultatul dorit.

O simulare de putere este utilă dacă ipotezele generatoare sunt explicite. Putem presupune anumite rate de eroare și corelații între parafraze, genera date sintetice și estima cât de des procedura ar detecta un efect. Aceste rezultate sunt despre designul statistic sub ipotezele alese, nu despre performanța reală a unui LLM. Cartea nu transformă asemenea simulări de planificare în dovezi empirice despre ipoteza familiarității.

Preregistrarea trebuie să fixeze rezultatul principal, contrastele, pragul de relevanță, excluderile, tratarea abținerilor și regulile pentru analize exploratorii. Nu trebuie să interzică descoperirile neașteptate. Trebuie să separe confirmarea unei predicții anterioare de formularea uneia noi după observarea datelor. Un rezultat interesant descoperit ulterior rămâne valoros, dar are nevoie de o replicare independentă înainte de a fi prezentat drept confirmare.

La final, ipoteza ar trebui evaluată printr-un profil de rezultate. Un efect de stil fără efect al expunerii controlate susține un bias comportamental, nu explicația sa de antrenare. Un efect al compresiei care dispare cu acces la original susține un mecanism informațional remediabil. Un eșec persistent cu antecedente perfecte și criteriu simplu indică o limită a comparației în configurația testată. O reușită robustă în lumea finită infirmă imposibilitatea universală, fără a certifica automat competența în știința deschisă.

Capitolul 9. Laboratorul controlat: noutate cu adevăr de referință exact

9.1. De ce circuitele finite sunt un laborator potrivit

Pentru a testa un detector trebuie să știm ce ar fi trebuit să detecteze. În știința deschisă, această condiție este dificilă: antecedentele pot lipsi, experții pot avea criterii diferite, iar contribuția poate fi încă nevalidată. Un laborator finit nu înlocuiește realitatea, dar permite izolarea unor mecanisme. Circuitele booleene sunt potrivite deoarece au o semantică exactă, pot fi reformulate în multe feluri și pot diferi pe un singur caz.

Un circuit boolean primește n intrări binare și produce o ieșire binară. Porțile AND, OR, NOT și XOR au semantici determinate. Pentru n fix, funcția circuitului poate fi reprezentată printr-un tabel cu 2^n la puterea n linii. Dacă două circuite au același tabel, sunt echivalente extensional pe acel domeniu. Dacă tabelele diferă, există cel puțin o intrare care servește drept martor al diferenței.

Definim o bibliotecă K de circuite și un candidat c . Noutatea funcțională relativă este unu dacă funcția lui c nu coincide cu funcția niciunui element din K . Această definiție este intenționat îngustă. Nu spune că c are o implementare originală, că este mai eficient sau că a fost descoperit pentru prima dată în istorie. Spune că biblioteca nu conține aceeași funcție. Avantajul este că verdictul poate fi calculat exact, independent de un evaluator lingvistic.

Un exemplu minim folosește două intrări a și b . Biblioteca conține AND și OR. Candidatul „negarea disjuncției negațiilor” este echivalent cu AND și trebuie clasificat drept vechi, chiar dacă formularea diferă. Candidatul XOR este diferit de ambele și trebuie clasificat drept nou față de această bibliotecă. Dacă adăugăm XOR în bibliotecă, același candidat devine vechi. Astfel testăm atât invarianța la reformulare, cât și dependența corectă de referință.

Acest exemplu este prea ușor pentru o evaluare amplă deoarece numele porților pot declanșa cunoștințe memorate. Putem defini operații cu nume aleatorii și putem furniza tabelele lor local. Putem construi expresii cu arbori diferiți, operații redundante și permutări de variabile. Putem cere modelului să folosească numai definițiile din context. Scopul nu este ascunderea artificială a sensului, ci eliminarea posibilității de a răspunde numai după reputația unui nume.

Trebuie păstrată separarea între verificator și generator. Generatorul creează candidații și variantele. Verificatorul calculează tabelele și etichetele. LLM-ul produce verdictul sau traduce descrierea într-o reprezentare verificabilă. Dacă același model generează etichetele și este apoi evaluat după ele, laboratorul pierde tocmai independența care îl face util. În anexa executabilă, etichetele sunt calculate prin enumerare exhaustivă, fără apel la un model.

Un laborator finit poate testa și noutatea operațională, dar criteriul trebuie schimbat. Două circuite echivalente pot avea adâncimi sau numere de porți diferite. Dacă noul candidat este mai mic decât toate implementările din bibliotecă, avem un alt tip de noutate relativă. Nu rezultă că este circuitul minim global; pentru aceasta ar trebui explorat un spațiu mai mare sau demonstrată o limită. Fiecare extindere a criteriului aduce o obligație de verificare.

9.2. Diferențe rare, coliziuni și familii de test

Un test critic pentru ipoteza inițială trebuie să includă diferențe rare. Alegem o funcție f și construim g astfel încât să coincidă cu f pe toate intrările, cu excepția uneia. Dacă intrările sunt uniforme, diferența apare cu probabilitatea 2 la puterea minus n . Pentru n egal cu opt , numai o linie din 256 distinge funcțiile. Noutatea funcțională este exactă, dar un eșantion mic de comportamente o poate rata.

Dacă observăm m intrări independente, cu înlocuire, probabilitatea de a rata complet diferența este următoarea:

$$P(\text{diferență ratată}) = (1 - 2^{-n})^m.$$

Formula nu este despre LLM-uri, ci despre informația furnizată de eșantionare. Pentru a reduce probabilitatea ratării sub α , bugetul trebuie să satisfacă relația derivată prin logaritmare. Această analiză arată că un eșec poate proveni din lipsa unui caz distinctiv, chiar dacă evaluatorul compară perfect toate observațiile primite.

$$m \geq \frac{\log \alpha}{\log(1 - 2^{-n})}.$$

Putem compara trei condiții. În prima, modelul vede numai un eșantion care nu conține martorul. În a doua, vede un eșantion care îl conține. În a treia, primește expresiile complete și poate raționa simbolic. Prima condiție nu permite identificarea sigură a diferenței numai din exemple; a doua oferă dovada locală; a treia testează capacitatea de a deduce diferența din structură. Aceste condiții nu trebuie agregate într-o singură rată de succes.

Pentru a testa netezirea, putem construi o reprezentare care elimină deliberat linia distinctivă sau care păstrează numai categoria tematică a circuitului. Coliziunea este atunci cunoscută prin construcție. Un evaluator bazat exclusiv pe reprezentarea comprimată nu poate distinge perechea. Acest experiment verifică limita informațională a pipeline-ului, nu incapacitatea particulară a unui LLM. Ulterior putem înlocui compresorul deliberat cu un sumarizator lingvistic și măsura cât de des apare o coliziune relevantă.

O altă familie folosește reformulări fără schimbarea funcției. Putem aplica dubla negație, legile lui De Morgan, reordonarea argumentelor comutative și introducerea unor subexpresii redundante. Aceste transformări produc texte diferite cu aceeași etichetă. Dacă modelul le consideră noi doar pentru că expresia este lungă sau neobișnuită, avem un fals pozitiv de originalitate sintactică. Dacă normalizează corect toate expresiile, avem o competență utilă de invarianța semantică.

Familia complementară schimbă o singură componentă relevantă și păstrează forma cât mai apropiată. Înlocuirea unei porți OR cu XOR poate produce o diferență funcțională locală. Schimbarea domeniului

intrărilor poate transforma o echivalență în neechivalență. Mutarea unui cuantificator într-o descriere poate schimba obiectivul. Aceste perechi minimale sunt utile deoarece reduc șansa ca modelul să folosească lungimea sau tema ca indiciu principal.

Un pericol al seturilor sintetice este apariția unor artefacte. Dacă toate exemplele noi au un nivel suplimentar de paranteze, modelul poate învăța parantezele. Dacă toate exemplele vechi sunt obținute printr-o singură regulă de rescriere, poate recunoaște regula fără comparația generală. Generatorul trebuie să echilibreze lungimea, structura și vocabularul între clase. Mai important, testul trebuie separat pe familii latente de transformări, nu doar prin împărțirea aleatorie a exemplelor aproape identice.

Putem păstra o familie de rescrieri exclusiv pentru test, un set de funcții de bază exclusiv pentru test și nume noi pentru fiecare rundă. Aceasta nu garantează absența tuturor scurtăturilor, dar face generalizarea mai exigentă. Rezultatele trebuie raportate pe fiecare familie. O medie bună poate ascunde eșecul exact pe diferențele rare sau pe schimbările de cuantificare care motivează cercetarea.

9.3. Ce ar demonstra un rezultat pozitiv sau negativ

Să presupunem că un model clasifică corect circuitele noi, recunoaște reformulările vechi și produce martori valizi ai diferenței pe familii nefolosite la pregătirea testului. Rezultatul ar demonstra o capacitate de comparație într-un domeniu finit, sub condițiile experimentului. Ar slăbi puternic teza că orice recunoaștere a noutății este numai recuperarea unor idei memorate. Nu ar demonstra că modelul poate verifica literatura științifică deschisă sau că poate aprecia importanța unei idei.

Dacă modelul reușește numai când primește tabelele complete, dar nu când primește descrierile, problema pare legată de interpretare sau calcul simbolic. Dacă reușește când martorul este furnizat, dar nu îl poate găsi, separăm verificarea de căutarea martorului. Dacă eșuează

chiar și când diferența este evidențiată explicit, putem investiga instrucțiunea, contextul sau capacitatea de a aplica criteriul. Aceste rezultate sunt mai informative decât un simplu „nu înțelege”.

Dacă toate modelele eșuează după o compresie care a eliminat martorul și informația structurală, nu avem o comparație utilă între modele. Am construit o sarcină neidentificabilă. Valoarea experimentului este demonstrarea defectului arhitectural. Un detector bun ar trebui cel puțin să recunoască insuficiența informației și să se abțină. Certitudinea unui verdict în această condiție este ea însăși un rezultat de calibrare.

Dacă stilul influențează verdictul deși circuitul și biblioteca sunt identice, există un efect comportamental. Pentru a-l interpreta trebuie verificat că variantele descriu exact același circuit. Putem genera descrieri dintr-o gramatică controlată și apoi include variante umane validate. Creșterea realismului lingvistic reduce controlul formal; de aceea, este utilă o progresie de la limbaj controlat la explicații naturale, nu înlocuirea bruscă a uneia cu cealaltă.

Un rezultat negativ pe laborator nu dovedește că modelul va eșua în orice sarcină reală. Oamenii pot utiliza analogii și cunoștințe de domeniu care nu sunt bine reprezentate de circuite aleatorii. Dar nici succesul pe sarcini reale apreciate subiectiv nu anulează eșecul formal. Cele două teste măsoară componente diferite. Un program de cercetare bun păstrează tensiunea dintre control și relevanță, în loc să aleagă numai testul favorabil.

Pentru raportare, fiecare caz ar trebui să includă expresia sau descrierea, biblioteca, criteriul, eticheta exactă, martorii existenți, transformările stilistice și ieșirea brută a evaluatorului. Dacă modelul propune un circuit intermediar, acesta trebuie păstrat separat de circuitul de referință. Un răspuns corect obținut dintr-o traducere greșită poate fi accidental. Un răspuns greșit dintr-o traducere corectă indică altă problemă.

Laboratorul poate fi extins către automate finite, expresii regulate pe domenii limitate, relații Datalog finite sau modele cauzale discrete. Fiecare domeniu oferă alte distincții: comportament temporal, cuantificare, dependențe sau intervenții. Extinderea nu trebuie făcută numai pentru a adăuga benchmarkuri. Ea trebuie să testeze o ipoteză precisă despre ce fel de diferență este pierdută sau recunoscută.

Scopul final al laboratorului nu este proclamarea unui câștigător. Este construirea unei anatomii a erorii. Un sistem care ratează antecedentul are nevoie de alt remediu decât unul care îl citește și șterge diferența. Un sistem care poate verifica, dar nu căuta un martor are alt profil decât unul care confundă criteriul. Numai după această anatomie merită discutată scalarea către documente reale.

Capitolul 10. Validarea pe cercetare reală

10.1. Reconstrucția temporală și limitele testelor retrospective

Un test pe lucrări reale are o atractivitate evidentă: ideile sunt autentice, limbajul este bogat, iar dificultățile seamănă cu cele din utilizare. Dar autenticitatea documentelor nu garantează validitatea etichetelor. Pentru a evalua noutatea la momentul publicării trebuie reconstruit ce era disponibil înainte, ce pretindea lucrarea și după ce criteriu era considerată o contribuție. O bază de date contemporană amestecă ușor documente dinainte și de după evenimentul evaluat.

Primul principiu este înghețarea temporală a corpusului de referință. Fiecare sursă trebuie să aibă o versiune și o dată verificabile. Preprintul, articolul final și documentația actualizată pot avea conținuturi diferite. Dacă un pasaj decisiv a fost adăugat după data de referință, nu trebuie folosit ca dovadă că ideea era deja cunoscută. Similar, un articol ulterior care explică retrospectiv contribuția nu poate fi tratat ca antecedent.

Al doilea principiu este recunoașterea limitelor anonimizării. Eliminarea numelor și a titlului nu șterge neapărat identitatea unei lucrări celebre. Formula, setul de date sau structura argumentului pot permite recunoașterea. Un model antrenat după publicare poate cunoaște rezultatul istoric al evaluării. Într-un asemenea test, nu putem atribui automat succesul comparației locale. Trebuie să raportăm posibilitatea contaminării și să folosim analize care o reduc.

O soluție este combinarea studiului retrospectiv cu un studiu prospectiv. În studiul prospectiv, modelul și procedura sunt fixate înainte de colectarea candidaților. Contribuțiile sunt evaluate înainte să existe un consens public stabil. Ulterior, se urmăresc antecedentele descoperite, validările și revizuirile. Acest design reduce unele forme de contaminare, dar are costuri de timp și nu produce imediat un adevăr final. Cercetarea reală poate rămâne controversată ani întregi.

Candidații prospectivi nu trebuie aleși numai dintre ideile care au trecut deja un filtru LLM. Altfel, populația de test este condiționată de mecanismul suspectat. Este necesar un eșantion independent, eventual stratificat după domeniu, tip de contribuție și grad de maturitate. Ideile respinse sau considerate neclare trebuie păstrate într-un strat separat, nu eliminate fără urmă. Altfel, tocmai cazurile care ar putea confirma ipoteza dispar înaintea evaluării.

Un protocol realist poate distinge noutatea pretinsă, noutatea susținută de comparația cu antecedente și noutatea rămasă după validarea tehnică. Aceste stări se pot modifica în timp. O propunere poate părea nouă, apoi poate fi anticipată de o sursă găsită ulterior. Poate părea greșită, apoi poate primi o demonstrație. Sistemul trebuie să permită revizuirea verdictului fără a falsifica istoricul. Noutatea evaluată este un obiect cu versiuni, nu o proprietate fixată etern la prima lectură.

10.2. Experți, dezacord și etichete verificabile

Experții sunt indispensabili în domenii deschise, dar nu sunt oracole perfecte. Un recenzent poate cunoaște foarte bine o subarie și poate rata o contribuție dintr-o arie vecină. Poate interpreta „nou” ca „important”, poate penaliza lipsa validării sau poate folosi o definiție diferită a problemei. Aceste posibilități nu trebuie folosite pentru a relativiza orice critică. Ele justifică un protocol care cere motive și surse, nu doar note.

O evaluare expertă utilă începe cu extragerea contribuției. Recenzentul trebuie să precizeze ce anume se compară. Apoi identifică antecedentele relevante și descrie relația cu fiecare. În final, separă verdictul asupra diferenței de verdictul asupra corectitudinii și valorii. O justificare de tipul „ideea este incrementală” trebuie tradusă într-o relație concretă: ce parte exista deja și ce parte rămâne. Fără această traducere, acordul dintre evaluatori poate fi doar acord asupra unei impresii.

Dezacordul trebuie clasificat. Uneori experții nu sunt de acord asupra sensului textului. Alteori asupra existenței unui antecedent. Alteori

asupra relevanței diferenței. Alteori asupra validității tehnice. Aceste dezacorduri cer soluții diferite: clarificare, căutare suplimentară, precizarea criteriului sau experiment. Un singur coeficient de acord nu spune unde se află problema.

Putem păstra etichete multiple și o adjudecare argumentată. Adjudecarea nu trebuie să șteargă pozițiile inițiale. Dacă un nou antecedent schimbă verdictul, jurnalul trebuie să arate schimbarea. Pentru unele cazuri, eticheta corectă poate rămâne „nedeterminat în condițiile curente”. Aceste cazuri nu sunt gunoi statistic. Sunt importante pentru evaluarea abținerii și pentru înțelegerea limitelor sistemului.

O grilă minimală poate fi organizată în două coloane, fără a reduce evaluarea la un formular mecanic.

Dimensiune	Întrebarea care trebuie rezolvată
Contribuția	Ce afirmație, mecanism sau capacitate pretinde textul că introduce?
Antecedentul	Ce sursă anterioară conține deja elementul relevant și în ce pasaj?
Diferența	Ce rămâne diferit după compararea ipotezelor, rezultatelor și resurselor?
Validitatea	Ce dovezi susțin sau infirmă diferența pretinsă?
Incertitudinea	Ce informație lipsă ar putea schimba verdictul?

Evaluatorii trebuie să aibă acces la resurse comparabile. Dacă omul poate căuta timp de două ore și modelul primește numai un rezumat, comparația măsoară și accesul. Dacă modelul poate consulta un index foarte mare, iar omul nu, situația se inversează. Sunt utile două niveluri de evaluare: competența de comparație cu același pachet de

surse și performanța end-to-end cu propriile instrumente, la costuri declarate.

Textele în limbi diferite merită un strat distinct. Traducerea poate îmbunătăți accesibilitatea, dar poate modifica terminologia sau poate netezi diferențe. Un studiu multilingv trebuie să păstreze originalul, traducerea și eventualele ambiguități. Nu este suficient să traducem toate documentele cu un singur LLM și să presupuneți că dificultatea lingvistică a fost eliminată. Poate fi doar mutată într-o etapă invizibilă.

În situații de conflict, un antecedent concret are o greutate diferită de un scor de similaritate. Dacă evaluatorul arată un pasaj care anticipează exact contribuția, avem o dovadă verificabilă. Dacă spune doar că ideea „seamănă cu” un domeniu, avem o pistă de investigație. Sistemul trebuie să distingă aceste niveluri de evidență. Altfel, o asociere vagă poate fi prezentată cu autoritatea unei înfirmări.

10.3. Un studiu longitudinal care poate schimba concluziile

Un program realist poate începe cu un corpus retrospectiv restrâns și bine documentat, pentru a verifica procedura de adnotare și instrumentele. Următoarea etapă introduce propuneri noi, evaluate în orb de modele și experți. Etapa longitudinală urmărește ce se întâmplă cu ele: apar antecedente, sunt demonstrate, sunt falsificate sau rămân neclare. Aceste etape au roluri diferite și nu trebuie combinate într-un scor unic de succes.

Rezultatul principal ar putea fi recuperarea contribuțiilor confirmate ulterior la un buget fix de verificare inițială. Dar „confirmat ulterior” trebuie definit cu atenție. Publicarea nu este identică cu adevărul, citarea nu este identică cu noutatea, iar lipsa continuării poate reflecta lipsa resurselor. O evaluare longitudinală trebuie să urmărească dovezi și comparații, nu numai succesul social al ideii.

Pentru a evita circularitatea, experții care stabilesc etichetele ulterioare nu ar trebui să cunoască scorul inițial al modelului, în măsura în care acest lucru este practic posibil. Dacă scorul a influențat finanțarea sau

atenția acordată ideii, rezultatul ulterior nu mai este independent de selecție. O idee favorizată poate primi mai multă dezvoltare și poate părea ulterior mai valoroasă. Acesta este un efect al intervenției asupra resurselor, nu neapărat o predicție corectă a unei proprietăți preexistente.

Putem reduce problema printr-un eșantion de audit finanțat sau evaluat independent de scor. O parte dintre ideile respinse este aleasă aleator pentru examinare aprofundată. Această procedură permite estimarea falselor negative. Fără ea, știm în detaliu ce s-a întâmplat cu ideile acceptate și aproape nimic despre cele eliminate. Un filtru poate părea excelent tocmai pentru că a făcut erorile sale imposibil de observat.

Costurile trebuie înregistrate pe componente. Cât durează extragerea contribuției? Câte căutări sunt necesare pentru antecedente? Cât timp consumă verificarea unui martor fals? Cât costă clarificarea unei ambiguități? Un model care produce multe justificări aparent precise, dar greu de verificat, poate transfera costul către expert. Eficiența nu este doar timpul până la primul verdict, ci timpul până la o concluzie susținută și auditabilă.

Rezultatele negative sunt informative dacă sunt localizate. Dacă o clasă de contribuții este ratată repetat, trebuie văzut dacă are antecedente greu de regăsit, schimbă ontologia sau conține diferențe logice mici. Nu este suficient să o numim „noutate radicală” după ce modelul a eșuat. Categoria trebuie definită prin proprietăți independente de rezultat. Altfel, ipoteza devine tautologică: numim radical ceea ce sistemul nu recunoaște și apoi concluzionăm că sistemul nu recunoaște radicalul.

La capătul unui asemenea studiu, concluzia poate fi mixtă. Sistemul poate fi foarte bun la identificarea redescoperirilor apropiate, util la construirea hărții de antecedente și slab la evaluarea schimbărilor de cadru. Poate economisi timp fără a fi potrivit pentru respingerea automată. Un asemenea rezultat nu este o victorie parțială de ascuns. Este exact tipul de profil operațional de care o comunitate are nevoie pentru a utiliza tehnologia fără a-i atribui competențe nedemonstrate.

Capitolul 11. Arhitectura unui evaluator bazat pe dovezi

11.1. Păstrarea obiectului evaluat și separarea operațiilor

Arhitectura propusă în acest capitol nu este un produs implementat și validat. Este un contract de cercetare pentru un sistem care folosește LLM-uri fără a transforma verdictul lor într-o autoritate opacă. Ideea centrală este că modelul trebuie să construiască obiecte verificabile: afirmații localizate în text, relații cu antecedente, diferențe explicite și întrebări care pot fi rezolvate prin instrumente sau experți.

Intrarea sistemului trebuie păstrată ca artefact imuabil sau versionat. Documentul original, data, proveniența și eventualele transformări sunt necesare pentru audit. Un hash poate ajuta la identificarea versiunii, dar nu demonstrează adevărul conținutului sau fidelitatea interpretării. Criptografia poate certifica faptul că examinăm aceeași octeți; nu certifică faptul că îi înțelegem corect. Această separare este importantă pentru a nu confunda integritatea tehnică cu validitatea epistemică.

Prima operație este extragerea contribuțiilor pretinse. Fiecare contribuție trebuie legată de pasaje și de un grad de explicitare. Unele afirmații sunt declarate direct, altele sunt deduse de evaluator. Cele două categorii trebuie marcate diferit. Dacă sistemul inventează o garanție pentru a face propunerea mai coerentă, el schimbă obiectul evaluării. O interpretare caritabilă poate fi păstrată ca ipoteză alternativă, nu substituită tăcut textului original.

A doua operație construiește întrebările de comparație. Pentru fiecare contribuție, sistemul caută antecedente pentru mecanism, rezultat, ipoteze și resurse. Nu trebuie să presupună că o singură interogare surprinde toate aceste dimensiuni. O contribuție poate avea același mecanism cu altă garanție sau aceeași garanție cu alte ipoteze. Piste

de căutare trebuie să reflecte această structură și să păstreze termenii neobișnuiți care ar putea fi decisivi.

A treia operație compară sursele recuperate cu candidatul. Rezultatul nu este încă un scor global. Este o hartă de relații: aceeași afirmație, rezultat mai restrâns, ipoteză diferită, antecedent doar tematic, contradicție sau informație insuficientă. Relațiile trebuie însoțite de dovezi. Un pasaj relevant într-o lucrare nu poate fi înlocuit de simpla citare a titlului lucrării.

A patra operație încearcă să verifice diferențele. Pentru programe poate căuta intrări distinctive. Pentru o demonstrație poate verifica un pas formalizabil. Pentru o propunere empirică poate identifica experimentul care ar separa mecanismul de antecedent. Nu toate diferențele pot fi certificate automat. Dar sistemul poate preciza ce fel de dovadă ar fi necesară și ce parte a verdictului rămâne condiționată.

Abia apoi apare agregarea. Un scor, dacă este necesar pentru prioritzare, trebuie derivat din relații și dintr-o politică explicită. Utilizatorul trebuie să poată vedea dacă un scor mic provine dintr-un antecedent puternic sau din lipsa informației. Aceste situații nu ar trebui să primească aceeași etichetă operațională. „Anticipat” și „nedeterminat” cer acțiuni diferite.

Un format de ieșire poate fi descris prin câteva câmpuri, fără a impune o ontologie exhaustivă.

Câmp	Conținutul verificabil cerut
Contribuție	Afirmația evaluată și pasajele originale care o susțin.
Referință	Corpusul, data și criteriul după care este judecată noutatea.
Antecedente	Sursele apropiate, pasajele relevante și limitele căutării.
Diferență	Ce rămâne neanticipat și sub ce interpretare.

Câmp	Conținutul verificabil cerut
Martor	Exemplu, calcul, contraexemplu sau procedură de verificare.
Verdict	Decizie condiționată, incertitudine și motivul eventualei abțineri.

Acest contract poate fi implementat printr-un graf de operații cu intrări și ieșiri explicite. Fiecare nod consumă artefacte versionate și produce un rezultat cu proveniență. Dacă o sursă se schimbă sau apare un antecedent nou, pot fi invalidate numai concluziile dependente. Nu este necesar să pretindem că întregul raționament intern al LLM-ului este transparent. Putem cere transparență asupra datelor, transformărilor și dovezilor externe pe care verdictul le invocă.

11.2. Regăsire diversă, comparație precisă și întoarcere la sursă

Arhitecturile de tip retrieval-augmented generation combină informația din model cu documente recuperate la momentul utilizării. Lewis și colaboratorii au demonstrat utilitatea unei asemenea combinații în sarcini de limbaj dependente de cunoaștere. Această idee oferă un principiu de acces la antecedente, nu o garanție că sursele recuperate sunt complete sau că relația de noutate este evaluată corect. [R14]

Un index lexical este bun pentru termeni exacți, formule, acronime și expresii rare. Un index semantic poate recupera descrieri apropiate formulate diferit. Reprezentări cu mai multe vectori pot păstra interacțiuni mai fine între părți de text. ColBERT, de Khattab și Zaharia, este un exemplu de regăsire cu interacțiune târzie între reprezentări de tokeni. Utilizarea unei asemenea tehnici nu înseamnă că diferențele de noutate sunt conservate automat; aceasta trebuie evaluată în sarcina concretă. [R15]

Strategia propusă este diversitatea justificată a regăsirii. Căutăm atât tema, cât și presupunerea eliminată, atât mecanismul, cât și consecința

distinctivă. Păstrăm rezultate care sunt apropiate pe dimensiuni diferite. Un top-k global poate elimina un antecedent important dacă este lexical îndepărtat, dar semantic decisiv. Putem aloca bugete separate pistelor de căutare și apoi deduplica, fără a presupune că un singur scor de similaritate este suficient.

Comparația finală trebuie făcută pe pasaje suficient de complete pentru a include condițiile. Un abstract poate afirma o garanție fără a enumera toate ipotezele. O propoziție din concluzie poate fi mai largă decât rezultatul demonstrat. Sistemul trebuie să poată urmări referințe interne și să verifice unde este justificată afirmația. Această capacitate poate fi costisitoare; de aceea, este utilă separarea dintre filtrarea inițială și examinarea aprofundată.

Rezumatele trebuie tratate ca vederi, nu ca înlocuitori definitiv autoritativi ai documentelor. Un rezumat este bun pentru navigare și pentru identificarea întrebărilor. Când verdictul depinde de o excepție, o negație sau un cuantificator, sistemul trebuie să revină la sursă. O regulă de escaladare poate cere accesul la original atunci când două interpretări posibile ar schimba decizia. Această regulă poate fi testată prin perechi minimale.

Un comparator poate produce un tabel intern de ipoteze și garanții, dar trebuie să permită valoarea „neprecizat”. Completarea automată a golurilor cu presupuneri tipice poate crea o falsă echivalență. Dacă antecedentul nu declară o proprietate în pasajele disponibile, nu putem presupune nici că o are, nici că nu o are. Trebuie căutat contextul relevant sau marcată incertitudinea. Lipsa unei afirmații în extras nu este identică cu negarea ei în lucrarea completă.

Un verificador adversarial poate încerca să infirme fiecare relație propusă. Dacă modelul spune că A anticipează B, verificadorul caută o diferență. Dacă spune că B este nou, verificadorul caută un antecedent sau o interpretare echivalentă. Rolurile trebuie să producă probe, nu doar opinii. Numărul de agenți nu este un substitut pentru independența dovezilor. Trei agenți care folosesc aceeași interpretare greșită pot consolida eroarea.

Arhitectura trebuie să gestioneze și documentele ca date potențial ostile. Un articol poate conține instrucțiuni sau texte care încearcă să influențeze evaluatorul. Acestea nu trebuie confundate cu instrucțiunile aplicației. Separarea dintre conținutul analizat și controlul instrumentelor este o cerință de inginerie. Într-un sistem de cercetare, compromiterea acestei separări poate afecta nu doar securitatea, ci și validitatea experimentului: modelul nu mai răspunde aceleiași sarcini.

11.3. Incertitudine, audit și criterii de acceptare a arhitecturii

Un sistem bazat pe dovezi trebuie să își reprezinte incertitudinea pe componente. Poate fi sigur că două expresii formale diferă, nesigur că traducerea textului în expresii este fidelă și foarte nesigur că biblioteca acoperă toate antecedentele. Un singur procent de încredere ascunde această structură. Este mai util să distingem incertitudinea de interpretare, de regăsire, de comparație și de validare.

Nu este necesar ca toate aceste incertitudini să fie probabilități bine calibrate de la început. Pot fi stări operaționale însoțite de motive: surse insuficiente, interpretări alternative, martor neverificat sau corpus incomplet. Important este ca etichetele să determine acțiuni potrivite. Un caz cu antecedent lipsă poate cere căutare suplimentară; un caz cu traducere ambiguă poate cere clarificarea autorului; un caz cu diferență formală verificată poate trece la evaluarea valorii.

Auditul trebuie să păstreze traseul deciziei. Ce versiune a modelului a fost folosită? Ce prompt? Ce documente au fost accesate? Ce interogări au fost executate? Ce pasaje au susținut concluzia? Ce operații au fost repetate? Aceste informații permit reproducerea și diagnosticul. Ele nu trebuie confundate cu o reproducere exactă garantată a unui serviciu extern care se poate modifica. Raportul trebuie să precizeze ce poate fi reluat și ce depinde de infrastructura furnizorului.

Criteriile de acceptare a arhitecturii trebuie formulate înaintea implementării complete. De exemplu, pe laboratorul finit,

transformările semantice echivalente nu ar trebui să schimbe verdictul peste pragul preregistrat. Pe cazurile cu antecedent furnizat, relațiile de anticipare trebuie susținute de pasaje corecte. Pe cazurile deliberat neidentificabile, sistemul trebuie să se abțină sau să formuleze un verdict condiționat. Pe fluxul real, auditul respingerilor trebuie să estimeze rata contribuțiilor pierdute.

Arhitectura ar fi infirmată în forma sa curentă dacă adaugă mult cost fără a reduce erorile decisive, dacă dovezile sunt frecvent fictive sau dacă accesul la original nu corectează pierderile introduse de compresie. Ar necesita revizuire dacă detectorul de ambiguitate escaladează aproape toate cazurile sau dacă verificarea martorilor consumă mai mult decât o evaluare umană directă. O propunere tehnică nu devine bună doar pentru că este mai complexă decât un prompt simplu.

O arhitectură minimală ar putea fi, de fapt, superioară: două extrageri independente ale contribuției, căutare diversă, comparație pe pasaje și o ieșire care separă antecedentul de incertitudine. Complexitatea suplimentară trebuie justificată prin experimente de ablație. Dacă eliminarea unui agent nu schimbă rezultatele, rolul său poate fi redundant. Dacă o regulă simplă de păstrare a cuantificatorilor rezolvă o mare parte a erorilor, ea poate valora mai mult decât un ansamblu costisitor de evaluatori.

Principiul final este că sistemul trebuie să fie corectabil. O nouă sursă trebuie să poată modifica verdictul. O eroare de interpretare trebuie să poată fi localizată. O diferență pierdută trebuie să poată fi recuperată prin acces la original. Aceste proprietăți nu garantează descoperirea tuturor ideilor noi, dar reduc riscul ca un verdict fluent și familiar să devină capătul investigației.

Capitolul 12. Filtrarea ideilor rare ca problemă de decizie

12.1. A recunoaște nu este același lucru cu a selecta

Chiar un detector perfect al noutății relative nu rezolvă automat problema selecției. O echipă poate avea nevoie de idei fezabile, de rezultate cu impact sau de proiecte compatibile cu resursele sale. Noutatea este o componentă a deciziei, nu obiectivul unic. Dacă aceste criterii sunt amestecate de la început, nu mai putem afla dacă sistemul a ratat originalitatea sau a făcut o alegere strategică diferită.

Putem reprezenta decizia prin utilitatea așteptată a examinării unei propuneri. Utilitatea poate depinde de probabilitatea ca diferența să fie reală, de valoarea posibilă a rezultatului, de costul verificării și de oportunitatea de învățare. Aceste componente sunt ipoteze ale decidentului. Ele nu sunt proprietăți pe care LLM-ul le poate deduce în mod obiectiv din text. Un sistem trebuie să ceară sau să declare politica de selecție.

Un exemplu simplificat poate avea două acțiuni: verificare aprofundată sau amânare. Dacă verificarea costă c , o contribuție validă aduce valoarea v , iar probabilitatea estimată a validității relevante este p , regula $p \cdot v > c$ poate justifica verificarea în modelul minimal. Dar v poate fi foarte incertă, iar verificarea poate produce informație utilă chiar dacă ideea este falsă. Exemplul arată structura deciziei, nu oferă un prag universal pentru cercetare.

Noutatea foarte rară complică estimarea. Dacă avem puține exemple confirmate, probabilitățile sunt greu de calibrat, iar erorile de model pot domina. O politică prudentă poate combina exploatarea scorurilor cu explorarea unor cazuri neobișnuite. Nu este necesar să alegem aleator jumătate din proiecte. Dar un sistem care nu explorează niciodată în afara regiunii sale de încredere nu va afla sistematic unde este greșit.

Distanța semantică nu trebuie folosită ca substitut direct pentru valoarea explorării. Un text foarte îndepărtat poate fi zgomot. O diferență mică într-un mecanism central poate fi mult mai importantă. Explorarea poate fi stratificată după tipul incertitudinii: antecedente greu de găsit, schimbări de ipoteze, contribuții în limbi diferite sau cazuri în care modelele și verificatoarele nu sunt de acord. Alegerea straturilor este o ipoteză care trebuie evaluată prin audit.

Există și valoarea negativă a unui fals verdict de vechime. Dacă sistemul spune „acest lucru există deja” fără un antecedent concret, autorul poate abandona o direcție promițătoare. Într-o aplicație de brainstorming, acest cost poate fi mai mare decât costul unei alarme false de noutate. Într-o aplicație editorială, costurile pot fi distribuite diferit. Politica de răspuns trebuie să reflecte contextul, nu doar acuratețea medie.

O recomandare normativă a acestei cărți este ca sistemele de cercetare să fie mai exigente când resping decât când propun o investigație. A susține „merită verificat” cere o pistă plauzibilă. A susține „nu există nimic nou” cere o comparație suficientă pentru a elimina diferențele pretinse. Această asimetrie nu este o lege statistică; este o alegere justificată de costul ireversibil al eliminării unor idei rare.

12.2. Cum observăm erorile asupra ideilor respinse

Un filtru produce două populații: candidații acceptați și candidații respinși. De regulă, cei acceptați sunt verificați mai atent. Aflăm astfel multe despre alarmele false, dar puțin despre noutățile ratate. Dacă raportăm numai precizia selecțiilor, putem avea impresia unui sistem excelent, în timp ce recall-ul rămâne necunoscut. Această asimetrie a observației trebuie corectată prin design.

O soluție este eșantionarea aleatorie a respingerilor pentru audit. Fiecare candidat respins primește o probabilitate cunoscută, nenulă, de a fi verificat. Probabilitățile pot diferi între straturi, de exemplu pentru a supraeșantiona cazurile cu incertitudine mare. Dar ele trebuie

păstrate pentru ponderarea estimărilor. Dacă verificăm numai respingerile care par retrospectiv interesante, nu obținem o estimare reprezentativă.

Să notăm cu A_i indicatorul că ideea i a fost auditată, cu q_i probabilitatea sa de includere și cu Y_i eticheta de noutate stabilită prin audit. Numărul total de noutăți din populația respinsă poate fi estimat prin suma ponderată următoare. Justificarea este elementară: media lui A_i/q_i este unu, dacă includerea respectă probabilitatea declarată.

$$\hat{T}_{rate} = \sum_{i \in respinse} \frac{A_i Y_i}{q_i}.$$

Estimarea poate avea variație mare când probabilitățile de audit sunt foarte mici. Nu este suficient să existe formal o șansă nenulă. Bugetul trebuie să permită intervale de incertitudine utile. Dacă noutățile sunt extrem de rare, auditul poate necesita multă examinare. Aceasta este o proprietate a problemei, nu o eroare a formulei. O strategie adaptivă poate crește eșantionarea în straturi unde apar semnale, păstrând regulile de estimare adecvate.

Auditul trebuie să urmărească și motivul respingerii. Un sistem poate rata contribuții deoarece le consideră vechi, neclare, nefezabile sau insuficient susținute. Dacă politica permite respingerea pentru nefezabilitate, trebuie separat cazul în care noutatea a fost recunoscută. Altfel, o analiză a falselor negative poate atribui detectorului o decizie luată de altă componentă.

O altă întrebare este cine stabilește eticheta după audit. Dacă folosește același LLM și aceleași surse, procedura poate reproduce eroarea inițială. Auditul trebuie să aducă informație sau verificare suplimentară: experți, căutare mai largă, instrumente formale sau timp pentru experiment. Repetarea aceluiași verdict cu un prompt diferit poate fi o verificare de stabilitate, dar nu este suficientă ca audit independent.

Arhiva respingerilor are și un rol longitudinal. O idee considerată neclară poate deveni inteligibilă după apariția unui nou cadru. O sursă

anterioară poate fi descoperită ulterior. Păstrarea versiunilor permite reevaluarea și învățarea din erori. Ștergerea respingerilor transformă selecția într-o operație ireversibilă, iar ireversibilitatea reduce capacitatea sistemului de a afla ce tipuri de noutate nu recunoaște.

12.3. Dinamica selecției și riscul uniformizării

Putem construi un model foarte simplu al efectului cumulativ al selecției. Avem o distribuție $p_t(x)$ a ideilor vizibile la runda t și o probabilitate de acceptare $a(x)$. Dacă numai ideile acceptate revin în rundă, distribuția următoare este proporțională cu produsul dintre vizibilitate și acceptare. Modelul este o idealizare didactică, nu o descriere empirică a unei comunități.

$$p_{t+1}(x) = \frac{a(x)p_t(x)}{\sum_u a(u)p_t(u)}.$$

Dacă două clase au probabilități constante de acceptare a_1 și a_2 , raportul frecvențelor lor este multiplicat la fiecare rundă cu a_1/a_2 . Un avantaj mic, dar persistent, poate deveni mare după multe runde. Această concluzie este algebrică. Nu spune că avantajul este nejustificat sau că toate ecosistemele funcționează astfel. Arată de ce un bias modest merită evaluat și dinamic, nu doar prin diferența de scor într-o singură rundă.

Introducerea ideilor externe schimbă procesul. Putem amesteca distribuția selectată cu o distribuție de aport nou r , cu ponderea λ . Dacă λ este pozitiv și r menține anumite clase, acestea nu dispar automat. Păstrarea arhivei și reevaluarea pot modifica, de asemenea, probabilitățile de acceptare. Astfel, uniformizarea nu este inevitabilă; depinde de mecanismele de alimentare și corectare.

$$p_{t+1} = (1 - \lambda) \text{Select}(p_t) + \lambda r.$$

Într-un sistem real, probabilitatea de acceptare poate depinde de frecvență. O idee poate fi favorizată pentru că este familiară sau, invers, pentru că este rară. Dacă raritatea este recompensată mecanic,

sistemul poate produce variații superficiale pentru a evita asemănarea. Dacă familiaritatea este recompensată mecanic, poate conserva tiparele dominante. Obiectivul nu trebuie să fie maximizarea uneia dintre extreme, ci păstrarea capacității de a verifica diferențe relevante.

O politică de portofoliu poate păstra proiecte cu profiluri diferite: contribuții robuste și incrementale, idei cu diferență clară dar validare incompletă și explorări care contestă criteriul. Nu este necesar ca toate să primească aceleași resurse. Dar evaluarea lor nu ar trebui să le forțeze pe aceeași scară fără explicație. Un proiect de clarificare conceptuală și unul de optimizare operațională pot avea tipuri diferite de rezultat.

Această discuție separă două întrebări normative. Vrem ca sistemul să imite judecățile curente ale comunității sau vrem să ajute comunitatea să își descopere punctele oarbe? Prima sarcină poate fi evaluată prin acordul cu experții. A doua cere cazuri în care dezacordul este investigat și uneori se dovedește justificat. Un model care reproduce perfect consensul nu este, prin aceasta, un detector perfect al contribuțiilor care vor schimba consensul.

Nu trebuie romantizată opoziția față de consens. Multe idei respinse sunt greșite sau insuficient dezvoltate. Dar un sistem de cercetare nu poate afla care excepții merită păstrate dacă echivalează lipsa familiarității cu lipsa sensului. Politica de selecție trebuie să permită verificarea unor cazuri pe care scorurile curente nu le favorizează, iar rezultatele auditului trebuie să poată modifica procedura.

Concluzia operațională este că detectorul de noutate și politica de alocare a atenției trebuie proiectate împreună, dar evaluate separat. Detectorul identifică relații și incertitudini. Politica decide cât cost acceptă pentru explorare și cât risc acceptă pentru respingere. Amestecarea lor într-un singur scor poate ascunde atât biasurile epistemice, cât și alegerile normative.

Capitolul 13. Obiecțiile cele mai puternice, în ambele direcții

13.1. Cazul sceptic: modelul poate învăța reputația inovației, nu inovația

Cea mai puternică versiune a scepticismului nu spune că un model nu poate produce o secvență care lipsea din antrenare. Acest lucru ar fi prea ușor de contrazis. Ea spune că noțiunea evaluativă de noutate este învățată din verdicturile unei comunități, iar aceste verdicturi conțin convenții, ierarhii și preferințe. Modelul poate deveni un bun predictor al recunoașterii sociale a inovării fără a deveni un bun detector al diferențelor care nu sunt încă recunoscute social.

Acesta este un argument serios deoarece separă eticheta de proprietate. Dacă datele spun că anumite idei sunt „noi” pentru că au fost publicate în contexte prestigioase, un model poate învăța contextul. Dacă exemplele de noutate sunt toate explicate retrospectiv, poate învăța forma narativă a succesului. Dacă ideile nerecunoscute nu apar în date, nu există feedback direct despre ele. Într-o asemenea lume, performanța pe un benchmark construit din aceleași convenții poate supraestima utilitatea pentru descoperirea excepțiilor.

Argumentul nu este înlăturat prin simpla adăugare de raționament verbal. Un sistem poate produce o justificare amplă a aceleiași etichete sociale. Nici existența unui corp mare de antrenare nu rezolvă automat problema: mai multe exemple ale aceleiași selecții pot consolida biasul. Pentru a răspunde scepticismului trebuie aduse dovezi că evaluatorul reacționează la diferențe controlate și poate contrazice un indiciu social atunci când antecedentele îl infirmă.

O a doua obiecție sceptică privește noutatea transformațională. Un model antrenat să reprezinte lumea într-un anumit vocabular poate avea dificultăți când contribuția schimbă vocabularul. Chiar dacă arhitectura poate exprima noi combinații, procedura de interpretare

poate normaliza noul cadru la cel vechi. Această obiecție nu demonstrează imposibilitatea, dar identifică o regiune unde testele standard, construite din categorii stabile, pot fi insuficiente.

O a treia obiecție privește lipsa unui adevăr de referință independent. Dacă nici experții nu pot stabili sigur noutatea, cum putem valida detectorul? Răspunsul nu poate fi o promisiune de omnisciență. Putem valida componente în lumi finite, putem verifica antecedente concrete și putem evalua decizii condiționate. Pentru schimbări conceptuale deschise, trebuie acceptate incertitudinea și urmărirea longitudinală. Faptul că nu există un etalon perfect nu înseamnă că orice metodă este la fel de bună; înseamnă că afirmațiile de performanță trebuie limitate la ceea ce a fost măsurat.

Scepticismul devine neproductiv când își schimbă criteriul după fiecare succes. Dacă orice diferență recunoscută este declarată retrospectiv „nu cu adevărat nouă”, ipoteza nu mai poate fi infirmată. O teză științifică trebuie să precizeze înainte ce ar conta drept recunoaștere. Putem cere generalizare la familii neobservate, martori corecți și robustețe la reformulare. Dar nu putem cere ca modelul să recunoască ceva indefinibil și apoi să folosim eșecul definiției drept dovadă împotriva lui.

13.2. Cazul optimist: procedurile vechi pot detecta obiecte noi

Cea mai puternică versiune a optimismului este procedurală. Un sistem nu trebuie să fi memorat o contribuție pentru a constata că diferă de un precedent. Poate învăța operații de comparație, poate utiliza surse noi și poate delega verificări unor instrumente. Noutatea obiectului nu cere noutatea fiecărei operații cognitive folosite pentru a-l evalua. Un microscop construit din principii cunoscute poate observa un specimen necunoscut; analogia ilustrează posibilitatea, nu echivalează LLM-ul cu un instrument măsurător calibrat.

Optimismul are un contraargument formal puternic împotriva imposibilității universale: într-o lume finită, o regulă exactă poate

decide noutatea relativă, iar un LLM poate participa la traducerea sau controlul procedurii. Dacă utilizarea unui LLM include accesul la asemenea instrumente, clasa sistemelor posibile este mai largă decât un generator izolat. A exclude instrumentele prin definiție poate fi legitim pentru un benchmark al modelului, dar nu pentru o concluzie despre utilitatea tuturor aplicațiilor LLM.

Există însă o capcană optimistă. Faptul că sistemul poate produce un martor nu garantează că martorul este corect. Faptul că poate cita o sursă nu garantează că sursa susține relația. Faptul că poate formaliza o afirmație nu garantează fidelitatea formalizării. Un lanț de componente aproximative nu devine verificat doar pentru că ultima componentă folosește logică exactă. Dacă traducerea este greșită, verificatorul poate certifica impecabil o altă problemă.

De aceea, argumentul procedural trebuie însoțit de contracte între etape. Modelul propune o interpretare; sursa permite verificarea ei. Modelul propune un martor; un executor îl testează. Modelul propune un antecedent; un comparator verifică pasajele. Unde nu există verificator automat, incertitudinea rămâne explicită. Această disciplină este mai puțin spectaculoasă decât promisiunea unui „cercetător autonom”, dar oferă un traseu experimental clar.

Un alt optimism excesiv afirmă că mărirea modelelor va rezolva inevitabil problema. Nu există în argumentele prezentate o asemenea garanție. Mai multă capacitate poate îmbunătăți anumite operații și poate reduce erori, dar nu rezolvă lipsa informației, criteriile incoerente sau coliziunile ireversibile ale unui pipeline. Un model final mai mare poate utiliza mai bine textul original; nu poate deduce sigur un antecedent inaccesibil sau o diferență care a fost eliminată complet din intrare.

Tot astfel, diversitatea de eșantionare nu este identică cu diversitatea de interpretare. Creșterea temperaturii poate produce mai multe formulări și ipoteze, dar acestea pot rămâne în aceeași familie conceptuală. Un sistem de explorare trebuie să urmărească diferențe operaționale între interpretări, nu doar variația lexicală. Dacă zece

răspunsuri propun același mecanism cu alte nume, nu avem zece direcții de cercetare.

Poziția optimistă defensabilă este, prin urmare, condiționată: anumite componente ale evaluării noutății pot fi automatizate util, iar limitele lor pot fi măsurate și reduse prin acces la surse, reprezentări mai bune și verificatoare. Nu rezultă că un scor lingvistic neauditat poate înlocui judecata științifică. Posibilitatea tehnică este începutul unei obligații de validare, nu sfârșitul ei.

13.3. O poziție intermediară care nu este un compromis comod

A susține simultan posibilitatea și limitele nu înseamnă a evita verdictul. Putem respinge ferm inferența „învățat din trecut, deci incapabil de comparații noi”. Putem accepta ferm limita „diferență pierdută, deci imposibil de recuperat numai din reprezentarea rămasă”. Putem considera probabilă, dar încă dependentă de configurație, existența unui bias de familiaritate în evaluarea noutății. Aceste poziții nu se contrazic deoarece privesc afirmații diferite.

Cea mai importantă schimbare conceptuală este înlocuirea întrebării despre esența modelului cu întrebarea despre contractul observațional. Ce diferențe trebuie să distingă sistemul? Ce informație primește? Ce transformări sunt admise? Ce martori pot fi verificați? Ce tip de eroare ar conta drept eșec? Această abordare este mai apropiată de ingineria verificabilă decât de disputa dacă modelul „înțelege cu adevărat”.

Totuși, problema înțelegerii nu dispare. Ea este operaționalizată parțial. Un sistem care poate identifica ipoteze, produce consecințe distinctive, rezista reformulărilor și revizui verdictul când apar antecedente manifestă o competență relevantă pentru evaluare. Nu am demonstrat prin aceasta o teorie completă a înțelegerii. Am definit comportamente care contează practic și care pot fi testate. Această modestie conceptuală este o virtute metodologică, nu o renunțare la întrebările profunde.

Noutatea poate necesita uneori o schimbare a întrebării, nu doar a răspunsului. Un detector fixat pe un criteriu poate fi corect în cadrul său și totuși insuficient pentru cercetare. De aceea, sistemele avansate ar trebui să poată semnala că o contribuție contestă criteriul sau că două interpretări produc evaluări diferite. Dar semnalarea nu trebuie recompensată automat ca originalitate. Trebuie urmată de clarificarea consecințelor și de testarea lor.

Cea mai fertilă versiune a intuiției inițiale este astfel o ipoteză despre conservarea diferențelor sub interpretare. Un sistem educat de trecut poate fi foarte bun la a face textele inteligibile în termenii trecutului. Tocmai această competență poate deveni o vulnerabilitate când sarcina este observarea unei excepții care cere extinderea termenilor. Nu este inevitabil să eșueze. Dar nu trebuie presupus că o interpretare fluentă a păstrat tot ceea ce conta.

Acest argument poate fundamenta un program de cercetare distinct: evaluarea fidelității față de diferențe rare, nu doar a fidelității medii față de conținut. Un rezumat poate fi evaluat după cât de bine păstrează întrebările care separă candidatul de antecedent. Un retriever poate fi evaluat după capacitatea de a găsi surse care infirmă sau confirmă diferența, nu doar surse tematice. Un evaluator poate fi evaluat după martori și condiții, nu doar după acordul cu note globale.

Verdictul acestei cărți nu este că trebuie să avem încredere sau neîncredere în LLM-uri ca bloc omogen. Este că încrederea trebuie atașată operațiilor și dovezilor. Putem avea încredere într-un martor executat corect, mai puțină încredere într-o traducere neverificată și foarte puțină într-o afirmație de absență istorică fără o căutare documentată. O asemenea distribuție a încrederii este mai exigentă și mai utilă decât o etichetă globală despre inteligența modelului.

Capitolul 14. Programul de cercetare și criteriile unui progres real

14.1. Un nucleu experimental minimal, dar decisiv

Un program de cercetare nu trebuie să înceapă prin construirea unui sistem foarte mare. Trebuie să înceapă printr-un experiment care poate separa explicații. Nucleul propus este un corpus finit de contribuții cu etichete exacte, reformulări echivalente și diferențe semantice minimale. Modelul este testat cu antecedente absente, furnizate și regăsite, iar reprezentarea integrală este comparată cu una comprimată. Fiecare factor corespunde unui mecanism distinct.

Un pilot ilustrativ ar putea utiliza 160 de cazuri independente, distribuite egal între opt familii de construcții. Pentru fiecare caz, patru prezentări, trei condiții de acces la antecedente și două trasee de reprezentare ar produce 3.840 de evaluări pentru un model. Trei repetări ale fiecărei evaluări ar produce 11.520 de apeluri. Aceste numere sunt un exemplu de planificare, nu un calcul de putere și nu o recomandare de cost. Cele 11.520 de ieșiri nu reprezintă 11.520 de idei independente.

Pilotul urmărește mai întâi integritatea instrumentelor: etichetele sunt corecte, variantele sunt echivalente, martorii funcționează și jurnalele sunt complete. Abia apoi estimăm mărimile efectelor și planificăm studiul confirmatoriu. Dacă generatorul are artefacte sau parserul pierde informație, un benchmark mare poate produce doar o estimare precisă a unei probleme greșit definite.

Rezultatul principal ar trebui să fie sensibilitatea la schimbarea semantică și invarianța la schimbarea irelevantă a formei. Acestea trebuie măsurate împreună. Un model care nu își schimbă niciodată verdictul este stabil la parafraze, dar nu detectează diferențe. Un model care își schimbă mereu verdictul este sensibil, dar nu discriminativ.

Competența cere schimbare când eticheta se schimbă și stabilitate când eticheta nu se schimbă.

O hartă de ipoteze poate fi păstrată într-un registru compact.

Ipoteză	Contrastul care o poate susține sau slăbi
Familiaritatea stilistică influențează verdictul	Aceeși contribuție, stiluri controlate, antecedente identice.
Compresia pierde diferențe relevante	Original, reprezentare comprimată și recuperare prin acces la sursă.
Regăsirea este blocajul dominant	Antecedente recuperate automat față de antecedente decisive furnizate.
Frecvența evaluativă din antrenare este o cauză	Intervenție asupra expunerii, cu resurse și adevăr de referință controlate.
Verdictul folosește diferența, nu doar retorica	Martori verificați și inversări ale bibliotecii de referință.
Filtrul pierde noutăți rare în utilizare	Audit probabilistic al respingerilor la buget fix de selecție.

Fiecare ipoteză are propriul nivel de generalizare. Un efect într-un model mic adaptat local este o dovadă de mecanism, nu o estimare directă pentru orice model mare. O reușită pe circuite este o dovadă de comparație formală, nu o dovadă a evaluării transformărilor culturale.

Registrul trebuie să împiedice transferul nejustificat al concluziilor între niveluri.

14.2. De la mecanism la arhitectură și la utilitate

După identificarea unui mecanism, următorul pas este intervenția remediatoare. Dacă problema este pierderea cuantificatorilor, putem adăuga o extracție explicită a lor și acces la pasaje. Dacă problema este căutarea tematică, putem adăuga interogări orientate spre diferență. Dacă problema este calibrarea, putem separa verdictul de abținere și evalua probabilitățile pe un set independent. Remediul trebuie ales după diagnostic, nu după popularitatea unei tehnici.

Fiecare remediu trebuie testat prin ablație. Comparăm sistemul complet cu o versiune fără componenta respectivă, păstrând bugetele cât mai comparabile. O îmbunătățire poate proveni din cost suplimentar, nu din mecanismul pretins. Este utilă și o comparație cu un baseline simplu, de exemplu un comparator pe texte integrale sau o regulă explicită în domeniul finit. Un sistem sofisticat care nu depășește un baseline modest nu justifică prin complexitate valoarea sa.

Un progres real poate consta și în reducerea încrederii nejustificate. Dacă noua arhitectură identifică mai bine cazurile în care informația este insuficientă, acuratețea brută poate să nu crească mult, dar riscul deciziilor automate poate scădea. Trebuie însă măsurat costul abținerilor. Un sistem care escaladează tot nu este un evaluator util, chiar dacă nu mai greșește singur.

După laborator, transferul către documente reale trebuie făcut gradual. Mai întâi, fragmente scurte cu diferențe validate. Apoi, lucrări complete cu pachete de antecedente adjudecate. Apoi, căutare end-to-end pe corpusuri versionate. În final, fluxuri prospective. Fiecare etapă adaugă o sursă de incertitudine. Dacă performanța scade, structura etapelor permite localizarea degradării.

Utilitatea trebuie evaluată în raport cu munca umană. Sistemul economisește timp de căutare? Produce comparații pe care experții le

pot verifica mai repede? Reduce redescoperirile? Păstrează mai multe contribuții rare la același buget? Aceste întrebări sunt mai concrete decât „poate AI să evalueze cercetarea?”. Un sistem poate fi valoros ca asistent de antecedente și nepotrivit ca filtru final. Această delimitare trebuie să apară în concluzii și în interfață.

Replicarea trebuie să includă familii de modele și condiții de utilizare diferite, fără a presupune că numele comercial definește o configurație stabilă. Versiunile, datele, instrumentele și parametrii trebuie documentați. Dacă un serviciu se schimbă, rezultatele istorice rămân valide pentru configurația testată, dar nu descriu automat configurația actuală. Un program matur tratează evaluarea ca pe un proces continuu, nu ca pe o certificare permanentă.

14.3. Ce ar însemna validarea sau invalidarea intuiției inițiale

Forma universală a intuiției ar fi contrazisă de o reușită robustă pe obiecte noi, cu adevăr de referință exact, criteriu fix și condiții care împiedică simpla recuperare a unei etichete memorate. Nu este nevoie ca modelul să descopere o lege fundamentală a naturii pentru a contrazice o afirmație universală de imposibilitate. Este suficient un domeniu nebanal în care comparația se generalizează corect la instanțe noi.

Forma comportamentală ar fi susținută dacă stilul familiar sau retorica de inovare modifică sistematic verdictul pentru același conținut, dincolo de un prag relevant, iar efectul se reproduce. Ar fi slăbită local dacă testele bine alimentate statistic arată invarianta la aceste manipulări și sensibilitate la schimbări semantice reale. Niciun singur experiment nu încheie problema pentru toate domeniile, dar poate delimita o zonă de încredere.

Forma cauzală despre antrenare ar necesita intervenții asupra expunerii. Un rezultat convingător ar arăta că asocierea repetată a unui tipar cu eticheta „nou” produce ulterior supraevaluarea acelui tipar, deși noutatea de referință este controlată. Dacă intervenția nu are efect

relevant în regimuri bine testate, explicația trebuie revizuită. Poate că problema vine mai ales din prompt, din criteriu sau din reprezentare, nu din frecvența presupusă.

Forma informațională are un statut diferit. Pentru o coliziune relevantă demonstrată, imposibilitatea clasificării perfecte din reprezentarea rămasă rezultă matematic. Ceea ce trebuie testat empiric este dacă și cât de des pipeline-urile reale produc asemenea coliziuni sau pierderi aproximative. Teorema nu oferă o estimare a frecvenței lor. Experimentul nu trebuie să redemonstreze teorema, ci să stabilească relevanța ei practică.

Forma instituțională ar necesita observații asupra fluxului de idei și a feedbackului. Dacă filtrele reduc sistematic diversitatea diferențelor verificate și dacă auditul descoperă contribuții relevante printre respingeri, există motive pentru schimbarea politicii. Dar impactul trebuie separat de lipsa resurselor, de calitatea ideilor și de alte filtre. O poveste plauzibilă despre uniformizare nu înlocuiește măsurarea.

La sfârșitul cercetării, este posibil să obținem o concluzie mai puțin dramatică, dar mai valoroasă decât ipoteza inițială: modelele pot detecta anumite tipuri de noutate, eșuează pe altele, iar o parte importantă a eșecului provine din pierderea diferențelor în reprezentări și din evaluarea unor substituții sociali sau retorici. Această concluzie ar conduce direct la arhitecturi mai bune, criterii mai clare și politici de audit.

Teza finală este următoarea. Trecutul nu face imposibilă recunoașterea noului; furnizează regulile, comparațiile și prejudecățile prin care îl examinăm. Problema decisivă este dacă aceste instrumente permit diferenței să rămână vizibilă. Un evaluator de noutate devine credibil nu când vorbește convingător despre originalitate, ci când poate arăta ce este diferit, față de ce, în ce condiții și prin ce dovezi și-ar schimba concluzia.

Anexa A. Demonstrații și exemple matematice desfășurate

A.1. De la frecvențe la decizie: trei calcule care nu trebuie confundate

Considerăm o lume cu două clase, nou și vechi. Dorim să înțelegem separat distribuția textelor, învățarea unei etichete și alegerea unei acțiuni. Aceste operații sunt adesea reunite într-o singură intuiție despre „ce este probabil”, deși răspund la întrebări diferite. Exemplele următoare sunt construcții didactice, cu numere alese pentru claritate, nu rezultate empirice despre modele lingvistice.

Mai întâi, să presupunem că într-un corpus apar nouă sute de descrieri ale ideii A și o sută ale ideii B. Un model ideal al identității ideii ar atribui probabilitățile 0,9 și 0,1. Dacă alegem întotdeauna ideea cea mai probabilă, vom produce numai A. Dacă eșantionăm corect din distribuție, vom produce și B, în proporția sa. Dacă întrebăm dacă B diferă de A și furnizăm definițiile lor, frecvențele nu decid singure răspunsul. Am trecut de la generare la comparație.

Acum introducem o etichetă evaluativă. În date, descrierile cu o anumită formă retorică S sunt numite „inovatoare” în 80% dintre cazuri, iar cele fără S în 20%. Un clasificator care folosește numai S poate avea o performanță bună dacă această corelație persistă în test. Pentru a afla dacă înțelege diferența conceptuală, construim un test în care S este independent de noutatea exactă. Dacă performanța scade, avem dovezi că indiciul a contat. Pentru a demonstra că frecvențele respective au cauzat utilizarea lui, trebuie să intervenim asupra datelor, nu doar să observăm corelația.

În sfârșit, alegem o acțiune. Chiar dacă probabilitatea noutății este estimată corect, decizia depinde de costuri. Dacă verificarea unui candidat este ieftină și pierderea unei descoperiri este costisitoare, pragul de selecție poate fi mic. Dacă verificarea este foarte scumpă, pragul poate crește. Două sisteme cu aceeași probabilitate estimată pot

lua decizii diferite fără ca unul să fie mai puțin capabil să detecteze noutatea. Diferența aparține politicii.

Derivăm acum descompunerea pierderii logaritmice. Pentru o mulțime finită și distribuții P și Q , costul mediu este suma $P(x)$ înmulțit cu minus $\log Q(x)$. Adăugăm și scădem minus $\log P(x)$. Obținem entropia lui P și suma $P(x) \log(P(x)/Q(x))$, adică divergența KL. Dacă Q atribuie probabilitate zero unui eveniment cu P pozitiv, costul este infinit. În rest, divergența este nenegativă, iar minimul ideal este atins la $Q=P$.

$$-\sum_x P(x) \log Q(x) = -\sum_x P(x) \log P(x) + \sum_x P(x) \log \frac{P(x)}{Q(x)}.$$

De ce divergența este nenegativă? Putem folosi inegalitatea $\log u \leq u-1$ pentru u pozitiv. Aplicată raportului $Q(x)/P(x)$, ea arată că suma $P(x) \log(Q(x)/P(x))$ este cel mult suma $Q(x)-\text{suma } P(x)$, adică zero. Schimbând semnul obținem nenegativitatea. Această demonstrație elementară explică de ce obiectivul ideal nu cere eliminarea evenimentelor rare. El cere alocarea unor probabilități corecte, inclusiv pentru ele.

Într-un model cu capacitate limitată, familia Q poate să nu conțină P . Atunci optimizarea alege cea mai bună aproximație după pierderea medie. Dacă erorile pe o clasă rară costă puțin în media totală, modelul poate sacrifica acea clasă pentru îmbunătățiri mai mari în regiuni frecvente. Acesta este un mecanism posibil de compromis. Nu este echivalent cu afirmația că orice clasă rară va fi ignorată. O regulă compactă poate explica simultan cazuri frecvente și rare.

Revenim la exemplul prevalenței. Pentru $\pi=0,001$, $\text{TPR}=0,9$ și $\text{FPR}=0,01$, probabilitatea ca o selecție să fie cu adevărat nouă este $0,0009$ împărțit la $0,01089$, adică aproximativ $0,08264$. Un detector cu aceste caracteristici recuperează majoritatea noutăților, dar produce multe alarme false. Dacă scădem FPR la $0,001$, păstrând ipotetic aceeași sensibilitate, precizia devine aproximativ $0,474$. Exemplul arată cât de mult contează rata alarmelor false într-un flux rar.

Această analiză nu justifică automat creșterea pragului. Pragul poate reduce și TPR . Trebuie analizată curba completă și capacitatea de verificare. Dacă alegem numai candidații cei mai siguri, putem elimina

exact contribuțiile neobișnuite. De aceea, o politică de selecție poate păstra un canal principal cu precizie mare și un canal de audit sau explorare. Proportțiile trebuie stabilite în raport cu costurile și evaluate, nu alese pentru a produce un scor convenabil.

A.2. Riscul Bayes, coliziunea și beneficiul posibil al unui rezumat

Să avem o reprezentare discretă Z și o etichetă binară Y . Pentru fiecare valoare z , un clasificator trebuie să aleagă zero sau unu. Dacă alege zero, greșește pe masa comună $P(Y=1, Z=z)$. Dacă alege unu, greșește pe masa $P(Y=0, Z=z)$. Alegerea optimă ia clasa cu masa mai mare, iar costul local este masa mai mică. Suma acestor minime dă riscul Bayes din capitolul 6.

Acest argument arată exact unde apare eroarea inevitabilă. Nu în complexitatea stilului sau în insuficiența raționamentului, ci în faptul că aceeași observație este compatibilă cu etichete diferite. Un algoritm mai bun poate atinge riscul Bayes, dar nu îl poate depăși fără informație suplimentară sau fără modificarea problemei. Într-o lume finită cu etichete deterministe și observații complete, riscul poate fi zero. După compresie, poate deveni pozitiv.

Pentru prioruri egale, notăm $p_0(z)=P(Z=z|Y=0)$ și $p_1(z)=P(Z=z|Y=1)$. Masa comună a fiecărei clase este jumătate din distribuția condiționată. Folosim identitatea $\min(a,b)=(a+b-|a-b|)/2$. După sumare, obținem riscul egal cu o jumătate minus un sfert din suma diferențelor absolute. Variația totală este jumătate din acea sumă, de unde rezultă formula din capitol.

$$TV(p_0, p_1) = \frac{1}{2} \sum_z a b s(p_0(z) - p_1(z)).$$

Dacă p_0 și p_1 sunt identice, TV este zero și eroarea minimă este o jumătate. Dacă distribuțiile au suporturi disjuncte, TV este unu și eroarea minimă este zero. Între aceste extreme există grade de separabilitate. Într-un experiment de compresie, putem întreba dacă transformarea face distribuțiile claselor mai asemănătoare în privința informației utile. Nu este necesar să observăm o coliziune exactă a

unor vectori reali pentru a avea o degradare practică; poate exista o apropiere care depășește rezoluția evaluatorului.

Trebuie însă diferențiată imposibilitatea informațională de dificultatea pentru un algoritm. Să presupunem că X este un document lung care conține explicit eticheta corectă într-o relație logică dificilă. Un rezumat Z o exprimă clar. Evaluatorul concret poate avea eroare mai mică pe Z . Aceasta nu contrazice faptul că un evaluator optim cu acces la X ar putea calcula același rezumat și decide cel puțin la fel de bine. Rezumatul schimbă costul și accesibilitatea, nu creează adevăr suplimentar despre lume.

Un exemplu construit are documente cu multe propoziții irelevante și două premise: dacă A atunci B ; A . Întrebarea este dacă B urmează. Un rezumat fidel poate păstra numai premisele și reduce erorile unui model limitat. Dar dacă întrebarea este dacă documentul afirmă și C , același rezumat poate fi insuficient. Fidelitatea este dependentă de sarcină. Un rezumat bun pentru concluzia B poate fi prost pentru inventarierea tuturor contribuțiilor.

Putem formula un obiectiv de compresie orientat spre o familie de întrebări Q . Dorim o reprezentare cu cost mic, astfel încât răspunsurile la întrebările relevante să fie conservate cu o eroare sub un prag. Acesta este un obiectiv de proiectare, nu o metodă completă. Dificultatea este că întrebările despre noutate pot fi necunoscute înaintea citirii. Dacă familia Q este prea îngustă, contribuțiile care schimbă întrebările pot fi pierdute. Dacă este nelimitată, cerința se apropie de păstrarea integrală a informației.

Un sistem poate gestiona tensiunea prin două niveluri. Reprezentarea compactă servește întrebărilor frecvente, iar arhiva originală rămâne accesibilă pentru întrebări noi. Costul este mutat de la stocare completă în fiecare context către acces selectiv. Garanția practică depinde de capacitatea sistemului de a recunoaște când are nevoie de sursă. De aceea, detectarea insuficienței reprezentării este o sarcină separată care trebuie evaluată.

O consecință subtilă este că explicația modelului poate fi mai informativă decât scorul și totuși insuficientă pentru verdict. Dacă explicația păstrează o diferență, dar scorul o ignoră, informația există în ieșire și poate fi recuperată de un alt agregator. Dacă explicația și scorul au fost construite după aceeași netezire, ambele pot rata diferența. Evaluarea ar trebui să inspecteze obiectele intermediare, nu doar ultima etichetă.

A.3. Diferențe rare și modele de selecție: calcule exacte

Construim două funcții pe opt biți. Prima returnează XOR-ul primilor doi biți. A doua returnează aceeași valoare, cu excepția intrării în care toți cei opt biți sunt unu, unde valoarea este inversată. Funcțiile diferă pe exact o intrare din 256. Dacă biblioteca conține numai prima funcție, a doua este nouă după criteriul echivalenței extensionale. Această etichetă nu depinde de frecvența cu care intrarea distinctivă apare în utilizare.

Dacă intrările sunt uniforme și observăm o sută de exemple independente cu înlocuire, probabilitatea de a nu vedea diferența este $(255/256)$ la puterea o sută, aproximativ 0,676. Cu o mie de exemple, probabilitatea este aproximativ 0,01996. Pentru a avea probabilitate de rată cel mult 0,05, avem nevoie de cel puțin 766 de observații în acest regim. Enumerarea fără înlocuire a tuturor celor 256 de intrări este, evident, suficientă. Regimul de eșantionare contează.

Dacă intrarea distinctivă are probabilitatea ε sub distribuția reală, formula generală este $(1-\varepsilon)^m$ la puterea m . Pentru ε mic, aproximarea exponențială $\exp(-m\varepsilon)$ arată că bugetul necesar crește aproximativ invers proporțional cu ε . Acesta este un motiv pentru a nu identifica absența unei diferențe observate cu echivalența funcțională. Un test poate fi foarte lung și totuși să rateze un caz rar dacă nu este proiectat să îl caute.

Un verficator simbolic poate evita uneori eșantionarea prin analizarea structurii. Pentru funcțiile de mai sus, observă direct condiția care inversează ieșirea. Dar nu trebuie să generalizăm de la această

construcție simplă la orice program. Căutarea unui martor poate fi dificilă computațional. Diferența dintre a verifica un martor furnizat și a-l descoperi este un element central al complexității operaționale a detectorului.

Să examinăm acum compresia. Dacă păstrăm ieșirile pe primele 255 de intrări în ordinea lexicografică și eliminăm ultima intrare, cele două funcții primesc aceeași reprezentare. Eroarea nu provine dintr-un model lingvistic, ci dintr-o proiecție deterministă. Dacă adăugăm ulterior ultima linie, diferența devine identificabilă. Exemplul este o demonstrație executabilă a dependenței verdictului de informația păstrată.

Pentru selecția repetată, considerăm două clase cu ponderi inițiale egale. Prima este acceptată cu probabilitatea 0,55, a doua cu 0,50, iar numai acceptatele revin. După t runde, raportul ponderilor este 1,1 la puterea t . După douăzeci de runde, raportul este aproximativ 6,73. Nu am modelat calitatea ideilor, apariția de contribuții noi sau corectarea erorilor. Calculul arată numai cum se poate amplifica o asimetrie persistentă într-un proces închis.

Dacă introducem în fiecare rundă idei externe și păstrăm auditul, dinamica se modifică. Clasele defavorizate pot fi reintroduse, iar probabilitățile de acceptare se pot schimba după descoperirea erorilor. Astfel, modelul simplu nu este o predicție inevitabilă a uniformizării. Este un instrument pentru a formula variabilele care trebuie măsurate: aportul extern, probabilitatea de selecție, rata reevaluării și dependența acestora de familiaritate.

Aceste calcule au un rol comun. Ele arată că o eroare observată poate avea surse foarte diferite: raritatea unui caz distinctiv, compresia informației sau o politică repetată de selecție. Niciuna nu trebuie atribuită automat esenței LLM-ului. În schimb, fiecare poate fi introdusă într-un experiment controlat și poate conduce la o intervenție concretă.

Anexa B. Protocol de preregistrare și registru al dovezilor

B.1. Fișa studiului și contractul inferențial

Protocolul de mai jos este un șablon conceptual pentru un studiu confirmatoriu. Valorile concrete trebuie stabilite înaintea colectării datelor, după un pilot independent. Nu este prezentat ca un protocol deja înregistrat și nu implică existența unui experiment executat. Scopul său este să împiedice schimbarea retrospectivă a ipotezelor, metricilor și populației până când rezultatul devine convenabil.

Titlul studiului trebuie să numească mecanismul și domeniul: de exemplu, influența familiarității stilistice asupra detectării noutății funcționale în circuite finite. O formulare de tipul „pot LLM-urile să fie creative?” este prea largă pentru un asemenea experiment. Populația vizată trebuie să precizeze familiile de obiecte și limbajele de descriere. Concluziile nu vor fi extinse automat la idei științifice deschise.

Ipoteza principală trebuie formulată ca un contrast măsurabil. De exemplu, rata identificării corecte a diferenței este modificată de stil când semantica și antecedentele sunt constante. Direcția poate fi preregistrată sau testul poate fi bilateral, dacă există motive pentru efecte în ambele sensuri. Trebuie ales un prag al efectului minim relevant, exprimat în puncte procentuale, diferență de scor sau cost de verificare. Pragul nu trebuie ales după rezultate.

Condițiile experimentale trebuie să definească exact ce primește modelul. Corpusul absent, regăsirea automată și pachetul de antecedente decisive sunt tratamente diferite. Textul integral, rezumatul și rezumatul cu acces la sursă sunt alte tratamente. În cazul unui design parțial, trebuie declarat de ce anumite combinații sunt omise. Un design redus poate fi foarte bun dacă răspunde unei întrebări precise.

Unitatea independentă principală este contribuția sau familia, nu numărul de răspunsuri generate. Repetările estimează variabilitatea modelului în aceeași situație; nu înmulțesc numărul de idei. Trebuie specificată structura de clustering și metoda de calcul a intervalelor. Dacă utilizăm mai multe modele, trebuie declarat dacă inferența privește modelele individuale sau o familie de proceduri de antrenare.

Element preregistrat	Specificația necesară
Populație	Domeniul, familiile de contribuții și criteriile de includere.
Adevăr de referință	Verificator exact sau procedură expertă, cu limite declarate.
Manipulări	Semantica, stilul, accesul, compresia și eventual expunerea.
Rezultat principal	Metrică unică sau familie restrânsă, aleasă înaintea testului.
Analiză	Contraste, interacțiuni, clustering și tratarea multiplicității.
Excluderi	Erori de generator, intrări invalide și reguli stabilite anterior.
Abțineri	Tratament explicit în acoperire, risc și cost.
Relevanță practică	Pragul efectului care ar modifica o decizie de utilizare.

Excluderile trebuie să privească defecte reale ale datelor, nu rezultate neconvenabile. Un caz cu etichetă ambiguă poate fi mutat într-un strat separat conform unei reguli anterioare. Nu trebuie eliminat pentru că modelul a răspuns altfel decât aștepta cercetătorul. Un răspuns într-un format greșit poate fi o eroare de urmărire a instrucțiunii și trebuie raportat ca atare; nu trebuie corectat manual în secret.

Planul de analiză trebuie să distingă confirmarea de explorare. Putem investiga ulterior de ce un model eşuează pe o familie, dar rezultatul este generator de ipoteze. Dacă schimbăm promptul după inspectarea testului, avem o nouă procedură şi este necesar un set de evaluare separat. Un benchmark folosit repetat pentru ajustare devine treptat parte din antrenarea sistemului, chiar dacă ponderile modelului nu se schimbă.

B.2. Registrul unui caz şi traseul de la text la verdict

Fiecare caz trebuie să aibă un identificator stabil şi o versiune. Identificatorul nu trebuie să dezvăluie eticheta. Datele trebuie să separe obiectul semantic de prezentarea sa. Pentru un circuit, obiectul poate fi arborele expresiei şi tabelul de adevăr. Prezentarea poate fi textul în limbaj natural. Pentru un articol, obiectul semantic nu este exact cunoscut, astfel încât păstrăm contribuţia extrasă împreună cu pasajele şi interpretările alternative.

Registrul trebuie să includă criteriul de noutate şi biblioteca exactă. Dacă biblioteca se modifică, eticheta poate să se schimbe fără modificarea candidatului. Aceasta nu este o inconsistenţă, ci o consecinţă a definiţiei relative. Versiunile trebuie păstrate pentru a putea reconstrui verdictul iniţial. Într-un studiu temporal, momentul referinţei este parte din caz, nu doar o metadată decorativă.

Transformările trebuie să aibă provenienţă. Cine sau ce a produs parafraza? Ce reguli garantează echivalenţa? A fost verificată de un executor, de un expert sau numai de un model? Pentru rezumate, trebuie păstrat ce informaţie a fost omisă. Dacă evaluarea descoperă ulterior o diferenţă, putem determina dacă ea exista în intrarea modelului sau fusese eliminată înainte.

Ieşirea evaluatorului trebuie stocată integral, înainte de orice normalizare. Un parser poate extrage scorul şi verdictul, dar ieşirea brută rămâne necesară pentru audit. Erorile de parser trebuie testate separat. Dacă modelul spune „nu pot decide”, iar parserul extrage un

număr dintr-un exemplu, analiza poate produce un rezultat fals fără ca modelul să fi luat acel verdict.

Martorii trebuie reprezentați ca obiecte verificabile. Pentru un circuit, martorul este o intrare și cele două ieșiri. Pentru un antecedent, este sursa, versiunea și pasajul care susține anticiparea. Pentru o ipoteză empirică, poate fi un protocol care ar produce rezultate diferite sub două mecanisme. Trebuie distins martorul verificat de martorul propus. O idee despre cum s-ar putea testa diferența nu este deja o demonstrație a diferenței.

B.3. Raportarea rezultatului și decizia de continuare

Raportul final trebuie să prezinte rezultatul principal chiar dacă nu susține ipoteza. Trebuie să arate mărimea efectului, incertitudinea, costul și analizele pe familii preregistrate. Nu este suficientă selectarea câtorva exemple spectaculoase. Exemplele sunt utile pentru mecanism, dar nu înlocuiesc distribuția rezultatelor. Un eșec dramatic poate fi rar; un bias mic poate fi sistematic.

Un rezultat nul trebuie interpretat în raport cu precizia estimării. Dacă intervalul este larg, studiul poate fi neconcludent. Dacă intervalul exclude efecte mai mari decât pragul practic, putem afirma că un efect relevant a fost slăbit în configurația testată. Nu trebuie convertită lipsa semnificației într-o demonstrație a absenței. În sens invers, o diferență semnificativă nu justifică automat un verdict despre importanța operațională.

Decizia de continuare ar trebui să depindă de informația câștigată. Dacă efectul de stil este mic, dar pierderea prin compresie este mare, proiectul poate muta accentul către reprezentări. Dacă regăsirea este principalul blocaj, investiția într-un evaluator mai scump poate fi prematură. Dacă niciun remediu nu depășește baseline-ul simplu la cost comparabil, arhitectura trebuie simplificată sau ipoteza revizuită.

Raportul trebuie să distingă ce a fost furnizat de experimentator, ce a fost învățat, ce a fost generat de model și ce a fost verificat exact.

Această distincție este crucială pentru sistemele hibride. O performanță bună poate proveni dintr-un pachet de antecedente perfect sau dintr-un generator care face sarcina prea ușoară. Aceste avantaje nu invalidează experimentul dacă sunt declarate, dar limitează concluziile.

Ultima secțiune a raportului ar trebui să precizeze ce observație viitoare ar schimba concluzia. Un nou domeniu, o altă familie de transformări sau un audit al respingerilor poate dezvălui limite. O concluzie științifică bună nu este protejată împotriva revizuirii; este formulată astfel încât revizuirea să fie posibilă și informativă.

Anexa C. Un exemplu executabil de noutate relativă

C.1. Ce verifică programul și ce nu verifică

Programul de mai jos este un exemplu complet, în Python, care utilizează numai biblioteca standard. A fost executat pentru verificarea calculelor și a proprietăților finite prezentate aici. Nu apelează un LLM, nu testează creativitatea unui model și nu furnizează dovezi empirice pentru biasul de familiaritate. El verifică independent câteva condiții pe care un viitor benchmark lingvistic ar trebui să le respecte.

Reprezentarea unui circuit este un arbore construit din tupluri. Un număr întreg desemnează indicele unei variabile. Un tuplu începe cu operatorul și continuă cu argumentele. Evaluarea este recursivă și nu folosește execuția dinamică a unor șiruri de cod. Numărul de intrări este limitat explicit pentru a evita enumerări accidental foarte mari. Limita din program este una de protecție practică, nu o limită teoretică a metodei.

Primul test arată că o reformulare prin legile lui De Morgan este echivalentă cu AND și deci veche față de biblioteca aleasă. Al doilea arată că XNOR nu este în biblioteca formată din AND, OR și XOR. Această noutate este relativă; adăugarea lui XNOR în bibliotecă ar schimba verdictul. Programul nu afirmă că XNOR este o invenție nouă în istoria logicii.

Al treilea test construiește două funcții pe opt biți care diferă numai când toate intrările sunt unu. Verificarea enumeră toate intrările și identifică martorul unic. Apoi elimină ultima linie din tabele și confirmă coliziunea reprezentărilor rămase. Astfel, exemplul separă o diferență reală de informația disponibilă evaluatorului. Niciun clasificator care primește numai cele două tabele trunchiate nu poate deduce sigur diferența lipsă fără ipoteze suplimentare.

Ultimele calcule folosesc eşantionare independentă cu înlocuire şi intrări uniforme. Ele nu descriu enumerarea exhaustivă şi nici distribuţii naturale de intrări. Această precizare este necesară pentru interpretarea numărului de observaţii. Programul poate fi salvat într-un fişier şi executat cu un interpretor Python 3; ieşirea deterministă este reprodusă după cod.

C.2. Implementarea completă

```

"""Exemplu didactic; nu evalueaza niciun LLM."""
from itertools import product
from math import ceil, log

def value(node, bits):
    """Evalueaza un arbore validat, fara eval()."""
    if type(node) is int:
        if not 0 <= node < len(bits):
            raise ValueError("Indice de variabila invalid")
        return bits[node]
    if not isinstance(node, tuple) or not node:
        raise ValueError("Nod invalid")
    op, *args = node
    arity = {"not": 1, "and": 2, "or": 2, "xor": 2}
    if not isinstance(op, str) or op not in arity:
        raise ValueError("Operator invalid")
    if len(args) != arity[op]:
        raise ValueError("Operator sau aritate invalida")
    values = [value(arg, bits) for arg in args]
    if op == "not":
        return 1 - values[0]
    a, b = values
    if op == "and":
        return a & b
    if op == "or":
        return a | b
    return a ^ b

def table(node, n):
    if type(n) is not int or not 1 <= n <= 16:
        raise ValueError("n trebuie sa fie intre 1 si 16")
    return tuple(value(node, bits)
                  for bits in product((0, 1), repeat=n))

```

```

def compare(candidate, library, n):
    """Noutate functională față de o bibliotecă finită."""
    target = table(candidate, n)
    matches = [name for name, node in library.items()
                if table(node, n) == target]
    return not matches, matches

def all_inputs_true(n):
    node = 0
    for index in range(1, n):
        node = ("and", node, index)
    return node

def main():
    library = {"AND": ("and", 0, 1),
               "OR": ("or", 0, 1),
               "XOR": ("xor", 0, 1)}
    old = ("not", ("or", ("not", 0), ("not", 1)))
    new = ("not", ("xor", 0, 1))
    assert compare(old, library, 2) == (False, ["AND"])
    assert compare(new, library, 2) == (True, [])
    print("Parafraza AND: veche")
    print("XNOR față de bibliotecă: nouă")

    n = 8
    baseline = ("xor", 0, 1)
    candidate = ("xor", baseline, all_inputs_true(n))
    first, second = table(baseline, n), table(candidate, n)
    witnesses = [bits for bits, a, b in
                  zip(product((0, 1), repeat=n),
                      first, second) if a != b]
    assert witnesses == [(1,) * n]
    assert first[:-1] == second[:-1]
    assert first != second
    print("Martor unic:", witnesses[0])
    print("Coliziune după eliminarea martorului: True")
    miss = (1 - 2 ** (-n)) ** 100
    needed = ceil(log(0.05) / log(1 - 2 ** (-n)))
    print(f'Ratare după 100 observații: {miss:.6f}')
    print("Observații pentru ratare ≤ 0.05:", needed)
    print("Toate verificările exacte au trecut.")

if __name__ == "__main__":
    main()

```


C.3. Ieșirea verificată și extensii legitime

Parafraza AND: veche
XNOR fata de biblioteca: noua
Martor unic: (1, 1, 1, 1, 1, 1, 1)
Coliziune dupa eliminarea martorului: True
Ratare dupa 100 observatii: 0.676116
Observatii pentru ratare ≤ 0.05 : 766
Toate verificarile exacte au trecut.

Aceste verificări validează construcțiile didactice, nu detectorul lingvistic propus. Pentru a transforma exemplul într-un benchmark trebuie adăugate generarea familiilor independente, echilibrarea artefactelor, variantele de limbaj, interfața evaluatorului și analiza statistică. Aserțiunile din program ar trebui păstrate în generator, astfel încât nicio etichetă să nu fie produsă numai pe baza intenției autorului testului.

Anexa D. Vocabularul tehnic și cunoștințele prealabile

D.1. Probabilitate, informație și statistică

Variabilă aleatoare. O funcție care asociază un rezultat numeric sau categorial fiecărei situații posibile într-un model probabilistic. În această carte, eticheta de noutate, verdictul evaluatorului și reprezentarea documentului pot fi variabile aleatoare. Caracterul aleator poate descrie variația cazurilor, nu neapărat o lume fizică fundamental nedeterministă.

Distribuție. Regula care atribuie probabilități valorilor unei variabile. Trebuie precizat ce populație descrie: textele de antrenare, ideile dintr-un flux, intrările unui circuit sau ieșirile modelului. Trecerea neanunțată de la o distribuție la alta este o sursă importantă de confuzie în discuția despre raritate.

Probabilitate condiționată. Probabilitatea unui eveniment după ce fixăm o informație. Frecvența globală a unei idei nu este aceeași cu probabilitatea etichetei „nou” după compararea ei cu antecedente explicite. Condiționarea poate schimba radical distribuția relevantă pentru decizie.

Prior. Distribuția folosită înainte de observarea informației curente, în raport cu un model probabilistic. Un prior nu este neapărat o prejudecată nejustificată. Devine problematic dacă domină dovezile relevante sau dacă este confundat cu o concluzie verificată despre cazul individual.

Posterior. Distribuția actualizată după observarea datelor, sub ipotezele modelului. Un posterior poate fi calculat impecabil într-un model prost specificat. Încrederea numerică rezultată nu elimină obligația de a verifica dacă variabilele și ipotezele corespund problemei de noutate.

Verosimilitate. Valoarea probabilității datelor privită ca funcție de parametrii unui model. Nu trebuie confundată cu probabilitatea că o ipoteză științifică este adevărată sau cu noutatea unei idei. Un text previzibil lingvistic poate conține o diferență conceptuală importantă.

Surpriză informațională. Minus logaritmul probabilității unui rezultat. Măsoară improbabilitatea față de o distribuție, nu valoarea, sensul sau prioritatea istorică. Zgomotul poate fi surprinzător, iar o contribuție importantă poate fi formulată foarte simplu.

Entropie. Media surprizei unei variabile. Este mică atunci când distribuția este concentrată și mare când există multe rezultate greu de anticipat. Entropia unui corpus nu este o măsură directă a originalității ideilor sale.

Entropie încrucișată. Costul logaritm mediu al predicțiilor unei distribuții Q pentru date provenite din P . Se descompune în entropia lui P și divergența KL. În antrenare, minimizarea ei încurajează predicția distribuției, nu doar alegerea celui mai frecvent rezultat.

Divergență Kullback–Leibler. O măsură asimetrică a diferenței dintre două distribuții, relevantă pentru costul predicției. Nu este o distanță geometrică obișnuită și nu măsoară automat diferența semantică dintre două idei. Alegerea variabilelor este la fel de importantă ca formula.

Informație mutuală. Cantitatea prin care observarea unei variabile reduce incertitudinea despre alta. În evaluarea reprezentărilor ne interesează informația despre eticheta sau întrebarea relevantă, nu numai informația despre document în ansamblu. O reprezentare poate păstra tema și pierde diferența.

Variație totală. O măsură a separării dintre două distribuții. În clasificarea binară cu prioruri egale, determină riscul Bayes minim. Dacă distribuțiile observației sunt identice în cele două clase, observația nu permite distingerea lor mai bine decât priorul.

Risc Bayes. Cea mai mică eroare așteptată posibilă pentru informația și pierderea specificate. Nu este eroarea unui model concret. Un algoritm poate fi mult mai slab decât limita informațională, iar o reprezentare poate impune o eroare pozitivă chiar unui algoritm optim.

Statistică suficientă pentru sarcină. O reprezentare care păstrează tot ceea ce este necesar pentru decizia vizată. În sensul operațional al cărții, suficiența este relativă la criteriu și întrebări. O reprezentare suficientă pentru clasificarea tematică poate fi insuficientă pentru noutatea mecanismului.

Schimbare de distribuție. Diferența dintre populația folosită la antrenare sau calibrare și populația întâlnită ulterior. În cercetarea noutății, schimbarea nu este doar o defecțiune accidentală; poate fi chiar fenomenul de interes. Garanțiile obținute pe trecut trebuie interpretate condiționat.

Prevalență. Proporția cazurilor pozitive în populația evaluată. O prevalență mică poate produce multe alarme false chiar pentru un detector cu sensibilitate bună. Precizia unei selecții nu poate fi interpretată fără a cunoaște sau estima prevalența relevantă.

Precizie. Proporția selecțiilor pozitive care sunt corecte. Într-un filtru de idei, răspunde întrebării câtă verificare se consumă pe alarme false. Nu spune câte contribuții noi au fost pierdute printre respingeri.

Recall sau sensibilitate. Proporția cazurilor realmente pozitive care sunt detectate. Pentru descoperire, măsoară capacitatea de a păstra noutățile. Poate fi estimată numai dacă avem informație și despre cazurile respinse, nu doar despre selecții.

Rată a falselor pozitive. Proporția cazurilor vechi clasificate drept noi. Diferă de proporția alarmelor false între selecții. Confundarea acestor două numitoare este una dintre cele mai frecvente erori în interpretarea detectorilor pentru evenimente rare.

Calibrare. Concordanța dintre probabilitățile declarate și frecvențele observate ale corectitudinii. Un sistem poate fi calibrat în medie și prost calibrat pe o clasă rară. Calibrarea nu certifică fidelitatea explicațiilor sau completitudinea corpusului de antecedente.

Scor Brier. Media pătratelor diferențelor dintre probabilitățile prezise și etichetele binare observate. Este o măsură a calității predicțiilor probabilistice. Pentru noutate, etichetele trebuie definite înainte; formula nu rezolvă ambiguitatea criteriului.

Clasificare selectivă. Procedură care permite abținerea pe unele cazuri. Trebuie evaluate împreună acoperirea, riscul pe cazurile decise și costul escaladării. Abținerea nu trebuie nici pedepsită automat ca eroare, nici exclusă astfel încât să cosmetizeze performanța.

Interval de încredere. Un interval produs de o procedură cu o anumită proprietate de acoperire în repetări ale studiului, sub ipotezele sale. Nu înseamnă automat probabilitatea că parametrul fix se află în intervalul particular observat. Interpretarea cere atenție la design și dependențe.

Mărimea efectului. Cantitatea diferenței dintre condiții, exprimată într-o unitate relevantă. Semnificația statistică nu spune singură dacă efectul contează pentru selecția ideilor. Un efect mic poate deveni important la scară mare, dar acest lucru trebuie analizat explicit.

Putere statistică. Probabilitatea ca un test să detecteze un efect specificat, sub un model al datelor. Nu este o proprietate universală a unui număr de exemple. Depinde de mărimea efectului, variație, corelații și procedura de analiză.

Clustering și pseudoreplicare. Observațiile provenite din aceeași idee sau familie pot fi dependente. Tratarea tuturor parafraselor și repetărilor ca independente poate subestima incertitudinea. Analiza trebuie să reflecte nivelul la care există replicări reale.

D.2. Modele lingvistice, reprezentări și regăsire

Token. Unitatea discretă procesată de modelul lingvistic. Poate fi un cuvânt, o parte de cuvânt sau un simbol. Compararea lungimii și perplexității între tokenizări diferite cere precauție, deoarece unitățile nu au aceeași granularitate.

Embedding. Reprezentare vectorială a unui obiect, token sau pasaj. Apropierea vectorială poate fi utilă pentru regăsire, dar nu este identică cu echivalența semantică. Obiectivul de antrenare stabilește ce asemănări sunt favorizate și ce diferențe pot fi ignorate.

Atenție. Mecanism de combinare a informației între poziții în arhitecturi de tip Transformer. Permite accesul dependent de context la alte reprezentări. Nu constituie singur o garanție că modelul utilizează toate premisele relevante pentru o judecată.

Autoregresiv. Mod de factorizare și generare în care fiecare element este condiționat de elementele anterioare. Descrie organizarea probabilistică a ieșirii, nu epuizează tipul operațiilor care pot fi realizate în calcularea acelei ieșiri.

Preantrenare. Etapă în care modelul învață dintr-un corpus larg, de regulă printr-un obiectiv general. Ipotezele despre frecvențele corpusului trebuie separate de efectele ajustării ulterioare, ale promptului și ale instrumentelor disponibile la utilizare.

Postantrenare. Etape care modifică comportamentul modelului după învățarea inițială, de exemplu prin demonstrații sau preferințe. Pot schimba stilul și urmărirea instrucțiunilor. Un efect observat în modelul final nu poate fi atribuit automat numai preantrenării.

SFT. Ajustare supravegheată pe exemple de intrări și ieșiri dorite. Pentru evaluarea noutății, selecția exemplilor și criteriile etichetării sunt importante: modelul poate învăța o procedură de comparație sau indicii ale verdictelor dorite.

RLHF. Familie de proceduri de învățare din feedback uman care implică optimizarea unei politici. Recompensa utilizată este un substitut pentru preferințele sau criteriile vizate. Nu trebuie presupus că recompensa coincide cu adevărul istoric al unei contribuții.

DPO. Optimizare directă a preferințelor printr-un obiectiv bazat pe perechi de răspunsuri preferate și nepreferate. În această carte contează faptul că preferințele pot modifica politica finală; nu atribuim metodei un efect universal asupra noutății.

Învățare din context. Modificarea comportamentului prin exemple și instrucțiuni furnizate în prompt, fără actualizarea parametrilor în acea interacțiune. Permite testarea unor lumi locale cu simboluri noi, dar nu garantează învățarea oricărei reguli din puține exemple.

Decodare. Procedura care transformă distribuțiile modelului într-o ieșire concretă. Alegerea greedy, eșantionarea și alte strategii pot produce rezultate diferite. Schimbarea decodării nu trebuie confundată cu schimbarea competenței de verificare a antecedentelor.

Temperatură. Parametru care modifică concentrarea distribuției folosite la eșantionare. O temperatură mai mare poate crește variația textuală. Nu garantează diversitate conceptuală, corectitudine sau originalitate istorică.

Perplexitate. Exponențiala pierderii logaritmice medii pe unitățile alese. Este o metrică de predicție a textului, dependentă de model, context și tokenizare. Poate fi un indiciu de familiaritate, dar nu o măsură directă a noutății.

LLM-as-a-judge. Utilizarea unui model lingvistic pentru a evalua alte ieșiri sau documente. Criteriul, formatul și sursele trebuie specificate. Acordul cu evaluatorii umani într-o sarcină nu se transferă automat la alte tipuri de judecată.

Bias de familiaritate. Sensibilitate a evaluării la potrivirea cu tipare familiare, atunci când aceasta nu este justificată de criteriul sarcinii. Pentru a-l demonstra trebuie controlate variabile precum claritatea și corectitudinea, nu doar observată o asociere cu stilul.

Scurtătură de învățare. Utilizarea unui indiciu corelat cu eticheta în locul relației vizate. Poate produce rezultate bune pe distribuția obișnuită și eșecuri când indiciul este decuplat de adevăr. Experimentele factoriale încearcă să creeze tocmai această decuplare.

Smoothing semantic. Termen de lucru pentru transformări care reduc variațiile dintre reprezentări. Este util când elimină diferențe irelevante și periculos când șterge ipoteze, excepții sau relații decisive. Nu este tratat ca o proprietate inevitabil negativă.

RAG. Generare augmentată prin regăsirea de documente. Adaugă informație accesibilă la momentul evaluării, dar nu garantează completitudinea corpusului sau corectitudinea comparației. Regăsirea și judecata trebuie măsurate separat.

Regăsire lexicală. Căutare bazată pe termeni și potriviri de suprafață. Poate fi valoroasă pentru formule, nume și expresii rare. Poate rata antecedente reformulate, dar nu trebuie eliminată în favoarea unei reprezentări semantice care pierde detalii exacte.

Regăsire semantică. Căutare bazată pe reprezentări ale sensului sau contextului. Ajută la depășirea diferențelor de vocabular. Similaritatea recuperată este o pistă pentru comparație, nu dovada că un antecedent anticipează contribuția.

Cross-encoder. Model care procesează împreună două texte pentru a evalua relația lor. Poate utiliza interacțiuni detaliate, dar are costuri diferite față de indexarea independentă. Alegerea tehnicii trebuie evaluată la același buget operațional.

Interacțiune târzie. Strategie în care reprezentările unor părți de text sunt calculate separat și combinate ulterior pentru scor. Poate păstra mai multă granularitate decât un singur vector global. Nu certifică însă automat conservarea diferențelor de noutate.

Top-k. Primele k rezultate după un scor de regăsire sau evaluare. Un antecedent decisiv poate lipsi din acest subset chiar dacă există în index. Alegerea lui k este o decizie de cost și acoperire, nu o garanție de completitudine.

Contaminare. Situația în care informație din test sau despre răspunsul său a fost disponibilă în pregătirea modelului ori a procedurii. Poate apărea și prin ajustarea repetată a promptului pe test. Anonimizarea superficială nu o elimină automat.

D.3. Semantică, circuite, compilatoare și verificare

Sintaxă. Forma expresiei după regulile unui limbaj. Două texte sintactic diferite pot avea același comportament. Un detector de noutate care măsoară numai schimbarea formei va confunda parafrazele cu contribuțiile.

Semantică. Regula sau familia de reguli prin care expresiile primesc interpretare. Pentru circuite poate fi funcția calculată; pentru o propunere poate include ipoteze și garanții. Nu există obligația ca toate întrebările de noutate să folosească aceeași semantică.

Semantică extensională. Descrierea unui program prin relația dintre intrări și ieșiri. Ignoră, în forma simplă, costul, structura internă și unele efecte observabile. Este exactă pentru anumite întrebări și insuficientă pentru altele.

Echivalență observațională. Indistinctibilitatea a două sisteme față de o clasă declarată de observații. Dacă schimbăm observațiile admise, de exemplu adăugând timpul sau informația dezvăluită, echivalența poate dispărea. Criteriul observațional trebuie declarat.

AST. Arbore de sintaxă abstractă, care reprezintă structura unei expresii fără toate detaliile grafice. În exemplul executabil, tuplurile joacă acest rol. AST-ul permite evaluare și transformări, dar nu garantează singur fidelitatea traducerii din limbaj natural.

Reprezentare intermediară. Formă internă utilizată între citirea sursei și execuție sau analiză. Poate facilita comparația și verificarea. Dacă pierde o diferență relevantă, etapele ulterioare nu o pot recupera numai din acea reprezentare.

Compiler. Procedură care traduce între reprezentări, cu scopul de a păstra proprietăți specificate. Analogia cu extragerea ideilor este utilă: trebuie declarat ce se conservă. O traducere fluentă nu este automat una corectă semantic.

SSA. Formă de reprezentare în care fiecare variabilă este atribuită o singură dată, utilă pentru urmărirea dependențelor. Într-un graf de analiză a contribuțiilor, o disciplină asemănătoare poate ajuta la versionarea rezultatelor. Nu conferă, singură, adevăr afirmațiilor stocate.

Circuit boolean. Graf finit de operații logice asupra intrărilor binare. Are semantică exactă pe un domeniu finit și permite verificarea exhaustivă pentru dimensiuni mici. Este un laborator controlat, nu un model complet al creativității științifice.

Tabel de adevăr. Enumerarea ieșirilor unei funcții booleene pentru toate intrările. Două circuite cu același tabel sunt echivalente extensional pe domeniul respectiv. Numărul liniilor crește exponențial cu numărul de intrări.

Martor. Obiect concret care susține o afirmație existențială, de exemplu o intrare pe care două funcții diferă. Un martor propus de model trebuie verificat. Existența unui martor corect poate fi mai informativă decât un scor global de originalitate.

Contraexemplu. Caz care infirmă o afirmație universală. Dacă un sistem susține echivalența a două programe, o singură intrare cu ieșiri diferite este suficientă pentru infirmare. Absența unui contraexemplu găsit nu dovedește automat echivalența.

SAT. Problema existenței unei atribuirii care face adevărată o formulă booleană. Poate fi folosită pentru căutarea unui martor de diferență între circuite. Utilizarea unui solver cere o traducere corectă a problemei; solverul nu verifică intenția autorului textului.

SMT. Satisfiabilitate în prezența unor teorii precum aritmetica sau tablourile. Extinde tipurile de afirmații formalizabile. O dovadă într-o formalizare nu garantează că formalizarea corespunde complet unei propuneri informale.

Miter. Construcție care combină două circuite astfel încât ieșirea indică o diferență între ele. Căutarea unei intrări care activează ieșirea produce un martor de neechivalență. Dacă verificarea completă dovedește imposibilitatea, avem echivalență în modelul formal ales.

Soundness, sau corectitudine logică a concluziilor. Proprietatea unei proceduri de a nu certifica afirmații false în modelul său formal. Trebuie separată de fidelitatea modelului față de textul sau lumea analizată. Un verificator corect poate primi premise greșite.

Completitudine. Capacitatea unei proceduri de a identifica toate cazurile adevărate din clasa declarată. Un sistem poate fi sigur când certifică, dar se poate abține pe multe cazuri. Nu trebuie confundată cu acoperirea unui corpus de documente.

Decidabilitate. Existența unui algoritm care se oprește și răspunde corect pentru fiecare instanță dintr-o clasă. Diferă de fezabilitatea practică. O procedură poate fi decidabilă și prea costisitoare pentru utilizare la scară mare.

Indecidabilitate. Absența unui algoritm total corect pentru toate instanțele unei clase. Nu înseamnă că nicio instanță nu poate fi rezolvată sau că metodele aproximative sunt inutile. Limita trebuie raportată la clasa exactă de probleme.

Complexitate. Studiul resurselor necesare calculului în funcție de dimensiunea intrării. Pentru noutate, costul căutării antecedentului, al traducerii și al verificării poate domina diferit. Un scor de acuratețe fără cost nu descrie complet utilitatea.

Datalog. Limbaj de reguli logice folosit pentru relații și inferențe, adesea pe baze finite. Poate reprezenta dependențe sau consecințe într-un laborator controlat. Alegerea regulilor și a semanticii negației trebuie făcută explicit; nu este un detector universal de noutate.

Închidere logică. Mulțimea consecințelor deducibile dintr-o bază de afirmații după reguli specificate. Dacă includem toate consecințele ideale, o nouă demonstrație poate să nu adauge o propoziție neimplicată anterior. Progresul epistemic poate privi accesibilitatea efectivă a consecinței.

Abstracție. Eliminarea controlată a unor detalii pentru a facilita analiza. Este utilă numai în raport cu proprietățile pe care trebuie să le păstreze. În evaluarea noutății, abstracția trebuie auditată pentru pierderea excepțiilor, ipotezelor și diferențelor de resurse.

Proveniență. Informația despre originea și transformările unui obiect sau verdict. Include sursa, versiunea și dependențele. Nu dovedește adevărul, dar permite verificarea, reproducerea și revizuirea concluziilor.

D.4. Epistemologie operațională și design experimental

Noutate relativă. Absența unui antecedent relevant într-un corp de referință declarat, după un criteriu fix. Este forma de noutate cel mai ușor de făcut testabilă. Nu trebuie extinsă automat la prioritatea istorică absolută.

Noutate epistemică. Schimbare în ceea ce un agent sau o comunitate cunoaște ori poate justifica. O demonstrație nouă poate avea acest rol chiar dacă rezultatul era implicit în axiome. Resursele și accesul efectiv contează.

Noutate transformațională. Schimbare a regulilor, reprezentării sau spațiului de probleme, nu doar o soluție suplimentară în cadrul existent. Identificarea ei cere examinarea consecințelor schimbării de cadru, nu recompensarea automată a vocabularului neobișnuit.

Anticipare. Relația prin care un antecedent conține deja elementele relevante ale contribuției evaluate. Poate fi asimetrică și mai largă decât identitatea textuală. În această carte este o noțiune operațională, nu o definiție juridică.

Diferență reziduală. Ceea ce rămâne neanticipat după compararea explicită cu antecedentele. Poate fi important, minor sau incert. Termenul obligă evaluatorul să descrie diferența, în loc să atribuie numai un scor de impresie.

Construct. Proprietatea teoretică pe care dorim să o măsurăm, precum noutatea mecanismului. Metricile sunt substituiți operaționali ai constructului. Acordul cu recenzorii poate măsura judecata comunității fără a coincide complet cu prioritatea istorică.

Validitate de construct. Gradul în care procedura măsoară proprietatea intenționată, nu alte variabile. Un benchmark poate fi fiabil și totuși să măsoare mai ales stilul inovator. Consistența măsurării nu este suficientă.

Identificabilitate. Posibilitatea de a determina proprietatea vizată din observațiile și ipotezele disponibile. Două lumi cu observații identice și verdictes istorice diferite fac proprietatea neidentificabilă fără informație suplimentară.

Confundare cauzală. Situația în care o asociere între două variabile este influențată de alte cauze. De exemplu, perplexitatea și scorul pot fi legate prin claritate. O corelație nu identifică singură frecvența de antrenare drept mecanism.

Intervenție. Modificarea controlată a unei variabile, folosită pentru a studia efectul său. Reformularea textului intervine asupra prezentării; reantrenarea cu frecvențe controlate intervine asupra expunerii. Cele două nu răspund aceleiași întrebări cauzale.

Design factorial. Combinarea sistematică a nivelurilor mai multor factori. Permite studierea efectelor și interacțiunilor, de exemplu dacă stilul contează numai când antecedentele lipsesc. Numărul condițiilor trebuie echilibrat cu bugetul și precizia dorită.

Interacțiune. Situația în care efectul unui factor depinde de alt factor. O medie globală poate ascunde efecte opuse în condiții diferite. De aceea, contrastele importante trebuie definite înainte, nu descoperite selectiv după rezultate.

Oracol experimental. Condiție în care experimentatorul furnizează informația decisivă pentru comparație. Nu este o afirmație de omnisciență. Rolul său este separarea accesului la antecedente de capacitatea de a le compara.

Ablație. Eliminarea unei componente pentru a estima contribuția ei la sistem. Trebuie controlat, pe cât posibil, costul total. O componentă poate părea utilă numai fiindcă adaugă timp sau apeluri suplimentare.

Preregistrare. Fixarea înaintea testului a ipotezelor, metricilor și regulilor de analiză. Nu interzice explorarea, dar o separă de confirmare. Reduce libertatea de a alege retrospectiv numai procedurile favorabile concluziei dorite.

Audit al respingerilor. Verificarea unui eșantion din cazurile eliminate de filtru. Este necesar pentru estimarea noutăților ratate. Fără el, observăm mai ales alarmele false dintre selecții și putem supraestima utilitatea sistemului.

Evaluare prospectivă. Testarea pe contribuții colectate după fixarea procedurii, înainte de un consens public stabil. Reduce unele forme de contaminare, dar cere urmărire în timp și acceptarea unor etichete încă nedeterminate.

Falsificabilitate locală. Existența unor observații care ar slăbi o afirmație precisă despre un model, o reprezentare sau un domeniu. Este mai utilă decât o teză globală protejată prin redefinirea continuă a ceea ce înseamnă „cu adevărat nou”.

Corectabilitate. Capacitatea sistemului de a revizui un verdict atunci când apar surse, interpretări sau martori noi. Este o proprietate arhitecturală și epistemică. Un evaluator credibil trebuie să păstreze traseul prin care concluzia sa poate fi infirmată.

Referințe și hartă de lectură

Surse primare consultate

Referințele de mai jos documentează afirmațiile despre literatura existentă. Definițiile de lucru, demonstrațiile elementare și protocoalele acestei monografii trebuie distinse de rezultatele raportate în surse. Metadatele și versiunile au fost verificate până la 11 septembrie 2026. Pentru lucrările distribuite prin arXiv este indicată această versiune accesibilă, fără a presupune că toate rezultatele au fost replicate independent. Când pagina consultată indică o conferință, acest statut este menționat explicit.

[R01] Boden, Margaret A. (2009). Computer Models of Creativity. AI Magazine, 30(3), 23. DOI: 10.1609/aimag.v30i3.2254. [Pagina publicației](#). Relevanță: tipuri de creativitate și diferența dintre combinare, explorare și transformarea unui cadru.

[R02] Shannon, Claude E. (1948). A Mathematical Theory of Communication. The Bell System Technical Journal, 27, 379–423 și 623–656. [Textul articolului](#), [reproducere academică](#). Relevanță: informație probabilistică, entropie și separarea problemei comunicației de semnificația mesajelor.

[R03] Vaswani, Ashish, și colaboratorii (2017). Attention Is All You Need. Advances in Neural Information Processing Systems. [arXiv:1706.03762](#). Relevanță: arhitectura Transformer; nu constituie o demonstrație a competenței de evaluare a noutății.

[R04] Brown, Tom B., și colaboratorii (2020). Language Models are Few-Shot Learners. Advances in Neural Information Processing Systems. [arXiv:2005.14165](#). Relevanță: comportamente condiționate de exemplele din context și distincția dintre memorarea instanței și adaptarea la sarcină.

[R05] Ouyang, Long, și colaboratorii (2022). Training language models to follow instructions with human feedback. Advances in Neural Information Processing Systems. [arXiv:2203.02155](#). Relevanță: ajustarea comportamentului prin demonstrații și preferințe; separarea preantrenării de politica finală.

[R06] Rafailov, Rafael; Sharma, Archit; Mitchell, Eric; Ermon, Stefano; Manning, Christopher D.; Finn, Chelsea (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Advances in Neural Information Processing Systems*. [arXiv:2305.18290](#). Relevanță: optimizarea directă pe preferințe, ca mecanism distinct de obiectivul inițial de modelare a limbajului.

[R07] Wataoka, Koki; Takahashi, Tsubasa; Ri, Ryokan (2024). Self-Preference Bias in LLM-as-a-Judge. [arXiv:2410.21819](#), [versiunea 1](#). Relevanță: relația dintre familiaritatea pentru model, perplexitate și preferințele evaluatorului. Domeniul studiului nu este identic cu noutatea științifică istorică.

[R08] Zheng, Lianmin, și colaboratorii (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *NeurIPS, Datasets and Benchmarks*. [arXiv:2306.05685](#). Relevanță: utilitatea evaluatorilor LLM și biasuri precum poziția, verbositatea și auto-favorizarea.

[R09] Si, Chenglei; Yang, Diyi; Hashimoto, Tatsunori (2024). Can LLMs Generate Novel Research Ideas? A Large-Scale Human Study with 100+ NLP Researchers. [arXiv:2409.04109](#), [versiunea 1](#). Relevanță: evaluarea umană oarbă a ideilor generate; diferența dintre noutatea percepută, fezabilitate și prioritatea verificată.

[R10] Gupta, Tarun; Pruthi, Danish (2025). All That Glitters is Not Novel: Plagiarism in AI Generated Research. *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics*. [ACL Anthology](#). Relevanță: examinarea explicită a antecedentelor pentru documente de cercetare generate de AI.

[R11] Schopf, Tim; Färber, Michael (2026). Is this Idea Novel? An Automated Benchmark for Judgment of Research Ideas. *RINoBench*. [arXiv:2603.10303](#), [versiunea 1](#). Metadatele consultate indică acceptarea la LREC 2026. Relevanță: evaluarea scorurilor și justificărilor de noutate; construcția și limitele unui etalon derivat din recenzii.

[R12] Wu, Wenqing; Zhao, Yi; Wang, Yuzhuo; Li, Siyou; Shao, Juexi; Long, Yunfei; Zhang, Chengzhi (2026). NovBench: Evaluating Large Language Models on Academic Paper Novelty Assessment. [arXiv:2604.11543](#), [versiunea 1](#). Metadatele consultate indică ACL 2026. Relevanță: evaluări de noutate bazate pe introduceri și recenzii, cu dimensiuni separate de calitate.

[R13] Liu, Yan; Yang, Zonglin; Poria, Soujanya; Nguyen, Thanh-Son; Cambria, Erik (2025). Harnessing Large Language Models for Scientific Novelty Detection. [arXiv:2505.24615](#), versiunea 1. Relevanță: regăsirea conceptuală a antecedentelor și evaluarea augmentată cu surse în benchmarkuri de noutate.

[R14] Lewis, Patrick, și colaboratorii (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems. [arXiv:2005.11401](#). Relevanță: combinarea memoriei parametrice cu documente recuperate la utilizare.

[R15] Khattab, Omar; Zaharia, Matei (2020). ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT. SIGIR. [arXiv:2004.12832](#). Relevanță: regăsire cu reprezentări granulare și interacțiune târzie; tehnică de acces, nu certificat de echivalență.

[R16] Liu, Nelson F.; Lin, Kevin; Hewitt, John; Paranjape, Ashwin; Bevilacqua, Michele; Petroni, Fabio; Liang, Percy (2024). Lost in the Middle: How Language Models Use Long Contexts. Transactions of the Association for Computational Linguistics. [arXiv:2307.03172](#). Relevanță: dependența performanței de poziția informației în contextele și modelele testate.

[R17] Nalisnick, Eric; Matsukawa, Akihiro; Teh, Yee Whye; Görür, Dilan; Lakshminarayanan, Balaji (2019). Do Deep Generative Models Know What They Don't Know? ICLR. [arXiv:1810.09136](#). Relevanță: limitele folosirii verosimilității drept indiciu al apartenenței la distribuție.

[R18] Guo, Chuan; Pleiss, Geoff; Sun, Yu; Weinberger, Kilian Q. (2017). On Calibration of Modern Neural Networks. Proceedings of Machine Learning Research, 70, 1321–1330. [Pagina PMLR](#). Relevanță: separarea încrederii numerice de corectitudinea empirică și proceduri de calibrare.

[R19] Saito, Takaya; Rehmsmeier, Marc (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, 10(3), e0118432. DOI:10.1371/journal.pone.0118432. Relevanță: măsurarea detectorilor în populații dezechilibrate.

[R20] Angelopoulos, Anastasios N.; Bates, Stephen (2021; revizuit 2022). A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification. [arXiv:2107.07511](#). Relevanță: predicție cu garanții marginale și importanța ipotezelor privind datele; nu o certificare a noutății individuale.

[R21] Ren, Jie; Liu, Peter J.; Fertig, Emily; Snoek, Jasper; Poplin, Ryan; DePristo, Mark A.; Dillon, Joshua V.; Lakshminarayanan, Balaji (2019).

Likelihood Ratios for Out-of-Distribution Detection. *Advances in Neural Information Processing Systems*. [arXiv:1906.02845](https://arxiv.org/abs/1906.02845). Relevanță: controlarea efectelor statisticilor de fundal în detecția în afara distribuției.

[R22] Uzzi, Brian; Mukherjee, Satyam; Stringer, Michael; Jones, Ben (2013).

Atypical Combinations and Scientific Impact. *Science*, 342(6157), 468–472. DOI:10.1126/science.1240474. [Înregistrarea bibliografică și rezumatul](#). Relevanță: combinații convenționale și atipice în literatura științifică; impactul prin citări nu este identic cu adevărul.

[R23] Shumailov, Iliia; Shumaylov, Zakhar; Zhao, Yiren; Papernot, Nicolas; Anderson, Ross; Gal, Yarin (2024).

AI models collapse when trained on recursively generated data. *Nature*, 631, 755–759. DOI:10.1038/s41586-024-07566-y. Relevanță: efecte ale unor regimuri de antrenare recursivă; nu dovada unui colaps inevitabil pentru orice utilizare a datelor sintetice.

[R24] Gerstgrasser, Matthias, și colaboratorii (2024). Is Model Collapse Inevitable? Breaking the Curse of Recursion by Accumulating Real and Synthetic Data. [arXiv:2404.01413](https://arxiv.org/abs/2404.01413). Relevanță: importanța diferenței dintre acumularea și înlocuirea datelor în regimuri recursive.

[R25] Hemaspaandra, Lane A.; Rothe, Jörg (1999). A Second Step Towards Complexity-Theoretic Analogs of Rice's Theorem. [arXiv:cs/9907038](https://arxiv.org/abs/cs/9907038). Relevanță: context formal pentru proprietăți semantice, indecidabilitate și clase restrânse de circuite. Nu este un studiu empiric despre modele lingvistice.

Cum se leagă sursele de argumentul cărții

Pentru fundamentele despre probabilitate și arhitectură, punctul de intrare este grupul R02–R06. Pentru ipoteza familiarității și limitele evaluării automate, nucleul este R07–R12. Pentru construcția unui sistem cu acces explicit la antecedente, sunt relevante R13–R16. Pentru măsurare și incertitudine, R17–R21 oferă avertizări și instrumente care trebuie adaptate, nu transferate mecanic. Pentru creativitate, combinații și dinamica datelor, R01 și R22–R24 completează perspectiva. R25 delimitează un tip de imposibilitate formală care nu trebuie confundat cu dificultatea practică a tuturor sarcinilor.