Sensul ca drum

VSS · VSA Semantic Space: un strat semantic verificabil între limbaj și acțiune

Cum devine o propoziție o constelație, ce se poate citi de pe harta ei și ce poți face cu asta

---

Cuprins

Rezumat într-o pagină

1. Ideea de la care am pornit

1.1 Ce înțelegem prin sens
1.2 Cine participă
1.3 Unde suntem

2. Cerul, sonda și pilotul

2.1 Un punct din cer: coordonate cu mii de rotițe
2.2 De ce două puncte alese la întâmplare n-au nicio legătură
2.3 Sonda: o singură operație
2.4 Steaua unui cuvânt
2.5 Harta propoziției: cum se desenează o constelație
2.6 Legenda și domeniile
2.7 Scanerul: cum se citește harta

3. Citirea unei propoziții

3.1 Pasul
3.2 Ce înseamnă că două propoziții „ajung în același loc”
3.3 Citirea hărții: cadrul
3.4 Propoziții în propoziții: legenda e relativă
3.5 Balizele de pe hartă: cum știe un cuvânt în ce domeniu să meargă
3.6 Trei desene pentru același cuvânt

4. De ce două propoziții de lungimi diferite pot însemna același lucru

Lungimea e o proprietate a drumului, nu a hărții
Cuvintele de legătură mută sonda, dar nu intră în cadru
Cuvinte diferite, aceeași destinație
Un exemplu urmărit, și unul care nu se potrivește
Când lungimea chiar contează, și ce face harta atunci

5. Același cuvânt în mai multe lumi: polisemie, domenii de cunoaștere, ontologii

Steaua e cuvântul, nu sensul
Când e ambiguu felul cuvântului
Lumea e un obiect de prim rang
Mai multe lumi deodată
Descoperim ontologii?
Aceleași cuvinte, teorii diferite

6. Cum învață pilotul

6.1 Ce primește: constelația lumii
6.2 De ce asta forțează sensul
6.3 Ce se învață, și cât de puțin

7. Ce rămâne pe hartă după o propoziție, și la ce e bun

8. Fenomene pe care le poți urmări pe hartă
Domeniul gol, și de ce „gol” e mai greu decât pare
Domeniul aglomerat
Stele în afara legendei, sau cum știe pilotul că o propoziție n-are sens pentru el
Cheia ruptă
Zgomotul, și de ce harta are o capacitate
Negația ca o stea, și unde trăiește scopul ei
Ambiguitatea ținută deschisă
Nivelul nemaivăzut, și cheia care nu există
O construcție nouă: o baliză lipsă
Structura anunțată după
Ordinea, și ce nu pot deosebi cheile care comută
Care verb? Predicatul e și el un domeniu
Mai multe evenimente, și același nume de două ori
Trei feluri de „aproape”
Ce nu ține minte pilotul
Pronumele: o stea de împrumut
De ce stelele cuvintelor sunt aleatoare, și trebuie să rămână așa
9. Unde duce
9.1 Asistenți care au voie să spună „nu știu”
9.2 Un verificator lângă modelele mari
9.3 Formalizarea unui domeniu pentru raționament simbolic
9.4 O graniță care învață
9.5 Un model al lumii pe care îl poți citi
10. Robotică: un dispozitiv de blocare semantică
Cum arată
De ce e ieftin, și de ce poate fi hardware
Ce face când nu e sigur
Ce decide cât de departe se merge
11. Enterprise și industrii puternic reglementate
Sisteme agentice: intenția citită fără model de limbaj
Industrii reglementate: documente care trebuie citite exact
Unde intră modelele mari, și unde nu
Ce decide ritmul
12. Mai departe: documente, noutate, părtinire, netezire
13. Pentru cei cu înclinație tehnică: povestea, tradusă
Familia
Atomi și compuși
Ce calculează modelul
Lumea și obiectivul
Citirea înapoi și diagnosticele
Ce e standard, ce e al nostru
14. Din ce se poate face cerul: variante de reprezentare, codul rar și creierul
Aceleași trei operații, mai multe materiale
De ce am ales fazele
Codul rar: același cer, scris în neuroni
De ce se crede că în creier codul e rar
Unde e inovația și unde e ingineria
15. Paralela cu O mie de creiere
Ce spune teoria, în cinci propoziții
Dicționarul
Ce am luat literal
Unde e votul

De ce doar trei
Unde ne despărțim, și de ce
16. Alinierea și problemele din jurul ei: ce se poate spune inginerește
Ideea de bază: legenda ca graniță
Problemele, una câte una
Ce nu rezolvă
Rezumat
17. Ce este, și ce nu este
Ce este
Față de ce se compară
Ce nu este
Ce ar putea schimba mesajul
Limite

Rezumat într-o pagină

Teza. Sensul unei propoziții, într-un domeniu dat, e setul de răspunsuri pe care le dă la o listă scurtă de întrebări fixe ale acelui domeniu (cine? ce? cui? când? sub ce condiție?), inclusiv răspunsul „nu spune”. Două propoziții înseamnă același lucru când dau aceleași răspunsuri, oricât de diferit ar suna. Numim traducerea unei propoziții în asemenea răspunsuri verificabile *formalizarea limbajului*.

Mecanismul. Un cititor mic, fără nicio cunoștință despre lume, parcurge propoziția cuvânt cu cuvânt ca pe un drum într-un spațiu de mii de dimensiuni: fiecare fel de cuvânt e un salt învățat; fiecare cuvânt e desenat acolo unde a ajuns drumul; drumuri diferite care ajung în aceleași locuri cu nume dau același cadru. Locurile cu nume (rolurile) vin de la domeniu; drumul se învață din exemple cu cadrele lor; nimic altceva nu e învățat. Tot ce știe cititorul încape într-un megaoctet; citirea costă microsecunde pe un procesor obișnuit; aceeași intrare dă mereu aceeași ieșire.

Ce s-a arătat până acum, pe lumi construite și pe un set real de întrebări. Formulări diferite ale aceluiași eveniment ajung la același cadru. Cititorul compune corect la o adâncime de imbricare pe care n-a văzut-o la antrenare, acolo unde o rețea neuronală cu aceeași intrare ghicește. Cuvinte noi se citesc fără reantrenare. Operatorii logici (negație, modalitate, condiționale) se citesc cu scopul lor corect, fără reguli scrise de mână. Pe întrebări reale, cu aceeași intrare și fără cunoaștere externă, structura de roluri se învață mai bine decât cu un transformer mic sau cu o metodă lexicală, la toate mărimile de date încercate. Și ce n-a fost înțeles se vede pe hartă (domeniu gol, domeniu aglomerat, rest neexplicat), în loc să fie acoperit de un răspuns fluent.

Ce nu este. Nu e un model de limbaj: nu generează, nu conversează, nu deține fapte. Nu înlocuiește modelele mari pe text deschis. Locul lui e lângă ele: stratul verificabil dintre limbaj și acțiune, cel care spune ce s-a înțeles, ce nu, și unde, și prin care trece tot ce ajunge la execuție sau în baza de date.

Unde duce. Asistenți pe domenii închise care au voie să spună „nu știu”; un verificator al formalizărilor făcute de modele mari; un dispozitiv de blocare semantică pentru roboți, ieftin, implementabil în hardware; citirea exactă a procedurilor, regulamentelor și rapoartelor în industrii reglementate; o interfață verificabilă pentru alinierea sistemelor agentice. Fiecare e descrisă cu mecanismul ei și cu măsura care îi decide ritmul.

Starea și ritmul. Semnalele sunt bune și de felul care contează; ce rămâne e, în cea mai mare parte, inginerie și ajustări ale modelului, cu pași incrementali și criterii scrise dinainte. Starea exactă a fiecărei măsurători e ținută la zi într-un singur fișier public: https://github.com/ml-circuits-research/vsa-semantic-space/blob/main/STATUS.md

---

1. Ideea de la care am pornit

Când citești o propoziție, nu aduni cuvintele într-un sac. Călătorești. Fiecare cuvânt te mută undeva, iar ce îți rămâne la sfârșit nu e lista cuvintelor, ci locul în care ai ajuns și ce ai lăsat

pe drum. „Ion îi dă Anei o carte” și „Ana primește o carte de la Ion” sunt două trasee diferite care se termină în același loc. De aceea înseamnă același lucru.

Am luat imaginea asta în serios și am construit-o. Ca să o explicăm fără să trișăm, descriem mai jos o poveste imaginară, un cer plin de stele, o sondă, un pilot și lumea despre care vorbesc propozițiile, care se comportă exact ca matematica din spatele sistemului: orice afirmație din poveste e adevărată și despre sistemul real, și nicio piesă din ea nu face ceva ce sistemul real nu face. La sfârșit, un tabel leagă fiecare piesă de numele ei tehnic.

1.1 Ce înțelegem prin sens

Înainte de poveste, o precizare despre cuvântul „sens”, pentru că îl folosim într-un înțeles anume, mai îngust decât cel obișnuit și tocmai de aceea măsurabil.

O propoziție descrie un eveniment: cineva a dat ceva cuiva, un furnizor a livrat niște cutii undeva, o profesoară ține un curs într-o sală la o oră. Despre un asemenea eveniment se pot pune întrebări: cine? ce? cui? unde? când? cât? Nu oricâte și nu orice: pentru un domeniu dat, lista întrebărilor care au sens e scurtă și fixă. O evidență de împrumuturi nu întreabă niciodată „la ce temperatură?”; un depozit nu întreabă „cui i-a plăcut?”. A ști ce înseamnă o propoziție, în acest document, înseamnă două lucruri: a ști *ce întrebări se pot pune* despre fapta pe care o descrie, și a ști, pentru fiecare, *ce răspuns dă propoziția*, inclusiv răspunsul „nu spune”. Un răspuns poate fi un cuvânt, poate fi negația unui cuvânt („nu Ion”), iar la „ce spune Maria?” poate fi un eveniment întreg, cu întrebările lui.

Definiția asta are trei consecințe pe care le vom folosi tot timpul. Întâi, sensul e relativ la un domeniu: aceeași propoziție are alt sens pentru depozit și pentru orar, pentru că listele lor de întrebări diferă; nu există „sensul în sine”, există sensul față de o listă de întrebări. Al doilea, două propoziții înseamnă același lucru exact când dau aceleași răspunsuri la aceleași întrebări, oricât de diferit ar suna. Al treilea, „n-am înțeles” devine ceva precis: o întrebare rămasă fără răspuns deși propoziția ar fi trebuit să-l dea, un răspuns în care doi candidați se bat, o bucată de propoziție care nu răspunde la nicio întrebare din listă, sau o întrebare pe care propoziția o ridică și lista n-o conține.

Răspunsurile au două surse, și le ținem separate. Propoziția spune ce spune: „Ion îi dă Anei o carte” răspunde la cine, ce și cui, și tace la când. Baza de date a domeniului știe restul, sau contrazice: că împrumutul a fost marți, că Ion n-are nicio carte. Sistemul descris aici face doar prima parte: transformă propoziția într-un set complet de răspunsuri la întrebările domeniului, cu golurile marcate, într-o formă pe care baza de date sau un motor de raționament o poate verifica și completa. Acestei transformări îi spunem *formalizarea limbajului*: nu formalizarea gramaticii, ci traducerea a ceea ce se spune în răspunsuri verificabile la întrebări știute dinainte. Restul documentului e despre cum se face asta fără ca sistemul să țină vreo bază de cunoștințe despre lume.

1.2 Cine participă

Patru participanți, și e important să nu-i amestecăm.

Cerul. Un singur univers, aproape gol. Un punct din cer e dat de *coordonate*, și atât: nu există nimic în el în afară de coordonate. Unele puncte au primit un nume sau au fost

însemnate de cineva; pe acelea le numim *stele*. O stea nu e un obiect; e un punct pe care cineva l-a notat. Vom întâlni trei feluri de stele: stelele cuvintelor, stelele cu nume ale lumii, și stelele pe care le desenează pilotul pe harta unei propoziții. Cerul nu e lumea despre care vorbesc propozițiile și nu știe nimic despre ea.

Sonda. Singurul lucru care se mișcă prin cer. Știe să facă două lucruri și nimic altceva: să *sară* dintr-un punct în altul, când i se dă o cheie, și să *raporteze* coordonatele punctului în care a ajuns. La începutul fiecărei propoziții e la *origine*, punctul cu toate coordonatele zero.

Lumea. Domeniul despre care vorbesc propozițiile, și singurul loc din poveste unde există fapte. Trei exemple, ca să fie concret:

- Un *depozit*. Propozițiile lui sună așa: „Furnizorul Alfa a livrat 40 de cutii la raionul B marți." Depozitul vrea să știe, din orice propoziție: *cine a livrat? ce? cât? unde? când?*
- Un *orar de școală*. „Doamna Pop ține fizica în sala 12 marți la ora 10." Orarul întreabă: *cine? ce curs? în ce sală? când?*
- O *evidență de împrumuturi* între prieteni. „Ion îi dă Anei o carte." Evidența întreabă: *cine dă? ce? cui?*

Fiecare lume are, deci, o listă scurtă de întrebări, mereu aceeași pentru toate propozițiile ei. O propoziție răspunde la unele și le lasă pe altele goale („Ion îi dă Anei o carte" nu spune *când*). Lucrul pe care îl descrie o propoziție (o livrare, o oră de curs, o predare a unei cărți) îl vom numi *eveniment*; cuvântul nu înseamnă nimic mai mult decât „ce s-a întâmplat, în propoziția asta". Lumea trăiește în afara pilotului, de pildă într-o bază de date: ea știe că Alfa e un furnizor și că raionul B există. Pilotul nu știe nimic din toate astea. O lume are lucrurile ei: legenda, felurile cuvintelor, carnetul de rute învățat pe propozițiile ei și baza de date; capitolul 5 le ia pe rând. În restul documentului folosim evidența de împrumuturi ca exemplu principal, pentru că e cea mai mică.

Pilotul. Un străin. Gândește-l ca pe un cartograf venit de foarte departe, care nu înțelege o iotă din limba noastră: nu știe cine e Ion, ce e o carte, dacă Ion chiar i-a dat-o Anei, și n-are cum să afle, pentru că nu pune niciodată piciorul în lume. Nu se mișcă; stă la *bază*, în afara cerului, și comandă sonda. Ce știe, și știe foarte bine, e un singur meșteșug, învățat din mii de propoziții: să recunoască *felul* unui cuvânt (nume de persoană, verb, prepoziție…) și să știe ce salt cere felul acela. Rostul lui e unul singur: să transforme fiecare propoziție într-o hartă a cerului pe care lumea o poate citi, adică să afle, pentru fiecare cuvânt, în ce *domeniu* al cerului trebuie să ajungă, fără să înțeleagă ce înseamnă cuvântul. Că nu înțelege nu e un neajuns al poveștii; e chiar ce vrem să arătăm: se poate ajunge la sens fără nicio cunoștință despre lume, doar din forma drumului. Pilotul ține trei documente, și toată povestea e despre ele:

- *Carnetul de rute*: ce salt cere fiecare fel de cuvânt (nume de persoană, verb, prepoziție…). E singurul lucru pe care pilotul l-a învățat vreodată, și singurul pe care îl va învăța.
- *Legenda*: lista de întrebări a lumii, cu câte o *stea cu nume* lângă fiecare întrebare. Pentru evidența de împrumuturi: „cine dă?" are *steaua agentului*; „ce?" are *steaua obiectului*; „cui?" are *steaua destinatarului*. Pentru depozit: steaua furnizorului, a

mărfii, a cantității, a locului, a momentului. Fiecare întrebare e un *rol*, iar steaua ei definește un *domeniu* al cerului, domeniul agentului, domeniul cantității, în care trebuie să ajungă cuvântul care răspunde la întrebare (ce e exact un domeniu, în 2.6). Cuvântul „domeniu" înseamnă în această carte numai asta; pentru un domeniu de cunoaștere sau de activitate spunem „lume". Stelele cu nume sunt trase la sorți o singură dată de cel care construiește lumea; nu le învață nimeni. Legenda e mică: câteva zeci de stele pentru un domeniu întreg de activitate. (De obicei are și o stea pentru acțiunea însăși, „dat" sau „împrumutat"; capitolul 8 spune de ce e nevoie de ea.)

- *Harta propoziției*: documentul pe care pilotul îl *construiește* în timp ce citește, cuvânt cu cuvânt, și care la sfârșit e *sensul* propoziției. O hartă a cerului, goală la început; la fiecare cuvânt pilotul desenează pe ea o stea: steaua cuvântului, mutată cu coordonatele raportate de sondă. La sfârșit, harta e o *constelație*; pilotul o citește prin legendă și începe una nouă.

Sensul unei propoziții e deci un lucru foarte concret: *ce cuvinte au ajuns în ce domenii*. Numele domeniilor vin din legendă (de la lume), drumul vine din carnet (învățat), iar „cine a ajuns unde" vine de pe hartă (construită la citire). Nimic nu se aprinde vreodată în cer; tot ce rămâne e pe hârtie, la bază.

Restul capitolului descrie piesele în ordinea în care sunt folosite: coordonatele unui punct, saltul sondei, steaua unui cuvânt, harta și constelația, legenda și domeniile, și scanerul cu care se citește harta.

1.3 Unde suntem

Documentul acesta descrie un sistem construit și măsurat, pe lumi construite și pe un set real de întrebări, și o direcție care merge mult mai departe decât ce e măsurat. Spunem o singură dată, aici, cum stau lucrurile, ca restul să poată fi citit fără o rezervă la fiecare paragraf.

Semnalele sunt bune, și sunt de felul care contează. Formulări diferite ale aceluiași eveniment ajung la același cadru. Sistemul compune corect la o adâncime pe care n-a văzut-o la antrenare, acolo unde o rețea neuronală cu aceeași intrare ghicește. Cuvinte noi se citesc fără reantrenare. Pe întrebări reale tastate de oameni, cu aceeași intrare și fără cunoaștere externă, învață structura mai bine decât un transformer mic și decât o metodă lexicală, la toate mărimile de date, de la o mie de exemple în sus. Operatorii logici, cu scopul lor, se citesc fără reguli scrise de mână. Și ce n-a fost înțeles se vede pe hartă, în loc să fie acoperit de un răspuns fluent. Niciunul dintre aceste rezultate n-a cerut un model mare: antrenarea durează minute pe un singur accelerator mic, iar citirea rulează pe un procesor obișnuit.

Ce rămâne e, în cea mai mare parte, inginerie și ajustări ale modelului; câteva extensii (ordinea operatorilor, deosebirea dintre mulțime și alternativă) cer alegeri de reprezentare, descrise la locul lor; niciuna nu e o barieră cunoscută. Fiecare piesă care nu e încă la locul ei are un mecanism precis, descris în capitolul ei, și o măsurătoare cu criteriul scris dinainte. Cât de departe se ajunge ține de efort, iar efortul e incremental: fiecare pas adaugă un domeniu, o legendă sau o măsurătoare, fără să schimbe ce e dedesubt. De aceea

capitolele care urmează explică *de ce* un asemenea sistem e util și *cum* se construiește, și nu țin socoteala măsurătorilor. Socoteala e ținută într-un singur fișier, la zi, cu criteriile și jurnalele fiecărui experiment, în depozitul proiectului:

https://github.com/ml-circuits-research/vsa-semantic-space/blob/main/STATUS.md

Convenția cărții e simplă: ea descrie arhitectura și direcția, inclusiv capabilități propuse, și spune local când o aplicație e proiect („ar putea", „ne imaginăm"); fișierul spune, la orice moment, ce e construit, ce e în lucru și ce e doar direcție. Când cele două diferă, fișierul are dreptate.

2. Cerul, sonda și pilotul

2.1 Un punct din cer: coordonate cu mii de rotițe

Coordonatele unui punct sunt un *cod*, ca la un lacăt cu cifru: un șir de rotițe, câteva mii, fiecare putând fi întoarsă oriunde pe cercul ei, de la 0 la 360 de grade. O poziție anume a tuturor rotițelor deodată e un punct din cer. Altă poziție e alt punct.

Ca să putem scrie exemple, să ne prefacem că sunt doar patru rotițe. Atunci un punct arată așa: (10°, 200°, 95°, 300°). Altul: (12°, 198°, 97°, 301°). Al treilea: (180°, 20°, 275°, 120°).

Două puncte sunt *aproape* când, rotiță cu rotiță, arată cam la fel: primele două de mai sus sunt aproape. Sunt *fără legătură* când rotițele nu se potrivesc: al treilea n-are nimic comun cu primele două. Asta e toată geometria cerului: nu distanțe în ani-lumină, ci acord sau dezacord între rotițe, numărat pe mii de rotițe. Între două puncte există, totuși, puncte intermediare, și vom avea nevoie de ele: un punct ale cărui rotițe stau la jumătate între ale celor două e pe jumătate aproape de fiecare.

Și încă ceva, ca să nu rămână nicio îndoială: cerul e gol. Nu există nimic în el de la sine, nici lume, nici cuvinte, nici drumuri bătute. Există doar puncte, iar un punct e un cod. Stelele sunt puncte pe care cineva le-a notat undeva, în catalog, în legendă sau pe o hartă; cerul însuși nu ține minte nimic.

2.2 De ce două puncte alese la întâmplare n-au nicio legătură

Aici e proprietatea pe care se sprijină tot restul. Întoarce toate rotițele la întâmplare, de două ori, și compară cele două coduri. La o rotiță anume, se potrivesc din întâmplare; la alta, nu; potrivirile și nepotrivirile se anulează. Peste mii de rotițe, acordul total e aproape exact zero. Două puncte alese la întâmplare sunt, cu o certitudine practică, *fără nicio legătură*: nu cele mai depărtate cu putință (asta ar însemna fiecare rotiță întoarsă exact invers), ci pur și simplu fără niciun acord care să conteze. Iar șansa ca două coduri aleatoare să semene vizibil scade exponențial cu numărul de rotițe; la mii de rotițe e, practic, zero.

Consecința: cerul are loc pentru un număr enorm de stele care nu se deranjează una pe alta. Orice primește coordonate alese la întâmplare e, cu aceeași certitudine practică, deosebit de orice altceva a primit unele. Aleatorul nu e o slăbiciune pe care o tolerăm; e sursa separării.

2.3 Sonda: o singură operație

Sonda are o singură operație, și e aceeași pe care o va folosi și pilotul la bază: *a muta un punct cu un cod*. Iei coordonatele punctului și un al doilea cod; pentru fiecare rotiță, întorci rotița punctului cu unghiul rotiței corespunzătoare din cod. Rezultatul e alt punct. Atât.

Saltul e această operație aplicată poziției sondei. O *cheie* e un cod: „rotița 1: +100°; rotița 2: +30°; rotița 3: +300°; rotița 4: +45°". Pilotul trimite cheia, sonda își mută poziția cu ea și e în alt punct al cerului. Era la (10°, 200°, 95°, 300°); acum e la (110°, 230°, 35°, 345°); rotița a treia a trecut de 360 și a luat-o de la capăt: 95 + 300 = 395, adică 35. Apoi sonda raportează noua poziție la bază. Cu cheia inversă (fiecare unghi cu minus) se întoarce exact de unde a plecat.

Trei proprietăți ale mutării, toate vizibile în exemplu, și toate folosite mai jos:

- *Mutarea păstrează forma.* Dacă două puncte erau aproape unul de altul și le muți pe amândouă cu același cod, rămân exact la fel de aproape, pentru că fiecare rotiță s-a întors cu același unghi la amândouă. O constelație întreagă, mutată, își păstrează desenul.
- *Mutarea se desface.* Muți înapoi cu codul invers și ai punctul de dinainte, fără pierdere. Orice șir de salturi se poate desface pas cu pas.
- *Punctul de după n-are legătură cu punctul de dinainte.* O cheie întoarce fiecare rotiță cu alt unghi, tras la sorți; deci punctul de plecare și cel de sosire sunt, pentru oricine se uită, două puncte aleatoare. Drumul înapoi există doar pentru cine are cheia.

Două chei una după alta sunt tot o cheie: unghiurile se adună, rotiță cu rotiță. De aici o consecință care e și comodă, și o limitare reală: *ordinea nu contează*. Cheia A apoi cheia B duce sonda exact unde o duce B apoi A, pentru că 100° + 30° e același lucru cu 30° + 100°. Poziția sondei ține minte *ce* chei s-au folosit de la origine, nu *în ce ordine*. Ne întoarcem la asta în capitolul 8.

Reținem: mutarea unui punct cu un cod se numește, în limbaj tehnic, *a lega* (bind). Saltul e mutarea poziției cu o cheie. Piesa următoare e aceeași operație, folosită de pilot pe stele.

2.4 Steaua unui cuvânt

Fiecare cuvânt are, la bază, o *stea a lui*: coordonate trase la sorți o singură dată, când cuvântul apare prima oară, și niciodată schimbate, niciodată învățate. „Ion" are steaua lui, să zicem (50°, 50°, 50°, 50°) în exemplul nostru cu patru rotițe; „carte" are alta, (300°, 120°, 40°, 210°). N-au nimic în comun și nu vor avea niciodată. Toate stelele cuvintelor stau într-un *catalog*, la bază.

Steaua nu spune nimic despre ce înseamnă cuvântul; îl face doar recognoscibil oriunde ar fi mutat, pentru că forma unei stele mutate se păstrează și mutarea se desface. Aici e deja o diferență față de orice e neuronal. Un model de limbaj își învață vectorii de cuvinte încet, din miliarde de exemple, iar un cuvânt nevăzut e descompus în bucăți și primește un vector ghicit din bucățile lui. Aici, un cuvânt nevăzut primește pe loc o stea nouă, la fel de bună ca oricare alta. Nimic din sistem nu depinde de ce coordonate a primit un cuvânt.

2.5 Harta propoziției: cum se desenează o constelație

Sonda tocmai a raportat poziția (110°, 230°, 35°, 345°), și cuvântul citit e „Ion”. Pilotul ia steaua lui Ion din catalog și o *mută* cu poziția raportată: aceeași operație ca la salt, doar că acum cel mutat e cuvântul, iar codul cu care se mută e poziția sondei. Ion, (50°, 50°, 50°, 50°), devine (160°, 280°, 85°, 35°) (ultima rotiță: 50 + 345 = 395, adică 35). Aceasta e o stea nouă, „Ion mutat cu poziția sondei”, și pilotul o desenează pe hartă. Nu mai arată deloc ca steaua lui Ion din catalog; dar oricine știe poziția sondei poate muta înapoi și obține (50°, 50°, 50°, 50°) exact. Așa spunem, în această poveste, „Ion a fost găsit acolo unde era sonda”.

Harta nu e o listă de stele desenate una lângă alta. E un singur cod, în care stelele sunt *topite*: pentru fiecare rotiță, iei unghiul de pe hartă și unghiul stelei noi, le desenezi ca două săgeți pe un cerc, le pui cap la cap și păstrezi săgeata rezultată, cu lungimea ei cu tot. Faci asta rotiță cu rotiță. Harta ține deci, pe fiecare rotiță, o săgeată care poate fi mai lungă sau mai scurtă; când compari două hărți sau cauți o stea în ele, contează direcțiile, acordul rotiță cu rotiță, nu lungimile. Harta rezultată seamănă parțial cu fiecare stea topită în ea și cu nimic altceva. Numim ce rezultă *constelația* propoziției, iar harta, documentul care o ține, e o *hologramă*: toate stelele sunt în ea deodată, suprapuse. Îi poți pune întrebări („conții steaua lui Ion mutată cu cutare poziție?”) și răspunde clar da sau nu, dar nu-ți poate *enumera* stelele; din suma săgeților nu recuperezi săgețile, poți doar să testezi candidați.

Două lucruri despre hartă trebuie reținute de la început.

Întâi: o stea desenată rămâne mutată cu poziția *din clipa aceea*. Sonda poate sări mai departe oriunde; steaua lui Ion de pe hartă nu se mai mișcă. Fiecare cuvânt poartă poziția sondei din momentul citirii lui, nu poziția de la sfârșitul propoziției.

Al doilea: harta are o capacitate. Cu cât topești mai multe stele, cu atât fiecare e mai greu de recunoscut, pentru că săgețile lor trag în direcții diferite. Cu câteva mii de rotițe, zeci de stele stau curat într-o constelație; sutele încep să se amestece; mai departe, harta alunecă spre o direcție mijlocie care nu seamănă cu nimic. E singura limită dură a poveștii, și motivul pentru care textele lungi vor fi mai multe hărți legate între ele, nu una singură.

2.6 Legenda și domeniile

Acum putem spune concret ce e legenda, pe exemplul evidenței de împrumuturi. Lumea pune trei întrebări: cine dă (agentul), ce (obiectul), cui (destinatarul). Cel care construiește lumea trage la sorți, o singură dată, câte o stea pentru fiecare întrebare: *steaua agentului*, *steaua obiectului*, *steaua destinatarului*. Trei puncte aleatoare din cer, fixe pentru totdeauna, fără nicio legătură între ele.

O stea cu nume definește un *domeniu* al cerului. Domeniul agentului e mulțimea tuturor stelelor pe care le obții mutând o stea de cuvânt cu coordonatele stelei agentului: steaua lui Ion mutată cu steaua agentului, steaua lui Petre mutată cu steaua agentului, și așa mai departe, câte una pentru fiecare cuvânt din catalog. E, dacă vrei, o copie întreagă a catalogului, mutată într-o altă parte a cerului, cu forma păstrată. Domeniul obiectului e altă copie, mutată cu steaua obiectului; domeniul destinatarului, a treia. Pentru că stelele cu

nume sunt aleatoare, cele trei domenii n-au nimic în comun și nu se confundă, cu aceeași certitudine practică din 2.2, deși fiecare conține toate cuvintele.

„Ion e în domeniul agentului" înseamnă deci exact: pe hartă e desenată steaua lui Ion mutată cu steaua agentului. Iar ca să fie așa, sonda trebuie să fi fost *la steaua agentului* când a fost citit „Ion": mutarea cu poziția sondei (2.5) și mutarea cu steaua agentului sunt atunci același lucru. Ca să verifici cine e în domeniul agentului, muți harta înapoi cu steaua agentului și te uiți ce stea din catalog a reapărut.

Același lucru pentru depozit, doar cu alte stele cu nume: a furnizorului, a mărfii, a cantității, a locului, a momentului. „Furnizorul Alfa a livrat 40 de cutii la raionul B marți" ar trebui să ajungă pe hartă cu „Alfa" în domeniul furnizorului, „cutii" în domeniul mărfii, „40" în domeniul cantității, „raionul B" în domeniul locului și „marți" în domeniul momentului. Dacă propoziția n-ar fi spus „marți", domeniul momentului ar fi rămas gol pe hartă, și asta se vede, cum arată capitolul 7.

Legenda e minusculă, stă la bază, și e singurul lucru pe care lumea și pilotul îl au în comun. Lumea o folosește ca să deseneze constelația corectă a unei propoziții („Ion în domeniul agentului, carte în domeniul obiectului, Ana în domeniul destinatarului"). Pilotul o folosește ca să-și citească propria hartă. Nimic altceva nu e comun: pilotul nu știe faptele lumii, iar lumea nu știe cum sare sonda.

2.7 Scanerul: cum se citește harta

Vrei să știi cine e în domeniul agentului. Pilotul mută întreaga hartă înapoi cu steaua agentului. Ce fusese în domeniul agentului se întoarce la steaua lui din catalog, recognoscibilă. Ce fusese în alte domenii e mutat acum cu un cod care nu era al lui și ajunge într-un punct fără legătură, adică zgomot. Rezultatul nu e un răspuns curat, ci un cod zgomotos: steaua lui „Ion", plus zgomot de la „carte" și „Ana".

Codul acesta intră în *scaner*. Scanerul îl compară cu fiecare stea din catalog și raportează pe cea mai apropiată, împreună cu două numere: cât de aproape e, și cu cât e în fața următoarei. Pentru că stelele cuvintelor sunt aleatoare și n-au legătură între ele, aproape întotdeauna una singură iese în evidență, iar restul stau la nivelul zgomotului: „Ion". Când niciuna nu iese în evidență, sau două ies la fel, asta e o informație în sine, pe care o vom folosi.

(În exemplul cu patru rotițe scanerul n-ar funcționa: patru rotițe nu ajung ca zgomotul să se anuleze. Cu mii de rotițe, rata de eroare scade exponențial cu numărul lor și depinde de câte stele sunt topite în hartă și de mărimea catalogului; capitolul 8 spune unde apare limita. De asta sunt mii.)

Cu atât e descrisă povestea: un cer în care un punct e doar coordonate, o sondă care sare și raportează, și un pilot cu un catalog de stele ale cuvintelor, o hartă pe care desenează constelația propoziției, o legendă cu stelele cu nume ale lumii și un scaner. Tot ce urmează e construit doar din acestea.

3. Citirea unei propoziții

3.1 Pasul

Carnetul de rute al pilotului are câte o cheie pentru fiecare *fel* de cuvânt (nume de persoană, verb, prepoziție, articol…). Acestea sunt cheile pe care pilotul le-a învățat, și singurele lucruri pe care le-a învățat. Legenda nu e în carnet; e folosită doar la citirea hărții, la sfârșit.

La fiecare cuvânt, pilotul face același lucru, identic:

1. Se uită ce fel de cuvânt e, ia din carnet cheia felului aceluia și o trimite sondei. Sonda sare și raportează poziția. Poziția e, în fiecare clipă, suma tuturor cheilor trimise de la începutul propoziției.
2. Ia steaua cuvântului din catalog, o mută cu poziția raportată și o topește în harta propoziției.

Atât. Harta de la sfârșit e *starea* propoziției: constelația ei. Nu păstrează lista cuvintelor, nici ordinea lor, nici vreun arbore gramatical. Doar stelele cuvintelor, fiecare mutată cu poziția la care era sonda când a fost citit cuvântul.

Toată partea învățată e carnetul: o cheie pe fel de cuvânt, câteva sute cu totul. Stelele cuvintelor, adică grosul vocabularului, nu se ating niciodată. Iar scopul învățării, pe care îl detaliem în capitolul 6, e unul singur: ca salturile dictate de carnet să aducă sonda, în clipa în care un cuvânt e citit, exact la steaua cu nume pe care legenda o cere pentru cuvântul acela, adică să-l așeze în domeniul lui.

3.2 Ce înseamnă că două propoziții „ajung în același loc”

Ia „Ion îi dă Anei o carte”. Pilotul trimite cheia pentru nume, apoi cheia pentru „îi”, apoi cheia pentru „dă”, apoi iar cheia pentru nume, apoi pentru articol, apoi pentru substantiv. Pe drum a desenat „Ion” mutat cu poziția de după primul salt, „Anei” cu cea de după al patrulea, „carte” cu cea de după al șaselea. Fiecare stea de pe hartă poartă punctul în care era sonda în acel moment.

Acum „Ana primește o carte de la Ion”. Alte cuvinte, alte chei, alt traseu. Dar dacă carnetul e învățat bine, „Ion” e desenat după un șir de salturi (primește, o, carte, de, la, nume) care aduce sonda exact la *steaua agentului*, adică în același punct în care era și când a citit „Ion” în prima propoziție. „Ana” ajunge în domeniul destinatarului, „carte” în domeniul obiectului.

Două propoziții înseamnă același lucru când desenează aceeași constelație: aceleași stele de cuvinte, în aceleași domenii. Traseul nu contează. Trei lucruri trebuie ținute separate aici. Hărțile, ca desene, nu sunt identice: cuvintele de legătură și drumurile diferite lasă urme diferite, și hărțile sunt doar *asemănătoare*; asemănarea asta e ce folosește antrenarea. Cadrele citite din ele, domeniu cu domeniu, sunt *egale*: aceleași stele în aceleași domenii. „Același sens” înseamnă al doilea lucru, și așa se măsoară: compari cele două hărți prin legendă, domeniu cu domeniu.

3.3 Citirea hărții: cadrul

Vrei să știi cine e agentul. Pilotul mută harta înapoi cu steaua agentului și dă rezultatul scanerului: „Ion”. Face asta pentru fiecare stea cu nume din legendă și are *cadrul*: agent Ion, obiect carte, destinatar Ana. Cadrul nu e calculat din hartă printr-un alt program; el *este* harta, citită prin legendă.

Cu fiecare răspuns vin cele două numere ale scanerului: cât de bine se potrivește câștigătorul, și cât de departe în urmă e al doilea. Diferența e *marja*. Marjă mare: un singur cuvânt a fost găsit în domeniul acela. Marjă mică: au fost găsite două, sau unul a fost desenat de la un punct aflat între două stele cu nume, deci e pe jumătate în două domenii. Marja e locul unde trăiește „nu sunt sigur”.

3.4 Propoziții în propoziții: legenda e relativă

„Maria spune că Ion îi dă Anei o carte.” Evidența noastră are în legendă și întrebări pentru relatări: *cine spune?* (vorbitorul) și *ce spune?*. Dar ce spune Maria nu e un cuvânt, e o propoziție întreagă, cu agentul, obiectul și destinatarul ei. Dacă pilotul l-ar desena pe „Ion” în domeniul agentului, n-am mai ști dacă Ion e agentul din propoziția mare sau din cea relatată. Trebuie un set separat de domenii pentru propoziția din interior, care să aibă totuși *aceleași nume*.

Soluția e tot o stea. Legenda are, pe lângă steaua vorbitorului, o stea pentru rolul „ce spune”: steaua *relatat*. Și aici e de văzut că stelele cu nume nu sunt, de fapt, puncte absolute, ci *deplasări față de originea propoziției*: „steaua agentului e la +cheia agentului față de origine”. Pentru propoziția relatată, originea e alta: e punctul în care ajunge sonda sărind cu steaua relatat. Steaua agentului *a propoziției relatate* e „origine + relatat + agent”: un punct nou, fără legătură cu steaua agentului din propoziția mare, și totuși cu același nume în legendă, citit de la altă origine. Toată constelația legendei se mută deodată, cu forma păstrată, pentru că mutarea păstrează forma.

Pilotul a învățat că felul de cuvânt „că” cere exact saltul relatat. De acolo, citește propoziția interioară cu aceleași chei din carnet ca de obicei. „Ion” e desenat în domeniul agentului de la originea relatată. Maria a rămas în domeniul vorbitorului, față de originea mare.

Ca să citească agentul interior, pilotul desface drumul: mută harta înapoi cu steaua relatat (se întoarce la originea propoziției mari), apoi cu steaua agentului, apoi scanerul: „Ion”. Două propoziții una în alta („Maria spune că Dan crede că Ion…”): desface două salturi relatat. Adâncimea imbricării e, literal, numărul de origini mutate; îi spunem *nivel*.

Și de aici vine un lucru pe care l-am măsurat: pentru că „mută originea” e aceeași cheie de fiecare dată, un pilot antrenat pe propoziții cu cel mult două niveluri citește corect o propoziție cu trei, fără nicio învățare nouă. E același salt, făcut încă o dată. Antrenat până la două niveluri, a citit trei fără greșeală, în timp ce o rețea neuronală antrenată pe aceleași propoziții, cu aceeași intrare, a ghicit la întâmplare la nivelul trei. Nimic special n-a fost construit pentru asta: fiecare nivel e legenda întreagă, citită de la o altă origine, și originile se pot muta de oricâte ori, pentru că o cheie poate fi folosită de oricâte ori și desfăcută de tot atâtea.

3.5 Balizele de pe hartă: cum știe un cuvânt în ce domeniu să meargă

Pasul din 3.1, în care cheia unui cuvânt depinde doar de felul lui, are o slăbiciune pe care o vezi imediat. „Ion dă…” și „Ion primește…” încep cu același cuvânt, de același fel, deci cu același salt. Dar Ion e agent în prima și destinatar în a doua. Când pilotul îl desenează pe Ion, după primul salt, nu are de unde să știe în ce domeniu trebuie să ajungă; ce urmează nu s-a citit încă.

Ce se întâmplă în practică: cheia învățată pentru nume ajunge la un compromis, un punct la jumătatea drumului între steaua agentului și steaua destinatarului. Propoziția se citește totuși corect, pentru că atunci când întrebi „cine e agentul?”, Ion e *cam pe jumătate* acolo (cât anume depinde de cum se măsoară apropierea), iar nimeni altcineva nu e deloc. Dar marja e subțire, și cu câteva asemenea compromisuri într-o propoziție citirea se tulbură.

Versiunea completă a pilotului rezolvă asta cu două obiceiuri în plus, tot fără să știe nimic despre lume.

Primul: unele cuvinte pun balize pe hartă. Luăm verbul ca exemplu pentru că e cel mai ușor de urmărit; care cuvinte pun balize de fapt se învață, și rezultatul e spus câteva paragrafe mai jos. Când pilotul ajunge la „dă”, cuvântul anunță: „după mine urmează un obiect și un destinatar”. Pilotul notează pe hartă două *balize*: „obiectul va fi la poziția raportată acum + cheia relativă pentru obiect”, „destinatarul la poziția de acum + cheia relativă pentru destinatar”. Cheile relative sunt și ele învățate, pe fel de cuvânt, și stau în același carnet. Un cuvânt care sosește mai târziu se uită dacă există o baliză pentru felul lui; dacă da, steaua lui e mutată cu *poziția balizei*, nu cu poziția raportată de sondă. Balizele sunt semne pe hartă, nu lumini aprinse în cer, și se șterg la sfârșitul propoziției.

Al doilea: un cuvânt sosit prea devreme e ținut deoparte. „Ion” de la începutul propoziției nu are încă nicio baliză care să-l aștepte. Pilotul nu-l desenează; îl ține deoparte, și merge mai departe. Când ajunge la „dă” și apare baliza „urmează un agent”, Ion de deoparte e primul care i se potrivește, și e desenat atunci, mutat cu poziția balizei, adică în domeniul cuvenit. Așa primește primul cuvânt domeniul lui, deși rolul lui se vede abia mai târziu.

Ce feluri de cuvinte au voie să pună balize nu decidem noi. Fiecare fel de cuvânt are, în carnet, pe lângă cheie, o *poartă*: un număr între zero (nu pune niciodată) și unu (pune mereu), învățat din același obiectiv ca tot restul. Noi am fi pus pe unu verbele și prepozițiile. Pilotul a ales altfel, singur: cuvintele care marchează o relație („lui”, „de la”, „de”, „că”, o virgulă) au porțile deschise; numele le au închise; verbele, surprinzător, tot închise. Explicația, odată văzută, e simplă: dacă cuvintele ținute deoparte pot fi așezate de ce urmează, prepoziția spune deja tot ce ar spune verbul. Aceeași alegere a reapărut, fără s-o cerem, când am antrenat pilotul pe întrebări reale tastate de oameni despre tabele. Structura „cine deschide un cadru” e, în acest sistem, un rezultat, nu o intrare.

3.6 Trei desene pentru același cuvânt

Avem acum două feluri de a afla cu ce poziție se mută steaua unui cuvânt: poziția balizei (precisă, dar fragilă: dacă o construcție e nouă și o baliză lipsește, cuvântul rămâne deoparte sau e desenat greșit) și poziția raportată de sondă, adică suma cheilor generice

ale cuvintelor de dinainte (robustă, dar neclară, cum am văzut cu Ion). Mai există un al treilea, mai grosolan: o poziție care depinde doar de *felul cuvântului anterior* („după o prepoziție, nume"), aproape niciodată greșită și aproape niciodată precisă.

Pentru că topirea în hartă e ieftină, pilotul nu alege între ele. Desenează steaua cuvântului de *trei ori*, mutată cu cele trei poziții, și topește toate cele trei copii în aceeași hartă. Când propoziția are o formă familiară, cele trei poziții sunt același punct și desenul e net. Când propoziția folosește o construcție nemaivăzută, una din poziții e aiurea, dar celelalte două tot aduc steaua destul de aproape de domeniul ei ca scanerul s-o recunoască. O cheie învățată greșit nu mai distruge citirea; doar o încețoșează. Pe construcții noi, redundanța asta a ridicat citirea corectă de la șase din zece la nouă din zece.

Cu asta, pilotul e complet: un carnet cu o cheie pe fel de cuvânt, chei relative pentru balize, o poartă pe fel, și pasul din 3.1, repetat identic la fiecare cuvânt, cu trei desene. Tot ce urmează e despre cum ajunge carnetul să fie bun, și ce poți face cu harta de la sfârșit.

4. De ce două propoziții de lungimi diferite pot însemna același lucru

„Ion îi dă Anei o carte" are șase cuvinte. „Ana primește o carte de la Ion" are șapte. „Cartea i-a fost dată Anei de către Ion" are opt. Un cititor care numără cuvinte, sau care ține minte ordinea lor, le vede ca trei lucruri diferite. Pilotul le vede ca unul singur. Capitolul acesta spune de ce, pas cu pas, pentru că aici se vede cel mai clar ce e și ce nu e harta.

Lungimea e o proprietate a drumului, nu a hărții

Sonda face câte un salt pe cuvânt: șase salturi pentru prima propoziție, șapte pentru a doua. Drumurile au lungimi diferite. Dar harta nu înregistrează drumul; înregistrează *unde era sonda când a fost citit fiecare cuvânt*. Pe hartă nu există „al treilea cuvânt" sau „după șase salturi". Există steaua lui Ion mutată cu steaua agentului, și atât. Dacă două drumuri de lungimi diferite aduc sonda la steaua agentului în clipa în care e citit „Ion", cele două hărți au exact aceeași stea în același loc, și nimic pe hartă nu mai spune cât de lung a fost drumul până acolo.

Asta nu e un accident, e o alegere. Niciuna dintre cele trei poziții cu care pilotul ștampilează un cuvânt (3.6) nu conține numărul de ordine al cuvântului în propoziție: poziția sondei e suma cheilor de dinainte, baliza e o deplasare față de cuvântul care a deschis cadrul, iar a treia depinde doar de felul cuvântului anterior. Am încercat la un moment dat și o poziție care conținea numărul de ordine; ea lega citirea de lungime și de ordine, adică exact de ce schimbă parafrazele, și am lăsat-o deoparte (capitolul 15 spune ce rămâne de măsurat acolo).

Cuvintele de legătură mută sonda, dar nu intră în cadru

„Îi", „o", „de", „la", „către" sunt și ele cuvinte, și pilotul le tratează ca pe oricare: fiecare are o cheie, sonda sare, steaua cuvântului e desenată pe hartă acolo unde a ajuns. Dar punctele în care ajung nu sunt stele cu nume. Când pilotul citește harta prin legendă, întreabă doar domeniile cu nume; steaua lui „de" stă într-un punct fără legătură cu oricare dintre ele și nu răspunde la nicio întrebare. Cuvintele de legătură sunt schelăria drumului: fără ele sonda n-

ar ajunge unde trebuie, dar odată ajunsă, ele nu mai contează. O propoziție cu mai multe cuvinte de legătură are mai multă schelărie pe hartă, în puncte fără nume, și același cadru.

De aceea și comparăm hărțile *domeniu cu domeniu*, nu ca pe două desene suprapuse. Două hărți ale aceluiași eveniment nu sunt identice punct cu punct, pentru că schelăria diferă; sunt identice acolo unde contează, în răspunsurile la întrebările legendei.

Cuvinte diferite, aceeași destinație

Rămâne întrebarea grea: de ce „dă” și „primește … de la” aduc sonda în aceleași stele cu nume, când sunt cuvinte diferite, cu chei diferite? Pentru că așa a fost învățat carnetul. La antrenare, cele două propoziții au primit aceeași constelație a lumii (6.1), iar singura libertate a pilotului era carnetul. Ca să satisfacă amândouă, a trebuit să găsească chei sub care „nume, dă, nume” și „nume, primește, …, de, la, nume” aduc numele la aceleași stele. Balizele fac asta posibil fără contorsiuni: în exemplul nostru „dă” pune balize pentru obiect și destinatar față de locul lui, iar „de la” pune o baliză pentru agent față de locul ei. (În carnetul învățat, balizele le pun mai ales cuvintele de relație, „îi”, „de la”, nu verbul; unde verbul tace, celelalte două desene din 3.6 aduc cuvântul la locul lui.) Cuvântul care urmează ia baliza, oriunde ar fi în propoziție. Lungimea dintre „de la” și „Ion” nu contează, pentru că baliza e o destinație, nu un număr de pași.

Verbele diferite, „dă” și „primește”, ajung și ele pe hartă, în domeniul predicatului (un domeniu al legendei complete; primele lumi măsurate nu-l aveau, cum spune capitolul 13). Dacă ele contează ca același eveniment sau ca două evenimente diferite nu decide pilotul, ci legenda lumii, care spune ce verbe descriu același eveniment (8, „Care verb?”). Pilotul doar le desenează consecvent.

Un exemplu urmărit, și unul care nu se potrivește

„Ion îi dă Anei o carte”: sonda pleacă din origine; la „Ion” pilotul îl ține deoparte (niciun cadru deschis încă); „îi” și „dă” deschid balize pentru agent, destinatar și obiect; Ion ia baliza agentului, „Anei” pe a destinatarului, „carte” pe a obiectului; „o” rămâne în schelărie. Harta: Ion în domeniul agentului, carte în al obiectului, Ana în al destinatarului, „dă” în al predicatului.

„Ana primește o carte de la Ion”: „Ana” ținută deoparte; „primește” (în exemplul nostru) deschide balize; Ana ia baliza destinatarului (pentru „primește”, cine primește e destinatarul, și asta e tot în carnet); „carte” ia obiectul; „de la” deschide baliza agentului; „Ion” o ia. Harta: Ion în domeniul agentului, carte în al obiectului, Ana în al destinatarului, „primește” în al predicatului. Șapte cuvinte, același cadru, cu excepția predicatului, pe care legenda îl declară același eveniment.

Acum „Ana primește marți o carte de la Ion”. Opt cuvinte, și o stea în plus: „marți” în domeniul momentului. Cele două hărți *nu* mai spun același lucru, și diferența e localizată exact: același răspuns la cine, ce, cui, un răspuns în plus la când. E al treilea fel de „aproape” din capitolul 8, și e tot ce înseamnă „mai lung” când lungimea aduce informație: un domeniu în plus umplut, nu o hartă mai mare.

Când lungimea chiar contează, și ce face harta atunci

Două cuvinte în loc de unul într-un domeniu („Ion și Petre”): domeniul e aglomerat, cu două stele, și asta e sensul corect, nu o eroare. Un cuvânt lipsă („Ion dă o carte”, fără destinatar): un domeniu rămâne gol, și asta e, iar, sensul corect, cu golul la vedere. O repetiție de întărire („foarte, foarte târziu”) desenează aceeași stea de două ori în același loc, ceea ce o face puțin mai puternică și nu schimbă cadrul; dacă o lume vrea să deosebească „târziu” de „foarte târziu”, trebuie să aibă un domeniu pentru asta. Și limita cunoscută: când forma propoziției se dezvăluie abia la sfârșit („…, spune Maria”), lungimea de dinainte a fost deja desenată față de originea greșită; un cititor care merge înainte nu poate repara asta, cum spune capitolul 8.

Pe lumile construite, formulări diferite ale aceluiași eveniment, cu numere diferite de cuvinte și ordine diferite, au ajuns la același cadru, domeniu cu domeniu; e rezultatul din care a pornit tot documentul. Pe text real, semnalul vine de la întrebările despre tabele, unde întrebări de lungimi diferite au dus la aceeași coloană în opt cazuri din zece.

5. Același cuvânt în mai multe lumi: polisemie, domenii de cunoaștere, ontologii

Un cuvânt ca „bancă” înseamnă altceva într-un text despre finanțe și altceva într-unul despre un râu. „Energie” înseamnă altceva în fizică și în nutriție. „Câmp” înseamnă altceva în algebră, în agricultură și în fizică. Un cititor care are o singură stea pentru fiecare cuvânt pare să nu poată face față. Capitolul acesta spune cum stau lucrurile de fapt, și ce *nu* pretindem.

O precizare de vocabular înainte: în această carte, *domeniu* înseamnă regiunea unui rol (domeniul agentului, domeniul cantității). Pentru un domeniu de cunoaștere sau de activitate, finanțe, fizică, un depozit, spunem *lume*, pentru că așa am numit-o în capitolul 1: lucrul despre care vorbesc propozițiile, cu lista lui de întrebări.

Steaua e cuvântul, nu sensul

Steaua lui „bancă” e una singură, fixă, aceeași oriunde. Asta nu e o slăbiciune; e consecința definiției din 1.1. Sensul unei propoziții e „la ce întrebări răspunde, și cu ce”. Sensul unui *cuvânt*, în aceeași definiție, e „la ce întrebări răspunde, în lumea în care e citit”. În lumea finanțelor, „bancă” răspunde la întrebări ca „cine a acordat creditul?”; în lumea geografiei, la „unde s-a oprit barca?”. Aceeași stea, legende diferite, domenii diferite. Pilotul nu trebuie să decidă niciodată *ce fel de bancă* e; trebuie doar s-o așeze în domeniul potrivit al lumii în care lucrează. Ce e o bancă, în acea lume, știe baza de date, și e treaba ei.

Spus altfel: polisemia nu trăiește în stele, trăiește în legende. Două sensuri ale aceluiași cuvânt sunt două legende în care el răspunde la întrebări diferite. Asta e și motivul pentru care stelele pot rămâne aleatoare și fixe (capitolul 8): nu au nimic de învățat despre sens, pentru că sensul e în altă parte.

Ce nu rezolvă legenda singură e sensul dublu în *aceeași* lume și *același* domeniu: „pe bancă”, ca loc, poate fi banca din parc sau clădirea băncii, și dacă steaua și domeniul sunt aceleași, harta nu le deosebește. Acolo dezambiguizarea rămâne a contextului, a unui

identificator de sens în legendă sau a bazei de date. Legenda îngustează ambiguitatea; nu o elimină.

Când e ambiguu felul cuvântului

Există o ambiguitate care îl privește direct pe pilot: când același cuvânt poate fi de două *feluri*, cu două chei diferite. „Car” e substantiv sau verb; „cer”, la fel. Felul decide saltul, deci aici pilotul chiar trebuie să aleagă. Mecanismul pentru asta există deja, și e cel din 3.5: un cuvânt al cărui fel nu e încă limpede e ținut deoparte, sau desenat la jumătatea drumului între cele două poziții, până când o baliză pentru unul dintre feluri îl ia. „Cer” după „pe” ia baliza substantivului; „cer” după „eu” ia baliza verbului. Dacă nicio baliză nu vine, cuvântul rămâne desenat pe jumătate în două domenii, și harta raportează asta ca pe orice domeniu aglomerat: „nu știu dacă e lucru sau acțiune”. E același lucru pe care îl facem cu primul cuvânt dintr-o propoziție, al cărui rol nu se vede încă; ambiguitatea lexicală nu cere nimic nou.

Lumea e un obiect de prim rang

Întrebarea firească: dacă „bancă” înseamnă altceva în două lumi, n-ar trebui ca și *saltul* pe care îl face sonda la „bancă” să fie altul în fiecare lume? Da, și așa și este; merită spus limpede ce anume aparține lumii și ce nu.

Singurul lucru pe care îl împart toate lumile e cerul, cu stelele cuvintelor: steaua lui „bancă” e una, pentru că e identitatea cuvântului, nu a sensului. Tot restul e al lumii. O lume are *legenda* ei (ce întrebări pune, cu stelele lor cu nume); *felurile* ei de cuvinte (în lumea finanțelor „bancă” e de felul instituțiilor, în geografie de felul locurilor, iar felul decide cheia); *carnetul* ei de rute (cheile se învață pe propozițiile acelei lumi, deci saltul la „bancă” e altul în fiecare lume, pentru că felul e altul și carnetul e altul); *fondul* ei pentru rest (cum arată o propoziție înțeleasă acolo); și *baza* ei de date, unde stau faptele. Pilotul ține câte un carnet pentru fiecare lume în care lucrează. Lumea e, deci, un obiect de prim rang în poveste, nu un context vag: are nume, are piese, se antrenează separat și se poate schimba fără să atingă celelalte lumi. Când în limbaj obișnuit spunem „domeniu științific” sau „domeniu de antrenare”, în poveste spunem *lume*, și ea e cetățean cu drepturi depline.

Există și o a doua cale, pe care n-am construit-o: lumea însăși ca stea. Așa cum cheia „relatat” mută toată legenda la altă origine, o stea a lumii ar putea muta legenda finanțelor într-o parte a cerului și pe a geografiei în alta, cu un singur pilot și un singur carnet. Ar fi mai economic, dar ar cere ca felurile cuvintelor să fie împărțite între lumi, și tocmai acolo e polisemia; ar fi nevoie atunci de suprapunerea felurilor din secțiunea anterioară. E o direcție de cercetare cu un compromis clar: un carnet pe lume e simplu și izolează lumile; o stea a lumii e economică și le leagă.

Mai multe lumi deodată

Un sistem instalat într-o întreprindere are de obicei mai multe lumi: facturi, livrări, concedii. Fiecare are legenda și carnetul ei, cum am spus. O propoziție nouă e citită de toți piloții deodată; costă microsecunde fiecare. Apoi se compară hărțile: la pilotul lumii potrivite, domeniile se umplu cu marjă clară și reziduul e mic; la ceilalți, stelele cad în afara

legendei și reziduul e mare. Lumea unei propoziții se recunoaște după cât de bine se potrivește legenda ei, ca o cheie într-o broască. Nu e nevoie de un clasificator separat de „despre ce e textul”: potrivirea e clasificatorul, și vine cu aceleași numere, marjă și reziduu, ca orice altă citire.

Două limite, spuse deschis. Când două lumi au vocabular comun și întrebări asemănătoare, potrivirea e mai slabă, și cât de slabă se măsoară, pe lumi construite cu suprapunere controlată. Și când o singură propoziție amestecă lumi, cum face literatura, metafora, gluma, pilotul n-are ce potrivi: raportează reziduu mare în toate legendele, adică „nu e a niciunei lumi pe care o cunosc”. Nu e o promisiune pe care o facem; literatura nu e ținta.

Descoperim ontologii?

Nu, și e important să nu lăsăm impresia asta. O ontologie, în sensul folosit în informatică, e o listă de tipuri de lucruri și de relații între ele, cu nume. Legenda unei lumi *este* o ontologie mică, cu câteva zeci de rânduri, și e scrisă de oameni, nu descoperită. Felurile de cuvinte vin dintr-o grupare statistică a corpusului, pe care am verificat-o: coincid cu ce dă o metodă clasică, și nu le revendicăm. Ce emerge cu adevărat din antrenare e un singur lucru: care feluri de cuvinte deschid cadre (porțile), și asta e mai puțin decât o ontologie.

Ce facem, în schimb, e să *populăm* o ontologie dată: citirea unui corpus întreg produce o listă de cadre, adică fapte cu roluri, adică un graf de cunoștințe relativ la legendă: cine a livrat ce, cui, când, de câte ori. Toate stelele care au ajuns vreodată în domeniul furnizorului sunt, luate împreună, vocabularul acelei lumi pentru „furnizor”; nimeni nu l-a scris, a rezultat din citire. E un inventar, nu o teorie, dar e un inventar verificabil propoziție cu propoziție.

Și mai e un lucru, care ține de ontologie fără să fie descoperirea ei: harta poate semnala că *lipsește o întrebare*. Dacă propozițiile unei lumi spun sistematic ceva la care legenda nu întreabă (toate livrările au o oră, dar legenda n-are „când”), stelele acelea cad mereu în afara legendei, și cad în același fel: reziduul nu e zgomot, are o direcție. Semnalul e „aici se spune ceva ce eu nu întreb”, iar răspunsul e o întrebare nouă în legendă, adăugată de un om și învățată apoi de pilot cu carnetul lui. Asta e bucla din 9.4, „o graniță care învață”, spusă concret: ontologia nu e descoperită de sistem, e *întreținută* de oameni cu semnalul sistemului.

Aceleași cuvinte, teorii diferite

Rămâne cazul cel mai interesant din întrebarea de la care am pornit: același cuvânt în două teorii, „masă” la Newton și în relativitate, „energie” în termodinamică și în nutriție. În termenii noștri, două teorii sunt două legende: aceleași cuvinte răspund la întrebări diferite și stau în relații diferite. Un text citit cu amândouă legendele dă două hărți, și diferența dintre ele, domeniu cu domeniu, spune exact unde cele două teorii folosesc același cuvânt altfel. E o direcție, nu un instrument: cere legende scrise pentru teorii, ceea ce nimeni n-a făcut încă, și texte care să le umple. Dar e același mecanism ca diferența între două versiuni ale unui regulament din 11, aplicat la ceva mai greu.

6. Cum învață pilotul

6.1 Ce primește: constelația lumii

Nimeni nu îi spune pilotului care propoziții sunt parafraze. Dar nici „fără nicio supraveghere” nu e, și asta trebuie spus limpede. Fiecare propoziție de antrenare vine cu o *constelație a lumii*: lumea, care știe evenimentul și are legenda, desenează ea însăși harta corectă: „steaua lui Ion mutată cu steaua agentului, a cărții cu steaua obiectului, a Anei cu steaua destinatarului, topite”. În unele dintre lumile pe care le-am construit, constelația lumii descrie evenimentul; în altele, consecința lui („Ana are cartea”). În toate, legenda (rolurile) e fixată dinainte de cel care a construit lumea; ce învață pilotul e *cum să ajungă* sonda la stelele ei cu nume, cuvânt cu cuvânt.

Antrenarea e atunci un singur joc, repetat: pilotul citește propoziția cu carnetul lui, își desenează harta, și harta lui e comparată, rotiță cu rotiță, cu constelația lumii. Cu cât se potrivesc mai bine, cu atât mai bine; cheile din carnet se ajustează puțin, în direcția care ar fi apropiat cele două hărți. Atât. Supervizarea e, deci, pe propoziție și structurală (o constelație cu roluri date dinainte), nu o listă cu ce propoziții înseamnă același lucru.

6.2 De ce asta forțează sensul

Două propoziții despre același eveniment primesc aceeași constelație a lumii. Deci sunt obligate să deseneze aceeași hartă. Singura libertate a pilotului e carnetul: o cheie pe fel de cuvânt, câteva sute de chei cu totul. Cu câteva sute de chei, memorarea propozițiilor una câte una e exclusă practic; ce poate găsi sunt regularități, și tocmai asta vrem. Deci singurul mod în care poate satisface amândouă cerințele e să găsească chei sub care ambele trasee aduc sonda la aceleași stele cu nume. Echivalența nu e etichetată pe perechi; e indusă de țintele comune și e soluția unei constrângeri.

Am încercat alternativele evidente și au eșuat instructiv. Dacă îi ceri pilotului să prezică *următorul cuvânt*, ca un model de limbaj, toate traseele devin la fel și domeniile dispar: nimic nu-l obligă să separe rolurile. Dacă îi dai o memorie care *caută* constelația lumii pornind de la harta lui, prezice perfect și nu aliniază nimic: o căutare poate duce trei hărți diferite la același răspuns fără să le facă vreodată aceeași hartă. Doar când pilotul trebuie să *producă* constelația lumii printr-o operație fixă și rigidă (harta lui, comparată direct) e forțat să facă hărțile să coincidă. Rigiditatea e esența.

6.3 Ce se învață, și cât de puțin

Câteva sute de chei (una pe fel de cuvânt), câteva sute de chei relative pentru balize, și o poartă pe fel. Totul e de ordinul unui megaoctet la mărimile pe care le folosim, câțiva megaocteți la mărimi mai mari. Stelele cuvintelor, grosul vocabularului, sunt aleatoare și fixe. Stelele cu nume din legendă sunt aleatoare și fixe. Toată partea antrenabilă e carnetul de rute.

De aceea antrenarea durează minute, de aceea un cuvânt nou nu costă nimic, și de aceea pilotul nu știe nimic despre lume: n-are unde să țină fapte. Faptele trăiesc în lume, care

într-un sistem instalat e o bază de date sau un motor de raționament, unde pot fi inspectate și corectate. Pilotul ține doar cum așază limba cuvintele în domenii.

7. Ce rămâne pe hartă după o propoziție, și la ce e bun

După ce o propoziție a fost citită, rămâne o singură hartă: constelația ei. Pe ea, recuperabile dar nu listate, sunt stelele cuvintelor, fiecare mutată cu poziția în care a fost găsită. Lângă ea e legenda: stelele cu nume. Și între hartă și legendă sunt niște distanțe care pot fi citite *fără să înțelegi nimic*: cât din constelație e explicat de domenii, cât de net e ocupat fiecare domeniu, dacă vreun domeniu pe care lumea îl vrea plin pare gol.

Asta e proprietatea pe care se sprijină tot restul. Harta nu e măsurată față de ea însăși; e măsurată față de legendă. Așa că pilotul poate spune, fără să înțeleagă o propoziție, *că* n-a înțeles-o, și în ce fel:

- *Nimic recunoscut într-un domeniu.* Muți harta înapoi cu steaua destinatarului și nicio stea din catalog nu iese în evidență. Fie propoziția n-a spus cine e destinatarul, fie l-a spus cu un cuvânt necunoscut; ca să le deosebești e nevoie de un mic dispozitiv în plus, descris în capitolul 8. Oricum: *destinatar nerecunoscut*.
- *Un domeniu aglomerat, sau ocupat pe jumătate.* Doi candidați, marjă mică. Ambiguitate, și pilotul îi poate numi pe amândoi.
- *Stele rămase neexplicate.* Iei fiecare rol recunoscut, reconstruiești constelația pe care ar produce-o aceste recunoașteri și o scazi din harta reală. Ce rămâne sunt stele pe care legenda n-a putut să le așeze în niciun domeniu: cuvinte citite, salturi făcute, desene puse, dar nu în domenii cu nume. Propoziția e despre ceva din afara lumii, sau e incoerentă, sau folosește o construcție pentru care carnetul n-are chei. Măsurabil ca mărimea acelui rest.
- *O cheie care n-a putut fi folosită.* Un cuvânt fără fel (o stea nouă primește orice cuvânt; o cheie, doar cuvintele cu un fel); traseul se rupe acolo, și fiecare desen de după poartă o poziție atinsă cu o cheie ghicită. Vizibil ca o prăbușire a marjei pentru toate rolurile de după cuvântul acela.

Două precauții, pentru că se uită ușor. O citire netă nu e o citire corectă: un cuvânt poate fi desenat cu încredere în domeniul greșit, și cât de des se întâmplă asta trebuie măsurat, nu presupus. Iar „nerecunoscut” e o afirmație despre legenda și catalogul pilotului, nu despre propoziție.

Un model de limbaj n-are legendă. Starea lui e un punct fără nimic față de care să fie măsurat, și răspunde cu aceeași fluență fie că traseul lui a trecut prin domenii cu nume, fie prin gol. Al nostru raportează unde a ieșit traseul din legendă. Fiecare aplicație de mai jos e această unică proprietate, în alt cadru.

8. Fenomene pe care le poți urmări pe hartă

Tot ce e în acest capitol se întâmplă în interiorul poveștii descrise și se poate măsura acolo. Nimic nu e o regulă scrisă de noi. Mergem încet, pentru că acestea sunt fenomenele care construiesc intuiția, și pentru că fiecare e și un diagnostic care poate fi arătat unui utilizator.

Domeniul gol, și de ce „gol” e mai greu decât pare

Muți harta înapoi cu steaua destinatarului și compari rezultatul cu fiecare stea din catalog. Fie una iese în evidență cu marjă clară (*destinatar: Ana*), fie niciuna.

Aici e o capcană în care e ușor să cazi. Ai putea spera să deosebești „nimeni n-a fost găsit în domeniul ăsta” de „a fost găsit cineva pe care nu-l cunosc” după cât de *multă lumină* se întoarce. Nu se poate, și merită spus de ce. Mutarea e rigidă: mută întreaga hartă, fiecare stea din fiecare domeniu, deodată. Ce se întoarce are întotdeauna „greutatea” întregii constelații, cu stelele celorlalte domenii împrăștiate ca zgomot. Cantitatea nu îți spune nimic; doar recunoașterea spune. „Ion dă o carte” și „Ion îi dă o carte lui Zxyq” arată la fel din domeniul destinatarului: nicio stea cunoscută nu iese în evidență.

Ca să le deosebești, e nevoie de un dispozitiv mic și explicit, standard în această familie de sisteme: împreună cu fiecare stea de cuvânt desenată, pilotul topește și un *marker* fix, același mereu, care înseamnă „aici a fost desenat ceva”. Atunci domeniul destinatarului poate fi întrebat două lucruri separate: e markerul aici (s-a desenat ceva), și ce stea e aici (și o cunosc). „Ion dă o carte”: fără marker, nimic desenat, *destinatar nedat*. „Ion îi dă o carte lui Zxyq”: marker prezent, stea care nu e în catalogul lumii, *destinatar prezent, necunoscut*. Dispozitivul e ieftin; fără el, citirea e una singură: *destinatar nerecunoscut*.

Domeniul aglomerat

Uneori două stele se întorc din același domeniu cu putere asemănătoare. Sunt două feluri în care se întâmplă, și arată la fel din afară, dar nu din interior.

Unu: propoziția chiar a pus două lucruri acolo. „Ion și Petre îi dau Anei o carte.” Domeniul agentului are pe hartă două stele topite, și amândouă se întorc cam pe jumătate. Nu e confuzie; e o mulțime, corect desenată, și pilotul trebuie să le raporteze pe amândouă. Harta singură nu deosebește însă „Ion și Petre” de „Ion sau Petre, nu știm care”: amândouă ar fi două stele în același domeniu. Deosebirea cere un marcaj în legendă, unul pentru „și”, altul pentru „una din două”, la fel cum markerul de ocupare deosebește golul de necunoscut.

Doi: un singur cuvânt a fost desenat de la un punct aflat *între* două stele cu nume. E soarta primului cuvânt la pilotul simplu din 3.1: „Ion” e citit înaintea verbului, nimeni nu știe încă dacă dă sau primește, și poziția sondei e la jumătatea drumului dintre steaua agentului și cea a destinatarului. Întrebi domeniul agentului și Ion se întoarce pe jumătate; întrebi domeniul destinatarului și tot pe jumătate. Citirea merge, pentru că nimeni altcineva nu e în niciunul din cele două, dar marja e subțire.

Balizele repară al doilea caz și îl lasă în pace pe primul. Când sosește cuvântul care pune balize, Ion, ținut deoparte, e desenat de la poziția balizei cuvenite și se întoarce cu putere întreagă. Înainte-și-după se vede ca un salt de marjă; în măsurătorile noastre, cam de trei ori. Domeniul aglomerat de primul fel rămâne aglomerat, pentru că așa trebuie.

Stele în afara legendei, sau cum știe pilotul că o propoziție n-are sens pentru el

Citești fiecare domeniu, iei stelele recunoscute, și reconstruiești constelația pe care ar produce-o: fiecare stea mutată cu steaua cu nume a domeniului ei, toate topite. Scazi constelația reconstruită din harta reală. Ce rămâne e partea din propoziție pe care legenda n-a putut-o explica. Îi spunem *rest*, și merită o explicație fără mister, pentru că e piesa pe care se sprijină cele mai multe diagnostice.

Restul nu apare la citire. Citirea unui domeniu, mutarea hărții înapoi și scanerul, e o operație exactă: mutarea e o izometrie, totul se mută intact, nimic nu „rămâne" în urmă. De aceea nici nu poți afla din *cât* se întoarce dacă domeniul e ocupat; se întoarce mereu întreaga hartă, mutată. Restul apare la *comparație*: după ce ai citit toate domeniile, ai cadrul (agent Ion, obiect carte, destinatar Ana); desenezi din nou, de la zero, harta pe care ar produce-o exact aceste răspunsuri; și o scazi din harta reală. E o împărțire, în sensul din statistică: harta = (ce explică legenda) + (rest). Cadrul e câtul, restul e restul. Câtul spune ce s-a înțeles; restul spune cât din propoziție n-a putut fi așezat în niciun domeniu cu nume.

Două precizări îl fac cinstit. Întâi, restul nu e niciodată zero: cuvintele de legătură desenate la poziții fără nume, copiile în plus din cele trei desene și zgomotul suprapunerii lasă un *fond* care nu stă în niciun domeniu; fondul se măsoară o dată, pe lume, pe propoziții înțelese, și ce contează e *cât depășește* restul acest fond. Al doilea, restul se calculează după ce constelația reconstruită e adusă la scara hărții: hărțile se compară pe direcții, nu pe lungimi, deci o hartă de trei ori mai „lungă" nu e de trei ori mai neînțeleasă. Cu aceste precizări: pentru o propoziție înțeleasă restul rămâne la fond; pentru una neînțeleasă crește, și de unde vine depinde de motiv:

- *Cuvinte cunoscute, într-o ordine neparcursă.* Fiecare cuvânt și-a folosit cheia, dar șirul de salturi a dus sonda în puncte pe care legenda nu le numește. Stelele sunt reale, ar fi recunoscute dacă ai ști cu ce să muți harta înapoi, dar nicio stea cu nume nu e cea potrivită. E forma unei construcții noi: piesele sunt familiare, traseul nu.
- *Cuvinte necunoscute.* Fiecare e o stea nouă, aleatoare, mutată cu poziția unde s-a nimerit sonda. Stele aleatoare în puncte arbitrare: adaugă greutate hărții și nu contribuie cu nimic la niciun domeniu. E forma nonsensului, sau a unui vocabular străin.
- *O propoziție despre altceva.* Cuvintele sunt cunoscute, construcția obișnuită, și legenda pur și simplu n-are domenii pentru acest fel de eveniment, pentru că lumea pe care a fost antrenat pilotul nu-l conține. Stelele ajung în puncte perfect bine formate și perfect fără nume. E forma unei întrebări din afara domeniului de activitate.

Observă ce e și ce nu e această măsurătoare. Nu e „propoziția n-are sens". E „cheile mele nu duc propoziția asta în legenda mea". O propoziție poate fi plină de sens pentru un om și totuși să cadă în afara legendei unui pilot antrenat pe facturi. Pilotul cunoaște limitele propriei legende, și tocmai felul acesta de ignoranță e util.

Cheia ruptă

Un cuvânt necunoscut nu doar că nu e recunoscut; el nici n-are cheie, pentru că n-are fel. Pilotul, ajuns la el, trimite o cheie ghicită, și tot ce citește după e desenat de la poziții care poartă acea cheie greșită. Desenele dinaintea cuvântului necunoscut sunt bune; cele de după sunt deplasate cu o cantitate necunoscută. Ceri rolurile și vezi tiparul: cele umplute înainte de ruptură se întorc nete, cele de după, la nivelul zgomotului. Ruptura e localizabilă: pilotul poate spune *am pierdut firul la cuvântul șase*. Cele trei desene îndulcesc asta, pentru că nu se rup toate deodată; dar ceva de după ruptură e întotdeauna începătoșat.

Zgomotul, și de ce harta are o capacitate

Fiecare stea topită adaugă puțin zgomot în fiecare domeniu. Când muți harta înapoi cu steaua agentului, aduci înapoi, slab, și tot ce era desenat în celelalte domenii, mutat cu un cod care nu era al lui și deci împrăștiat aleator. Cu puține stele, împrăștierea e mult sub semnal. Cu multe, se adună, și la un moment dat cuvântul din domeniul agentului nu mai e clar deasupra împrăștierii din tot restul.

Cât înseamnă „multe” depinde de câte rotițe au coordonatele. Cu câteva mii, zeci de stele sunt curate, o sută-două încă lizibile cu grijă, iar dincolo harta alunecă spre mijloc, unde nimic nu mai e recognoscibil. Nu e un defect; e geometria. De aceea un document nu e o hartă, ci mai multe hărți legate prin chei, fiecare ținând ce a desenat o propoziție sau un eveniment. Saltul „relatat” e deja o astfel de legătură: propoziția interioară e constelația ei proprie, mutată întreagă la altă origine, în harta celei exterioare.

Negația ca o stea, și unde trăiește scopul ei

„Ion nu îi dă Anei cartea.” Legenda dă o stea pentru negație. Întrebarea e ce poziții o poartă. Dacă toate desenele evenimentului poartă steaua negației, negația e a propoziției: nu e cazul că Ion dă. Dacă doar desenul lui „Ion” o poartă, înainte de steaua agentului, negația e a agentului: nu Ion e cel care dă. Dacă doar desenul Anei o poartă, negația e a destinatarului: nu Ana e cea care primește, iar cine primește rămâne o întrebare deschisă (nu „nimeni”: „nimeni” e un cuvânt al lui, cu desenul lui, pe care legenda îl tratează separat).

Scopul unei negații nu e deci o etichetă; e *ce cuvinte au fost desenate de la poziții care conțin steaua negației*. Citești harta înapoi și vezi: muți toată harta cu negația și citești apoi domeniile; dacă toate stelele reapar la locul lor, negația era a propoziției întregi; dacă reapare doar Ion, era a lui; dacă nu reapare nimic, negația nu era acolo. Pilotul citește care dintre cazuri e, pentru opt feluri de a spune negația, fără o regulă pentru niciunul.

Și iată de ce un sac de cuvinte nu poate face asta. Pentru sac, „nu” e un cuvânt ca oricare altul: propoziția negată și cea afirmată au în comun toate cuvintele în afară de unul și sunt aproape identice. În povestea noastră, propoziția negată are stelele mutate cu o cheie în plus, și cele două constelații sunt departe, aproape ca două puncte aleatoare. Diferența dintre „aceleași cuvinte” și „același sens” e diferența dintre a număra stelele și a întreba unde au fost desenate.

Ambiguitatea ținută deschisă

„Fiecare copil citește o carte.” O carte pentru toți, sau câte una fiecare? Propoziția nu spune. Un cititor obligat să aleagă va alege și va greși jumătate din timp fără să știe.

În povestea noastră, cele două citiri sunt două aranjamente diferite ale domeniilor de cuantificator. Am antrenat pilotul doar pe propoziții neambigue, fiecare cu un aranjament clar, și apoi i-am arătat unele ambigue. Ce am observat e că harta lui cade între cele două aranjamente: ceri oricare citire și se întoarce, cu putere aproape egală. Nu l-am învățat să ezite, și nimic din geometrie nu garantează dinainte acest rezultat; e o constatare experimentală, și una binevenită. Pilotul raportează ambele citiri, iar un cuvânt ulterior care se potrivește doar cu una („aceeași carte”) ar închide-o pe cealaltă. O precizare: suprapunerea a două citiri nu ține minte și legătura dintre alegeri (care substantiv merge cu care citire); e o reprezentare a îndoielii, nu a celor două înțelesuri întregi. E același fenomen ca primul cuvânt desenat pe jumătate, în alt cadru: o stea desenată între două domenii până când ceva o așază.

Nivelul nemaivăzut, și cheia care nu există

De ce poate pilotul citi o propoziție cu trei niveluri când a fost antrenat pe două? Pentru că „mută originea” e o cheie: de două ori e o cheie, de trei ori e o cheie, iar desfacerea e același număr de pași înapoi. Al treilea nivel n-are nimic nou; e același salt, încă o dată.

Și de ce n-a reușit, prima dată, să citească o negație *în interiorul* unei propoziții relatate? Pentru că acea combinație cerea o înlănțuire de chei pe care pilotul n-o făcuse niciodată: negație-la-nivel. Nu o cheie nouă, ci o înlănțuire nouă, pentru care n-avea nicio cheie relativă învățată. Odată ce acea înlănțuire a apărut în antrenare la un nivel, a citit-o la nivelul următor fără antrenare suplimentară. Tiparul merită spus ca ceea ce e: pilotul compune ce are chei pentru. O înlănțuire pe care n-a făcut-o niciodată nu e începătoșată, e lipsă. Asta înseamnă „generalizează cu un nivel mai departe decât a fost antrenat, odată ce înlănțuirea a fost văzută la un nivel mai jos”, și e și exact locul unde metoda eșuează: pe o combinație de operatori cunoscuți pe care nu i-a văzut niciodată împreună.

O construcție nouă: o baliză lipsă

„Cartea, Ion i-o dă Anei.” Cuvinte cunoscute, ordine neparcursă. Nicio cheie nu e, în sine, greșită: fiecare cuvânt are felul lui și cheia felului. Ce se strică e altceva, și merită spus exact ce, pentru fiecare dintre cele trei desene. *Baliza*: construcția nouă deschide așteptările în altă ordine; „Cartea” sosește înainte de orice baliză și poate fi luată de una nepotrivită sau de niciuna; desenul prin balize e cel mai fragil aici. *Poziția sondei*: suma cheilor e o combinație nouă de chei cunoscute, deci un punct pe care sonda nu l-a mai atins; nu e aiurea, dar nici exact la steaua cu nume; desenul e deplasat. *Felul cuvântului anterior*: „după un articol, substantiv” e același ca în orice propoziție; desenul e grosolan, dar neatins.

Cu un singur desen, cel prin balize, cuvântul ar fi pierdut. Cu trei, celelalte două îl aduc destul de aproape de domeniul lui ca scanerul să-l recunoască, cu marjă mai mică. Citirea e începătoșată, nu distrusă. Ăsta e întregul conținut al rezultatului despre redundanță: o construcție nouă costă o parte din marjă în loc de toată.

Structura anunțată după

„Ion îi dă Anei o carte, spune Maria.” Până la „spune Maria”, prima propoziție a fost deja desenată pe hartă, față de originea mare, ca afirmație simplă. Saltul relatat vine prea târziu: stelele sunt deja desenate, și un pilot care merge doar înainte n-are cum să le ridice și să le mute la altă origine după fapt. La fel pentru o virgulă care reordonează o propoziție, și pentru orice construcție a cărei formă se dezvăluie doar la sfârșit.

E o limită reală a citirii înainte, și o declarăm ca atare. E și, precis, ce face „ținutul deoparte” pentru cuvinte singure, extins la propoziții întregi; singurul loc unde ideea că un cuvânt poate trebui reașezat de ce urmează supraviețuiește, în forma ei forțată de date.

Ordinea, și ce nu pot deosebi cheile care comută

Cheile comută. Relatat apoi negație duce sonda exact unde o duce negație apoi relatat. Deci propoziția interioară din „Maria spune că nu e cazul că P” și cea din „nu e cazul că Maria spune că P” au aceeași origine. Cele două propoziții se deosebesc totuși, dar numai pentru că *altceva* diferă: în a doua, și desenul Mariei poartă steaua negației. Acolo unde nimic altceva nu diferă, ordinea a doi operatori e pierdută.

Asta e cea mai adâncă limită structurală a poveștii așa cum o folosim, și trebuie declarată ca atare: o poziție ține minte ce chei s-au folosit, ca multimulțime (repetarea aceleiași chei contează, ordinea nu), nu ca șir; drumurile prin cer formează o grilă, nu un arbore. E același fapt, văzut din altă parte, care dă pilotului libertatea de a compune („încă o dată același salt” nu cere nicio învățare). În variantele pe care le-am cântărit, chei care nu comută, prin permutări, sau câte o stea relatat pentru fiecare nivel, ordinea se cumpără cu o parte din acea libertate. Nu e o imposibilitate matematică (există operații care păstrează ordinea și compun), ci un compromis al variantelor concrete, și se măsoară: am măsurat ce poate și ce nu poate versiunea care comută, iar propozițiile în care doar ordinea poartă sensul se testează cu ambele remedii.

Care verb? Predicatul e și el un domeniu

„Ion îi dă Anei o carte”, „Ion îi împrumută Anei o carte”, „Ion îi vinde Anei o carte”: aceiași participanți, aceleași domenii, trei evenimente diferite. Dacă harta ține doar cine a fost găsit în domeniile agentului, obiectului și destinatarului, nu le poate deosebi. Verbul însuși trebuie desenat într-un domeniu al lui, domeniul predicatului, și legenda trebuie să aibă steaua lui. În lumile noastre timpurii n-o avea: a da și a vinde primiseră aceeași constelație a lumii și erau deci același eveniment pentru pilot. A fost o lacună în felul în care am construit acele lumi, nu o proprietate a poveștii, și se închide. Răspunde și la o întrebare firească: „dă” și „primește” ajung la aceeași constelație pentru că lumea spune că descriu același eveniment; „împrumută” ajunge la alta pentru că lumea spune așa. Lumea decide ce e același eveniment; pilotul trebuie doar să fie consecvent cu ea.

Mai multe evenimente, și același nume de două ori

O hartă, un eveniment. Dacă două evenimente sunt topite într-o singură hartă fără nimic care să le țină separate, participanții se amestecă: agentul primului și agentul celui de-al

doilea sunt amândoi în domeniul agentului, și nimeni nu mai poate spune cine ce a făcut cui. Povestea are remediul evident, fiecare eveniment mutat la propria origine înainte de topire, exact cum o propoziție relatată e ținută separat de cea care o relatează; dar l-am folosit doar pentru relatare, nu pentru „Ion îi dă Anei o carte și Petre îi împrumută un pix". Până devine general, aria cinstită a unei hărți e un singur eveniment. La fel pentru un nume care apare de două ori în roluri diferite: sunt două desene în două domenii, se deosebesc, dar marja scade puțin, cum scade ori de câte ori aceeași stea e desenată în două locuri.

Trei feluri de „aproape"

Pentru că harta păstrează și stelele cuvintelor, și domeniile, două propoziții pot fi aproape una de alta în trei feluri, și harta le deosebește.

- Aceleași stele în aceleași domenii: propozițiile înseamnă același lucru. „Ion îi dă Anei o carte" și „Ana primește o carte de la Ion".
- Aceleași stele în domenii diferite: propozițiile sunt despre aceleași lucruri și înseamnă altceva. „Ion îi dă Anei o carte" și „Ana îi dă lui Ion o carte". Un sac de cuvinte nu vede deloc diferența; aici cele două constelații sunt departe.
- Stele diferite în aceleași domenii: aceeași formă, alt conținut. „Ion îi dă Anei o carte" și „Petre îi împrumută Mariei o mașină". Același cadru, alte umpluturi; echivalente structural.

Un scor de similaritate le strivește pe cele trei într-un singur număr. Harta noastră le ține ca trei răspunsuri, iar o comparație a două texte poate spune ce fel de apropiere a găsit și în ce domenii.

Ce nu ține minte pilotul

Între propoziții, nimic. Cât timp citește o propoziție, pilotul are un mic set de lucru, balizele de pe hartă și cuvintele ținute deoparte, dar îl aruncă la sfârșit; ce supraviețuiește e doar harta. Propoziția următoare începe una nouă, iar sonda pleacă iar de la origine. E o goliciune deliberată: pilotul n-are memorie în care să acumuleze convingeri, și deci nu poate să derive sau să confabuleze de-a lungul unei conversații. Memoria e externă: cadrele citite sunt stocate într-o bază de date sau un motor de raționament, iar o propoziție ulterioară care se referă înapoi („ea o citește") e rezolvată legându-i harta de cadrele stocate, printr-o căutare, nu printr-o memorie din interiorul pilotului. Legarea asta e condiția pentru orice la scara unui document. Secțiunea următoare spune cum se face.

Pronumele: o stea de împrumut

„Ion îi dă Anei o carte. Ea o citește." Pentru pilot, „ea" e un cuvânt ca oricare altul: are steaua lui în catalog, e de felul „pronume feminin", și ajunge pe harta propoziției a doua în domeniul agentului. Harta e corectă și, în același timp, nu spune cine e agentul: spune *ea*. Nimic din cer nu poate spune mai mult, pentru că steaua lui „ea" n-are nicio legătură cu steaua Anei; legătura dintre ele nu e în limbă, e în ce s-a spus înainte.

De aceea referința nu se rezolvă în cer, ci la bază, prin căutare, la fel ca greșelile de scriere. Baza păstrează constelațiile propozițiilor recente, un *atlas* al conversației. Când pilotul

întâlnește un pronume, caută în atlas o stea de cuvânt compatibilă cu felul pronumelui: „ea” cere un nume feminin la singular, „acela” un lucru deja menționat, „celălalt” al doilea membru al unei perechi de același fel. Caută de la propoziția cea mai recentă înapoi, și se uită mai întâi în domeniile pe care verbul propoziției de față le așteaptă (după „citește”, un agent de felul persoană). Steaua găsită, a Anei, e *împrumutată*: e desenată pe harta propoziției a doua în locul stelei lui „ea”, iar harta spune de acum „agent: Ana”. Dacă două stele se potrivesc la fel de bine (doi candidați feminini la fel de recenți), pilotul nu alege: le topește pe amândouă în domeniul agentului, cu marcajul „una din două”, ca harta să nu le citească drept „Ion și Petre”. O propoziție următoare, sau lumea, o poate închide: lumea știe că o carte nu citește, pilotul nu, și nici nu trebuie.

Împărțirea e aceeași ca peste tot în poveste: pilotul propune după formă (felul cuvântului, recența, domeniile așteptate), lumea decide după fapte. Nimic din asta nu cere pilotului să înțeleagă cine e Ana.

Mecanismul e precis și nu cere pilotului nimic nou de învățat: piesele există deja (catalogul, domeniile, topirea candidaților, căutarea). Ce se măsoară e cât de des alege bine pe text real, și cât de des spune că nu poate alege când chiar nu poate.

De ce stelele cuvintelor sunt aleatoare, și trebuie să rămână așa

Ai putea crede că stele învățate ar fi mai bune: „pisică” lângă „câine”, „carte” lângă „roman”. Dar în povestea asta, apropierea între stelele cuvintelor e interferență. Dacă „Ion” și „Petre” ar fi aproape, domeniul agentului nu i-ar putea deosebi; marja pe care se sprijină fiecare diagnostic de mai sus s-ar micșora. Stelele aleatoare sunt fără legătură una cu alta, și asta e ce face fiecare domeniu lizibil. Apropierea semantică între cuvinte aparține altundeva: felului în care cuvintele sunt grupate în feluri (care decide cheile lor) și cunoașterii pe care lumea o are despre ce e o pisică. Treaba pilotului e să deseneze steaua potrivită în domeniul potrivit; are nevoie ca stelele să fie deosebite, nu asemănătoare. Asta rezolvă și greșelile de scriere: un cuvânt scris greșit e potrivit cu forma lui corectă *înainte* de citire, printr-o căutare care poate folosi tipare de litere, și steaua formei corecte, aleatoare ca toate, e cea desenată. Toleranța trăiește în căutare, niciodată în stele.

9. Unde duce

9.1 Asistenți care au voie să spună „nu știu”

Ia un singur domeniu de activitate: un orar, un inventar, un catalog de produse, fizica de liceu odată ce numerele și unitățile au stele cu nume proprii. Scrie-i legenda: rolurile pe care le pot avea întrebările lui, fiecare cu steaua ei. Antrenează carnetul de rute pe întrebări din acel domeniu, împerecheate cu constelațiile lor corecte (o interogare, o căutare, un răspuns calculat). Apoi rulează.

Un utilizator tastează. Cuvânt cu cuvânt, sonda sare și pilotul desenează; poți literalmente arăta cadrul cum se umple pe măsură ce tastează, pentru că fiecare pas e câteva mii de răsuciri și toată propoziția costă microsecunde pe un procesor obișnuit. Când propoziția se termină, cadrul e citit de pe hartă și dat bazei de date sau motorului de raționament.

Răspunsul vine derivat, iar derivarea poate fi arătată lângă el: iată ce am înțeles, iată ce am întrebat, iată ce a venit înapoi.

Când harta nu se potrivește cu legenda, asistentul nu ghicește. Un domeniu rămas nerecunoscut: „n-ai spus care produs”. Un domeniu aglomerat: „factura din martie sau cea din aprilie?”. Stele rămase neexplicate: „nu am informații despre asta”. Un cuvânt fără stea: „nu cunosc termenul X”. Fiecare refuz e o distanță citită de pe hartă, nu o politică scrisă de mână; și fiecare e o afirmație despre propria legendă a pilotului, nu un verdict asupra utilizatorului.

Un astfel de asistent e mai greu de cap decât un chatbot. Nu face conversație, n-are opinii, nu știe nimic în afara legendei. În schimb, răspunsurile lui sunt restrânse la ce conțin legenda și baza de date, fiecare vine cu o marjă, și fiecare poate fi reprodus și verificat. Poate totuși greși cu încredere, desenând un cuvânt în domeniul greșit cu marjă clară; cât de des se întâmplă asta e un număr de măsurat pe fiecare domeniu de activitate, și asistentul trebuie judecat după el. Nu e niciun model de limbaj în buclă, niciun GPU, niciun apel în cloud. Poate rula pe un telefon sau într-un browser, și își poate permite să verifice fiecare mesaj.

Intrarea dezordonată e tratată în straturi, și cinstit. Greșelile de scriere sunt absorbite în mare parte de corecția clasică de dinainte de citire, o căutare care duce forma greșită la cea corectă; steaua desenată e întotdeauna a formei corecte. Când o propoziție e cu adevărat incoerentă, un model de limbaj mic poate fi pus să o rescrie, dar nu are ultimul cuvânt. Rescrierea e citită și ea; fiecare stea recunoscută în original trebuie să fie încă prezentă; tot ce a adăugat rescrierea e marcat ca presupunere și pus utilizatorului ca întrebare. Asistentul nu pretinde că a verificat o rescriere a ceva ce n-a înțeles. Limitează ce poate strica rescrierea, și întreabă.

9.2 Un verificator lângă modelele mari

Direcția cealaltă. Un model de limbaj mare citește un document complex și propune o citire formală: un rezumat, o extracție, un set de fapte, o formă logică. Știe mult mai multă limbă decât noi. Și, uneori, scapă o propoziție, inversează două roluri sau adaugă în tăcere un detaliu plauzibil.

Noi citim același document cu pilotul nostru, separat, și comparăm constelațiile domeniu cu domeniu. Patru verdicte, nu trei. *Acord*: aceeași stea în același domeniu; două citiri separate sunt de acord, ceea ce nu înseamnă că citirea e adevărată, și nici că erorile lor sunt independente, mai ales când amândouă au învățat din texte produse de aceleași modele. *Compatibil, incomplet*: una spune „marți”, cealaltă „marți dimineață”; nu e contradicție, e detaliu în plus. *Contradicție*: stele diferite în același domeniu, fără ca una să o rafineze pe cealaltă; spunem în ce domeniu, nu cine are dreptate. *Neverificabil*: harta noastră e nesigură, un domeniu nerecunoscut sau aglomerat, sau propoziția e în afara legendei. Ultimul verdict e cel valoros: un model de limbaj poate fi învățat să se abțină, dar abținerea lui nu e legată de o structură pe care un om s-o verifice; a noastră spune în ce domeniu și de ce.

Pentru asta trebuie să fim și noi antrenați pe domeniul de activitate; nu ca să egalăm acoperirea modelului mare, ci ca să avem propria constelație a textului cu care să comparăm. Partea dintr-un document pe care o putem confirma sau contrazice crește cu antrenarea, iar partea marcată neverificabilă scade. Verificatorul e cinstit în fiecare punct despre care e care. În domenii reglementate, cinstea asta valorează mai mult decât încă un punct de acuratețe.

9.3 Formalizarea unui domeniu pentru raționament simbolic

Cadrul citit de pe hartă e deja o structură cheie-valoare, cu niveluri acolo unde propoziția avea propoziții în propoziții. A-l transforma în fapte pentru un motor logic sau în constrângeri pentru un solver e o rescriere mecanică *odată ce cadrul, cu operatorii lui, are o semantică fixată*: domeniul agentului devine primul argument al unui predicat, nivelurile devin imbricare de termeni, o negație desenată ca rol devine un literal negat. Alegerile grele se fac o dată, în definiția cadrului, nu în traducere: ce înseamnă un cuantificator, cum se identifică două mențiuni ale aceleiași entități, cum se tratează timpul și modalitatea, și ce fel de negație se traduce (negația clasică a unei formule nu e negația prin eșec a unui program logic). Traducerea nu mai învață nimic, deci nu greșește ca pașii învățați; dar traduce consecvent și o definiție greșită.

Drumul de la limbaj natural la raționament formal devine: text, hartă, cadru, enunț formal, motor de raționament, răspuns. Fiecare verigă e inspectabilă. Toată bucla poate fi verificată față de propriul răspuns al lumii, și în lumile noastre controlate e exactă, inclusiv pe niveluri niciodată antrenate.

Operatorii logici înșiși sunt stele în legendă. Negația e o stea: lucrul negat e desenat de la o poziție care o conține, iar scopul ei, ce anume e negat, e pur și simplu ce a fost desenat așa: întreaga propoziție, sau un singur argument. „Ion nu îi dă cartea Anei” și „Ion nu dă cartea nimănui” desenează lucruri diferite, iar pilotul citește diferența fără o regulă pentru niciuna. Cuantificatorii sunt stele atașate argumentelor. Acolo unde o propoziție e cu adevărat ambiguă, „fiecare copil citește o carte”, harta ține ambele citiri și, citită, le arată pe amândouă cu putere aproape egală: ambiguitatea e raportată, nu rezolvată printr-o ghicire, și pilotul n-a fost antrenat pe propoziții ambigue ca să facă asta. Am observat-o; n-am proiectat-o.

Pe un domeniu limitat cu o schemă cunoscută, acest formalizator e mai rapid decât orice model de limbaj cu ordine de mărime și cel puțin la fel de corect, cu diferența decisivă că raportează cât de sigur e, domeniu cu domeniu, și poate fi tras la răspundere pentru acel raport. Pe text deschis, rolul realist e cel din 9.2: nu să înlocuiască formalizarea modelului mare, ci s-o verifice și s-o completeze.

9.4 O graniță care învață

Orice sistem construit din mai multe modele are cusături, și la fiecare cusătură apare ceva simbolic: o listă de obiecte detectate cu poziții și viteze, un set de câmpuri extrase, o comandă analizată. Trebuie să apară: oamenii inspectează cusătura, părțile se antrenează separat, regulile trăiesc acolo. Slăbiciunea cunoscută e că schema cusăturii e desenată de ingineri dinainte și pierde tot ce n-au prevăzut; iar reacția cunoscută, antrenarea a tot de la

un capăt la altul într-un singur spațiu latent, cumpără acoperire cu prețul unei cusături pe care nimeni n-o poate citi.

Harta noastră e o cusătură de primul fel cu o parte din virtutea celui de-al doilea. Domeniile ei, rolurile, sunt tot date de lume; dar felul în care cuvintele ajung la ele, și ce cuvinte pun balize, e învățat, nu scris de mână; stele cu nume noi pot fi adăugate în legendă când lumea le cere, cu doar carnetul de reantrenat; e lizibilă prin construcție; și poate păstra, topit lângă domenii, un rezidual pentru tot ce n-are încă nume, astfel încât ce n-a prevăzut schema e începătoșat, nu pierdut. Aceeași hartă poate fi umplută din mai multe simțuri deodată, pentru că o stea e doar coordonate și un domeniu e doar o stea cu nume: un cuvânt, un obiect detectat într-o imagine și desenat de la o poziție care îi codifică locul, un eveniment dintr-un jurnal, o citire de la un senzor. De fapt, limbajul a fost cazul greu: în text, cheia trebuie ghicită din cuvânt. Oriunde cheia e dată direct, de o comandă motorie, de timpul scurs, de o coordonată, mașinăria se aplică fără nimic de ghicit, ceea ce e tocmai cadrul pentru care a fost gândită teoria lui Hawkins despre cortex de la început.

9.5 Un model al lumii pe care îl poți citi

Acolo unde constelația lumii e consecința unui eveniment, nu descrierea lui, a învăța să o produci din propoziție e un pas spre învățarea dinamicii unei lumi: stare plus eveniment dă starea următoare. Am făcut asta doar pe lumi mici, iar a citi un eveniment într-un cadru nu e încă același lucru cu a prezice ce urmează din el; afirmația de aici e o direcție, nu un rezultat. Modelele de lume de azi fac asta într-un spațiu latent pe care nu-l citește nimeni, și își imaginează viitorul rulând o rețea înainte, pas după pas, cu erori care se adună și nimic față de care să verifice. Starea noastră e o hartă cu o legendă. Oriunde lumea are reguli, date și termene, contracte, proceduri, cod, baze de date, „imaginarea consecinței” poate fi dată unui motor de raționament simbolic care lucrează pe cadru: exact, explicabil, stabil peste oricâți pași. Acolo unde lumea n-are reguli scrise, căderea unui pahar, abordarea latentă își păstrează locul, iar un hibrid folosește cadrul ca schelet și un rezidual latent pentru rest.

10. Robotică: un dispozitiv de blocare semantică

Roboții primesc tot mai des comenzi în limbaj natural, iar drumul de la comandă la motor trece printr-un model mare: un planificator care transformă „pune cutia pe raftul de sus” într-o secvență de mișcări. Modelul e capabil și opac. Când greșește, greșește în lumea fizică, și nimeni nu vede greșeala înainte să se întâmple. Industria are, pentru restul robotului, o soluție veche și bună: *interlock*-ul, dispozitivul care taie fizic alimentarea unei acțiuni nepermise, indiferent de ce a decis restul sistemului. Ce lipsește e un interlock pentru *sens*: ceva care să știe ce s-a cerut și ce s-a propus, și să blocheze înainte de mișcare ce nu e permis.

Cum arată

Între planificator și actuatoare stă pilotul, cu o legendă de acțiune scrisă pentru robotul acela: ce acțiune, asupra cărui obiect, unde, cu ce viteză sau forță, sub ce condiție, la cererea cui. Orice comandă venită de la om și orice acțiune propusă de planificator trec prin el și devin răspunsuri la aceste întrebări. Ce nu încape în legendă nu există pentru interlock, deci nu poate fi executat: o acțiune pe care nimeni n-a prevăzut-o nu are cum să fie

exprimată. Cadrul citit se traduce mecanic în fapte, iar politicile de siguranță sunt reguli în același limbaj: nicio mișcare rapidă cât timp o persoană e în zona B; niciun obiect din clasa „fragil” deasupra vitezei V; orice acțiune asupra obiectelor din lista L cere confirmare. Un motor de reguli decide, cu o derivare care se poate afișa, și numai cadrele permise ajung la actuatoare.

Partea care face asta mai mult decât un filtru de cuvinte e că aceeași legendă citește și *lumea senzorială*. Un obiect detectat cu poziția lui, o persoană intrată într-o zonă, o ușă deschisă sunt și ele fapte cu roluri (ce, unde, când), și intră pe aceeași hartă printr-un salt dat direct de senzor, fără nimic de ghicit (9.4). Regula „nu te mișca rapid cât timp cineva e în zona B” se verifică atunci pe aceeași hartă pe care stă și comanda, în același motor. Interlock-ul vede comanda și contextul în aceeași formă.

De ce e ieftin, și de ce poate fi hardware

Tot ce face pilotul e adunare de unghiuri pe câteva mii de rotițe și o comparație cu un catalog. O comandă costă microsecunde pe un procesor obișnuit; carnetul de rute încape într-un megaoctet; nu e nevoie de niciun accelerator. Cu codurile rare pe blocuri din capitolul 14, operațiile devin aritmetică pe indici întregi, exact genul de lucru care se pune într-un microcontroler sau într-un FPGA. Asta deschide o arhitectură pe care siguranța funcțională o cunoaște bine: interlock-ul semantic pe un circuit separat, cu propria alimentare și propriul ceas, care primește comanda și contextul de la calculatorul principal și singur emite semnalul de *enable* spre actuatoare. Calculatorul principal poate fi oricât de complex și oricât de opac; dispozitivul care dă voie e mic, determinist și citibil linie cu linie.

Determinismul contează aici mai mult decât oriunde. Aceeași comandă dă aceeași hartă, de fiecare dată; nu există eșantionare, nu există temperatură, nu există răspuns „creativ”. Fiecare blocare poate fi reprodusă și explicată: iată cadrul citit, iată regula încălcată. Fiecare acceptare la fel. Pentru certificarea unui sistem de siguranță, asta e diferența dintre un component care poate fi analizat și unul care trebuie crezut pe cuvânt.

Ce face când nu e sigur

Implicitul unui robot e repausul. Când harta e nesigură, un domeniu cu marjă mică, un reziduu mare, un cuvânt fără fel, interlock-ul nu ghicește și nu blochează orbește: *oprește și întreabă*, și poate spune exact ce a înțeles: „Am înțeles: mută cutia la raionul B, fără viteză precizată. Confirmi?”. Confirmarea e tot o propoziție, citită în aceeași legendă. Dialogul de confirmare e, de fapt, interfața firească a dispozitivului: omul vede cadrul înainte de mișcare, nu după.

Ce decide cât de departe se merge

Piesele sunt cele din tot documentul: cititorul, cadrul, traducerea în reguli, diagnosticele. Legenda de acțiune pentru un robot anume și regulile lui sunt inginerie de domeniu, ca la orice sistem de siguranță. Măsura care decide cât de departe se poate merge e aceeași din capitolul 16: scopul negației pe comenzi reale („nu lăsa cutia aici, du-o acolo”) și rata greșelilor făcute cu încredere, pentru că un interlock blochează prin construcție doar ce nu poate exprima: o acțiune periculoasă poate fi perfect exprimabilă (ștergerea obiectului

greșit, un șir de acțiuni fiecare permisă), iar o citire greșită cu marjă mare rămâne posibilă. Interfața restrânge și verifică; nu garantează. Corectitudinea citirii și potrivirea politicilor se măsoară separat.

11. Enterprise și industrii puternic reglementate

Sisteme agentice: intenția citită fără model de limbaj

Un sistem agentic de întreprindere primește cereri în limbaj natural („mută factura 4471 pe centrul de cost al departamentului de vânzări și anunță-l pe Popescu") și le transformă în apeluri către software: ERP, CRM, sistemul de tichete, calendarul. Azi, pasul de la cerere la apel îl face un model mare, la fiecare cerere, cu latența, costul și nedeterminismul lui, și cu riscul ca o cerere să fie înțeleasă altfel decât a fost spusă și executată oricum.

Pentru un domeniu fixat, domeniul unui software de întreprindere, cu entitățile, acțiunile și parametrii lui, pilotul face acest pas singur. Legenda e schema sistemului: ce acțiuni există, asupra căror obiecte, cu ce câmpuri. Carnetul de rute se antrenează o dată pe cereri din acel domeniu, cu cadrele lor, produse de conducta de adnotare cu modele mari (9.1) și auditate pe un eșantion. După aceea, o cerere clară devine un cadru complet în microsecunde, pe un procesor obișnuit, în interiorul rețelei companiei, fără niciun apel extern: *intenția* e acțiunea al cărei domeniu s-a umplut, *parametrii* sunt stelele din celelalte domenii, iar ce lipsește e la vedere. „Mută factura 4471 pe centrul de cost al departamentului de vânzări și anunță-l pe Popescu": acțiune mutare, obiect factura 4471, destinație centrul de cost vânzări, notificat Popescu; termen, nedat.

Modelul mare nu dispare; își schimbă locul. Arhitectura e cu două căi. Calea rapidă: cererea e citită de pilot; dacă harta e netă, toate domeniile obligatorii pline cu marjă clară și reziduu mic, cadrul merge direct la execuție, după verificarea politicilor. Calea lentă: dacă harta e nesigură, cererea merge la modelul mare, care o reformulează sau o completează, iar rezultatul lui e citit din nou de pilot, pentru că nimic nu ajunge la execuție altfel decât ca un cadru verificat. Modelul mare lucrează pe coada grea a cererilor, nu pe toate; costul și latența lui se plătesc pe o parte din cereri, nu pe toate; cât de mare e partea se măsoară pe fiecare domeniu, nu se presupune.

Trei lucruri vin gratis din această așezare. *Autorizarea* devine o regulă pe cadru: cine are voie să facă ce acțiune asupra căror obiecte se scrie în același limbaj ca politicile din capitolul 16, și se verifică înainte de execuție, nu după. *Jurnalul* e o listă de cadre, nu de texte: fiecare acțiune executată are lângă ea cererea, cadrul citit, marja și regula care a permis-o, lizibile de un om fără instrumente. Și *determinismul*: aceeași cerere dă același cadru, azi și peste un an, ceea ce face posibile testele de regresie pe înțelegere, nu doar pe cod.

Industrii reglementate: documente care trebuie citite exact

În farmaceutică, bănci, aviație, energie, documentele care guvernează activitatea (proceduri standard de operare, legi, regulamente, ghiduri, rapoarte de audit) sunt, în esență, liste de fapte cu roluri: cine trebuie să facă ce, când, în ce condiție, cu ce dovadă, cu

ce excepție, în baza cărui articol. Sunt lungi, se schimbă des și trebuie citite exact, pentru că o obligație scăpată sau un termen înțeles greșit costă.

O legendă pentru acest fel de text are câteva zeci de întrebări: actorul obligat, acțiunea, obiectul, termenul, condiția, excepția, dovada cerută, referința normativă. Cu ea, pilotul transformă un document într-o listă de cadre, câte unul pe propoziție care spune ceva, fiecare legat de propoziția lui, cu domeniile goale la vedere și cu reziduul care arată ce n-a încăput în legendă. De aici, câteva operații care astăzi se fac manual sau cu modele mari fără verificare devin comparații între hărți:

- *Diferența între două versiuni ale unui regulament*: nu ce cuvinte s-au schimbat, ci ce obligații au apărut, au dispărut sau și-au schimbat termenul ori actorul, domeniu cu domeniu.
- *Conformitatea unei proceduri cu norma*: procedura și regulamentul citite în aceeași legendă, apoi comparate; o obligație din regulament fără cadru corespunzător în procedură e un gol vizibil, nu o părere.
- *Extracția fiabilă de date* din rapoarte, formulare, notificări: fiecare valoare extrasă vine cu domeniul ei, cu marja și cu propoziția sursă, iar „nu e precizat” e un răspuns, nu o celulă goală fără explicație.
- *Verificarea rezumatelor și extracțiilor făcute de modele mari* (9.2): confirmat, contrazis, neverificabil, cadru cu cadru, cu indicarea exactă a locului de verificat.

Ce caută un auditor sau un regulator la un asemenea sistem e exact ce are: aceeași intrare dă aceeași ieșire; fiecare răspuns e trasabil la o propoziție și la o linie din legendă; modelul e mic și poate fi inspectat în întregime; datele nu părăsesc instituția, pentru că nu e nevoie de niciun serviciu extern ca să citești. Logica de validare a sistemelor computerizate din industriile reglementate cere componente al căror comportament poate fi specificat, testat și reprodus; un cititor determinist cu o legendă scrisă de oameni se potrivește acelei logici într-un fel în care un model mare, prin natura lui, nu se poate potrivi.

Unde intră modelele mari, și unde nu

Nu ascundem că modelele mari sunt necesare. Ele scriu primele versiuni ale cadrelor de antrenare, parafrazează, rezumă text deschis, tratează coada grea a cererilor și propun formalizări ale documentelor complexe. Rolul nostru e cel definit în tot acest document: stratul verificabil dintre limbaj și acțiune, cel care spune ce s-a înțeles, ce nu, și unde, și prin care trece tot ce ajunge la execuție sau în baza de date. Împărțirea e curată: modelul mare pentru acoperire, pilotul pentru verificare. Într-o întreprindere, asta înseamnă costuri de inferență mai mici, latență sub milisecundă pe calea rapidă, și un jurnal pe care îl poate citi un auditor. Într-o industrie reglementată înseamnă posibilitatea de a folosi limbaj natural acolo unde până acum nu era permis, pentru că nu putea fi verificat.

Ce decide ritmul

Pentru fiecare domeniu, legenda și carnetul: inginerie de domeniu, cu conducta de adnotare deja desenată. Măsurile care decid ritmul sunt verificatorul cu erori injectate pe text real, calibrarea raportată pe fiecare tabel și proporția de cereri care rămân pe calea rapidă într-un domeniu real. Direcția e clară și pașii sunt incrementali; ce se câștigă la

fiecare pas se măsoară în cereri servite fără model mare și în erori prinse înainte de execuție.

12. Mai departe: documente, noutate, părtinire, netezire

O propoziție e un traseu scurt. Un document e unul lung: multe hărți, legate prin chei („contractul menționat mai sus” e o cheie înapoi spre o hartă anterioară). Odată ce documentele sunt hărți cu legende, trei lucruri care îi interesează pe oameni se dovedesc geometrice.

Noutatea. Citește un articol științific față de legenda domeniului lui, unde stelele cu nume sunt rolurile proprii domeniului: problema abordată, metoda folosită, mărimea măsurată, rezultatul obținut. Cea mai mare parte a constelației articolului cade în domenii deja ocupate de stele cunoscute: o metodă cunoscută, o problemă cunoscută. Noutatea e regiunea în care nu cade așa: o stea într-un domeniu în care câmpul avea alt ocupant, sau stele în puncte pe care legenda nu le numește deloc. Nu „sună nou”, ci „diferă de legendă aici, în domeniul ăsta”. Mărimea și locul acelei regiuni sunt măsura.

Părtinirea. Două relatări ale aceluiași eveniment ar trebui să deseneze aceeași constelație. Când o sursă desenează constant aceleași stele în domenii deplasate, cel care a acționat devine cel afectat, cauza devine o împrejurare, acea deplasare e o cheie în plus, aceeași peste multe perechi de relatări. Părtinirea unei surse e direcția medie în care constelațiile ei deviază de la ale celorlalte, lizibilă domeniu cu domeniu. Nu cere să știi ce s-a întâmplat de fapt; cere doar mai multe relatări de comparat, și legenda.

Netezirea (smoothing). E un concept din propria noastră cercetare: o părtinire care nu deformează, ci omite. Consecința care nu convine pur și simplu nu e menționată. Răspunsul e lustruit, diplomatic, și nimic din el nu e fals. Metodele care examinează ce se spune nu o pot vedea, pentru că nimic din ce se spune nu e greșit. În povestea noastră e o părtinire a absenței. Legenda unui eveniment are un domeniu pentru consecința lui și unul pentru cine o suportă; în relatările neutre ale acelui fel de eveniment, domeniile acelea sunt pline de cele mai multe ori. La o sursă care netezește, ele sunt sistematic goale. Traseul ocolește o regiune a cerului. Propunem să-i spunem *evitare de regiune a cadrului*, și poate fi măsurată fără să înțelegi conținutul consecinței: e de ajuns să știi că acel domeniu există în legendă, că de obicei e plin, și că aici nu e.

Toate trei sunt *indicatori candidați*, nu măsuri validate: un rest mare poate fi o citire greșită, nu noutate; o abatere de la celelalte surse poate fi o minoritate care are dreptate, nu părtinire; un domeniu gol poate fi concizie sau lipsă de informație, nu netezire. Fiecare cere controale (întrebarea pusă, informația disponibilă, lungimea, relevanța consecinței omise) înainte să primească numele fenomenului. Și toate sunt direcții. Au nevoie de legende la nivelul evenimentelor, nu al propozițiilor, de rate de bază pe domeniu de activitate pentru cât de des se umple fiecare domeniu, și de legarea referințelor între propoziții. Nu are nevoie ca pilotul să cunoască lumea. Are nevoie doar de forma evenimentelor, iar forma e ce învață.

13. Pentru cei cu înclinație tehnică: povestea, tradusă

Tot ce e mai sus a fost spus în imagini. Capitolul acesta spune aceleași lucruri în vocabularul domeniului din care vin imaginile. Nimic de aici nu schimbă imaginea; îi numește părțile. Întâi dicționarul, apoi detaliile.

În poveste	În matematică
un punct din cer; coordonatele lui (codul cu mii de rotițe)	un vector de D numere complexe de modul unu (faze); D de ordinul miilor
„aproape” / „fără legătură”	similaritate cosinus mare / aproape zero
două puncte aleatoare n-au legătură	cvasi-ortogonalitatea vectorilor aleatori (concentrarea măsurii)
steaua unui cuvânt; catalogul	hipervectorul-identitate: aleator, fix, neînvățat; codebook-ul
a muta un punct cu un cod	binding: înmulțire element cu element = adunare de faze; izometrie, inversabilă, comutativă
cheia inversă; a muta înapoi	înmulțire cu conjugatul (unbinding)
pilotul	modelul: parametrii învățați plus procedura fixă de citire; nu conține fapte despre lume
sonda; poziția raportată	starea de adresă A_t: produsul vectorilor de deplasare folosiți până la t
cheia unui fel de cuvânt; carnetul de rute	vectorii de deplasare învățați, pe categorie
a desena steaua cuvântului mutată cu poziția sondei	binding-ul identității cu adresa curentă: A_t (x) f_w
harta propoziției; constelația; a topi	starea S = bundle (sumă nerenormalizată) a depunerilor; se compară prin cosinus
legenda; steaua cu nume a unui rol	vectorii de rol R_r, dați de lume
domeniul unui rol	mulțimea {R_r (x) f : f în codebook}; o copie izometrică a codebook-ului
„Ion în domeniul agentului”	R_agent (x) f_Ion
scanerul	cleanup: cel mai apropiat vecin din codebook, după cosinus; marja = diferența între primii doi
steaua „relatat”; originea mutată; nivelul	vectorul de rol R_rep; imbricarea = binding cu R_rep de d ori
balize cu chei relative, ținut deoparte, porți	codul-lanț cu reașezare spre stânga; porțile = sigmoide învățate
cele trei desene	bundle de coduri de adresă: drum, bigram, lanț

În poveste	În matematică
constelația lumii	S_lume = suma R_r (x) f_umplutură, cu operatorii ca roluri
stele neexplicate	reziduul de reconstrucție
markerul „aici a fost desenat ceva”	un vector fix topit cu fiecare umplutură
drumurile formează o grilă, nu un arbore	comutativitatea binding-ului: adresa e un multiset de roluri

Familia

Povestea e o Arhitectură Vector-Simbolică (VSA), numită și calcul hiperdimensional, o linie de lucru care urcă până la reprezentările holografice reduse ale lui Plate (1995), calculul hiperdimensional al lui Kanerva (2009) și multiply-add-permute al lui Gayler. Dintre variantele ei folosim pe cea complexă cu componente de modul unu, pe care Plate a introdus-o și pe care Frady, Kleyko și Sommer au dezvoltat-o în *codarea cu puteri fracționare*. Cele două operații, binding și bundling, sunt primitivele oricărei VSA; cleanup-ul e recuperarea celui mai apropiat vecin. Cvasi-ortogonalitatea vectorilor aleatori e faptul de concentrare a măsurii care dă familiei puterea ei: cosinusul așteptat între doi vectori aleatori de fază unitară e zero, cu varianță de ordinul unu pe D.

Atomi și compuși

Identitatea unui cuvânt e un hipervector atomic. Vectorii de rol sunt și ei atomici, trași o dată și ficși. O pereche rol-umplutură e binding-ul celor doi; un cadru e bundle-ul perechilor lui, codarea VSA standard a unei structuri, datorată lui Plate și, înaintea lui, produselor tensoriale ale lui Smolensky. Imbricarea e binding cu vectorul de rol „relatat”; citirea unui rol la adâncimea d înseamnă unbinding cu conjugatul acelui vector de d ori, apoi cu conjugatul rolului, apoi cleanup. Compoziția la o adâncime nevăzută e asociativitatea acestei algebre.

Ce calculează modelul

Pentru cuvintele w_1 … w_T, fiecare cu identitate fixă f_w și categorie c_w, starea e S = suma peste t din A_t (x) f_{w_t}, unde A_t e adresa poziției t: un bundle de coduri, fiecare un produs de vectori de fază învățați. Codul *drum*: produsul vectorilor de categorie ai tuturor cuvintelor până la t (integrarea de drum). Codul *bigram*: un vector indexat de categoria anterioară și cea curentă. Codul *lanț*: adresa luată de la o așteptare; un cuvânt a cărui categorie are poarta deschisă (sigmoidă învățată) emite, pentru fiecare categorie, o așteptare la adresa lui legată de un vector relativ învățat; un cuvânt ulterior din acea categorie ia cea mai recentă așteptare neconsumată; un cuvânt sosit înaintea oricărei așteptări e reținut și așezat de primul emițător care urmează. Pentru învățarea porților, o relaxare diferențiabilă ponderează fiecare adresă candidată cu sigmoida porții, astfel încât porțile și fazele se antrenează cu același gradient.

Pentru că înmulțirea element cu element comută, fiecare adresă e un multiset de vectori, nu un șir: drumuri de roluri care diferă doar prin ordine se leagă la aceeași adresă. Variantele necomutative (binding cu permutări, roluri indexate pe nivel) sunt alternativele cunoscute

și cedează compoziția liberă peste adâncimi. Lumile de până acum n-aveau rol de predicat, nici identificatori de eveniment; amândouă sunt adăugiri care nu schimbă arhitectura.

Toate codurile sunt învățate pe categorie, niciodată pe cuvânt: câteva sute de vectori de fază plus un scalar de poartă pe categorie. Categoriile vin din afara modelului (date, pe lumi sintetice; din gruparea unui embedding skip-gram, pe text real). Am arătat că grupările induse de propriile deplasări coincid cu ale unui skip-gram simplu pe aceleași propoziții, și nu le revendicăm ca emergente; porțile nu sunt recuperabile din co-apariție și sunt partea care emerge.

Lumea și obiectivul

Lumea dă, pentru fiecare propoziție, S_lume = suma peste roluri din R_r (x) f_umplutură, cu imbricarea prin R_rep și operatorii (negație, scop de cuantificator) legați ca roluri în jurul scopului lor. Identitățile sunt împărțite între model și lume; vectorii de rol sunt legenda. Obiectivul e maximizarea cosinusului între S și S_lume. E generativ: modelul produce vectorul lumii printr-o izometrie fixă, nu printr-o funcție învățată. Am arătat că această fixitate e ce forțează convergența: o citire asociativă învățată, chiar cu rang limitat, duce stări distincte la aceeași țintă fără să le facă egale, și apoi nu generalizează la identități noi și adâncimi nevăzute, exact ca un transformer mic. Antrenarea e Adam pe faze și pe logit-urile porților; minute pe un GPU, fezabil pe CPU.

Citirea înapoi și diagnosticele

Decodarea rolului r la adâncimea d: S legat de conjugatul lui R_rep de d ori și de conjugatul lui R_r, apoi cosinus cu fiecare candidat; argmax-ul e umplutura, diferența față de al doilea e marja; adâncimea se estimează încercând fiecare d. Cadrul e mulțimea acestor citiri; conversia în Prolog sau SMT-LIB e o rescriere sintactică a cadrului, dată o semantică fixată a operatorilor (negația clasică în SMT; în Prolog negația prin eșec, cu precauțiile ei).

Diagnosticele din capitolul 8 vin din aceleași citiri, cu o precizare ușor de scăpat din vedere: unbinding-ul e o izometrie, deci norma a ce se întoarce dintr-un rol nu spune nimic despre ocupare. Disponibile sunt: cel mai bun cosinus și marja (recunoașterea); reziduul de reconstrucție, după potrivirea scării, relativ la normă și la fondul lumii (materia neexplicată); poziția la care marjele se prăbușesc (cheia ruptă). A deosebi umplutura absentă de cea necunoscută cere markerul de ocupare. S e sumă simplă, nerenormalizată; comparațiile sunt prin cosinus.

Ce e standard, ce e al nostru

Standard: algebra, codarea rol-umplutură, imbricarea prin binding, cleanup-ul, rezultatele de capacitate, codarea cu puteri fracționare și citirea celulelor grilă prin ea (Frady, Kleyko, Sommer), care e legătura cu teoria lui Hawkins.

Al nostru, și testat: că adresele pot fi *învățate* ca produse de vectori de fază pe categorie dintr-un obiectiv generativ pe o lume cu roluri explicite, astfel încât parafrazele își leagă umpluturile de aceleași roluri fără etichete de parafrază; că un bundle de coduri de adresă redundante face asta robust la construcții nevăzute; că adresarea prin așteptări cu reașezare spre stânga dă adrese nete și compune cu un nivel mai departe decât a fost

antrenată; că porțile emerg prin gradient și coincid între lumi și cu textul real; că operatorii logici legați ca roluri în jurul scopului sunt citiți corect, inclusiv scopul, fără reguli; și că aceeași stare dă, prin marje și reziduul de reconstrucție, o relatare utilizabilă a ceea ce cititorul n-a înțeles.

14. Din ce se poate face cerul: variante de reprezentare, codul rar și creierul

Povestea a fost spusă într-un singur material: puncte cu coordonate pe mii de rotițe, adică vectori de faze. Nu e singurul material posibil. Familia de reprezentări din care facem parte, arhitecturile vector-simbolice, a construit aceleași trei operații, a muta, a topi, a recunoaște, în mai multe feluri, iar alegerea între ele e o decizie de inginerie cu consecințe pentru cost, hardware și apropierea de ce se știe despre creier. Capitolul acesta spune care sunt variantele, de ce am ales-o pe a noastră, ce ar aduce codul rar, de ce se crede că în creier codul e rar, și, mai ales, ce parte din ce am construit depinde de material și ce parte nu.

Aceleași trei operații, mai multe materiale

Tot ce cere povestea de la un material e: puncte alese la întâmplare să fie fără legătură între ele; mai multe puncte să poată fi topite într-unul singur din care fiecare să rămână recunoscibil; și o operație de mutare care păstrează forma și se desface exact. Fiecare familie le realizează altfel.

- *Vectori de semne* (+1 și −1 pe mii de poziții): mutarea e înmulțirea poziție cu poziție, care e propriul ei invers; topirea e un vot majoritar pe fiecare poziție. Simplu, binar, ieftin; mutarea e exactă doar aproximativ după topire, pentru că votul rotunjește.
- *Vectori reali cu convoluție circulară* (reprezentările holografice reduse ale lui Plate): mutarea e convoluția, inversul e aproximativ (corelația), topirea e adunarea. Istoric prima variantă completă; inversul aproximativ costă precizie la adâncimi mari.
- *Faze complexe* (varianta noastră, numită și holografică în domeniul frecvenței): fiecare poziție e un unghi; mutarea e adunarea unghiurilor, inversul e scăderea lor, exact; topirea e adunarea săgeților. E convoluția lui Plate scrisă în domeniul Fourier, unde devine exactă și ieftină.
- *Coduri rare pe blocuri*: fiecare poziție e un bloc de L unități din care e activă una; mutarea e deplasarea unității active în bloc; topirea e suprapunere urmată de competiție în bloc. Echivalentul rar al fazelor, pe care îl descriem mai jos.
- *Coduri binare rare cu subțiere*: puține unități active din foarte multe; topirea cere o operație care păstrează raritatea; mutarea e o operație dependentă de context. Cele mai apropiate de reprezentările rare din neuroștiință, cele mai departe de învățarea cu gradient.
- *Legare prin permutări sau matrici*: mutarea e o permutare a pozițiilor sau o înmulțire cu o matrice; nu comută, deci păstrează ordinea, cu prețul discutat în capitolul 8 la „Ordinea”.

Ce au în comun toate: separarea prin aleator, suprapunerea, inversabilitatea. Unde diferă: cât de exact e inversul, câte lucruri încap într-o hartă la același număr de poziții, cât costă o operație, și cât de ușor se poate învăța o mutare cu gradient.

De ce am ales fazele

Patru motive, în ordinea importanței. Inversul e exact, deci citirea unui domeniu la orice adâncime nu acumulează erori de material, ci doar zgomotul suprapunerii. Mutările sunt continue, deci carnetul de rute se învață cu gradient, pas cu pas, ceea ce a făcut posibil tot capitolul 6. Aceeași codare servește și mărimi continue: un număr, o poziție, un moment sunt faze cu unghi proporțional cu mărimea, iar „40” și „41” sunt stele apropiate fără să fie identice. Și, al patrulea, fazele sunt exact modelul matematic prin care literatura de calcul hiperdimensional a descris integrarea de drum a celulelor grilă, ceea ce leagă direct povestea de teoria din capitolul următor.

Prețul e că fazele sunt dense: fiecare rotiță are mereu o valoare, și o hartă e un șir de mii de numere reale. Pe un procesor obișnuit nu contează; pe hardware foarte simplu, sau ca model al cortexului, contează.

Codul rar: același cer, scris în neuroni

Reprezentarea densă cu faze are un echivalent rar, și echivalența e exactă, nu o analogie: o rotiță cu L poziții e un bloc de L unități din care e activă una singură, cea de la unghiul rotiței. Mutarea devine deplasarea unității active în interiorul blocului (adunare modulo L); topirea devine suprapunere, mai multe unități active în bloc, urmată de o competiție care păstrează cele mai active k; scanerul rămâne același. Familia e cunoscută (coduri rare pe blocuri), iar echivalența cu fazele trece prin transformata Fourier.

Ce ar aduce. Aritmetică pe indici întregi în loc de numere complexe, deci implementare directă pe microcontrolere sau circuite programabile, exact ce cere interlock-ul din capitolul 10. Memorie de ordinul biților pe rotiță (log L biți) în loc de zeci. O normalizare naturală: competiția în bloc e tocmai ce lipsește hărții dense, care la multe stele alunecă spre „mijloc”; și, interesant, competiția păstrează reuniunile de ipoteze: două unități active într-un bloc înseamnă „ori una, ori alta”, adică exact reuniunea de ipoteze din teoria lui Hawkins, apărută de la sine. Și o raritate de ordinul procentului, ca în cortex.

Ce ar costa. Unghiurile se cuantizează la L poziții, deci mărimile continue au granularitate 360/L; la L de ordinul zecilor sau sutelor probabil nu doare, dar e un parametru în plus. Antrenarea rămâne pe faze continue, cuantizarea făcându-se la sfârșit; cât se pierde se măsoară, și e unul dintre experimentele planificate. Capacitatea e comparabilă ca ordin de mărime, dar detaliile diferă cu L și k.

De ce se crede că în creier codul e rar

Trei linii de dovezi, cu rezervele lor. Întâi, bugetul energetic: un neuron care descarcă consumă mult, iar estimările clasice arată că cortexul nu-și poate permite decât o fracție mică de neuroni activi în același timp, de ordinul procentelor; un cod dens ar fi nesustenabil metabolic. Al doilea, codarea rară ca principiu de calcul: lucrările lui Olshausen și Field au arătat că un sistem care învață să reprezinte imagini naturale cu cât mai puține unități active deodată regăsește de la sine câmpurile receptive observate în cortexul vizual; e unul dintre cele mai reproduse rezultate din neuroștiința computațională. Al treilea, structura: modulele de celule grilă funcționează ca atractori în care e activ un

singur „ghem” de celule, a cărui poziție codifică faza, adică exact un bloc rar cu o unitate activă; iar teoria din capitolul următor pune reprezentările rare la baza întregului neocortex.

Rezervele, la fel de clar: există arii și regimuri cu activitate densă; dezbaterea despre cât contează rata de descărcare față de sincronizarea descărcărilor nu e închisă; și „rar” e o constatare despre activitate, nu o dovadă că algebra folosită de creier e una dintre cele de mai sus. Spunem deci „se crede, cu dovezi consistente”, nu „se știe”.

Unde e inovația și unde e ingineria

Algebra, oricare dintre variante, e standard și veche de treizeci de ani; nu revendicăm nimic din ea. Ce am construit stă *deasupra* materialului și nu depinde de el: deplasările învățate pe fel de cuvânt, cele trei desene ale aceluiași cuvânt, porțile care decid cine pune balize, lumea ca țintă de antrenare, operatorii ca roluri în jurul scopului lor, citirea cu marjă și rest. Fiecare dintre acestea se scrie la fel pe faze, pe blocuri rare sau pe semne; ar fi aceeași poveste, cu alt cer. Pentru cine evaluează proiectul, asta e un argument de robustețe: rezultatele nu atârnă de o alegere de material, iar materialul se poate schimba când ținta de hardware o cere.

Ingineria e alegerea materialului pentru țintă: numărul de rotițe, L și k pentru codul rar, cuantizarea, maparea pe un circuit. Și cercetarea viitoare e tot aici, cu întrebări precise: dacă antrenarea direct pe cod rar (nu doar cuantizarea la sfârșit) păstrează rezultatele; dacă competiția în bloc dă reuniunea de ipoteze cu aceeași precizie ca suprapunerea densă; dacă legarea necomutativă se poate adăuga doar operatorilor, păstrând compoziția liberă pentru rest; și cât din capacitatea unei hărți se recuperează prin structuri de hărți în loc de rotițe în plus. Niciuna nu schimbă povestea; fiecare schimbă cât de ieftin și cât de aproape de creier poate fi spusă.

15. Paralela cu *O mie de creiere*

Povestea de mai sus n-a apărut din nimic. Punctul de plecare a fost teoria lui Jeff Hawkins despre neocortex, expusă în *A Thousand Brains* (2021) și în lucrările grupului Numenta dinaintea ei. Datorăm o punere față în față cinstită: ce am luat, ce am tradus, ce avem în altă formă și ce n-avem deloc. E și instructiv, pentru că fiecare piesă a poveștii are un corespondent în teorie, iar diferențele spun exact ce fel de lucru am construit.

Ce spune teoria, în cinci propoziții

Neocortexul e făcut din zeci de mii de *coloane corticale*, toate cu aceeași structură. Fiecare coloană învață modele complete ale obiectelor din lume, nu fragmente. Un model e un *cadru de referință* ancorat pe obiect, în care trăsăturile sunt stocate la *locații*: a cunoaște o cană înseamnă a ști ce se simte la fiecare loc de pe ea. Locația curentă e ținută de celule asemănătoare celulelor grilă din hipocamp și e actualizată prin *mișcare*: când degetul se mută, locația se mută cu el, înainte ca orice senzație să sosească (integrare de drum). Coloanele, fiecare cu dovezi parțiale, *votează* prin legături lungi și converg rapid pe un singur obiect; cât nu converg, țin deschisă o reuniune de ipoteze. Și, afirmația cea mai

îndrăzneață: același mecanism, cadre de referință plus mișcare, servește și pentru concepte și limbaj, unde „mișcarea” e abstractă.

Dicționarul

În teoria lui Hawkins	În poveste	În matematică
cadrul de referință al unui obiect	cerul, cu legenda ca ancore	spațiul vectorilor de fază; vectorii de rol
o locație în cadru; celulele grilă	un punct din cer; fiecare rotiță e faza unui modul de grilă	un vector de faze (codarea cu puteri fracționare)
mișcarea; integrarea de drum	saltul sondei; poziția = suma cheilor	binding-ul adreselor; produsul deplasărilor
o trăsătură stocată la o locație	steaua unui cuvânt mutată cu poziția sondei	A_t (x) f_w
modelul unui obiect	constelația unui eveniment	starea S
recunoașterea obiectului	compararea constelațiilor; cadrul citit prin legendă	cosinus cu S_lume; unbinding și cleanup
celulele de deplasare; obiect în obiect	steaua „relatat”; legenda mutată la altă origine	binding cu R_rep; imbricarea
predicția următoarei senzații	balizele: unde va cădea următorul cuvânt de un anumit fel	codul-lanț cu vectori relativi
votul între coloane	cele trei desene ale aceluiași cuvânt, topite; scanerul	bundle de coduri de adresă; cleanup cu marjă
reuniunea de ipoteze	o stea desenată între două domenii; ambiguitatea ținută deschisă	superpoziția a două adrese în S
surpriza; ce nu se potrivește cu modelul	stelele în afara legendei	reziduul de reconstrucție
mii de coloane	un singur pilot	un singur model

Ce am luat literal

Două lucruri sunt luate ca atare, nu ca metaforă. Întâi, *locația ca fază*. Celulele grilă codifică o poziție ca un set de faze, câte una pe modul, iar mișcarea adună faze; codarea cu puteri fracționare pe care o folosim e exact acest mecanism scris ca vectori, și a fost propusă în literatura de calcul hiperdimensional tocmai ca model al celulelor grilă și al integrării de drum. Rotițele din poveste corespund, în modelul matematic, modulelor de grilă; e o corespondență formală, nu o afirmație despre biologie. Al doilea, *cunoașterea ca trăsături la locații*. Harta unei propoziții nu stochează cuvintele, ci cuvintele-la-poziții, și două propoziții sunt același obiect când au aceleași trăsături la aceleași locații, indiferent de drumul senzorului. Asta e definiția unui obiect la Hawkins, aplicată la evenimente.

A treia preluare e cea pe care am descoperit-o abia pe drum: *compoziția prin deplasare*. Hawkins propune „celule de deplasare” care țin vectorul dintre două locații, ca să poată pune un obiect în cadrul altuia: sigla pe cană e cadrul siglei, așezat la o deplasare în cadrul cănii. Propoziția relatată din „Maria spune că…” e exact asta: cadrul propoziției interioare, așezat la deplasarea „relatat” în cadrul celei exterioare. Faptul că pilotul citește trei niveluri după ce a învățat două e proprietatea pe care teoria o prezice pentru deplasări: o deplasare se aplică de oricâte ori.

Unde e votul

Întrebarea cea mai bună pe care ne-a pus-o cineva despre poveste a fost „unde e votul?”. În teorie, votul e între coloane: fiecare coloană are o ipoteză despre ce obiect simte, ipotezele se trimit una alteia, și mulțimea candidaților se îngustează până rămâne unul. Noi n-avem coloane; avem un singur pilot. Dar votul există, în două locuri mai mici.

Primul: *cele trei desene*. Pilotul are trei feluri de a afla unde e un cuvânt, din trei surse de dovezi diferite, cu moduri de a greși diferite: drumul parcurs (suma tuturor cheilor de la începutul propoziției), tranziția locală (ce fel de cuvânt a fost chiar înainte) și așteptarea deschisă de un cuvânt anterior (baliza). Fiecare e o „coloană” care spune „cuvântul e aici”. Nu le lăsăm să discute; le topim. Topirea e un vot prin suprapunere: unde cele trei sunt de acord, săgețile se adună și steaua e netă; unde una greșește, celelalte două o acoperă și steaua e doar puțin încețoșată. E un vot fără dezbatere, într-o singură rundă, și tocmai de aceea e ieftin.

Al doilea: *scanerul*. Când harta e mutată înapoi cu o stea cu nume, ce rezultă e comparat cu toate stelele din catalog deodată, și cea mai apropiată câștigă, cu o marjă. E un vot între candidați, nu între coloane, dar are aceeași formă: toți concurează, unul iese, iar diferența față de al doilea spune cât de convins e votul. Iar când nu iese unul, când doi candidați sunt la fel de aproape, pilotul nu forțează; raportează amândoi. Asta e *reuniunea de ipoteze* din teorie, ținută deschisă până sosește o dovadă care o închide: așa citim „fiecare copil citește o carte” cu ambele înțelesuri deodată, și așa stă primul cuvânt pe jumătate în două domenii până sosește verbul.

De ce doar trei

Pentru că trei e numărul surselor de dovezi *diferite* pe care le-am găsit, nu un număr ales. Un vot folosește doar dacă votanții greșesc în feluri diferite; trei copii ale aceluiași calcul nu adaugă nimic. Drumul parcurs greșește când o cheie din șir e greșită și duce tot ce urmează aiurea; tranziția locală nu greșește aproape niciodată, dar e grosolană, pentru că nu știe decât ce a fost chiar înainte; baliza e precisă, dar lipsește când construcția e nouă și nimeni n-a anunțat-o. Cele trei se acoperă reciproc, și măsurătoarea arată cât: construcțiile nemaivăzute se citesc nouă din zece cu toate trei, șase din zece cu una singură.

Am încercat și o a patra sursă: locul cuvântului în propoziție, al treilea, al cincilea. A adus puțin în plus pe construcțiile noi, și totuși am renunțat la ea. Argumentul de principiu e că leagă citirea de locul cuvântului în șir, adică exact de lucrul pe care parafrazele îl schimbă; iar decizia se remăsoară cu ambele variante pe aceleași teste. O a cincea sursă ar trebui să

fie din nou un fel diferit de a greși, și n-am găsit-o încă. Dacă apare, se adaugă ca o nouă săgeată la topire, fără să se schimbe altceva: acesta e avantajul votului prin suprapunere.

Există și un răspuns mai larg la „de ce nu mii". În teorie, miile de coloane primesc fiecare altă bucată din lume: alt deget, alt petic de retină. În text, intrarea e un singur șir de cuvinte, și nu există mii de senzori independenți care să-l simtă din unghiuri diferite. Versiunea cu adevărat „cu o mie de creiere" ar avea mulți piloți care citesc același text cu catalogul literelor, cu cel al cuvintelor, cu cel al grupurilor de cuvinte, sau mai multe simțuri deodată, cum spune 9.4, și ar vota între ei. E un pas de făcut; cele trei desene sunt forma ei cea mai mică, într-un singur pilot.

Unde ne despărțim, și de ce

Mișcarea e ghicită, nu dată. În teorie, locația se actualizează din mișcarea senzorului, pe care creierul o cunoaște pentru că el a comandat-o. În text, nimeni nu ne spune cât „ne mișcăm" la fiecare cuvânt; saltul trebuie dedus din felul cuvântului, și asta e tot ce învață pilotul. Limbajul e cazul greu al teoriei, nu cel ușor; oriunde mișcarea e dată direct, de un senzor, de o comandă motorie, de timp, mașinăria se aplică fără partea învățată.

Învățarea e de la lume, nu din predicție. Coloanele lui Hawkins învață prezicând următoarea senzație, fără profesor. Pilotul nostru învață de la constelația lumii: i se spune cum trebuie să arate harta, și își ajustează cheile ca să ajungă acolo. Am încercat varianta cu profesor zero, prezicerea următorului cuvânt, și domeniile au dispărut: nimic n-a obligat pilotul să separe rolurile. Nu afirmăm că în creier e altfel; afirmăm că în textul fără lume, predicția singură nu ne-a dat cadre de referință cu roluri. E o diferență de regim, nu de mecanism, și o declarăm ca atare.

Cadrul e dat, nu învățat. La Hawkins, coloana învață ea însăși cadrul obiectului. La noi, stelele cu nume ale legendei vin de la lume; ce învață pilotul e drumul spre ele și cine deschide cadre (porțile). Am verificat că felurile de cuvinte nu apar de la sine din obiectivul nostru, și am retras afirmația contrară; porțile, în schimb, apar.

Un singur drum înainte, fără memorie între propoziții. Teoria are coloane care integrează în timp și se întorc asupra ipotezelor; pilotul merge înainte, o propoziție, o hartă, și uită. Structura anunțată după și referința pronumelor sunt exact locurile unde se vede lipsa.

Substratul. Reprezentările din teorie sunt rare și binare; ale noastre sunt dense, faze pe mii de rotițe. Proprietățile care contează pentru poveste (două puncte aleatoare n-au legătură, suprapunerea ține mai multe lucruri, mutarea păstrează forma) sunt comune celor două familii; detaliile de capacitate diferă.

Ce rămâne, după ce scădem diferențele, e afirmația pe care am testat-o și care ține: un cadru de referință cu locații date de mișcare și trăsături depuse la locații, cu compoziție prin deplasare și vot prin suprapunere, e suficient pentru ca propoziții diferite despre același eveniment să ajungă la aceeași hartă, pe lumi construite și pe un set real de întrebări, și pentru ca harta să spună unde n-a ajuns. Restul teoriei, miile de coloane, învățarea fără profesor, cadrele învățate, e ce urmează, și e lista de pe masă.

16. Alinierea și problemele din jurul ei: ce se poate spune inginerește

Prin *aliniere* înțelegem aici ceva modest și verificabil: un sistem care primește cereri în limbaj să facă ce i s-a cerut, numai ce e permis, și să se vadă limpede când n-a înțeles sau când a ieșit din ce e permis. Nu propunem o soluție la alinierea modelelor mari de limbaj; nu le atingem interiorul și nu pretindem că l-am putea atinge. Ce avem e altceva: o *interfață verificabilă* între limbaj și acțiune, și câteva măsurători care devin posibile de îndată ce sensul e definit ca în 1.1, un set de răspunsuri la întrebări știute dinainte. Capitolul spune, pentru fiecare problemă, ce mecanism avem; ce e construit și ce e în lucru din fiecare se citește în fișierul de stare al proiectului (https://github.com/ml-circuits-research/vsa-semantic-space/blob/main/STATUS.md).

Ideea de bază: legenda ca graniță

Un sistem care acționează în lume primește cereri în limbaj natural și produce acțiuni: o interogare, o comandă, un răspuns, o modificare într-o bază de date. Cele mai multe probleme de aliniere trăiesc la această trecere: cererea e înțeleasă altfel decât a fost spusă, acțiunea e alta decât cea cerută, sau răspunsul sună bine și e fals. Propunerea inginerească e ca trecerea să nu se facă direct. Orice cerere și orice acțiune propusă de modelul mare trec prin pilot, care le transformă în răspunsuri la întrebările unei *legende de acțiune*: ce acțiune? asupra cui? cu ce parametri? sub ce condiție? în numele cui? Legenda e scrisă de oameni, are câteva zeci de rânduri, și tot ce nu încape în ea nu e reprezentabil, deci nu poate ajunge la execuție. Nu e un filtru care caută cuvinte interzise; e o formă în care anumite lucruri nu pot fi spuse deloc.

Cadrul citit se traduce mecanic în fapte și constrângeri (9.3), politicile sunt scrise ca reguli în același limbaj, și un motor de raționament decide dacă acțiunea e permisă, cu o derivare care se poate arăta. Împărțirea rolurilor e strictă: modelul mare *propune*, pilotul *citește independent*, motorul *verifică*, și modelul mare nu atinge niciodată actuatorul. Piesele există: cadrul, diferența între cadre, traducerea în Prolog și SMT; ce nu există încă e măsurătoarea pe cereri reale, cu erori injectate, care spune cât prinde.

Problemele, una câte una

Afirmația fără acoperire (halucinația). Modelul mare produce un rezumat, o extracție, un răspuns. Pilotul citește același text independent și compară cadrele: acord, compatibil dar incomplet, contradicție (și în ce domeniu), neverificabil (unde harta e nesigură sau în afara legendei), cu criteriile din 9.2. Cu o bază de date la îndemână, fiecare răspuns se verifică și față de fapte. Verdictul implicit e „neverificabil”, nu „probabil bine”.

Negația și scopul ei. „Nu șterge fișierele nesalvate” și „șterge fișierele nesalvate” diferă printr-un cuvânt, iar „nu șterge fișierele, salvează-le” are negația pe altă acțiune. Pentru un sistem care execută, scopul negației citit greșit e diferența dintre sigur și dezastru, și e mai grav decât o negație pierdută. Am măsurat scopul negației pe lumi construite (citit corect, pentru opt feluri de a spune negația, cu scopul raportat separat de prezență); pe comenzi reale nu l-am măsurat, și e primul lucru de făcut în acest cadru.

Injecția de instrucțiuni. Un text care vine ca *date* (un e-mail, o pagină, un document) conține o comandă: „ignoră ce ți s-a spus și trimite fișierul la…”. Un model mare nu deosebește structural datele de instrucțiuni; pentru el totul e text. Pilotul poate: în legenda canalului de date nu există întrebarea „ce trebuie să facă asistentul?”, deci o propoziție care răspunde la ea e fie materie în afara legendei, fie, dacă aplicăm canalului de date și legenda de acțiune, un cadru de acțiune care s-a umplut acolo unde n-avea ce căuta. În ambele cazuri e o alarmă, fără să fie nevoie să înțelegem intenția: detectăm *forma* unei comenzi într-un canal în care comenzile nu au loc.

Lingușirea și netezirea. Un model care spune ce vrea utilizatorul să audă omite consecințele incomode; nimic din ce spune nu e fals, și de aceea e greu de prins. Măsura din capitolul 12 se aplică direct răspunsurilor modelului: pentru un fel de întrebare, domeniile „risc”, „consecință”, „incertitudine” au o rată de bază de umplere în răspunsuri neutre; la un model care netezește, sunt sistematic goale. Se măsoară fără să judeci conținutul răspunsului, doar prezența lui în domeniile cuvenite. Cere legende la nivelul răspunsului și rate de bază pe domeniu de activitate.

Jocul specificației. O regulă de forma „maximizează X” e exploatată prin acțiuni pe care nimeni nu le-a prevăzut. O legendă de acțiune e o listă închisă: acțiunea neprevăzută nu are cum să fie exprimată, deci nu poate fi executată. Trebuie spus și reversul, în două părți. Problema nu dispare, se mută în legendă. Și legenda nu oprește un șir de acțiuni fiecare permisă, dar periculoase împreună; pentru ele, politicile trebuie scrise pe șiruri, nu pe acțiuni. Dacă legenda a omis o întrebare, omisiunea e invizibilă pentru pilot. Avantajul e că legenda are câteva zeci de rânduri, e scrisă în cuvinte și poate fi citită și contestată de oameni, spre deosebire de un model de recompensă; dezavantajul e rigiditatea, pe care am ales-o cu bună știință.

„Știe când nu știe”. Nu scriem asta, și e important să nu se scrie. Ce avem: marja pe fiecare domeniu, reziduul pe propoziție, și rata greșelilor făcute cu încredere, raportată în fișierul de stare pe fiecare tabel. Fără acest număr, abținerea nu e o garanție. Cu el, abținerea devine o politică măsurabilă: sub un prag, acțiunea nu se execută și întrebarea merge la om, iar cât de des se întâmplă asta și cât de des pragul lasă să treacă o greșeală sunt două curbe, nu două adjective.

Inspectabilitate și audit. Tot ce știe pilotul e un carnet cu câteva sute de chei; fiecare decizie e o hartă care se citește domeniu cu domeniu; nu există memorie între propoziții, deci nu există o stare ascunsă care să derive de-a lungul unei conversații; faptele stau într-o bază de date unde pot fi corectate. Toate acestea sunt despre pilot, nu despre modelul mare, care rămâne la fel de opac. Ce facem transparent e *interfața*: locul unde limbajul devine acțiune.

Atacuri asupra pilotului însuși. Un adversar care cunoaște mecanismul poate încerca parafraze construite ca să se citească într-un cadru inofensiv, cuvinte necunoscute puse anume ca să rupă o cheie, propoziții aglomerate ca să înece un domeniu. Tot ce rupe citirea scade marja sau crește reziduul și cade în „neverificabil”, care e implicitul sigur; dar un atacator care știe carnetul poate construi propoziții cu marjă mare și cadru greșit, și rata la care reușește trebuie măsurată, cu un atacator automat (un model mare pus să genereze parafraze adversariale), nu presupusă.

Ce nu rezolvă

Nu spune nimic despre obiectivele interne ale modelelor mari și nu le schimbă. Nu funcționează pe domenii deschise, fără legendă. O legendă greșită sau incompletă dă o verificare greșită sau incompletă, cu încredere. Și tot ce e mai sus se sprijină pe un număr raportat în fișierul de stare, rata greșelilor făcute cu încredere; el decide pragurile, nu arhitectura.

Rezumat

Problema	Mecanismul	Ce se măsoară
afirmații fără acoperire	citire independentă, diferență între cadre, verdict „neverificabil” implicit	precizie și acoperire pe erori injectate
negația și scopul ei	operatorii ca roluri; scopul raportat separat de prezență	scopul pe comenzi reale; greșeli cu încredere
injecția de instrucțiuni	cadru de acțiune apărut într-un canal de date; materie în afara legendei	alarme adevărate și false pe un canal de date
lingușire, netezire	domenii de risc/consecință sistematic goale față de rata de bază	rata de umplere față de rata de bază
jocul specificației	legendă de acțiune închisă; politici ca reguli; motor care decide	acoperirea legendei; mută problema în legendă
abținere	marjă, reziduu, rata greșelilor cu încredere, prag	curba acurateță–acoperire
audit	carnet mic, hartă lizibilă, fără stare între propoziții, fapte externe	lizibilitatea jurnalului, pe eșantion
atacuri asupra pilotului	implicit „neverificabil”; rată de reușită cu atacator automat	rata de reușită a atacatorului

17. Ce este, și ce nu este

Povestea cu cerul, sonda și pilotul e o imagine; capitolul acesta o lasă deoparte și spune ce fel de sistem e, față de ce se compară, și unde îi sunt limitele, în termenii în care s-ar discuta într-un articol.

Ce este

Este un *cititor vector-simbolic* de propoziții: o schemă de adresare învățată, pusă peste o algebră fixă. Algebra e cea a arhitecturilor vector-simbolice cu faze (binding prin înmulțire

element cu element, bundling prin adunare, cleanup prin cel mai apropiat vecin); identitățile cuvintelor și vectorii de rol sunt aleatori și ficși; ce se învață sunt vectorii de deplasare pe categorie de cuvânt, vectorii relativi ai așteptărilor și o poartă pe categorie, în total de ordinul unui megaoctet. Ieșirea e o stare care codifică un cadru rol-umplutură, imbricat prin binding repetat, și care se citește înapoi prin unbinding și cleanup, cu o marjă pe rol și un reziduu de reconstrucție pe propoziție. Obiectivul de antrenare e potrivirea, prin cosinus, cu o stare-țintă construită de o lume cu roluri explicite; supervizarea e structurală și pe propoziție, cu roluri date dinainte, și nu conține etichete de parafrază.

Ca tip de sistem, e un analizor semantic în cadre (un *frame parser*) cu o particularitate geometrică: starea nu e produsă de un decodor, ci compusă algebric, astfel încât compoziția la adâncimi nevăzute, tratamentul vocabularului nou și diagnosticele de incertitudine decurg din algebră, nu din învățare. Nu deține fapte: faptele stau într-o bază de date sau un motor de raționament, iar cadrul se traduce mecanic în fapte Prolog sau constrângeri SMT.

Față de ce se compară

Față de transformere și modelele de limbaj. Nu există obiectiv de predicție a cuvântului următor și nu există generare. Comparația cinstită e cu un transformer mic antrenat pe aceeași intrare și aceleași ținte: pe lumi construite, la o adâncime de imbricare neîntâlnită la antrenare, cititorul decodează rolurile interioare complet, iar transformerul e la nivelul hazardului; pe WikiSQL, într-o configurație modificată față de protocolul oficial (întrebarea singură, fără schema tabelului; se prezice coloana selectată, nu interogarea executată), coloana selectată e 0,82 față de 0,54 pentru transformerul cu aceeași intrare (0,65 cu un buget de zece ori mai mare) și 0,50 pentru o regresie logistică pe sac de cuvinte, la toate mărimile setului de antrenare începând de la o mie de exemple (tabelul pe mărimi, cu semințe și intervale, e în depozit). În sens invers, acolo unde decizia e lexicală (agregatorul din aceleași interogări), clasificatorii neuronali câștigă (0,89), iar acuratețea pe interogarea întreagă (0,37) nu e comparabilă direct cu cifrele sistemelor specializate, care văd schema tabelului și raportează alte metrici; e departe de ele. Afirmația susținută e deci precisă: pe aceeași intrare, fără cunoaștere externă, cu date puține, cititorul învață structura de roluri mai bine și generalizează compozițional; nu e un concurent pe text deschis și nu pretinde să fie.

Față de analizoarele semantice cu aceeași supervizare (etichetare de roluri semantice, parsare în cadre). Supervizarea e de același fel: ținte structurate pe propoziție. Diferențele sunt reprezentarea (stare vectorială compozabilă, nu arbore produs de un decodor), vocabularul (identități aleatoare plus categorie, deci cuvinte noi fără reantrenare) și citirea incertitudinii (marjă, reziduu, abținere). Comparația directă cu un analizor clasic antrenat pe exact aceleași ținte, clasificator pe rol, e în planul de măsurători; până atunci, comparăm pe proprietăți, nu pe cifre.

Față de reprezentările tensoriale și holografice (Smolensky, Plate, Kanerva, codarea cu puteri fracționare a lui Frady, Kleyko și Sommer). Codarea cadrelor prin binding rol-umplutură și bundling e standard și veche de treizeci de ani. Ce e nou aici e că adresele sunt *învățate* din obiectivul generativ, că sunt redundante (trei coduri de adresă topite), că adresarea prin așteptări cu reașezarea cuvintelor timpurii dă adrese nete și compune cu un

nivel mai departe decât a fost antrenată, și că porțile (ce categorii deschid cadre) emerg prin gradient și coincid între lumi și cu textul real. Am verificat și ce *nu* emerge: categoriile de cuvinte coincid cu cele date de un skip-gram simplu pe aceleași propoziții și nu sunt revendicate.

Față de teoria celor o mie de creiere, capitolul 15: cadre de referință cu locații date de mișcare, trăsături la locații, compoziție prin deplasare, vot prin suprapunere; fără mii de coloane, fără învățare nesupervizată, cu cadrul dat de lume.

Față de modelele de lume latente (Dreamer, JEPA): aceeași sarcină formală, stare plus eveniment dă starea următoare, cu o stare lizibilă în loc de una latentă; direcție, nu rezultat.

Ce nu este

Nu e un model de limbaj; nu e o bază de cunoștințe; nu e nesupervizat; nu e un înlocuitor al modelelor mari pe text deschis. Locul lui realist e lângă un model mare, ca partea care produce un cadru verificabil și spune ce n-a putut așeza.

Ce ar putea schimba mesajul

E cinstit să spunem noi care măsurători viitoare pot muta mesajul științific al acestei cărți, și în ce direcție. Trei o pot face. *Calibrarea*: dacă rata greșelilor făcute cu încredere iese mare și nu scade cu îmbunătățirile cunoscute, „spune unde n-a înțeles” devine „raportează incertitudine, dar prost calibrată”, și capitolele despre verificare, robotică și aliniere trebuie rescrise în consecință; e măsurătoarea cu cea mai mare miză. *Textul real cu parafraze libere, față de o bază de comparație cu aceeași supervizare*: dacă un clasificator clasic pe rol, antrenat pe exact aceleași ținte, egalează cititorul pe text real, mesajul se mută de la „învață structura mai bine” la „comparabil ca acuratețe, cu compoziție la adâncimi nevăzute și cu diagnostice”; unicitatea rămâne la compoziție și la citirea înapoi, nu la cifre. *Cuantificatorii*: dacă nici corecția lumii nu-i aduce în rând cu ceilalți operatori, „operatorii sunt roluri, citiți fără reguli” capătă o graniță declarată.

Ce nu se poate schimba: faptele matematice (izometria, comutativitatea, lipsa de legătură a punctelor aleatoare, scalarea capacității) și rezultatele deja măsurate pe lumi construite. Iar câteva măsurători pot doar îmbunătăți: remediile necomutative pentru ordine, markerul de ocupare și predicatul, pronumele, detectarea întrebării lipsă, codul rar. Teza, sensul ca răspunsuri la întrebările unei legende, atinse printr-un drum învățat, stă pe ce nu se poate schimba.

Limite

Limitele structurale: capacitatea unei stări (zeci până la sute de perechi la câteva mii de dimensiuni; textele lungi sunt structuri de stări); comutativitatea binding-ului (ordinea a doi operatori e reținută doar când altceva diferă; remediile necomutative cedează compoziția liberă și sunt de testat); citirea doar înainte (structura anunțată după scopul ei nu poate fi așezată); un cuvânt nou fără context primește o categorie aleatoare.

Rezultatele de la momentul scrierii vin din lumi construite, cu cinci semințe, și dintr-un singur set real. Ce e măsurat, ce e în lucru și cu ce criteriu se găsește, la zi, în fișierul de

stare al proiectului:
https://github.com/ml-circuits-research/vsa-semantic-space/blob/main/STATUS.md.
Documentul acesta nu se schimbă la fiecare experiment; fișierul da.